

最优化理论与算法

考试速通小册子

姚祉圻 2025018017

第一部分：线性规划（50 分）

第 1 章 LP 标准型与基本性质

1.1 从一个具体问题说起

假设你开了一家小工厂，生产两种产品 A 和 B。每生产一件 A 赚 3 元，一件 B 赚 5 元。但生产受限于两种原料：

- 原料 M1 库存 40 单位。每件 A 消耗 2 单位

M1, 每件 B 消耗 4 单位 M1。

- 原料 M2 库存 50 单位。每件 A 消耗 3 单位 M2, 每件 B 消耗 2 单位 M2。

问：各生产多少件，总利润最大？

建模：设 x_1 为 A 的产量， x_2 为 B 的产量。则：

$\max 3x_1 + 5x_2$ ——目标：总利润最大

s.t. $2x_1 + 4x_2 \leq 40$ ——原料 M1 约束

$3x_1 + 2x_2 \leq 50$ ——原料 M2 约束

$x_1 \geq 0, x_2 \geq 0$ ——产量不能为负

这就是一个线性规划问题（Linear Programming，简称 LP）。"线性"体现在：目标函数 $3x_1 + 5x_2$ 是变量的一次函数，每条约束也是变量的一次函数。没有 x_1^2 、 x_1x_2 、 $\sin(x_1)$ 这样的项。"规划"就是要在满足约束的前提下，找到使目标最优的决策。

画出这个问题的可行域（所有满足约束的点 (x_1, x_2) 构成的区域），它是一个凸多边形。最优解在某个"角点"（极点）上达到——具体是 $(15, 2.5)$ ，最优利润 $3 \times 15 + 5 \times 2.5 = 57.5$ 元。为什么最优解一定在角点上？这正是本章要回答的核心问题。




图 1.1：工厂问题的可行域与最优解

定义 1.1 (线性规划的一般形式)

一般形式的线性规划问题写为：

$$\begin{aligned} \min (\text{或 max}) \quad & \sum_{j=1}^n c_j x_j \\ \text{s.t.} \quad & \sum_{j=1}^n a_{ij} x_j \leq b_i, \quad i \in I_1 \\ & \sum_{j=1}^n a_{ij} x_j \geq b_i, \quad i \in I_2 \\ & \sum_{j=1}^n a_{ij} x_j = b_i, \quad i \in I_3 \\ & x_j \geq 0, \quad j \in J \end{aligned}$$

其中 c_j 称为目标函数系数（也叫价格系数）， a_{ij} 称为技术系数（或约束系数）， b_i 称为右端常数（代表资源限量）， x_j 称为决策变量。

例：上面的工厂问题中， $n = 2$ （两个决策变量）， $c_1 = 3$ ， $c_2 = 5$ ，约束矩阵 $A = \begin{pmatrix} 2 & 4 \\ 3 & 2 \end{pmatrix}$ ，右端

$b = \begin{pmatrix} 40 \\ 50 \end{pmatrix}$ 。目标求 $\max$ ，两个约束都是 $\leq$ 型，变量都 ≥ 0 ——这是典型的生产计划 LP。

什么叫“线性”？ 目标函数和所有约束都是变量的一次函数。这意味着可行域是由平面（超平面）围成的凸多面体，而最优解一定可以在某个顶点（角点）上找到——这就是第 2 章要讲的单纯形法的几何基础。如果是非线性（比如目标里有 x_1^2 ），最优解完全可能在内部点或边界但非顶点处出现。

PPT 第 4.1 和 4.3 页展示了线性规划从一般形式到标准形式的过渡。PPT 第 4.1 页给出了矩阵表示 $\min c^T x, \text{ s.t. } Ax = b, x \geq 0$ ——这是本书后续所有讨论的出发点。

2.线性规划-标准形式

称如下形式的线性规划为**标准形式**

$$\begin{aligned} \min \quad & \sum_{j=1}^n c_j x_j \\ \text{s.t.} \quad & \sum_{j=1}^n a_{ij} x_j = b_i, \quad i=1,2,\dots,m \\ & x_j \geq 0, \quad j=1,2,\dots,n \end{aligned} \quad (2.1)$$

矩阵表示

$$\begin{aligned} \min \quad & cx \\ \text{s.t.} \quad & Ax = b, \quad (2.2) \\ & x \geq 0, \end{aligned}$$

其中A是 $m \times n$ 矩阵, c 是 n 维行向量, b 是 m 维列向量。

注: 为计算需要, 一般假设 $b \geq 0$ 。否则, 可在方程两端乘以 (-1) 即可化为非负。

2.线性规划-形式

则有

$$\begin{aligned} \min \quad & c_1 x_1 + c_2 x_2 + \dots + c_n x_n \\ \text{s.t.} \quad & a_{11} x_1 + a_{12} x_2 + \dots + a_{1n} x_n + x_{n+1} = b_1 \\ & a_{21} x_1 + a_{22} x_2 + \dots + a_{2n} x_n + x_{n+2} = b_2 \\ & \dots\dots\dots \\ & a_{m1} x_1 + a_{m2} x_2 + \dots + a_{mn} x_n + x_{n+m} = b_m \\ & x_j \geq 0, \quad j=1,2,\dots,n+m \end{aligned}$$

若某变量 x_j 无非负限制, 则引入

$$x_j = x'_j - x''_j, \quad x'_j, x''_j \geq 0.$$

若有上下界限限制, 比如 $x_j \geq l_j$, 令 $x'_j = x_j - l_j$, 有 $x'_j \geq 0$ 。

1.2 线性规划的标准型：为什么要统一格式？

刚才的工厂问题中，目标求 $\max$ ，约束是 $\leq$ 。但如果我们遇到另一个问题，目标求 $\min$ ，约束有 $\geq$ 、有 $=$ ，变量还有不受符号限制的，那岂不天下大乱？我们需要一种统一的格式，让后续的求解算法能处理任意形式的 LP。

所以数学家的策略是：先把任何 LP 都写成一种统一格式，然后只针对这种格式设计算法。这个统一格式就是”标准型”。

定义 1.2 (标准型 LP 的四条硬性要求)

一个线性规划称为标准型，当且仅当同时满足：

- (1) 目标函数为**极小化** ($\min$)
- (2) 所有约束为**等式** ($=$)
- (3) 所有右端常数**非负** ($b_i \geq 0$)
- (4) 所有变量**非负** ($x_j \geq 0$)

写成矩阵形式 (记 $x = (x_1, \dots, x_n)^T$, $c = (c_1, \dots, c_n)^T$, $b = (b_1, \dots, b_m)^T$, $A = (a_{ij})_{m \times n}$):

$$\min c^T x, \quad \text{s.t. } Ax = b, \quad x \geq 0, \quad b \geq 0$$

每条要求都有它的道理。我们逐条看：

- (1) **目标 $\min$** : 求解算法的符号规则 (称为检验数, 详见第 2 章) 建立在 $\min$ 问题上。如果是 $\max$, 要么先转成 $\min$, 要么反转所有符号规则——统一成 $\min$ 最省事。
- (2) **约束 $=$** : 求解算法操作的是等式方程组 (行

变换、转轴)。不等式没法直接做行变换，需要先引入额外变量变成等式。

- (3) $b \geq 0$: 求解算法需要一个初始基本可行解（见 1.3 节）。如果 A 中包含单位子阵（比如松弛变量列）， $b \geq 0$ 就能直接读出初始解。 $b_i < 0$ 会让初始读出值是负数——不合法。
- (4) $x \geq 0$: 非负条件定义了可行域是“第一象限 + 超平面”。去掉非负限制，可行域变成整个子空间，极点概念不再适用。

正例与反例对照： 正例（标准型）： $\min 2x_1 + 3x_2$ ，约束 $x_1 + x_2 = 5$ ， $x_1, x_2 \geq 0$ 。满足全部四条——目标 $\min$ 、约束 $=$ 、 $b = 5 \geq 0$ 、变量 ≥ 0 。

反例 1（违反 (1)）： $\max 2x_1 + 3x_2$ ，目标是 $\max$ 而非 $\min$ 。改法：目标乘 -1 变 $\min$ 。

反例 2（违反 (2)）： 约束是 $x_1 + 2x_2 \leq 10$ ，不是等式。改法：加松弛变量。

反例 3（违反 (3)）： 右端 $2x_1 - x_2 = -3$ ， $b_1 = -3 < 0$ 。改法：乘 -1 翻正。

反例 4 (违反 (4))： x_2 无符号限制。改法： $x_2 = x_2^+ - x_2^-$ 。

1.3 化标准型：四条规则，一步一步来

现在我们把一个任意 LP 转成标准型。这是考试第一题常见问法，也是后续求解的前提。四条规则对应四种“不合规”情况。每条规则我们都说清楚：什么情况下用、为什么这样做、做完得到什么。

方法 1.1（化标准型四步法）

1. $\max \rightarrow \min$: 目标函数乘 -1 。即 $\max c^T x$ 等价于 $\min -c^T x$ 。最优解不变，最优值变号。
2. $\leq$ 约束（资源约束）: 左端加松弛变量 $s \geq 0$ 。
 $a^T x \leq b \rightarrow a^T x + s = b$ 。
3. $\geq$ 约束（需求约束）: 左端减剩余变量 $s \geq 0$ 。
 $a^T x \geq b \rightarrow a^T x - s = b$ 。
4. 自由变量（无符号限制的变量）: 拆成两个非负变量的差。 $x_j = x_j^+ - x_j^-$ ，且 $x_j^+, x_j^- \geq 0$ 。
5. $b_i < 0$: 约束两端乘 -1 。注意：若原约束是 $\leq$ 或 $\geq$ ，乘 -1 后不等号方向反转。

下面逐条展开，每条都配具体数字例子。

规则 1: $\max$ 变成 $\min$

从哪来？原问题求 $\max$ （比如最大化利润）。

为什么做？标准型要求 $\min$ 。从几何上， $\max c^T x$ 和 $\min -c^T x$ 在同一个点取得最优（因为乘 -1 只是把函数图像上下翻转，最低点对应原来的最高点）。

得到什么？目标系数全部变号，约束和变量不变。最后算出的最优值记得变回来。

例：

$$\max 3x_1 + 5x_2$$

$$\text{s.t. } 2x_1 + 4x_2 \leq 40, 3x_1 + 2x_2 \leq 50, x_1, x_2 \geq 0$$

化为 $\min$ ：

$$\min -3x_1 - 5x_2$$

$$\text{s.t. } 2x_1 + 4x_2 \leq 40, 3x_1 + 2x_2 \leq 50, x_1, x_2 \geq 0$$

最优解仍是 $(15, 2.5)$ ，最优值变为 -57.5 （原最优值 57.5 的相反数）。

规则 2： $\leq$ 约束——加松弛变量

从哪来？约束左边 $\leq$ 右边，意思是“已消耗量 $\leq$ 资源总量”。

为什么做？需要把不等式变成等式。怎么变？不等式左边和右边的差距是一个非负的量——我们给它

起个名字，叫松弛变量。 $2x_1 + 4x_2 \leq 40$ 的意思是“已经用了 $2x_1 + 4x_2$ 份原料，还剩一些”。剩多少？ $40 - (2x_1 + 4x_2) \geq 0$ 。把这份剩余量记为 x_3 ，就有 $2x_1 + 4x_2 + x_3 = 40$ ，且 $x_3 \geq 0$ 。

得到什么？ 每个 $\leq$ 约束新增一个松弛变量，该变量系数在约束行中为 +1，在目标中系数为 0（松弛不产生利润/成本）。这些 +1 列在矩阵中天然构成单位向量——以后做初始基极其方便。

例：

$$\begin{array}{ll}\min & -3x_1 - 5x_2 \\ \text{s.t.} & 2x_1 + 4x_2 \leq 40 \\ & 3x_1 + 2x_2 \leq 50\end{array}$$

加松弛变量后：

$$\begin{array}{ll}\min & -3x_1 - 5x_2 \\ \text{s.t.} & 2x_1 + 4x_2 + x_3 = 40 \\ & 3x_1 + 2x_2 + x_4 = 50 \\ & x_3, x_4 \geq 0\end{array}$$

注意： 松弛变量的经济含义 = 未被使用的资源量。在最优解中，如果松弛变量 > 0 ，说明该资源有剩余

(约束是松的)；如果松弛变量 = 0，说明资源被用完 (约束是紧的)。

规则 3: $\geq$ 约束——减剩余变量

从哪来？约束左边 $\geq$ 右边，意思是“产出量 $\geq$ 最低要求”。

为什么做？还是要把不等式变等式。这次左边更大，差距在左边减右边。 $x_1 + 2x_2 \geq 10$ 意思是“总产出至少 10”。超出多少？ $(x_1 + 2x_2) - 10 \geq 0$ 。把这个超出量记为 $x_5 \geq 0$ ，就有 $x_1 + 2x_2 - x_5 = 10$ 。

得到什么？每个 $\geq$ 约束新增一个剩余变量，系数为 -1 。这带来一个麻烦： -1 不能做单位基向量——以后要靠人工变量（见第 2 章）来补。

例：

$$\begin{aligned} \min \quad & 2x_1 + 3x_2 \\ \text{s.t.} \quad & x_1 + x_2 \leq 20 \\ & x_1 + 2x_2 \geq 10 \\ & x_1, x_2 \geq 0 \end{aligned}$$

化为：

$$\min 2x_1 + 3x_2$$

$$\text{s.t. } x_1 + x_2 + x_3 = 20$$

$$x_1 + 2x_2 - x_4 = 10$$

$$x_1, x_2, x_3, x_4 \geq 0$$

规则 4：自由变量——拆成两个非负变量

什么是自由变量？就是没有符号限制的变量——它可以取正值、零、或负值。标准型要求所有变量 ≥ 0 ，所以自由变量必须处理。

为什么需要拆？求解算法要求所有变量 ≥ 0 ，因为基本可行解的定义是 $x \geq 0$ ，而且非负限制确保了可行域是第一象限与超平面的交集，从而”极点”有意义。如果一个变量可以随意取负数，可行域就没有”角”了——因为你可以往负方向无限走。

为什么拆成 $x^+ - x^-$ ？任何一个实数都可以写成两个非负数的差。比如 $5 = 5 - 0$ ， $-3 = 0 - 3$ ， $0 = 0 - 0$ 。所以令 $x_j = x_j^+ - x_j^-$ ($x_j^+, x_j^- \geq 0$)， x_j 就能取遍全体实数。 x_j^+ 捕获正值部分， x_j^- 捕获负值部分的绝对值。**得到什么？**一个自由变量变成两个非负变量，变量总

数增加。目标中 $c_j x_j$ 变成 $c_j x_j^+ - c_j x_j^-$ ，约束中 $a_{ij} x_j$ 变成 $a_{ij} x_j^+ - a_{ij} x_j^-$ 。

例：

$$\begin{aligned} \min \quad & x_1 + 2x_2 \\ \text{s.t.} \quad & x_1 + x_2 = 5 \\ & x_1 \geq 0, \quad x_2 \text{ 自由} \end{aligned}$$

化为：

$$\begin{aligned} \min \quad & x_1 + 2x_2^+ - 2x_2^- \\ \text{s.t.} \quad & x_1 + x_2^+ - x_2^- = 5 \\ & x_1 \geq 0, \quad x_2^+ \geq 0, \quad x_2^- \geq 0 \end{aligned}$$

注意： x_2^+ 和 x_2^- 在最优解中不会同时为正——因为同时为正意味着你可以同时减小两者而不改变 x_2 的值，但减小了一个非负变量的取值。更严格的理由：在基本解中，非基变量全部为 0， x_2^+ 和 x_2^- 不可能同时进基（它们的列是线性相关的： $a_{x_2^+} = -a_{x_2^-}$ ，同时选入基会导致 B 奇异）。

规则 5： $b_i < 0$ ——翻转约束

从哪来？某个约束的右端常数是负数。

为什么做？ 标准型要求 $b \geq 0$ ，否则初始 BFS 无法直接读出（基变量的初始取值就是 b ，如果是负数就不满足 $x \geq 0$ ）。

得到什么？ 等式约束：两端乘 -1 。不等式约束：两端乘 -1 且翻转不等号。乘 -1 后若变成 $\geq$ 或 $\leq$ ，再分别按规则 2/3 处理。

例：

$$\begin{aligned} \min \quad & x_1 + x_2 \\ \text{s.t.} \quad & 3x_1 - 2x_2 \leq -6 \\ & x_1, x_2 \geq 0 \end{aligned}$$

逐步变换：

$$\begin{aligned} & 3x_1 - 2x_2 \leq -6 \\ \rightarrow & -3x_1 + 2x_2 \geq 6 \quad (\text{乘 } -1, \text{ 不等号反转}) \\ \rightarrow & -3x_1 + 2x_2 - x_3 = 6 \quad (\text{减剩余变量}) \end{aligned}$$

PPT 第 4.5 页展示了一个二维 LP 的图解法求解过程——只有两个变量时，画图比代数计算快得多。图中的可行域是几条直线围成的凸多边形，目标函数等值线平行移动，碰到的第一个/最后一个顶点就是最优解。这张 PPT 揭示了后面要讲的单纯形法的几何

直观：在顶点间沿着边移动。

2.线性规划-图解法


4.5

$$\text{Min } 3x + 2.5y$$

$$\text{s.t. } 2x + 4y \geq 40$$

$$3x + 2y \geq 50$$

$$x, y \geq 0.$$



可行区域的极点：

(0, 25)

(15, 2.5) 最优解

(20, 0)

1.4 真题操练：第一题 (1)——标准型化

【2025 真题 · 第一题】考虑下述线性规划：

$$\min 2x_1 - x_2 + x_3$$

$$\text{s.t. } 3x_1 + x_2 + x_3 \leq 6$$

$$x_1 - x_2 + 2x_3 \geq 1$$

$$x_1 + x_2 - x_3 \leq 2$$

$$x_1, x_2, x_3 \geq 0$$

逐步化为标准型。

第 0 步——审视原问题：目标已是 $\min$ ，三变量均非负，三个右端均 > 0 ——这三条已满足标准型。问题只在约束：第一条是 $\leq$ ，第二条是 $\geq$ ，第三条是 $\leq$ 。所以只需处理约束类型。

第 1 步——第一条约束 $3x_1 + x_2 + x_3 \leq 6$ ：这是个“资源型”约束。左端消耗的某种资源不超过右端的 6 单位。不等式两端差为 $6 - (3x_1 + x_2 + x_3)$ ，这个非负差值就是未使用的资源量。令其为松弛变量 $x_4 \geq 0$ ：

$$3x_1 + x_2 + x_3 + x_4 = 6, \quad x_4 \geq 0$$

x_4 的系数列是 $(1, 0, 0)^T$ ——天然单位向量，可以直接做基变量。

第 2 步——第二条约束 $x_1 - x_2 + 2x_3 \geq 1$ ：这是“需求型”约束。左端输出至少要达到右端的 1 单位。超出量为 $(x_1 - x_2 + 2x_3) - 1 \geq 0$ ，令其为剩余变量 $x_5 \geq 0$ ：

$$x_1 - x_2 + 2x_3 - x_5 = 1, \quad x_5 \geq 0$$

x_5 的系数是 -1 ——不能做基向量。这意味着第二条约束缺少“自然基变量”，后面大 M 法中要引入人工变量（见第 2 章）。

第 3 步——第三条约束 $x_1 + x_2 - x_3 \leq 2$ ：加松弛变量 $x_6 \geq 0$ ：

$$x_1 + x_2 - x_3 + x_6 = 2, \quad x_6 \geq 0$$

x_6 的系数列是 $(0, 0, 1)^T$ ——又一个天然单位向量。

最终标准型：

$$\begin{aligned} \min \quad & 2x_1 - x_2 + x_3 \\ \text{s.t.} \quad & 3x_1 + x_2 + x_3 + x_4 = 6 \\ & x_1 - x_2 + 2x_3 - x_5 = 1 \\ & x_1 + x_2 - x_3 + x_6 = 2 \\ & x_j \geq 0, \quad j = 1, \dots, 6 \end{aligned}$$

关键观察：矩阵 A 是一个 3×6 矩阵。 x_4 列 = $(1, 0, 0)^T$ ， x_6 列 = $(0, 0, 1)^T$ ——两个现成的单位列。但还缺一个—— x_5 列 = $(0, -1, 0)^T$ 不是 $(0, 1, 0)^T$ 。三阶单位阵缺一个列，意味着我们需要人工变量（第 2 章）。

1.5 基、基本解、基本可行解

标准型 $\min\{c^T x \mid Ax = b, x \geq 0\}$ 中， A 是 $m \times n$ 矩阵，通常 $m < n$ （变量比方程多）。这意味着方程组 $Ax = b$ 有无穷多解——我们要从中挑出“候选最优解”。

让我们从一个具体的小矩阵开始。

例：考虑标准型 LP：

$$\min 2x_1 + x_2 + 3x_3 + x_4$$

$$\text{s.t. } x_1 + 2x_2 + x_3 = 4$$

$$2x_1 + x_2 + x_4 = 6$$

$$x_1, x_2, x_3, x_4 \geq 0$$

系数矩阵 $A = \begin{pmatrix} 1 & 2 & 1 & 0 \\ 2 & 1 & 0 & 1 \end{pmatrix}$ 。 $m = 2$ 个约束， $n = 4$ 个变量。我们要从中挑 2 列组成一个可逆的 2×2 方阵。

定义 1.3（基、基变量、非基变量）

设 A 为 $m \times n$ 矩阵（ $m < n$ ），其列向量记为 $a_1, \dots, a_n$ 。

从中选出 m 个线性无关的列，组成 $m \times m$ 可逆方阵 $B = (a_{B_1}, \dots, a_{B_m})$ ，称 B 为一个基（basis）。这 m 个列对应的变量 $x_{B_1}, \dots, x_{B_m}$ 称为基变量（basic variables）。

其余 $n - m$ 个变量称为非基变量（non-basic variables），对应的列组成 $m \times (n - m)$ 矩阵记为 N 。

例(续): A 有 4 列: $a_1 = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$, $a_2 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$, $a_3 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$,

$a_4 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$ 。任选 2 个线性无关的列即可组成基。

考察一个具体的选择: 取 a_3 和 a_4 为基列, 即

$B = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = I_2$, 显然可逆。基变量: x_3, x_4 ; 非基变量: x_1, x_2 。

定义 1.4 (基本解与基本可行解)

给定基 B , 令所有非基变量取值为 0 ($x_N = 0$), 从 $Bx_B = b$ 解出基变量的值 $x_B = B^{-1}b$ 。由此得到的解

$$x = \begin{pmatrix} x_B \\ x_N \end{pmatrix} = \begin{pmatrix} B^{-1}b \\ 0 \end{pmatrix}$$

称为对应于 B 的基本解 (basic solution)。

若此解满足 $x_B \geq 0$ (所有基变量非负), 则称其为基本可行解 (Basic Feasible Solution, 简称 BFS)。若某个基变量恰好为 0, 称此 BFS 为退化的 (degenerate)。

例 (续): 对 $B = I_2$ (x_3, x_4 为基), 令 $x_1 = x_2 = 0$, 则:

$$\begin{cases} x_3 = 4 \\ x_4 = 6 \end{cases} \implies x = (0, 0, 4, 6)^T$$

$4 > 0, 6 > 0$, 非退化 BFS。目标值 $z = 2 \cdot 0 + 1 \cdot 0 + 3 \cdot 4 + 1 \cdot 6 = 18$ 。

再看看另一个基: 取 a_1 和 a_4 , 则 $B = \begin{pmatrix} 1 & 0 \\ 2 & 1 \end{pmatrix}$,

$\det B = 1 \neq 0$ 。令 $x_2 = x_3 = 0$:

$$\begin{cases} x_1 = 4 \\ 2x_1 + x_4 = 6 \end{cases} \Rightarrow x_4 = -2$$

故 $x = (4, 0, 0, -2)^T$ 。 $x_4 = -2 < 0$, 这是基本解, 但不是基本可行解。

再试一个: 取 a_1 和 a_2 , $B = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}$, $\det B = 1 - 4 = -3 \neq 0$ 。令 $x_3 = x_4 = 0$:

$$\begin{cases} x_1 + 2x_2 = 4 \\ 2x_1 + x_2 = 6 \end{cases} \Rightarrow x_1 = \frac{8}{3}, x_2 = \frac{2}{3}$$

$x = (8/3, 2/3, 0, 0)^T$, 全部 ≥ 0 , 是 BFS。目标值 $z = 2 \cdot \frac{8}{3} + \frac{2}{3} = \frac{18}{3} = 6$ 。这个目标值 (6) 比之前的 18 好多了!


可见不同 BFS 对应不同目标值。这就是后续求解算法要做的事: 在 BFS 之间跳跃, 让目标值不断下降, 直到不能再降。

PPT 第 4.16 页展示了基矩阵个数的有限性——最多 $\binom{n}{m}$ 个, 从而 BFS 的个数也是有限的。这意味着我们不需要在无穷多个可行点中搜索, 只需遍历有限个 BFS。虽然 $\binom{n}{m}$ 本身可能很大 ($\binom{50}{25} \approx 10^{14}$), 求解算法在实践中通常只需 $O(m)$ 到 $O(n)$ 次迭代。

2.线性规划-性质14

- 容易知道,基矩阵的个数是有限的,因此基本解从而基本可行解的个数也是有限的,不超过

$$\binom{n}{m} = \frac{n!}{m!(n-m)!}$$



基本可行解



极点

1.6 BFS 与极点的等价性（定理 1.1）

几何和代数的桥梁。这是整个求解算法的理论基础。先回顾一个几何概念：可行域 $S = \{x \mid Ax = b, x \geq 0\}$ 是一个凸多面体。一个点叫“极点”（extreme point，也叫顶点），意思是它不能被表示为 S 中另外两个不同点的严格凸组合。想象一个立方体：八个角是极点，棱上的点不是（它是两端点的凸组合），面内部的点也不是。

定理 1.1 (BFS $\Leftrightarrow$ 极点)

设可行域 $S = \{x \mid Ax = b, x \geq 0\}$ 非空，且 $\text{rank}(A) = m$ 。点 $\bar{x} \in S$ 是 S 的极点当且仅当 $\bar{x}$ 是一个基本可行解。

这个定理意味着什么？从代数角度定义的”基本可行解”（非基变量 $=0$ ，基变量 $=B^{-1}b \geq 0$ ）和从几何角度定义的”极点”（凸多面体的角点），竟然是同一回事。这使求解算法能大步前进：后面会看到，单纯形表操作的是基矩阵（代数），但实际效果是在可行域的顶点之间沿棱移动（几何）。

证明直觉（跳过严格细节）：

- **BFS $\Rightarrow$ 极点**：BFS 的正分量对应的列线性无关（因为它们是基列），这就保证了它在 S 中不能被写为其他两个点的凸组合——因为任何满足 $Ax = b$ 且和 BFS 有相同零分量的点，其非零分量必须满足同样的线性方程组，而基矩阵的列线性无关意味着解唯一。
- **极点 $\Rightarrow$ BFS**：如果 $\bar{x}$ 是极点但其正分量对应的列线性相关，则可以在 $\bar{x}$ 附近找到另外一个点

$y \neq \bar{x}$ 满足 $Ay = b$ 且 y 在 $\bar{x}$ 的零分量位置也为 0。那么 $\bar{x}$ 可以写为 $\bar{x} = \frac{1}{2}(\bar{x} + \epsilon d) + \frac{1}{2}(\bar{x} - \epsilon d)$ ，其中 d 是非零方向——这就违反极点定义。所以正分量对应的列必须线性无关，再补到 m 列即得基。

PPT 第 4.17 页展示了定理 2.4 的陈述与上述完全一致：极点集 = BFS 集合。这张 PPT 也给出了证明提纲——和上面的直觉版互为补充。掌握这个等价关系，是理解第 2 章单纯形法”在顶点间跳跃”的关键。

2.线性规划-性质15

4.17

定理2.4 令 $K = \{x \mid Ax = b, x \geq 0\}$, A 是 $m \times n$ 阵, $\text{秩}(A) = m$, 则 K 的极点集与 $Ax = b, x \geq 0$ 的基本可行解集合等价.

证明: (提纲)

- 1) 设 x 是 K 的极点, 则 x 是 $Ax = b, x \geq 0$ 的基本可行解.
- 2) 设 x 是 $Ax = b, x \geq 0$ 的基本可行解, 则 x 是 K 的极点.

1.7 最优 BFS 的存在性（定理 1.2）

现在我们知道极点就是 BFS。但还有一个关键问题：**最优解一定在 BFS 中吗？**会不会最优解在可行域内部的某个点，或者在某条边的中间？

答案是：**如果最优值有限，那么一定存在某个 BFS 达到最优值。**也就是说，你永远可以在“角点”中找到最优解。这就是求解算法只搜索 BFS 而不搜索内部点的理论保证。

定理 1.2（最优 BFS 的存在性）

对于标准型 LP $\min\{c^T x \mid Ax = b, x \geq 0\}$ ：

若可行域非空（ $S \neq \emptyset$ ）且目标函数在 S 上有下界（即最优值有限，不会趋于 $-\infty$ ），则存在一个基本可行解是最优解。

直觉论证：假设 x^* 是最优解但不是 BFS。用表示定理（见 1.8 节）， x^* 可以写成若干个极点的凸组合加上极方向的非负组合：

$$x^* = \sum_i \lambda_i v_i + \sum_j \mu_j d_j, \quad \sum_i \lambda_i = 1, \lambda_i, \mu_j \geq 0$$

由于 x^* 最优且最优值有限，沿任何极方向 d_j 目标不能严格下降（即 $c^T d_j \geq 0$ ，否则拖着 d_j 可以无限走下去，目标趋 $-\infty$ ，与有限矛盾）。所以：

$$c^T x^* = \sum_i \lambda_i c^T v_i + \sum_j \mu_j c^T d_j \geq \sum_i \lambda_i c^T v_i$$

由于 $\sum_i \lambda_i = 1$ ， $c^T x^*$ 是各极点目标值的加权平均。既然是“平均”，最小的那个极点目标值一定 $\leq$ 平均值，也就是 $\leq c^T x^*$ 。但 x^* 是最优的——那个极点的目标值不可能更小。因此那个极点的目标值等于 $c^T x^*$ ，即该极点也是最优的。得证。

一个重要的特殊情况：无穷多最优解。如果两个不同的 BFS 都是最优的（目标值相同），那么它们之间线段上的所有点都是最优解。这意味着最优解可能不止在极点上——但至少有一个极点是最优的。

PPT 第 4.6 和 4.23 页反复强调：可行域是凸集，最优解一定能在极点上达到。这是整个线性规划理论最重要的结论之一。

2.线性规划-基本性质1

□ 线性规划的可行域

定理 2 线性规划的可行域是凸集.

□ 最优极点

观察上例发现, 最优解在极点(15,2.5)达到, 我们有如下事实:

线性规划若存在最优解,则最优解一定可在某极点上达到.

2.线性规划-性质21

□ 总结:

- 线性规划存在最优解, 目标函数的最优值一定能在某极点上达到. 可行域 $K=\{x \mid Ax=b, x \geq 0\}$ 的极点就是其基本可行解.

从而, 求线性规划的最优解, 只需求出最优基本可行解即可.

1.8 表示定理（选读）

定理 1.3（表示定理，Representation Theorem）

设 $S = \{x \mid Ax = b, x \geq 0\}$ 为标准型 LP 的可行域。 S 中任意点 x 可以唯一地表示为：

$$x = \sum_{i=1}^k \lambda_i v_i + \sum_{j=1}^{\ell} \mu_j d_j$$

其中：

- $v_1, \dots, v_k$ 是 S 的全部极点（即全部 BFS）
- $d_1, \dots, d_{\ell}$ 是 S 的全部极方向（extreme directions）——即 S 中无法再分解的“射线方向”
- $\lambda_i \geq 0$, $\sum_{i=1}^k \lambda_i = 1$ （凸组合部分）
- $\mu_j \geq 0$ （锥组合部分）

什么意思？ 可以把可行域理解为：先取所有极点，用凸组合“填满”极点围成的有界凸多面体；然后沿着

极方向把这些点往外”推”，覆盖整个无界区域。如果 S 有界（比如所有变量都有上界），则没有极方向（ $\ell = 0$ ），此时 $S =$ 极点的凸包。

对求解算法的意义： 目标函数 $c^T x$ 作用在 x 上：

$$c^T x = \sum_i \lambda_i (c^T v_i) + \sum_j \mu_j (c^T d_j)$$

- 如果某个极方向 d_j 满足 $c^T d_j < 0$ （沿此方向走目标不断下降），且 μ_j 可以无限增大——则最优值无下界（ $-\infty$ ），这就是求解算法中”无界解”的判断依据。
- 如果所有 $c^T d_j \geq 0$ ，则最优值一定在某个极点 v_i 上达到（因为 μ_j 项非负，取 $\mu_j = 0$ 不会更差）——这就回到了定理 1.2。

PPT 第 4.7 和 4.24 页介绍了表示定理及其推论：定理 2.5 保证可行域非空时一定存在 BFS；而最优解总能在 BFS 中找到。

2.线性规划-性质2

考察线性规划的标准形式(2. 2)

设可行域的极点为 $x^{(1)}, x^{(2)}, \dots, x^{(k)}$, 极方向为 $d^{(1)}, d^{(2)}, \dots, d^{(t)}$ 。

根据多面体表示定理, 任意可行点 x 可表示为

$$x = \sum_{i=1}^k \lambda_i x^{(i)} + \sum_{i=1}^t \mu_i d^{(i)} \quad (2.3)$$

$$\sum_{i=1}^k \lambda_i = 1$$

$$\lambda_i \geq 0, \quad i = 1, 2, \dots, k$$

$$\mu_i \geq 0, \quad i = 1, 2, \dots, t.$$

2.线性规划-性质22

□ 基本可行解的存在问题

定理2.5 若 $Ax=b, x \geq 0$ 有可行解, 则一定存在基本可行解, 其中 A 是秩为 m 的 $m \times n$ 矩阵。

证明: 记 $A = (p_1, p_2, \dots, p_n)$

设 $x = (x_1, x_2, \dots, x_s, 0, 0, \dots, 0)^T$ 是一可行解,

其中 $x_j > 0, j = 1, 2, \dots, s$.

若 x 的 s 个正分量对应的列 $p_1, p_2, \dots, p_s$ 线性无关, 则可以将其扩充为一组基, 从而得 x 即一基本可行解。

1.9 真题操练：第三题（基本性质证明）

这道题综合考察 BFS、极点和目标函数线性性的理解。我们重述完整推理过程。

【2025 真题 · 第三题】若标准型形式的线性规划有一个不是基本可行解的最优解，试证：它要么有两个或两个以上的最优基本可行解；要么它至少有一个最优基本可行解，但其一个棱可以无限延伸，即可行域内有一条以该最优基本可行解为顶点的射线。

先把题读透。题目给出：存在某个最优解 x^* ，它不是 BFS。在此前提下，要证明两种可能情况至少发生其一：

- **情况 1：**有 ≥ 2 个最优 BFS（多最优解）
- **情况 2：**有 1 个最优 BFS，但存在以它为起点的射线，射线上所有点都是最优解（无界多最优解）

证明：

第一步——最优 BFS 确实存在。

由定理 1.2，既然题设给出了最优解 x^* （目标值有限，不会 $-\infty$ ），且可行域非空（ x^* 就在其中），则一定存在至少一个最优 BFS。记其中一个为 y^* 。由于 x^* 本身不是 BFS，所以 $y^* \neq x^*$ 。

第二步——分情况讨论最优 BFS 的个数。

情况 A：最优 BFS 不止一个。那命题的第一部分直接成立——确实有两个或以上的最优 BFS。完成。

情况 B：恰好只有一个最优 BFS，即 y^* 是唯一的。（这是需要细致分析的情况。）

因为只有一个最优 BFS，而我们手中还有另一个最优解 x^* （非 BFS）。从 y^* 指向 x^* 的方向向量为 $d = x^* - y^* \neq 0$ 。

考虑射线 $\{y^* + \lambda d \mid \lambda \geq 0\}$ 。当 $\lambda = 0$ 时是 y^* ，当 $\lambda = 1$ 时是 x^* 。射线上任意点的目标值：

$$c^T(y^* + \lambda d) = c^T y^* + \lambda \cdot c^T d$$

计算 $c^T d$ ：

$$c^T d = c^T(x^* - y^*) = c^T x^* - c^T y^* = z^* - z^* = 0$$

所以射线上所有点的目标值都是 z^* ——整条射线都是最优的！

第三步——验证射线在可行域内。

需要证明对任意 $\lambda \geq 0$, $y^* + \lambda d$ 满足 $Ax = b$ 和 $x \geq 0$ 。

约束验证: $A(y^* + \lambda d) = Ay^* + \lambda A(x^* - y^*) = b + \lambda(b - b) = b$ 。通过。

非负验证: 由于 y^* 是极点, 非基变量为 0。 d 在 y^* 的非基变量分量方向上的取值来自 x^* , 而 x^* 在这些位置上的值 ≥ 0 (x^* 是可行解)。因此 d 的这些分量 ≥ 0 。当 λ 增大时, 这些分量从 0 变正——所以对于基变量方向, 需要论证不会变负。事实上, 由于 y^* 是唯一最优 BFS 且射线上所有点目标值相同, 射线必须在可行域内——否则射线离开可行域的时刻会遇到一个新的极点 (因为可行域是闭凸集, 射线与边界的交点如果不是极点也会导出另一个极点), 而该极点的目标值也是最优 (连续性), 这就和“唯一最优 BFS”矛盾。

因此射线完全含于可行域内, 且 y^* 是它的起点 (顶点)。

总结：两种情况覆盖了所有可能性。这道题的目的在于让你深刻理解：非 BFS 的最优解”夹在”BFS 之间（或者说由 BFS 和极方向组合而成），而目标函数的线性性保证了各分量对目标值的贡献可以分离。

本章速查

第 1 章核心知识点

- **标准型四要素**： $\min$ 、 $=$ 、 $b \geq 0$ 、 $x \geq 0$ （缺一不可）
- **化标准型**： $\max \rightarrow \min$ （乘 -1 ）、 $\leq$ （加松弛变量）、 $\geq$ （减剩余变量）、自由变量 $x = x^+ - x^-$ 、 $b < 0$ （乘 -1 + 翻转不等号）
- **关键因果链**：为什么要标准型？因为求解算法需要统一的操作对象。为什么 $b \geq 0$ ？初始 BFS 直接读出需要非负右端。为什么拆自由变量？求解算法要求 $x \geq 0$ 。
- **基 $\rightarrow$ 基本解 $\rightarrow$ BFS**：选 m 个线性无关列 $\rightarrow$ 基 $B \rightarrow$ 非基变量 $= 0 \rightarrow x_B = B^{-1}b \rightarrow$ 若 ≥ 0 则为 BFS
- **BFS $\Leftrightarrow$ 极点**（定理 1.1）：代数和几何的统一——求解算法在顶点间跳跃
- **最优值有限 $\Rightarrow$ 存在最优 BFS**（定理 1.2）：

第 2 章 单纯形法

2.1 从枚举到智能搜索

第 1 章的核心结论：标准型 LP 的最优解一定在某个基本可行解（BFS，即可行域的极点）上。理论上，只需枚举全部 $\binom{n}{m}$ 个 BFS，比较目标值挑最优即可。但这不现实—— $\binom{50}{25} \approx 10^{14}$ ，宇宙年龄都不够用。

单纯形法（Simplex Method）是一种“聪明地遍历”BFS 的方法：从一个初始 BFS 出发，每一步只考虑能让目标值下降的相邻 BFS，沿着可行域的棱走过去。绝大多数候选 BFS 根本不用看。

核心思想：在顶点间沿棱跳跃，每一步都让目标值严格下降（对 min 问题）。因为 BFS 总数有限且目标严格单调，算法必然在有限步终止。

PPT 第 5.1 页展示了这一几何直觉——可行域是一个凸多面体，单纯形法从某个顶点出发，沿着边界棱的方向移动到相邻顶点，目标值不断改善。




图 2.1：单纯形法的几何直觉——沿棱在顶点间移动

5.1

上一节课我们学习了线性规划的基本性质，我们知道：若线性规划

$$\begin{array}{ll}\text{Min} & c^T x \\ \text{s.t.} & Ax = b \\ & x \geq 0\end{array}$$

有最优解，则最优解可在基本可行解上达到。

如何来求这个最优的基本可行解呢？

2.2 检验数：衡量”进基是否划算”

从基矩阵分解出发

设当前基为 B ($m \times m$ 可逆)，非基矩阵为 N 。将矩阵分块：

$$A = [B \mid N], \quad x = \begin{pmatrix} x_B \\ x_N \end{pmatrix}, \quad c = \begin{pmatrix} c_B \\ c_N \end{pmatrix}$$

约束 $Ax = b$ 写为 $Bx_B + Nx_N = b$ 。因为 B 可逆，基变量可由非基变量表出：

$$x_B = B^{-1}b - B^{-1}Nx_N$$

代入目标函数：

$$\begin{aligned} z &= c_B^T x_B + c_N^T x_N = c_B^T (B^{-1}b - B^{-1}Nx_N) + c_N^T x_N \\ &= c_B^T B^{-1}b + (c_N^T - c_B^T B^{-1}N) x_N \end{aligned}$$

令 $z_0 = c_B^T B^{-1}b$ (当前目标值)，则：

$$z = z_0 + \sum_{j \in \text{非基}} (c_j - c_B^T B^{-1}a_j) x_j$$

定义 2.1 (检验数 / Reduced Cost)

非基变量 x_j 的检验数定义为:

$$\sigma_j = z_j - c_j = c_B^T B^{-1} a_j - c_j$$

其中 $z_j = c_B^T B^{-1} a_j$ 是“引入一单位 x_j 的机会成本”——把 x_j 从 0 提升到 1, 为了保持等式成立, 基变量必须调整; z_j 就是这些调整带来的目标变化。

最优性条件 (对 min 问题): 若所有非基变量的检验数 $\sigma_j \leq 0$, 则当前 BFS 为最优解。

例: 考虑标准型 LP:

$$\min 2x_1 + 3x_2 + x_3 + x_4$$

$$\text{s.t. } x_1 + x_2 + x_3 = 4$$

$$x_1 + 2x_2 + x_4 = 6$$

$$x_j \geq 0$$

取基 $B = [a_3, a_4] = I_2$, 则 $c_B = (1, 1)^T$, $B^{-1} = I_2$ 。

非基变量 x_1 的检验数：

$$\sigma_1 = c_B^T B^{-1} a_1 - c_1 = (1, 1) \begin{pmatrix} 1 \\ 1 \end{pmatrix} - 2 = 2 - 2 = 0$$

x_2 的检验数：

$$\sigma_2 = (1, 1) \begin{pmatrix} 1 \\ 2 \end{pmatrix} - 3 = 3 - 3 = 0$$

全部 $\sigma_j \leq 0$ ，当前 BFS $(0, 0, 4, 6)^T$ 已是最优解（目标值 $z_0 = 10$ ）。

检验数的直觉： $\sigma_j > 0$ 意味着增大 x_j （让非基变量进基）能使目标下降（对 min 问题，我们希望检验数 ≤ 0 时为最优， $\sigma_j > 0$ 说明 x_j 有改善潜力）。 σ_j 就是“让 x_j 增加 1 单位的净收益”——省下的成本减去新增的成本。

PPT 第 5.6 页展示的是检验数的推导过程——从可行方向的定义到 $c^T \Delta x = c_j - z_j$ ，正是检验数的雏形。PPT 用向量推导而非分块矩阵，两种推导等价。

$$c^T \Delta x = c_j - c_B^T B^{-1} N e_j = c_j - z_j$$

故当 $z_j - c_j > 0$ 时, $c^T \Delta x < 0$, 于是 Δx 为改进方向。

称 $z_j - c_j$ 为检验数, 对应的非基变量 x_j 为进基变量。

如何沿改进可行方向 Δx 搜索得到一个新的基可行解?

$$\text{由 } x^{(t)} + \lambda \Delta x \geq 0, \quad x^{(t)} \geq 0$$

知: 若 $\Delta x \geq 0$, 则 λ 可取无穷大, 从而

$$c^T(x^{(t)} + \lambda \Delta x) \text{ 趋于 } -\infty.$$

即问题无下界 (无有限最优解)。

2.3 单纯形表：手工计算的载体

单纯形表把基矩阵信息、检验数、当前解值压缩在一张表格里, 便于手工迭代。

单纯形表的结构

基	x_1	x_2	$\cdots$	x_j	$\cdots$	x_n	b
x_{B_1}	$\bar{a}_{11}$	$\bar{a}_{12}$	$\cdots$	$\bar{a}_{1j}$	$\cdots$	$\bar{a}_{1n}$	$\bar{b}_1$
x_{B_2}	$\bar{a}_{21}$	$\bar{a}_{22}$	$\cdots$	$\bar{a}_{2j}$	$\cdots$	$\bar{a}_{2n}$	$\bar{b}_2$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
x_{B_m}	$\bar{a}_{m1}$	$\bar{a}_{m2}$	$\cdots$	$\bar{a}_{mj}$	$\cdots$	$\bar{a}_{mn}$	$\bar{b}_m$
σ_j	σ_1	σ_2	$\cdots$	σ_j	$\cdots$	σ_n	$-z_0$

其中 $\bar{A} = B^{-1}A$, $\bar{b} = B^{-1}b$ 。末行检验数，末格为 $-z_0$ （当前目标值的相反数）。

读出信息的规则：

- 基变量对应的列是单位向量（如基变量 x_4 列的对应行是 1，其余行 0），其检验数恒为 0
- b 列 = 当前基变量的取值（非基变量均为 0）
- 末行末格 = $-z_0$ ，目标值 z_0 = 它的相反数

PPT 第 5.10 页给出了表格形式单纯形方法的全貌

——初始表如何建立、旋转元如何选取、行变换如何执行。这张 PPT 与上述表格结构完全一致，是从代数推导到手工操作的桥梁。

表格形式的单纯形方法

5.10

考虑标准型

$$\begin{aligned} \min \quad & cx \\ \text{s.t.} \quad & Ax = b \\ & x \geq 0, \end{aligned} \quad (3.1)$$

记 $A = [B, N]$, $x = \begin{pmatrix} x_B \\ x_N \end{pmatrix}$, x_B 为基变量, x_N 为非基变量。

则标准型等价于

$$\begin{aligned} \min \quad & f \\ \text{s.t.} \quad & f - c_B x_B - c_N x_N = 0 \\ & Bx_B + Nx_N = b \\ & x_B \geq 0, x_N \geq 0 \end{aligned}$$

2.4 一次单纯形迭代：三步走透

假设当前 BFS 非退化，一次完整的单纯形迭代由三步组成。每一步我们都说清楚因果链条。

方法 2.1（单纯形法一次迭代）

1. **进基选择**：在检验数行中，找最大的正检验数 σ_k ，对应的非基变量 x_k 进基。若所有检验数 ≤ 0 ，当前解已最优，停止。
2. **离基选择（最小比值原则）**：对 x_k 列中所有 $\bar{a}_{ik} > 0$ 的行，计算 $\theta_i = \bar{b}_i / \bar{a}_{ik}$ ，取最小 θ_i 对应的基变量 x_r 离基。若该列无正系数，问题无下界（目标可无限下降），停止。
3. **转轴运算（Pivot）**：以 $\bar{a}_{rk}$ 为主元，对单纯形表进行行变换——主元行除以 $\bar{a}_{rk}$ 使主元变为 1，然后用此行消去其他所有行（包括检验数行）的 x_k 列，使该列变成第 r 个分量为 1 的单位向量。

下面逐条展开因果。

进基：为什么选最大正检验数？

从哪来？检验数 σ_j 衡量的是“让 x_j 增加 1 单位，目标能改善多少”。对 min 问题， $\sigma_j > 0$ 意味着增加 x_j （从 0 变正）能让目标下降。

为什么做？选最大正检验数就是选“单位增量收益最大”的变量进基——贪心思想，每步选下降最快的方向。实际单纯形法也常用其他规则（如选第一个正检验数），理论效率相近。

得到什么？确定进基变量 x_k ，即下一步要增大哪个非基变量。

例：设检验数行为 $(\sigma_1, \sigma_2, \sigma_3, \sigma_4, \sigma_5) = (3, -1, 0, 0, 5)$ 。最大正检验数是 $\sigma_5 = 5$ ，所以 x_5 进基。这意味着让 x_5 从 0 增大，每增 1 单位目标下降 5 单位——最划算。

离基：为什么取最小正比值？

从哪来？当 x_k 增大时，基变量随之变化： $x_{B_i} = \bar{b}_i - \bar{a}_{ik} \cdot \Delta$ 。如果 $\bar{a}_{ik} > 0$ ， x_{B_i} 随 x_k 增大而减少。

为什么做？基变量必须 ≥ 0 （可行性要求）。 x_k 最多能增到多大？对每个 $\bar{a}_{ik} > 0$ 的行，上限是 $\bar{b}_i / \bar{a}_{ik}$ （再

大该基变量就变负了)。取所有上限中的最小值——最先被逼到 0 的基变量就是“瓶颈”，它离基。

得到什么？确定离基变量 x_r 和主元 $\bar{a}_{rk}$ 。 x_k 增大到 $\theta = \min_i \{\bar{b}_i / \bar{a}_{ik} \mid \bar{a}_{ik} > 0\}$, x_r 降为 0 出基。

为何只看正系数？ $\bar{a}_{ik} \leq 0$ 时， x_k 增大反而让 x_{B_i} 增大或不变——这条约束不限制 x_k 的增长，不是瓶颈。

例：设 $x_k = x_3$ ，其列系数为 $(2, -1, \frac{1}{2})^T$ ，右端 $b = (6, 4, 3)^T$ 。比值： $6/2 = 3$, $4/(-1)$ 跳过, $3/(1/2) = 6$ 。最小是 3，对应第一行，该行基变量 x_1 离基，主元为 $\bar{a}_{13} = 2$ 。

转轴：为什么这样做？

从哪来？已有进基变量 x_k 和离基变量 x_r ，主元 $\bar{a}_{rk}$ 。

为什么做？转轴运算是一次基变换的代数实现——用进基列替换离基列，使新基仍然是单位阵。主元行除以主元让新基变量列在对应位置为 1；用此行消去其他行让该列其他位置为 0。

得到什么？新单纯形表，新 BFS，目标值下降（或不变，退化时）。检验数行也同时更新。

PPT 第 5.4 和 5.5 页展示了单纯形法推导的数学细

节——从当前 BFS 出发，构造改进可行方向 Δx ，推导进基和离基的代数条件。PPT 上的符号体系（ Δx_N 取单位向量 e_j ， $\Delta x_B = -B^{-1}Ne_j$ ）与上述表格操作完全对应。

5.4

设当前基本可行解为 $x^{(t)}$ ， B 为对应的基变量下标集， N 为非基变量下标集。令搜索方向为 Δx ，要保持可行，则

$$A(x^{(t)} + \lambda \Delta x) = b, \quad Ax^{(t)} = b$$

得 $A\Delta x = 0$ 。

因 $x^{(t)}$ 是非退化的基本可行解，故对充分小的 λ ， $x^{(t)} + \lambda \Delta x \geq 0$ 。即 Δx 是可行方向。

Δx 是改进方向，则 $c^T(x^{(t)} + \lambda \Delta x) < c^T x^{(t)}$

即 $c^T \Delta x < 0$

于是：若 $c^T \Delta x < 0, A\Delta x = 0$ ，则 Δx 为改进可行方向。

下面来求这种形式的改进可行方向。

为方便，也用 $B(N)$ 表示 A 中基变量（非基变量）对应的子矩阵，于是 $A=(B,N)$ ，

可行方向条件 $A\Delta x=0$ 化为

$$B \Delta x_B + N \Delta x_N = 0,$$

于是 $\Delta x_B = -B^{-1}N \Delta x_N$ ，

若取 Δx_N 等于单位向量 e_j （第 j 个分量为1，其余全为0），则 $\Delta x_B = -B^{-1}N e_j$

2.5 自编例题：从头到尾走一遍单纯形法

下面用一个简单的 2 变量问题，展示从标准型到最优表的完整单纯形迭代。这个例子变量少，每一步都能看清因果。

问题：

$$\begin{aligned} \max \quad & 3x_1 + 2x_2 \\ \text{s.t.} \quad & x_1 + x_2 \leq 4 \\ & x_1 \leq 3 \\ & x_2 \leq 2 \\ & x_1, x_2 \geq 0 \end{aligned}$$

第 0 步：化为标准型

目标 $\max \rightarrow \min$ （乘 -1 ）；三个 $\leq$ 约束各加松弛变量 x_3, x_4, x_5 ：

$$\begin{aligned} \min \quad & -3x_1 - 2x_2 \\ \text{s.t.} \quad & x_1 + x_2 + x_3 = 4 \\ & x_1 + x_4 = 3 \\ & x_2 + x_5 = 2 \\ & x_j \geq 0, \quad j = 1, \dots, 5 \end{aligned}$$

初始单纯形表

初始基变量： x_3, x_4, x_5 （三个松弛变量的列恰好构成 I_3 ），初始 BFS： $x = (0, 0, 4, 3, 2)^T$ ，目标值 $z_0 = 0$ 。

表 2.A: 初始表

基	x_1	x_2	x_3	x_4	x_5	b
x_3	1	1	1	0	0	4
x_4	1	0	0	1	0	3
x_5	0	1	0	0	1	2
σ_j	3	2	0	0	0	0

检验数解读： $\sigma_1 = 3 > 0$, $\sigma_2 = 2 > 0$ ——增大 x_1 或 x_2 都能改善目标。 σ_1 更大，先让 x_1 进基。

第一次迭代

进基： x_1 ($\sigma_1 = 3$, 最大正检验数)。

离基： 看 x_1 列正系数： $\bar{a}_{11} = 1$ (第 1 行), $\bar{a}_{21} = 1$ (第 2 行)。比值： $\theta_1 = 4/1 = 4$, $\theta_2 = 3/1 = 3$ 。最小是 3，第 2 行基变量 x_4 离基。主元 $\bar{a}_{21} = 1$ 。

转轴： 主元已是 1，只需消去第 1 行和第 3 行以及检验数行的 x_1 列。第 1 行 $\leftarrow$ 第 1 行 - 第 2 行；检验数行 $\leftarrow$ 检验数行 - 3 $\times$ 第 2 行。

表 2.B: 第一次迭代后

基	x_1	x_2	x_3	x_4	x_5	b
x_3	0	1	1	-1	0	1
x_1	1	0	0	1	0	3
x_5	0	1	0	0	1	2
σ_j	0	2	0	-3	0	-9

当前解: $x_1 = 3$, $x_3 = 1$, $x_5 = 2$, $x_2 = x_4 = 0$ 。目标值 $z_0 = 9$ (表中末格 -9 , 所以 $z_0 = 9$; 这是 min 目标值, 原 max 目标为 -9 的相反数即 9)。检验数 $\sigma_2 = 2 > 0$, 尚未最优。

第二次迭代

进基: x_2 ($\sigma_2 = 2 > 0$, 唯一正检验数)。

离基: x_2 列正系数: $\bar{a}_{12} = 1$ (第 1 行), $\bar{a}_{32} = 1$ (第 3 行)。比值: $\theta_1 = 1/1 = 1$, $\theta_3 = 2/1 = 2$ 。最小是 1, 第 1 行基变量 x_3 离基。主元 $\bar{a}_{12} = 1$ 。

转轴: 主元已是 1, 消去第 2 行和第 3 行的 x_2 列。

表 2.C: 最优表

基	x_1	x_2	x_3	x_4	x_5	b
x_2	0	1	1	-1	0	1
x_1	1	0	0	1	0	3
x_5	0	0	-1	1	1	1
σ_j	0	0	-2	-1	0	-11

所有检验数 ≤ 0 , 已达最优。最优解: $x_1^* = 3$, $x_2^* = 1$, $x_5^* = 1$ (松弛), $x_3 = x_4 = 0$ 。min 最优值 $z_0 = 11$, 原 max 最优值 = 11 (注意符号: min 目标 $-3x_1 - 2x_2$ 最优值为 -11, 表中 $-(-11) = 11$ 是 min 值的相反数? 不对——让我重新验证)。

验证: 表 2.C 末格 -11, 即 $-z_0 = -11$, 所以 $z_0 = 11$ 。但这是 min 问题的目标值, min $-3x_1 - 2x_2$ 在 (3, 1) 处 $= -3 \cdot 3 - 2 \cdot 1 = -11$ 。等一下——检验数行末格在最优表中是 $-z_0$, 初始表中 z_0 按“min 目标值在初始 BFS 的值”算。初始 (0, 0, 4, 3, 2) 处 min 目标 = 0, 所以初始末格 0。第一次迭代后 BFS (3, 0, 1, 0, 2) 处 min 目标 = -9, 末格应为 9 ($-(-9)$), 表 2.B 末格 -9……说明末格不是 $-z_0$ 而是 z_0 。我之前的说法需要修正。

实际上在教材中, 检验数行末格通常记为目标函数值

z_0 或其相反数，不同教材习惯不同。在本题中，我们按“末格 = 当前 z 值”理解：初始 $z = 0$ ，第一次迭代后 $z = -9$ ，最优表 $z = -11$ 。原 max 目标的最优值 = 11。

最优解（原问题）： $x_1^* = 3$, $x_2^* = 1$ ，最大利润 $3 \cdot 3 + 2 \cdot 1 = 11$ 。松弛变量 $x_5 = 1$ 说明第三种资源（ $x_2 \leq 2$ 约束）有剩余—— $x_2^* = 1 < 2$ ，剩余 1 单位。 $x_3 = x_4 = 0$ 说明前两种资源被用完—— $x_1 + x_2 = 4$ （恰好）， $x_1 = 3$ （恰好）。

复盘总结： 两轮迭代，目标值从 0 降到 -9 再降到 -11（min 意义下的下降；max 意义下的上升）。每一步选择进基变量时看谁带来的边际改善最大，离基变量由“谁先被逼到零”决定。

2.6 初始基本可行解从哪里来？

单纯形法需要一个初始 BFS 才能启动。但并非所有标准型 LP 的系数矩阵都包含现成的单位子阵。

什么时候直接有？ 全部是 $\leq$ 约束且 $b \geq 0$ ：每个约束加的松弛变量系数为 +1，天然构成 m 阶单位阵。松弛变量就是初始基变量，初始 BFS =

$(0, \dots, 0, b_1, \dots, b_m)^T$ 。如上面 2.5 节的例题——三个松弛变量构成初始基，毫不费力。

什么时候没有？两种情况导致缺基变量列：

- 约束中有 $\geq$ ：剩余变量系数是 -1 ，不能当单位向量
- 约束中有 $=$ ：根本没有自然添加的变量

这两种情况下，系数矩阵缺少足够的 $+1$ 单位列，无法直接读出初始 BFS。这就需要用大 M 法或两阶段法来“造”初始基。

PPT 第 5.8 页展示了单纯形法的几何图景——从初始顶点出发沿棱移动。这张图片对应的是“已经找到初始 BFS”之后的迭代过程；初始 BFS 本身如何获得，正是大 M 法和两阶段法要解决的问题。

单纯形法

步1: 找出初始可行基 $B = [A_{B(1)}, A_{B(2)}, \dots, A_{B(m)}]$ 及初始基可行解 x ;

步2: 计算 $c'_B B^{-1} A_j - c_j = z_j - c_j$

若 $z_j - c_j \leq 0, \forall j \in N$, 则 x 为最优解, 停止

否则, 选取 j 使得 $z_j - c_j > 0$.

步3: 计算 $y = B^{-1} A_j$

若 $y \leq 0$, 则目标值无下界, 停止

否则, 计算 $\lambda^* = \min_{i=1,2,\dots,m, y_{ij} > 0} \left\{ \frac{\bar{b}_i}{y_{ij}} \right\} = \frac{\bar{b}_t}{y_{tj}}$

步4: 用 A_j 替代 $A_{B(i)}$, 得一新的基 $A_{B(1)}, A_{B(2)}, \dots, \underset{\text{第 } t \text{ 项}}{A_j}, \dots, A_{B(m)}$,

令 $x_j = \lambda^*$, $x_{B(i)} = x_{B(i)} - \lambda^* y_{ij}$, $x_k = 0, k \in N \setminus \{j\}$

得新可行解 x , 转步1.

2.7 大 M 法：透彻解析

问题根源：为什么需要人工变量？

回到 2.6 节的情况——某个约束缺少“系数为 +1 且在其他行系数为 0”的变量。例如 $\geq$ 约束减去剩余变量后，剩余变量的系数是 -1，把它放进基意味着 $x_B = -b < 0$ （因为 $b > 0$ ），不是可行解。

人工变量的思路：既然缺 +1 列，我们就硬塞一个 +1 列进去。在每个缺基变量的行引入一个人工变量

$x_a \geq 0$ ，系数正好是 +1。这样人工变量加上原有的松弛变量，恰好凑出完整的 m 阶单位阵——初始基就有了。

核心矛盾：人工变量是”假的”

人工变量不是原问题的变量——它只是我们为了凑初始基人为添加的。在真正的最优解中，人工变量必须等于 0（否则原约束被篡改了）。但单纯形法不知道谁是”假的”——如果不加干预，算法会让 $x_a > 0$ 留在解中。

大 M 法的解决策略：惩罚驱赶

为什么加 M？在目标函数中对每个人工变量加上一个巨大的惩罚系数 $M > 0$ （对 min 问题加 $+Mx_a$ ，对 max 问题加 $-Mx_a$ ）。 M 是”非常大”的正数——大到任何不含人工变量的可行解目标值，都优于含正人工变量的可行解。

M 为什么能赶走人工变量？考虑 min 问题。目标变为 $\min c^T x + M \sum x_a$ 。如果某人工变量 $x_a > 0$ ，目标中 Mx_a 这一项就极大，整个目标值被拖累得很差。

单纯形法要最小化目标——它会主动让所有正检验数对应的人工变量尽快离基，因为 M 的系数巨大，人工变量的检验数（含 M 项）是最大的正检验数，算法优先级最高的就是把它们赶出基。

一旦人工变量全部离基（取值 $=0$ ）， $M \sum x_a = 0$ ，目标函数恢复为原问题目标——此时得到的 BFS 就是原问题的 BFS。

如果赶不走怎么办？ 最优时若人工变量仍为正——说明在原问题的约束下，根本找不到让该人工变量为 0 的解。原问题不可行。

方法 2.2 (大 M 法标准流程)

1. **标准化后审视约束矩阵：**找出哪些行缺少 +1 单位列。每个“松弛变量”列 (+1) = 天然的基候选；每个“剩余变量”列 (-1) 或缺变量行 = 需要人工变量。
2. **引入人工变量：**在每个缺基的行添加人工变量 $x_a \geq 0$ ，系数 +1。人工变量只出现在自己的那行（系数列是单位向量）。
3. **修改目标函数：**对 min 问题，目标加 $M \sum x_a$ (M 为充分大的正数)；对 max 问题，目标减 $M \sum x_a$ 。
4. **建立初始单纯形表：**以人工变量 + 原有松弛变量为初始基。注意检验数行中人工变量的检验数含 M 项——手工计算时将含 M 和不含 M 的部分分开写（通常写成两行或括号）。
5. **正常执行单纯形法：**由于 M 极大，含 M 正系数的检验数最大——算法优先迭代赶走

例：考虑问题：

$$\begin{aligned} \min \quad & x_1 + 2x_2 \\ \text{s.t.} \quad & x_1 + x_2 \geq 3 \\ & x_1, x_2 \geq 0 \end{aligned}$$

标准化：加剩余变量 x_3 ：

$$x_1 + x_2 - x_3 = 3, \quad x_3 \geq 0$$

x_3 系数是 -1 ，缺基变量。引入人工变量 $x_4 \geq 0$ ：

$$x_1 + x_2 - x_3 + x_4 = 3$$

目标变为 $\min x_1 + 2x_2 + Mx_4$ 。初始基变量： x_4 ，初始 BFS: $(0, 0, 0, 3)^T$ 。

初始表（只有一行， $c_B = M$ ）：

基	x_1	x_2	x_3	x_4	b
x_4	1	1	-1	1	3
σ_j	$M - 1$	$M - 2$	$-M$	0	$-3M$

$\sigma_1 = M - 1 > 0$, $\sigma_2 = M - 2 > 0$ —— M 极大，这两个是很大的正数，都是进基候选。 $\sigma_3 = -M < 0$,

$\sigma_4 = 0$ 。 σ_1 最大 ($M - 1 > M - 2$)， x_1 进基。这正是大 M 法的驱动力：含 $+M$ 系数的非基变量检验数被放大为最大正检验数，算法优先选它们进基，从而推动人工变量尽快离基。

实际上在初始表中，检验数行含 M 的变量会被优先处理。我们不做完整计算（考试中真题会处理），关键是理解机制。

PPT 第 5.30 页明确了大 M 法的动机：两阶段法分两步走——先找初始 BFS 再求最优；大 M 法把两步合并，用一个极大的惩罚因子 M 在目标中“同步”驱赶人工变量。PPT 第 5.31 页进一步说明惩罚因子的选取—— M 要“充分大”，大到任何可行解都比含人工变量的解好。实际操作中 M 取 10^4 或 10^6 量级即可（对考试手工计算保持为符号 M ）。

- 前面所说的两阶段法分成两步走。能不能把这两步合并？如何合并？

• (二) 大M法

设原问题为

$$\begin{aligned} \min & c^T x \\ \text{s.t.} & \begin{cases} Ax = b \\ x \geq 0 \end{cases} \end{aligned}$$

引入m个人工变量 $x_{n+1}, \dots, x_{n+m}$

$$\begin{aligned} \text{s.t.} \quad & a_{11} x_1 + a_{12} x_2 + \dots + a_{1n} x_n + x_{n+1} = b_1 \\ & a_{21} x_1 + a_{22} x_2 + \dots + a_{2n} x_n + x_{n+2} = b_2 \\ & \dots \quad \dots \\ & a_{m1} x_1 + a_{m2} x_2 + \dots + a_{mn} x_n + x_{n+m} = b_m \\ & x_1, \dots, x_n, x_{n+1}, \dots, x_{n+m} \geq 0 \end{aligned}$$

大M法

- 现在关键是如何选取目标函数，因要包含原问题，所以必须包含原目标。联系到两阶段法，我们要强迫人工变量取值为0，于是加上一个惩罚因子，因为是极小化，所以希望这个惩罚因子越大越好！！

在目标函数中增加 $M \sum_{i=1}^m x_{n+i}$ 项，得如下规划

$$\begin{aligned} \min z &= c^T x + M \sum_{i=n+1}^{n+m} x_i \\ \text{s.t.} \quad & \begin{cases} Ax + x_\alpha = b \\ x \geq 0, x_\alpha \geq 0 \end{cases} \end{aligned}$$

两阶段法简介

两阶段法是大 M 法的替代方案，避免 M 带来的数值问题（实际计算中 M 过大导致舍入误差）。

- **第一阶段：**目标设为 $\min \sum x_a$ （最小化人工变量之和），求解辅助 LP。若最优值 = 0 则所有人工变量可驱为 0，得到原问题的一个初始 BFS；若最优值 > 0 则原问题无可行解。
- **第二阶段：**去掉人工变量，从第一阶段得到的 BFS 出发，用原目标函数继续单纯形法求最优解。

两阶段法逻辑更清晰但步骤多；大 M 法一步到位但需处理 M 符号。考试中大 M 法更常考。

2.8 真题操练：第一题 (1)——大 M 法完整求解

回到第 1 章 1.4 节所化的标准型。该标准型中第二条约束缺基变量列，需要用大 M 法。

引入人工变量

标准型回顾：

$$\begin{aligned}\min \quad & 2x_1 - x_2 + x_3 \\ \text{s.t.} \quad & 3x_1 + x_2 + x_3 + x_4 = 6 \\ & x_1 - x_2 + 2x_3 - x_5 = 1 \\ & x_1 + x_2 - x_3 + x_6 = 2 \\ & x_j \geq 0, \quad j = 1, \dots, 6\end{aligned}$$

缺基分析：第一条约束有松弛变量 x_4 （系数 +1），第三条有松弛变量 x_6 （系数 +1）——两个现成的单位列。第二条约束只有剩余变量 x_5 （系数 -1）——缺 +1 单位列。

引入人工变量：在第二条约束中添加人工变量 $x_7 \geq 0$ ：

$$x_1 - x_2 + 2x_3 - x_5 + x_7 = 1$$

目标函数加惩罚项 Mx_7 （ M 为充分大的正数）：

$$\min \quad 2x_1 - x_2 + x_3 + Mx_7$$

初始基变量： x_4 （约束 1）， x_7 （约束 2，人工）， x_6 （约束 3）。初始 BFS： $X = (0, 0, 0, 6, 0, 2, 1)^T$ 。

初始单纯形表

表 2.1: 第一题初始单纯形表

基	x_1	x_2	x_3	x_4	x_5	x_6	x_7	b
x_4	3	1	1	1	0	0	0	6
x_7	1	-1	2	0	-1	0	1	1
x_6	1	1	-1	0	0	1	0	2
$z_j - c_j$	$-2 + M$	$1 - M$	$-1 + 2M$	0	$-M$	0	0	

检验数计算详解 ($c_B = (0, M, 0)$, 理解每步因果):

$$\sigma_1 = 0 \cdot 3 + M \cdot 1 + 0 \cdot 1 - 2 = M - 2$$

$$\sigma_2 = 0 \cdot 1 + M \cdot (-1) + 0 \cdot 1 - (-1)$$

$$= -M + 1 = 1 - M$$

$$\sigma_3 = 0 \cdot 1 + M \cdot 2 + 0 \cdot (-1) - 1 = 2M - 1$$

$$\sigma_5 = 0 \cdot 0 + M \cdot (-1) + 0 \cdot 0 - 0 = -M$$

检验数中 M 的角色: $\sigma_1 = M - 2$, $\sigma_3 = 2M - 1$ ——因为 M 极大, 这两个是很大的正数 (对 min 问题正检验数 = 进基候选)。 $\sigma_2 = 1 - M$ 是很大的负数—— x_2 绝不可能进基 (增大 x_2 会严重恶化目标)。 $\sigma_5 = -M$ —— x_5 也不会进基。

实际上 M 在检验数中的作用是：人工变量所在的行通过 c_B 把 M 传播到非基变量的检验数中，产生”驱动力”——含 $+M$ 系数的检验数最大，优先被选中进基，从而推动人工变量尽快离基。

第一次迭代

进基：比较正检验数—— $\sigma_3 = 2M - 1$ 中 M 的系数最大（2 vs 1）， x_3 进基。

离基：看 x_3 列正系数：

$$\theta_{x_4} = 6/1 = 6, \quad \theta_{x_7} = 1/2 = 0.5$$

（ θ_{x_6} 因系数为负（-1）跳过） $\min = 0.5$ ， x_7 离基。

关键：人工变量在第一轮迭代就被赶走了！主元 $\bar{a}_{23} = 2$ 。

转轴：第 2 行除以 2，主元变 1。用此行消去其他行的 x_3 列。 x_7 已离基且是人工变量，可从表中删去其列。

注：若有退化的基本可行解，则上述算法迭代时由最小比值原则确定的步长 λ 可能取值为0，进基变量替换离基变量得到的解不发生变化，但基变量会发生变化，此时在新的基下继续进行迭代即可。

定理 (单纯形法的收敛性)

对于每个**基可行解都是非退化的**LP问题，那么经过有限次迭代后，单纯形法或者得到最优基本可行解或判断问题无界。

退化情形下的收敛性后面再讨论。

表 2.2: 第一次迭代后 (x_7 列已删除)

基	x_1	x_2	x_3	x_4	x_5	x_6	b
x_4	2.5	1.5	0	1	0.5	0	5.5
x_3	0.5	-0.5	1	0	-0.5	0	0.5
x_6	1.5	0.5	0	0	-0.5	1	2.5
$z_j - c_j$	-1.5	0.5	0	0	-0.5	0	

人工变量已全部离基 (x_7 出基且已从表中删除)，检验数行不再含 M 。现在就是普通的单纯形迭代。 $\sigma_2 = 0.5 > 0$ ，继续。

第二次迭代

进基： x_2 ($\sigma_2 = 0.5 > 0$, 唯一正检验数)。

离基：看 x_2 列正系数：

$$\theta_{x_4} = 5.5/1.5 = 11/3, \quad \theta_{x_6} = 2.5/0.5 = 5$$

(x_3 行系数 $-0.5 < 0$, 跳过)。 $\min = 11/3$, x_4 离基。

主元 $\bar{a}_{12} = 1.5$ 。

转轴：第 1 行除以 1.5, 主元变 1。消去其他行的 x_2 列。

表 2.3: 最优单纯形表

基	x_1	x_2	x_3	x_4	x_5	x_6	b
x_2	5/3	1	0	2/3	1/3	0	11/3
x_3	4/3	0	1	1/3	-1/3	0	7/3
x_6	2/3	0	0	-1/3	-2/3	1	2/3
$z_j - c_j$	-7/3	0	0	-1/3	-2/3	0	

全部检验数 ≤ 0 , 已达最优。人工变量全为 0 (x_7 早在第一轮就被赶走), 目标函数恢复为原目标——这是合法的最优解。

读出最优解：

$$x_1^* = 0, \quad x_2^* = \frac{11}{3}, \quad x_3^* = \frac{7}{3},$$

$$x_4^* = 0, \quad x_5^* = 0, \quad x_6^* = \frac{2}{3} \quad \text{最优值 } z^* = 2 \cdot 0 - \frac{11}{3} + \frac{7}{3} = -\frac{4}{3}。$$

迭代总结

迭代	进基	离基	主元	目标值变化	备注
0	—	—	—	含 M 项	初始表, x_7 在基中
1	x_3	x_7	2	赶走人工变量	x_7 列删除, 不再含 M
2	x_2	x_4	1.5	z 持续下降	普通单纯形迭代

三种终止状态的判定:

1. **得最优解:** 所有检验数 ≤ 0 且基变量中无人工变量
2. **问题无界 (无下界):** 某检验数 > 0 但该列所有系数 ≤ 0 (没有正系数就没法算最小比值, 意味着可以沿该方向无限走)
3. **原问题无可行解:** 所有检验数 ≤ 0 但某个人工变量仍为正 (基变量中还有人工变量 > 0) —— 大 M 法的惩罚没把它赶走, 说明原约束下该变量无法为 0

2.9 退化与 Bland 规则

退化是什么？

退化指某个基变量取值为 0（即 $x_{B_i} = 0$ ）。退化的 BFS 中，正分量的个数严格小于 m 。

退化为什么麻烦？ 最小比值可能是 0（因为 $\bar{b}_i = 0$ 且 $\bar{a}_{ik} > 0$ ），导致步长为 0——进基变量取代离基变量后，解不变（还是同一个点），但基变了。如果一连串 0 步长迭代后回到之前访问过的基——循环发生，算法永不终止。

Bland 规则（防循环）

进基： 在所有 $\sigma_j > 0$ 的变量中，选下标最小的那个进基。

离基： 若最小比值平局，选下标最小的基变量离基。

Bland 规则是理论保障——严格证明有限步终止。实际计算中循环极其罕见，商业求解器通常不用 Bland 规则（有其他更高效的处理方式）。

PPT 第 5.9 页展示了退化与收敛性——PPT 指出步

长可能为 0，但 Bland 规则保证不会无限循环。

5.9

注：若有退化的基本可行解，则上述算法迭代时由最小比值原则确定的步长 λ 可能取值为0，进基变量替换离基变量得到的解不发生变化，但基变量会发生变化，此时在新的基下继续进行迭代即可。

定理（单纯形法的收敛性）

对于每个**基可行解都是非退化的**LP问题，那么经过有限次迭代后，单纯形法或者得到最优基本可行解或判断问题无界。

退化情形下的收敛性后面再讨论。

本章速查

- 检验数 $\sigma_j = c_B^T B^{-1} a_j - c_j$ （min 问题 $\sigma_j \leq 0 \ \forall j$ 为最优）
- 一次迭代：进基（最大正检验数） $\rightarrow$ 离基（ $\min\{b_i/a_{ik} \mid a_{ik} > 0\}$ ） $\rightarrow$ 转轴（行变换使进基列为单位向量）

- **最小比值的几何意义：**沿进基方向走多远会碰到边界——取最近的那个边界
- **大 M 法因果链：**缺基 $\rightarrow$ 引入人工变量（凑单位阵） $\rightarrow$ 目标加 Mx_a （惩罚驱赶） $\rightarrow M$ 极大 $\rightarrow$ 含 M 的检验数驱动算法优先赶走人工变量 $\rightarrow$ 人工变量全 0 后恢复原目标
- **两阶段法：**阶段一 $\min \sum x_a$ 找初始 BFS，阶段二从该 BFS 求原问题最优
- **Bland 规则：**进基选最小下标正检验数，离基平局选最小下标。防循环。
- **退化：**基变量 $=0$ 导致步长 $=0$ ，可能循环，Bland 规则保证终止

第 3 章 对偶理论

3.1 什么是对偶

每一个线性规划问题（称为原问题，Primal）天然对应着另一个线性规划问题（称为对偶问题，Dual）。

对偶的产生有一个直观的经济背景——食谱问题：一个家庭想用最少的钱购买食品（奶和蛋）来满足每日营养需求，这是原问题（min 成本）。一家制药商想给维生素定价卖给家庭，价格不能超过食品的市场价（否则顾客不如直接买食品），又要使收入最大——这是对偶问题（max 收入）。两个问题共享同一组数据（营养含量表），只是“角色互换”。

对偶的用途极广：

- 一个问题的对偶有时比原问题更容易求解（约束少、变量少的方向）
- 弱/强对偶定理为最优性提供验证工具——对偶目标值给出原问题最优值的界
- 互补松弛条件可以从一侧最优解反推另一侧最优解，省去重算
- 对偶变量就是资源的影子价格，灵敏度分析直接使用

PPT 第 6.1 页用食谱问题引出对偶动机：同一组数据从消费者（min 成本）和生产者（max 收入）两个角度形成一

对规划，二者最优值相等——这在数学上有一般性结论。

6.1

对偶问题

重新考虑食谱问题，假想有一家制药商，计划生产维生素V_c和维生素V_b片并在市场上销售以获取利润。以制药商的利益出发，他知道奶和蛋按其维生素V_c和V_b的含量而有一定的价值。他的问题是确定出售维生素V_c的价格 x 和维生素V_b的价格 y ：他不能将价格订得高于奶和蛋的市场流行价，否则将失去他的顾客；他希望药店的总收入为最大。

维生素	奶中含量	蛋中含量	每日需求
V _c (mg)	2	4	40
V _b (mg)	3	2	50
单价(元)	3	2.5	

3.2 对偶关系表

从任意形式的 LP 构造它的对偶，核心工具是原-对偶对应关系表。只要记住这张表，任何形式的对偶都能机械写出。

表 3.1：原-对偶对应关系

原问题 (min)	对偶问题 (max)	简要解释
约束 $i: \leq$	变量 $w_i \leq 0$	$\min + \leq$ 约束 $\rightarrow$ 乘子需非正才形成下界
约束 $i: \geq$	变量 $w_i \geq 0$	$\min + \geq$ 约束 $\rightarrow$ 乘子自然 ≥ 0
约束 $i: =$	变量 w_i 自由	等式约束乘子方向不影响，无符号限制
变量 $x_j \geq 0$	约束 $j: \leq$	对偶是 $\max$ ，原 $x_j \geq 0$ 使对偶约束不等号与原目标反向
变量 $x_j \leq 0$	约束 $j: \geq$	$x_j \leq 0$ 等价取负方向，对应对偶约束 $\geq$
变量 x_j 自由	约束 $j: =$	自由变量无限制，对偶约束需精确匹配，用等式

记忆规律：原问题 $\min \rightarrow$ 对偶 $\max$ 。原约束不等号方向与对偶变量符号方向一致 ($\leq \rightarrow \leq 0, \geq \rightarrow \geq 0$)。原变量符号与对偶约束不等号方向相反 ($x_j \geq 0 \rightarrow$ 约束 $\leq, x_j \leq 0 \rightarrow$ 约束 $\geq$)。考试直接背表，不要现推。

例：原问题 $\min 3x_1 + 5x_2, \text{ s.t. } 2x_1 + x_2 \leq 10, x_1 - 3x_2 \geq 4, x_1 \geq 0, x_2 \leq 0$ 。

查表： $\min \rightarrow \max$ ；约束 $1 \leq \rightarrow w_1 \leq 0$ ；约束 $2 \geq \rightarrow w_2 \geq 0$ ； $x_1 \geq 0 \rightarrow$ 约束 $1 \leq$ ； $x_2 \leq 0 \rightarrow$ 约束 $2 \geq$ 。得对偶： $\max 10w_1 + 4w_2, \text{ s.t. } 2w_1 + w_2 \leq 3, w_1 - 3w_2 \geq 5, w_1 \leq 0, w_2 \geq 0$ 。

PPT 第 6.4 页展示对称形式 ($\min, Ax \geq b, x \geq 0$) 和非对称形式 (标准型 $\min, Ax = b, x \geq 0$) 两种最常见的对偶转化。PPT 第 6.8 页汇总了原-对偶全部对应规则——考试查表写对偶的标准依据。

6.4

□ 对偶问题的表达

1, 对称形式的对偶

$$\begin{array}{ll} \text{Primal} & \text{Min } cx \\ & \text{s.t. } Ax \geq b, \quad (1) \\ & x \geq 0 \end{array}$$

$$\begin{array}{ll} \text{Dual} & \text{Max } wb \\ & \text{s.t. } wA \leq c, \quad (2) \\ & w \geq 0 \end{array}$$

2, 非对称形式 (标准型) 的对偶

$$\begin{array}{ll} \text{Primal} & \text{Min } cx \\ & \text{s.t. } Ax = b, \quad (3) \\ & x \geq 0 \end{array}$$

$$\begin{array}{ll} \text{Dual} & \text{Max } wb \\ & \text{s.t. } wA \leq c, \quad (4) \\ & w \text{ 无约束} \end{array}$$

由以上分析可知有如下关系

原问题(P) min	对偶问题(D) max
0 0 变量 无限制	行 约 束 =
行 约 束 =	0 0 变量 无限制

对偶的对偶是原问题：将已写出的对偶问题再套一次对偶关系表（注意此时原问题是 max，行对应关系要反过去），会回到最初的原问题。这个性质说明原-对偶是完全对称的关系——PPT 第 6.9 页对此有详细说明，考试中若怀疑写错了对偶，可以用这个性质自检。

引理1 对偶问题的对偶是原始问题
(The dual of the dual is the primal.)

证明：仅就对称形式的对偶规划证明。

原始问题

对偶规划

$$\begin{array}{ll}\text{Primal} & \text{Min } cx \\ & \text{s.t. } Ax \geq b, \quad (1) \\ & \quad x \geq 0\end{array}$$

$$\begin{array}{ll}\text{Dual} & \text{Max } wb \\ & \text{s.t. } wA \leq c, \quad (2) \\ & \quad w \geq 0\end{array}$$

$$\begin{array}{ll}\text{-Min} & -b^T w^T \\ \text{s.t.} & -A^T w^T \geq -c^T \\ & w \geq 0\end{array}$$

$$\begin{array}{ll}\text{-Max} & -x c^T \\ \text{s.t.} & -x A^T \leq -b^T, \\ & x \geq 0\end{array}$$

即得原问题

$$\begin{array}{ll}\text{Min} & cx \\ \text{s.t.} & Ax \geq b, \\ & x \geq 0\end{array}$$

3.3 自编例题：工厂生产的对偶与影子价格

这道例题演示从实际背景出发，建立原问题、构造对偶、并解释对偶变量的经济含义。

例 3.1（工厂生产问题） 某工厂用两种原料 R_1 、 R_2 生产两种产品 P_1 、 P_2 。数据如下：

	产品 P_1	产品 P_2	原料存量
原料 R_1 (kg/件)	2	1	100
原料 R_2 (kg/件)	1	3	150
利润 (元/件)	4	5	—

问如何安排生产使利润最大？设 x_1, x_2 分别为 P_1, P_2 产量。

原问题 (max 利润):

$$\max 4x_1 + 5x_2$$

$$\text{s.t. } 2x_1 + x_2 \leq 100 \quad (\text{原料 } R_1)$$

$$x_1 + 3x_2 \leq 150 \quad (\text{原料 } R_2)$$

$$x_1, x_2 \geq 0$$

约束是 $\leq$ 型，原问题 max、对偶 min，查反向关系表得对偶变量 $y_1, y_2 \geq 0$ 。变量 $x_1, x_2 \geq 0$ ($\max \rightarrow \min$) $\rightarrow$ 对偶约束 $\geq$ 。

$$\min 100y_1 + 150y_2$$

$$\text{s.t. } 2y_1 + y_2 \geq 4 \quad (\text{对应 } x_1, \text{ 原利润系数 } 4)$$

$$y_1 + 3y_2 \geq 5 \quad (\text{对应 } x_2, \text{ 原利润系数 } 5)$$

$$y_1, y_2 \geq 0$$

用图解法求解对偶 (2 变量，比原问题好解)：两条约束线交于 $(y_1, y_2) = (7/5, 6/5) = (1.4, 1.2)$ ，目标值 $100 \times 1.4 + 150 \times 1.2 = 140 + 180 = 320$ 。由

强对偶定理，原问题最优利润也是 320 元（产量 $x_1^* = 30$, $x_2^* = 40$ 可验证）。

影子价格的含义：对偶变量 $y_1 = 1.4$ 意味着——如果原料 R_1 的存量从 100 增加到 101（多 1kg），最优利润将增加约 1.4 元。 $y_2 = 1.2$ 同理。这就是影子价格：它不是原料的市场价格，而是在当前最优生产方案下，该资源的边际价值。若市场上 R_1 的购入价低于 1.4 元/kg，工厂就有动力买入更多 R_1 扩大利润。

3.4 弱对偶定理

定理 3.1（弱对偶定理）

设 x 是原问题（ $\min c^T x$ ，约束 $Ax \geq b$, $x \geq 0$ ）的任意可行解， w 是对偶问题（ $\max b^T w$ ，约束 $A^T w \leq c$, $w \geq 0$ ）的任意可行解。则恒有：

$$c^T x \geq b^T w$$

即：原问题的目标值永远不小于对偶的目标值——对偶的目标值给出原问题最优值的下界。

证明思路（为什么恒成立）： 利用原可行性和对偶可行性的不等式链：

$$c^T x \geq (A^T w)^T x = w^T A x \geq w^T b = b^T w$$

第一步用对偶约束 $A^T w \leq c$ 且 $x \geq 0$ ；第二步用原约束 $Ax \geq b$ 且 $w \geq 0$ 。弱对偶无需额外条件——各自可行即成立。

例（弱对偶验证）：

原： $\min x_1 + x_2$, s.t. $x_1 + 2x_2 \geq 4$, $2x_1 + x_2 \geq 4$, $x_1, x_2 \geq 0$ 。

对偶： $\max 4w_1 + 4w_2$, s.t. $w_1 + 2w_2 \leq 1$, $2w_1 + w_2 \leq 1$, $w_1, w_2 \geq 0$ 。

取原可行解 $x = (4, 0)$ ($4 \geq 4$, $8 \geq 4$)，目标值 = 4。

取对偶可行解 $w = (0, 0)$ ，目标值 = 0，弱对偶成立： $4 \geq 0$ 。

取更好的 $w = (0.2, 0.2)$ ($0.6 \leq 1$, $0.6 \leq 1$)，目标值 = 1.6，仍 ≤ 4 。

PPT 第 6.10 页陈述了对偶定理及其推论（原无界 $\rightarrow$ 对偶不可行；原/对偶均不可行可同时发生），并给出强对偶定理标准证明。

➤ 对偶定理

注意到, 原问题和对偶问题是由同一数据集 (A, b, c) 所定义, 且对偶问题的对偶即是原问题, 因此可以选择原始-对偶对中任一为原问题, 而另一个则自动为对偶。下面讨论两者间的关系。

定理1 设 $x^{(0)}$ 和 $w^{(0)}$ 分别是原问题(1)和对偶问题(2)的可行解, 则 $cx^{(0)} \geq w^{(0)}b$.

证明: 利用对偶定义立明:


$$\text{由于 } Ax^{(0)} \geq b, w^{(0)} \geq 0 \Rightarrow w^{(0)}Ax^{(0)} \geq w^{(0)}b, \quad (7)$$

$$\text{又 } c \geq w^{(0)}A, x^{(0)} \geq 0 \Rightarrow cx^{(0)} \geq w^{(0)}Ax^{(0)}, \quad (8)$$

推论:

- 若原问题无下界 ($\min \rightarrow -\infty$), 则对偶必无可行解
- 若对偶无上界 ($\max \rightarrow +\infty$), 则原问题必无可行解
- 若找到 $c^T x^* = b^T w^*$, 则 x^* 和 w^* 各为原/对偶最优解 (最优性的充分条件, 无需 KKT)

弱对偶的几何直觉: 对偶最优值从”下方”逼近原最优值。原最优值 $\geq$ 对偶最优值, 差值称为对偶间隙。LP 的强对偶定理保证间隙总是零——这是 LP 的独特性质。非线性规划间隙可能为正, 需凸性 + 约束规格才能消除。



3.5 强对偶定理

定理 3.2 (强对偶定理)

设原问题和对偶问题均可行。则两者都存在最优解，且最优目标值相等：

$$\min c^T x = \max b^T w$$

为什么重要？ 强对偶定理是线性规划的核心定理。它意味着：

- 求解原问题等同于求解对偶——选哪个更容易就解哪个
- 单纯形法最优表同时给出原和对偶最优解：检验数行 $c_B^T B^{-1}$ 就是对偶最优解
- 互补松弛条件作为最优性的充要条件，正是建立在强对偶之上

例 (续弱对偶例验证强对偶)：

原: $\min x_1 + x_2$, s.t. $x_1 + 2x_2 \geq 4$, $2x_1 + x_2 \geq 4$, $x_1, x_2 \geq 0$ 。

图解法: 两约束线交于 $x_1 = x_2$, 代入得 $3x_1 = 4 \rightarrow x_1 = 4/3$ 。

原最优解 $x^* = (4/3, 4/3)$, 最优值 $z_P^* = 8/3$ 。

对偶: $\max 4w_1 + 4w_2$, s.t. $w_1 + 2w_2 \leq 1$, $2w_1 + w_2 \leq 1$, $w_1, w_2 \geq 0$ 。

图解法: 交于 $w_1 = w_2$, 代入得 $3w_1 = 1 \rightarrow w_1 = 1/3$ 。

对偶最优解 $w^* = (1/3, 1/3)$, 最优值 $z_D^* = 8/3$ 。

强对偶: $z_P^* = z_D^* = 8/3$, 间隙为零。

3.6 互补松弛条件

定理 3.3 (互补松弛条件)

设 x^* 和 w^* 分别是原问题 ($\min c^T x$, $Ax \geq b$, $x \geq 0$) 和对偶问题 ($\max b^T w$, $A^T w \leq c$, $w \geq 0$) 的可行解。它们是各自最优解的充要条件是:

$$(1) \quad w_i^* \cdot (a_i^T x^* - b_i) = 0 \quad \forall i$$

$$(2) \quad x_j^* \cdot (c_j - w^{*T} a_j) = 0 \quad \forall j$$

即: (1) 对偶变量 $\times$ 原约束松弛量 $= 0$; (2) 原变量 $\times$ 对偶约束松弛量 $= 0$ 。

互补松弛的直观含义:

- **(1) 约束侧：**若 $w_i^* > 0$ （正影子价格），原约束必紧（ $a_i^T x^* = b_i$ ，资源恰好用完）。若原约束松（ $a_i^T x^* > b_i$ ，资源有剩余），则 $w_i^* = 0$ （多余资源边际价值为零）。
- **(2) 变量侧：**若 $x_j^* > 0$ （该产品被生产），对偶约束必紧（ $w^{*T} a_j = c_j$ ，边际收益 = 边际成本）。若对偶约束松（ $w^{*T} a_j < c_j$ ），则 $x_j^* = 0$ （不生产——因为”不值得”）。
- ”互补”：乘积中一个为正，另一个必为零。

例：已知对偶最优解 $w^* = (1/3, 1/3)$ （见 3.5 节），用互补松弛反推原最优解。

- $w_1^* = 1/3 > 0 \Rightarrow$ 原约束 1 紧： $x_1 + 2x_2 = 4$
- $w_2^* = 1/3 > 0 \Rightarrow$ 原约束 2 紧： $2x_1 + x_2 = 4$
- 解方程组得 $x_1 = 4/3, x_2 = 4/3$ 。由互补松弛即原最优解（无需单纯形验证）。

PPT 第 6.10 页讨论了对偶定理体系（弱对偶 $\rightarrow$ 强对偶 $\rightarrow$ 互补松弛），PPT 第 6.15 页给出互补松弛的正式表述与例题——已知对偶最优解，用互补松弛联立方程组即可得原最优解，比单纯形法快得多。

➤ 对偶定理

注意到, 原问题和对偶问题是由同一数据集 (A, b, c) 所定义, 且对偶问题的对偶即是原问题, 因此可以选择原始-对偶对中任一为原问题, 而另一个则自动为对偶。下面讨论两者间的关系。

定理1 设 $x^{(0)}$ 和 $w^{(0)}$ 分别是原问题(1)和对偶问题(2)的可行解, 则 $cx^{(0)} \geq w^{(0)}b$.

证明: 利用对偶定义立明:

$$\text{由于 } Ax^{(0)} \geq b, w^{(0)} \geq 0 \Rightarrow w^{(0)}Ax^{(0)} \geq w^{(0)}b, \quad (7)$$

$$\text{又 } c \geq w^{(0)}A, x^{(0)} \geq 0 \Rightarrow cx^{(0)} \geq w^{(0)}Ax^{(0)}, \quad (8)$$

互补松弛的另一个重要应用在 PPT 第 6.15 页体现: 对偶的一个严格不等式约束直接推出对应原变量为零, 大幅简化联立方程组的规模。

➤ 互补松弛性质

定理3 (互补松弛定理) 若 $x = (x_1, x_2, \dots, x_n)$ 和 $w = (w_1, w_2, \dots, w_m)$ 分别是原始问题 (1) 和对偶问题 (2) 的可行解, 则 x 和 w 都是相应问题的最优解当且仅当下述条件成立:

原始互补松弛条件:

对每一 $1 \leq j \leq n$: 要么 $x_j = 0$, 要么 $\sum_{i=1}^m a_{ij}w_i = c_j$;

对偶互补松弛条件:

对每一 $1 \leq i \leq m$: 要么 $w_i = 0$, 要么 $\sum_{j=1}^n a_{ij}x_j = b_i$

考试怎么用？已知原（或对偶）最优解，用互补松弛反推另一侧最优解。步骤：

1. 看每个对偶变量 w_i^* 是否 > 0 ——若是，对应原约束取等号
2. 看每个原约束是否松——若是，对应 w_i^* 必为 0
3. 看每个原变量 x_j^* 是否 > 0 ——若是，对应偶约束取等号
4. 看每个对偶约束是否松——若是，对应 x_j^* 必为 0
5. 联立所有等式，解出未知量

不需要跑单纯形法。

3.7 对偶的经济解释：影子价格

对偶变量 w_i 的绝对值有明确的经济含义——它是第 i 种资源的影子价格。在最优基不变的前提下（即灵敏度分析的有效范围内）：

$$w_i = \frac{\partial z^*}{\partial b_i}$$

即：增加一单位资源 b_i ，最优目标值恰好改变 w_i 。这从强对偶定理可直接推出：

$$z^* = c_B^T B^{-1} b = w^{*T} b = \sum w_i^* b_i \quad \Rightarrow \quad \frac{\partial z^*}{\partial b_i} = w_i^*$$

影子价格的用途：

- 判断哪种资源是瓶颈（ w_i 大 $\rightarrow$ 稀缺）——应优先增加
- 判断购入额外资源是否划算（市价 $<$ 影子价格 $\rightarrow$ 买入有利）
- 灵敏度分析中， b 在小范围内变化时，最优基不变，影子价格不变，可直接计算新最优值

回顾 3.3 节的工厂例题： $y_1 = 1.4$ 元/kg 就是原料 R_1 的影子价格。如果供应商以 1.0 元/kg 出售额外 R_1 ，工厂应该买入——每多 1kg 净赚 $1.4 - 1.0 = 0.4$ 元。

3.8 真题示例：第一题 (2)——构造对偶规划

【2025 真题 · 第一题 (2)】写出以下 LP 的对偶规划：

$$\begin{aligned} \min \quad & 2x_1 - x_2 + x_3 \\ \text{s.t.} \quad & 3x_1 + x_2 + x_3 \leq 6 \\ & x_1 - x_2 + 2x_3 \geq 1 \\ & x_1 + x_2 - x_3 \leq 2 \\ & x_1, x_2, x_3 \geq 0 \end{aligned}$$

逐步构造对偶——查表法：

第 1 步：确认原问题类型和对偶方向。原问题是 min，有 3 个约束、3 个变量。对偶将是 max，有 3 个变量 w_1, w_2, w_3 （对应原问题 3 个约束）和 3 个约束（对应原问题 3 个变量）。

第 2 步：逐一查表确定对偶变量的符号。

- 约束 1: $3x_1 + x_2 + x_3 \leq 6$ ，是 $\leq$ 型。原 min + 约束 $\leq \rightarrow$ 对偶变量 $w_1 \leq 0$ （原因： $\leq$ 约束化为 $-Ax \geq -b$ 后乘子 ≥ 0 ，令 $w = -$ 乘子）

- 约束 2: $x_1 - x_2 + 2x_3 \geq 1$, 是 $\geq$ 型 $\rightarrow w_2 \geq 0$
- 约束 3: $x_1 + x_2 - x_3 \leq 2$, 是 $\leq$ 型 $\rightarrow w_3 \leq 0$

第 3 步: 确定对偶约束的不等号方向。原变量 $x_1, x_2, x_3 \geq 0$ 。原 $\min$ + 原变量 $\geq 0 \rightarrow$ 对偶约束是 $\leq$ 型 (原变量符号与对偶约束不等号方向相反)。

第 4 步: 写出对偶目标和约束。

对偶目标函数: 原问题右端项 $b = (6, 1, 2)^T$ 作为对偶目标系数, 且对偶是 $\max$:

$$\max 6w_1 + w_2 + 2w_3$$

对偶约束: 原目标系数 $c = (2, -1, 1)^T$ 作为对偶约束的右端。约束矩阵转置 A^T 作为对偶约束矩阵。逐列对应:

- 对 x_1 ($c_1 = 2$): 取 A 第 1 列 $(3, 1, 1)^T$, 得约束 $3w_1 + w_2 + w_3 \leq 2$
- 对 x_2 ($c_2 = -1$): 取 A 第 2 列 $(1, -1, 1)^T$, 得约束 $w_1 - w_2 + w_3 \leq -1$
- 对 x_3 ($c_3 = 1$): 取 A 第 3 列 $(1, 2, -1)^T$, 得约束 $w_1 + 2w_2 - w_3 \leq 1$

第 5 步：汇总写出完整对偶规划。

$$\begin{aligned} \max \quad & 6w_1 + w_2 + 2w_3 \\ \text{s.t.} \quad & 3w_1 + w_2 + w_3 \leq 2 \quad (\text{对应 } x_1) \\ & w_1 - w_2 + w_3 \leq -1 \quad (\text{对应 } x_2) \\ & w_1 + 2w_2 - w_3 \leq 1 \quad (\text{对应 } x_3) \\ & w_1 \leq 0, \ w_2 \geq 0, \ w_3 \leq 0 \end{aligned}$$

验证：将对偶再取一次对偶（注意此时对偶是 $\max$ ，需反向查表），应回到原问题——考试中可用此方法自检。

PPT 第 6.4 页展示对称和非对称形式的标准写法，PPT 第 6.8 页的对偶关系表是考试构造对偶的核心工具——建议默写到草稿纸上逐条对照，避免遗漏符号或不等号方向。

□ 对偶问题的表达

1. 对称形式的对偶

$$\begin{array}{ll} \text{Primal} & \text{Min } cx \\ & \text{s.t. } Ax \geq b, \quad (1) \\ & x \geq 0 \end{array}$$

$$\begin{array}{ll} \text{Dual} & \text{Max } wb \\ & \text{s.t. } wA \leq c, \quad (2) \\ & w \geq 0 \end{array}$$

2. 非对称形式（标准型）的对偶

$$\begin{array}{ll} \text{Primal} & \text{Min } cx \\ & \text{s.t. } Ax = b, \quad (3) \\ & x \geq 0 \end{array}$$

$$\begin{array}{ll} \text{Dual} & \text{Max } wb \\ & \text{s.t. } wA \leq c, \quad (4) \\ & w \text{ 无约束} \end{array}$$

由以上分析可知有如下关系

原问题(P) min	对偶问题(D) max
变量 0 0 无限制	行 约 束 $=$
行 约 束 $=$	变 量 0 0 无限制

查表的常见陷阱:

- 原问题是 max 时, 对偶是 min, 表中的不等号和符号关系要反过来理解
- 自由变量的对偶约束是等式——很多人写成不等式
- 约束带等号时, 对应的对偶变量无符号限制——不要漏写”自由”
- 三个检查: 原目标方向 $\rightarrow$ 对偶目标方向 / 原约束 $\rightarrow$ 对偶变量符号 / 原变量符号 $\rightarrow$ 对偶约束不等号

本章速查

- 原-对偶关系表: $\min \leftrightarrow \max$; 原约束不等号 $\rightarrow$ 对偶变量符号 (一致); 原变量符号 $\rightarrow$ 对偶约束不等号 (相反)
- 弱对偶: $c^T x \geq b^T w$ (对任意可行解恒成立, 无需任何条件)
- 强对偶: 原和对偶均可行 $\rightarrow$ 最优值相等 (LP 特有, 互补松弛的基础)
- 互补松弛: $w_i(a_i^T x - b_i) = 0$ 且 $x_j(c_j - w^T a_j) = 0$ ——最优性充要条件

- 影子价格： $w_i = \partial z^* / \partial b_i$ ——资源边际价值，用于灵敏度分析和资源配置
- 构造对偶步骤：判方向 $\rightarrow$ 定对偶方向 $\rightarrow$ 逐约束查变量符号 $\rightarrow$ 逐变量查约束方向 $\rightarrow$ 转置写系数 $\rightarrow$ 汇总

第 4 章 对偶单纯形法与灵敏度分析

4.1 为什么需要对偶单纯形法

第 2 章的（原始）单纯形法走的是”原始可行 $\rightarrow$ 对偶可行”的路线：始终保持 $b \geq 0$ （原始可行），通过迭代逐步让检验数全部 ≤ 0 （达到对偶可行，即最优）。

但在实际中，我们经常遇到反过来的情况：已经有一张检验数全部 ≤ 0 的表（对偶可行），但某些 $b_i < 0$ （原始不可行）。此时重头用大 M 法太浪费——对偶单纯形法（Dual Simplex Method）正是为这种场景设计的。

对偶单纯形法的核心思想

保持对偶可行性（检验数 ≤ 0 ），逐步消除 b 列的负值，最终达到原始可行——此时既是原始可行又是对偶可行，即为最优解。

典型适用场景：

- 灵敏度分析中 b 改变导致基变量取值变负
- 新增一个约束后原最优解不再满足
- 初始表中检验数已 ≤ 0 ，但某些 $b_i < 0$ （例如 $\geq$ 约束标准化时乘以 -1 ）

PPT 第 6.19 页阐述了对偶单纯形法的基本思想：
与原始单纯形法（见第 2 章）“保原始可行、追对偶可行”对称，
对偶单纯形法“保对偶可行、追原始可行”，两者构成

对偶单纯形法

1对偶单纯形法基本思想

考虑标准形式的线性规划：

$$\begin{aligned} \min \quad & cx \\ \text{s.t.} \quad & Ax = b, \quad (3) \\ & x \geq 0 \end{aligned}$$

定义1 设 $x^{(0)}$ 是标准型(3)的一个基本解,它对应的基为 B ,记 $w = c_B B^{-1}$,若 w 是(3)的对偶问题的可行解,即对所有 j 成立 $w p_j - c_j \leq 0$,则称 $x^{(0)}$ 为原问题的**对偶的基本解**.

完美的镜像。

4.2 对偶单纯形法操作步骤

方法 4.1（对偶单纯形法一次迭代）

前提：表中所有检验数 ≤ 0 （对偶可行），但存在 $\bar{b}_r < 0$ （原始不可行）。

1. **离基选择**：选择 b 列中最负值所在行的基变量离基，记为第 r 行。
2. **进基选择（对偶最小比值）**：在第 r 行中，对所有负系数 $\bar{a}_{rj} < 0$ ，计算 $\theta_j = \frac{|\sigma_j|}{|\bar{a}_{rj}|}$ 。取 θ_j 最小的变量 x_k 进基。
若该行全无负系数，则原问题无可行解。
3. **转轴**：以 $\bar{a}_{rk}$ 为主元进行行变换，使 x_k 列成为单位向量，同时更新检验数行。

PPT 第 6.20 页给出了对偶单纯形法的详细推导，包括离基变量和进基变量的选取准则、主元消去后对偶可行性的保持证明。

注:对偶可行的基本解不一定是原问题的可行解. 若还是原问题的可行解, 则此解即为最优解.

回忆(修正)单纯形法的基本思路是保持原问题的可行性和互补松弛条件下, 在它的最优解上寻求对偶问题的可行性.

类似的, 对偶单纯形法的**基本思路**是: 在保持对偶可行性和互补松弛条件下, 在它的最优解上寻求原问题的可行性.

设从基矩阵 B 开始, 由它形成对偶可行解 w , 使得

$$w^T = c_B^T B^{-1}, A^T w \leq c$$

进一步定义:

$$x = \begin{bmatrix} x_B \\ x_N \end{bmatrix} = \begin{bmatrix} B^{-1}b \\ 0 \end{bmatrix}$$

原始单纯形 vs 对偶单纯形对比:

	原始单纯形	对偶单纯形
先选什么	进基 (最大正检验数)	离基 (最负 b 值)
后选什么	离基 ($\min b_i/a_{ik}$)	进基 ($\min \sigma_j / a_{rj} $)
比值在哪儿算	进基列 (纵向)	离基行 (横向)
保持什么	原始可行 ($b \geq 0$)	对偶可行 ($\sigma \leq 0$)
推动什么	检验数全部 ≤ 0	b 列全部 ≥ 0

4.3 为什么是这个顺序——因果解释

为什么先选离基（最负 b ）？

对偶单纯形法的目标是消除 b 列的负值。最负的 b_r 意味着第 r 个约束被违反得最严重——这个基变量取值为负，离可行域最远。优先修正它能最快地向可行域靠近。这和对偶问题中目标函数是 $\max b^T w$ 有关： $b_r < 0$ 时让 x_{B_r} 离基，等价于对偶问题中让目标函数值增加——这正是对偶问题要做的（最大化）。

为什么在负行系数上取最小比值？

假设第 r 行上 $\bar{a}_{rj} < 0$ 。当 x_j 进基时，第 r 个基变量的值变为：

$$\bar{b}'_r = \frac{\bar{b}_r}{\bar{a}_{rj}} \quad (\text{因为主元消去后新 } b_r \text{ 为原值除以主元})$$

更精确地说，转轴后 b_r 变为 $\bar{b}_r / \bar{a}_{rj} > 0$ （因 $\bar{b}_r < 0$ 且 $\bar{a}_{rj} < 0$ ）。但其他行 $i \neq r$ 的 b_i 也会受影响： $\bar{b}'_i = \bar{b}_i - \frac{\bar{a}_{ij}}{\bar{a}_{rj}} \bar{b}_r$ 。取 $\theta_j = |\sigma_j| / |\bar{a}_{rj}|$ 最小，相当于在对偶问题中做“最保守的步子”——保证所有检验数都保持在 ≤ 0 ，不破坏对偶可行性。这与原始单纯形法中“取最小 b_i / a_{ik} 以保证不跑出可行域”的几何直觉完全对称。

两者的对称性总结：原始单纯形在对偶不可行的方向上试探，用最小比值保护原始可行性；对偶单纯形在原始不可行的方向上试探，用最小比值保护对偶可行性。

4.4 自编例子：对偶单纯形法完整迭代

下面用一个自编的简单 LP 展示对偶单纯形法的完整过程，并与原始单纯形法的迭代思路对照。

问题：

$$\begin{aligned} \min \quad & x_1 + 2x_2 \\ \text{s.t.} \quad & x_1 + x_2 \geq 3 \\ & 2x_1 + x_2 \geq 4 \\ & x_1, x_2 \geq 0 \end{aligned}$$

标准化（引入剩余变量 $x_3, x_4 \geq 0$ ）：

$$\begin{aligned} \min \quad & x_1 + 2x_2 \\ \text{s.t.} \quad & x_1 + x_2 - x_3 = 3 \\ & 2x_1 + x_2 - x_4 = 4 \\ & x_j \geq 0, \quad j = 1, \dots, 4 \end{aligned}$$

两个约束都是 $\geq$ 型，剩余变量系数为 -1 ，没有现成的初始基。将约束两边乘 -1 ，得：

$$\begin{aligned} -x_1 - x_2 + x_3 &= -3 \\ -2x_1 - x_2 + x_4 &= -4 \end{aligned}$$

此时 x_3, x_4 构成初始基，但 $b = (-3, -4)^T$ 为负。检验数呢？ $c_B = (0, 0)$ ，全部 $\sigma_j = 0 - c_j \leq 0$ ： $\sigma_1 = -1$ ， $\sigma_2 = -2$ ， $\sigma_3 = \sigma_4 = 0$ 。这是一张典型的对偶可行但原始不可行的表——对偶单纯形法的起点。

初始表（表 4.1）：

基	x_1	x_2	x_3	x_4	b
x_3	-1	-1	1	0	-3
x_4	-2	-1	0	1	-4
σ_j	-1	-2	0	0	—

迭代 1：

- 离基： b 列最负为 -4 （第 2 行）， x_4 离基。
- 进基：第 2 行负系数有 $x_1(-2)$ 、 $x_2(-1)$ 。

$$\theta_1 = |-1|/|-2| = 0.5, \theta_2 = |-2|/|-1| = 2.$$

$\min = 0.5$ ， x_1 进基。主元 $= -2$ 。

- **转轴：**第 2 行 $\div(-2)$ ，再用它消去其他行的 x_1 列。

基	x_1	x_2	x_3	x_4	b
x_3	0	$-1/2$	1	$-1/2$	-1
x_1	1	$1/2$	0	$-1/2$	2
σ_j	0	$-3/2$	0	$-1/2$	—

所有 $\sigma \leq 0$ (对偶可行保持)，但 $b_1 = -1$ 仍为负。

迭代 2:

- **离基：** $b_1 = -1$ ， x_3 离基。
- **进基：**第 1 行负系数 $x_2(-1/2)$ 、 $x_4(-1/2)$ 。
 $\theta_2 = (3/2)/(1/2) = 3$ ， $\theta_4 = (1/2)/(1/2) = 1$ 。
 $\min = 1$ ， x_4 进基。主元 $= -1/2$ 。
- **转轴：**第 1 行 $\times(-2)$ 后消去。

基	x_1	x_2	x_3	x_4	b
x_4	0	1	-2	1	2
x_1	1	1	-1	0	3
σ_j	0	-1	-1	0	—

$b \geq 0$ 且 $\sigma \leq 0$ ，达到最优！最优解 $x^* = (3, 0, 0, 2)^T$ ， $z^* = 1 \times 3 + 2 \times 0 = 3$ 。

对称性观察：如果这个 LP 变个方向用原始单纯形法（见第 2 章），需要先找初始 BFS（比如用大 M 法加人工变量），走”保 $b \geq 0$ 追 $\sigma \leq 0$ ”的路线。而对偶单纯形法利用了对偶可行性，省掉了人工变量——因为 $\geq$ 约束乘 -1 后自动给出对偶可行的初始表。这正是对偶单纯形法的实用价值。

4.5 灵敏度分析

灵敏度分析（Sensitivity Analysis）回答一个实际问题：当 LP 的参数（价格 c 、资源量 b 、工艺系数 A ）发生变化时，最优解会怎么变？我们从已求出的最优表出发分析，而非重头求解。

灵 敏 度 分 析 总 决 策 表

原问题状态	对偶问题状态	应对措施
可行 + 对偶可行	对偶可行	最优解/最优基不变
可行 + 对偶不可行	对偶不可行	原始单纯形继续迭代
不可行 + 对偶可行	对偶可行	对偶单纯形继续迭代
不可行 + 对偶不可行	对偶不可行	加人工变量从头求解

4.5.1 目标系数 c 的变化

PPT 第 6.46 页讲解了改变系数向量 c 时的灵敏度分析

框架：分为非基变量和基变量两种情况。

PPT 第 6.47 页进一步说明 c 变化时只需计算新的检

改变系数向量c

考虑标准LP问题为

$$\min c^T x$$

$$s.t. \begin{cases} Ax = b \\ x \geq 0 \end{cases}$$

假定得到最优单纯形表如下

	x_B	x_N	RHS
z	0	$c_B^T B^{-1} N - c_N^T$	$c_B^T B^{-1} b$
x_B	I	$B^{-1} N$	$B^{-1} b$

最优基本可行解 $x = \begin{pmatrix} x_B \\ x_N \end{pmatrix} = \begin{pmatrix} \bar{b} \\ 0 \end{pmatrix}$ 及最优值 $z^* = c_B^T \bar{b}$;

验数,其余不变。

改变系数向量c

6.47

当c发生变化时,可能发生改变的是检验数和目标函数值,其它没有改变,因而只需计算新的检验数和目标函数值

$$\xi'_N = c'^T_B B^{-1} N - c'^T_N$$

$$z'_0 = c'^T x^{\text{opt}} = c'^T_B B^{-1} b$$

如果检验数非正,则原最优解依然是最优解;

否则是基本可行解,以此为初始基可行解按单纯形法进行迭代就可以求出新问题的解。

情况一：非基变量 x_j 的 c_j 变为 c'_j 。

只有 x_j 自己的检验数受影响：

$$\sigma'_j = z_j - c'_j = \sigma_j - (c'_j - c_j)$$

若 $\sigma'_j \leq 0$ ，最优解不变；若 $\sigma'_j > 0$ ，以当前表为起点， x_j 进基继续单纯形迭代。

为什么只影响一个检验数？检验数的计算公式是 $\sigma_j = c_B^T B^{-1} a_j - c_j$ 。非基变量的 c_j 只出现在公式的第 2 项。 c_B （基变量价格向量）不变， $B^{-1} a_j$ 不变，所以 $z_j = c_B^T B^{-1} a_j$ 不变——唯一变化的是减去新 c'_j 。而基变量 c 变化时 c_B 改变，所有 z_j 都要重新算。

情况二：基变量 x_k 的 c_k 变为 c'_k 。

c_B 变了，所有非基变量的检验数须全部重新计算：

$$\sigma'_j = (c'_B)^T B^{-1} a_j - c_j, \quad \forall j \in \text{非基}$$

还须更新目标值： $z'_0 = (c'_B)^T B^{-1} b$ 。若所有 $\sigma'_j \leq 0$ ，仍最优；否则继续迭代。

例：在 §4.4 的最优表中， c_1 由 1 变为 3。 x_1 是基变量（ c_B 中 c_1 变了），重算： $c'_B = (c_4 = 0, c_1 = 3)$ ， $\sigma'_2 = (0, 3) \cdot (1, 1)^T - 2 = 3 - 2 = 1 > 0$ ， $\sigma'_3 = (0, 3) \cdot (-2, -1)^T - 0 = -3 \leq 0$ 。 $\sigma'_2 > 0$ ，最优解改变！但若 c_1 由 1 变为 0： $\sigma'_2 = (0, 0) \cdot (1, 1)^T - 2 = -2 \leq 0$ ， $\sigma'_3 = (0, 0) \cdot (-2, -1)^T - 0 = 0 \leq 0$ ，仍最优。

4.5.2 右端项 b 的变化

b 变为 b' 后，新右端 $\bar{b}' = B^{-1}b'$ 。

- 若 $\bar{b}' \geq 0$ ：最优基不变，只是基变量取值变了。新目标值 $z' = c_B^T \bar{b}'$ 。
- 若出现 $\bar{b}'_i < 0$ ：检验数仍 ≤ 0 （ b 变化不影响 σ ），但对偶可行而原始不可行——用对偶单纯形法恢复可行性。

4.5.3 新增约束

PPT 第 6.57 页讲解加入新约束的处理流程：

先检验原最优解是否满足新约束；若不满足，将新约束添入最优表，

消去基变量在该行的影响后，用对偶单纯形法继续求

6.57

加入新的约束

设原有约束为 $Ax=b$ ，在此基础上，我们增加一个新的约束

$$p^{m+1}x \leq b_{m+1}$$

(1)若原来的最优解仍满足新的约束,则它仍是问题的最优解

(2)若原问题的最优解不满足新的约束，则需要把新的约束条件增加到原来的最优表中再解新问题。

设原来的最优基为 B 。最优解为

$$\bar{x} = \begin{pmatrix} x_B \\ x_N \end{pmatrix} = \begin{pmatrix} B^{-1}b \\ 0 \end{pmatrix}$$

解。

步骤：

1. 将原最优解代入新约束。若满足 $\rightarrow$ 最优解不变，结束。
2. 若不满足：引入松弛/剩余变量，将新约束作为新行添入最优表。
3. 在新行中消去基变量（用现有的约束行消去基变量在新行中的系数）。

4. 此时检验数仍 ≤ 0 (新松弛变量检验数为 0), 但新行 b 可能为负 $\rightarrow$ 用对偶单纯形法。

4.5.4 新增决策变量

新变量 x_{n+1} 的 c_{n+1} 和列 a_{n+1} 已知。计算 $B^{-1}a_{n+1}$ 代入表, 计算 $\sigma_{n+1} = c_{n+1}^T B^{-1}a_{n+1} - c_{n+1}$ 。若 ≤ 0 , 原解仍最优; 否则新变量进基继续迭代。

4.6 自编例题：灵敏度分析全流程

问题 (自编): 某工厂生产甲、乙两种产品, LP 模型如下:

$$\min -2x_1 - 3x_2 \quad (\text{即 } \max 2x_1 + 3x_2)$$

$$\text{s.t. } x_1 + 2x_2 \leq 8 \quad (\text{原料 A})$$

$$3x_1 + x_2 \leq 9 \quad (\text{原料 B})$$

$$x_1, x_2 \geq 0$$

引入松弛变量 x_3, x_4 化为标准型后, 用单纯形法求得最优表 4.2:

基	x_1	x_2	x_3	x_4	b
x_2	0	1	3/5	-1/5	3
x_1	1	0	-1/5	2/5	2
σ_j	0	0	-7/5	-1/5	—

最优解 $x^* = (2, 3, 0, 0)^T$, $z^* = -13$ (利润 = 13)。

$$B^{-1} = \begin{bmatrix} 3/5 & -1/5 \\ -1/5 & 2/5 \end{bmatrix} \quad (\text{从 } x_3, x_4 \text{ 列读得})。$$

情景 A：非基变量 c_3 变化。 x_3 是松弛变量，原 $c_3 = 0$ 。若原料 A 有了成本， c_3 变为 1：

$$\sigma'_3 = \sigma_3 - (c'_3 - c_3) = -\frac{7}{5} - (1 - 0) = -\frac{12}{5} \leq 0$$

最优解不变。解释： x_3 是松弛变量，当前 = 0，提高其成本只会让它更不值得入基，最优解不受影响。读者可验证：只有当 $c'_3 - c_3 \leq -7/5$ ，即 c_3 降低到 $-7/5$ 以下时， σ'_3 才变正， x_3 才应进基。

情景 B：基变量 c_1 变化。 产品甲的价格变化， c_1 从 -2 变为 -1 (利润从 2 降到 1)。 x_1 是基变量， c_B 改变，重算所有非基检验数：

$$c'_B = (c_2 = -3, c_1 = -1)$$

$$\sigma'_3 = (-3, -1) \cdot \begin{bmatrix} 3/5 \\ -1/5 \end{bmatrix} - 0 = -\frac{9}{5} + \frac{1}{5} = -\frac{8}{5} \leq 0$$

$$\sigma'_4 = (-3, -1) \cdot \begin{bmatrix} -1/5 \\ 2/5 \end{bmatrix} - 0 = \frac{3}{5} - \frac{2}{5} = \frac{1}{5} > 0$$

$\sigma'_4 > 0$ ，最优解改变！需以当前表为起点， x_4 进基继续迭代（略）。

情景 C：右端 b 变化（基不变）。原料 A 从 8 增到 10 ($b'_1 = 10$)：

$$\bar{b}' = B^{-1}b' = \begin{bmatrix} 3/5 & -1/5 \\ -1/5 & 2/5 \end{bmatrix} \begin{bmatrix} 10 \\ 9 \end{bmatrix} = \begin{bmatrix} 21/5 \\ 8/5 \end{bmatrix} \geq 0$$

$b' \geq 0$ ，最优基不变。新解： $x_2 = 21/5$, $x_1 = 8/5$, $z' = -79/5$ （利润 15.8）。

情景 D：右端 b 变化（需对偶单纯形）。原料 A 从 8 减到 2 ($b'_1 = 2$)：

$$\bar{b}' = B^{-1}b' = \begin{bmatrix} 3/5 & -1/5 \\ -1/5 & 2/5 \end{bmatrix} \begin{bmatrix} 2 \\ 9 \end{bmatrix} = \begin{bmatrix} -3/5 \\ 16/5 \end{bmatrix}$$

$\bar{b}_1 = -3/5 < 0$ ！原基不可行，但检验数仍 ≤ 0 ——恰好用对偶单纯形法：

基	x_1	x_2	x_3	x_4	b
x_2	0	1	$3/5$	$-1/5$	$-3/5$
x_1	1	0	$-1/5$	$2/5$	$16/5$
σ_j	0	0	$-7/5$	$-1/5$	—

x_2 离基 ($b_1 = -3/5$ 唯一负)。第 1 行负系数仅 $x_4(-1/5)$, $\theta_4 = (1/5)/(1/5) = 1$, x_4 进基。转轴后:

基	x_1	x_2	x_3	x_4	b
x_4	0	-5	-3	1	3
x_1	1	2	1	0	2
σ_j	0	-1	-2	0	—

新最优解 $x^* = (2, 0, 0, 3)^T$, $z^* = -4$ (利润 4)。原料 A 锐减后, 产品乙停产, 只剩产品甲 $x_1 = 2$ 。

4.7 真题：第一题 (3)——非基变量 c 变化

【2025 真题 · 第一题 (3)】 第一题求得最优解 $x^* = (0, 11/3, 7/3)^T$ (见第 2 章表 2.3) 后, 若 c_1 由 2 改为 0, 原最优解是否仍为最优解?

在表 2.3 中, x_1 是非基变量 (取值为 0), 其当前检验数 $\sigma_1 = -7/3$ (见第 2 章最优表的末行首列)。这

是典型的”情况一”——非基变量的 c 变化只影响自己的检验数。

当 c_1 从 2 变为 0 时：

$$\sigma'_1 = \sigma_1 - (c'_1 - c_1) = -\frac{7}{3} - (0 - 2) = -\frac{7}{3} + 2 = -\frac{1}{3} \leq 0$$

检验数仍 ≤ 0 ，故原最优解不变。

注：此题体现了灵敏度分析的考试典型套路——不需要重跑单纯形法，只需从最优表中提取非基变量的检验数，用一步公式即可判断。

4.8 真题：第二题——新增约束 + 对偶单纯形法

【2025 真题 · 第二题】 已知某 LP 的初始和最优单纯形表如下。加入新约束 $2x_1 - x_2 + x_3 \leq 9$ 。原最优解是否满足新约束？若不满足，求新最优解。

题目给定的初始表：

基	x_1	x_2	x_3	x_4	x_5	b
x_4	2	3	1	1	0	4
x_5	5	4	3	0	1	11
$z_j - c_j$	9	8	5	0	0	0

题目给定的最优表：

基	x_1	x_2	x_3	x_4	x_5	b
x_1	1	5	0	3	-1	1
x_3	0	-7	1	-5	2	2
$z_j - c_j$	0	-2	0	-2	-1	-19

原最优解： $x^* = (1, 0, 2, 0, 0)^T$ ， $z^* = 19$ （注意：题目检验数行末是 -19 ，故 $z^* = 19$ ）。

第一步：检查新约束。将 x^* 代入 $2x_1 - x_2 + x_3 \leq 9$ ：

$$2 \cdot 1 - 0 + 2 = 4 \leq 9 \quad \checkmark$$

验证结果 $4 \leq 9$ ，满足新约束，最优解不变。本题按此逻辑到此即止。

以下为标准示范：为演示新增约束 + 对偶单纯形法的完整流程，对约束参数作了调整以使原最优解不满足（原题答案为“满足，不变”）。读者应关注方法步骤本身。

标准示范——假设不满足新约束：

引入松弛变量 $x_6 \geq 0$ ，新约束化为 $2x_1 - x_2 + x_3 + x_6 = 9$ 。将新行添入最优表，利用 x_1 行和 x_3 行消去新行中基变量的系数。 x_1 行系数为 $(1, 5, 0, 3, -1, 0 \mid 1)$ ，

x_3 行系数为 $(0, -7, 1, -5, 2, 0 \mid 2)$ 。新行 = 新约束系数 $-2 \cdot (\text{行}x_1) - 1 \cdot (\text{行}x_3)$ ，计算得：

基	x_1	x_2	x_3	x_4	x_5	x_6	b
x_1	1	5	0	3	-1	0	1
x_3	0	-7	1	-5	2	0	2
x_6	0	-2	0	5	-2	1	-1
$z_j - c_j$	0	-2	0	-2	-1	0	-19

所有检验数 ≤ 0 （对偶可行），但 $b_3 = -1 < 0$ （原始不可行）。对偶单纯形法：

离基： $b_3 = -1$ 唯一负值， x_6 离基（第 3 行）。

进基： 第 3 行负系数有 $x_2(-2)$ 、 $x_5(-2)$ 。

$\theta_{x_2} = |-2|/|-2| = 1$ ， $\theta_{x_5} = |-1|/|-2| = 0.5$ 。

$\min = 0.5$ ， x_5 进基。主元 = -2。

转轴后得：

基	x_1	x_2	x_3	x_4	x_5	x_6	b
x_1	1	6	0	1/2	0	-1/2	3/2
x_3	0	-9	1	0	0	1	1
x_5	0	1	0	-5/2	1	-1/2	1/2
$z_j - c_j$	0	-1	0	-9/2	0	-1/2	-37/2

所有 $b_i \geq 0$ ，所有检验数 ≤ 0 ，达到最优。新最优解：

$$x^* = \left(\frac{3}{2}, 0, 1, 0, \frac{1}{2}, 0 \right)^T, \quad z^* = \frac{37}{2} = 18.5$$

本章速查

- 对偶单纯形法：保持 $\sigma \leq 0$ ，消除 $b < 0$ 。先选最负 b 离基 $\rightarrow$ 在负系数行上 $\min |\sigma|/|a|$ 选进基
- 与原始单纯形对称：进基/离基顺序互换，比值方向互换（列 $\leftrightarrow$ 行）
- 非基变量 c 变： $\sigma'_j = \sigma_j - (c'_j - c_j)$ ，只改一个检验数
- 基变量 c 变： c_B 变了，所有非基 σ 须重算，目标值也变
- b 变： $\bar{b}' = B^{-1}b'$ 。若 $\geq 0 \rightarrow$ 基不变；若有负 $\rightarrow$ 对偶单纯形法恢复
- 新增约束：代入检查 $\rightarrow$ 不满足则添行消去基变量 $\rightarrow$ 对偶单纯形法
- 新增变量：算 $B^{-1}a_{n+1}$ 和 σ_{n+1} ， ≤ 0 则不变

第二部分：非线性规划（50 分）

第 5 章 凸集与凸函数

5.1 为什么非线性规划需要凸性

线性规划天然就是“好的”——可行域是凸多面体，局部最优就是全局最优，单纯形法保证找到全局最优解。但到了非线性规划，目标函数与可行域都可能非凸，局部最优不再自动等于全局最优。

凸性（convexity）是判断“局部 $\Rightarrow$ 全局”是否成立的关键条件。本章构成非线性规划的理论基础，直接服务于第 6 章（凸规划下 KKT 条件变为充要条件）和第 8 章（共轭梯度法/拟牛顿法的收敛性分析依赖凸性假设）。

核心逻辑链：凸集 $\rightarrow$ 凸函数 $\rightarrow$ 凸规划 $\rightarrow$ 局部极小 = 全局极小 $\rightarrow$ KKT 条件充要。

考试定位：25 年章末未直接出大题，但凸性判别嵌入于非线性规划的各类问题中。判定 Hessian 正定是第 8 章（Newton 法/拟 Newton 法）的必备步骤。此外，判断一个问题是否为凸规划，直接影响 KKT 点（将在第 6 章详述）是局部最优还是全局最优的结论。

5.2 凸集

定义 5.1（凸集）

集合 $C \subseteq \mathbb{R}^n$ 称为凸集，如果对任意 $x, y \in C$ 和任意 $\lambda \in [0, 1]$ ，有：

$$\lambda x + (1 - \lambda)y \in C$$

几何意义：连接 C 内任意两点的线段，整个都在 C 内。” 实心、无洞、无凹坑”。

PPT 第 3.1 页给出凸集的形式定义；PPT 第 3.2 页

介绍仿射集（比凸集更强——要求过任意两点的整条直线在集合内，而非仅线段）。仿射集 $\subseteq$ 凸集，线性方程组 $Ax = b$ 的解集是典型的仿射集。

3.1


1 凸集

•1. 1 凸集与锥

定义1 设 S 为 n 维欧氏空间 R^n 中的一个集合。若对任意两点 $x^{(1)}, x^{(2)} \in S$ 及每个实数 $\lambda \in [0,1]$,有

$$\lambda x^{(1)} + (1-\lambda)x^{(2)} \in S$$

则称 S 为**凸集**。 $\lambda x^{(1)} + (1-\lambda)x^{(2)}$ 称为 $x^{(1)}$ 和 $x^{(2)}$ 的**凸组合**。



- **定义2 仿射集**: 如果过集合C中的任意两点的直线都在C内, 则称C为**仿射集**, 即

$$x_1, x_2 \in C \implies x_1 + (1 - \lambda)x_2 \in C; \quad \lambda \in \mathbb{R}$$

- 线性方程组 $Ax = b$ 的解集X是仿射集, 反之, **任何仿射集均可表示为某一线性方程组的解集**.
- 仿射集显然是凸集。

例 1 (凸集正例, 带验证):

- 多面体 $C = \{x \mid Ax \leq b\}$ 。取任意 $x, y \in C$, 有 $Ax \leq b, Ay \leq b$ 。则

$$\begin{aligned} A(\lambda x + (1 - \lambda)y) &= \lambda Ax + (1 - \lambda)Ay \\ &\leq \lambda b + (1 - \lambda)b = b \end{aligned}$$

故 $\lambda x + (1 - \lambda)y \in C$ 。✓ 凸。LP 可行域 $\{x \mid Ax = b, x \geq 0\}$ 是它的特例。

- 单位圆盘 $C = \{(x_1, x_2) \mid x_1^2 + x_2^2 \leq 1\}$ 。由 ℓ_2 范

数的三角不等式：

$$\begin{aligned}\|\lambda x + (1 - \lambda)y\|_2 &\leq \lambda\|x\|_2 + (1 - \lambda)\|y\|_2 \\ &\leq \lambda \cdot 1 + (1 - \lambda) \cdot 1 = 1\end{aligned}$$


✓ 凸。

- **半空间** $C = \{x \mid a^T x \leq b\}$ 。线性不等式定义的区域，是多面体的基本构件。✓ 凸。


例 2（凸集反例——为什么不是凸）：

- **圆环** $C = \{(x_1, x_2) \mid 1 \leq x_1^2 + x_2^2 \leq 4\}$ 。取 $x = (1, 0)$, $y = (-1, 0)$, 中点 $z = (0, 0)$, 则 $\|z\|_2 = 0 < 1$, 不在环内。非凸！原因：中间有“洞”。
- **坐标轴十字** $C = \{(x_1, x_2) \mid x_1 x_2 = 0, x_1 \geq 0, x_2 \geq 0\}$ 。取 $(1, 0)$ 和 $(0, 1)$, 中点 $(0.5, 0.5)$ 不在坐标轴上 ($0.5 \cdot 0.5 \neq 0$)。非凸！原因：形状不实心。
- **整数点集** $C = \mathbb{Z}^n$ 。取 0 和 1, 中点 $0.5 \notin \mathbb{Z}$ 。非凸！原因：离散不连通。


直观判断法：脑子里想象集合形状——”实心无洞无凹坑”就是凸。圆盘、多面体、半空间是凸；甜甜圈（有洞）、月牙（有凹）、离散点集（不连通）不是凸。




凸集：实心圆盘



非凸：圆环（有洞）



非凸：月牙形（有凹坑）



非凸：十字形（不实心）

图 5.1：凸集与非

凸集示例

定义 5.2（凸组合与凸包）

点 $x_1, \dots, x_k$ 的凸组合： $\sum_{i=1}^k \lambda_i x_i$ ，其中 $\lambda_i \geq 0$ ， $\sum \lambda_i = 1$ 。

集合 S 的凸包 $\text{conv}(S)$ ：包含 S 的最小凸集，等于 S 中所有点的所有凸组合的集合。

PPT 第 3.3 页用图形展示凸包的构造过程：两点凸组合 = 线段；三点凸组合 = 三角形区域（含内部）。凸包就是把离散点集”填满”成包含它们的最小凸集。

1 凸集

3.3

例1 超平面 $H = \{x \mid p^T x = \alpha\}$ 为凸集，其中 p 为 n 维列向量， α 为实数。此外，下面相对于法向量 p 的半空间都是凸集：

正的闭半空间 $H^+ = \{x \mid p^T x \geq \alpha\}$

负的闭半空间 $H^- = \{x \mid p^T x \leq \alpha\}$

正的开半空间 $\overset{\circ}{H}^+ = \{x \mid p^T x > \alpha\}$

负的开半空间 $\overset{\circ}{H}^- = \{x \mid p^T x < \alpha\}$

例 3： $S = \{(0,0), (1,0), (0,1)\}$ ，则 $\text{conv}(S)$ 是以此三点为顶点的直角三角形（含内部），即 $\{(x_1, x_2) \mid x_1 + x_2 \leq 1, x_1 \geq 0, x_2 \geq 0\}$ 。

定义 5.3 (多面体)

多面体 (polyhedral set) 是有限个闭半空间的交: $\{x \mid Ax \leq b\}$ 。LP 的可行域 $\{x \mid Ax = b, x \geq 0\}$ 也是多面体—— $Ax = b$ 等价于 $Ax \leq b$ 且 $-Ax \leq -b$, $x \geq 0$ 等价于 $-x_i \leq 0$ 。

PPT 第 3.4 页验证了凸集的常见例子 (半空间、超平面、多面体、球等); PPT 第 3.5 页展示多面体的几何定义——有限个半空间的交集形成凸多面体。

1 凸集

3.4

运用定义不难验证如下命题:

命题1 设 S_1 和 S_2 为 $\mathbb{R}^n$ 中两个凸集, β 是实数, 则

1, $\beta S_1 = \{\beta x \mid x \in S_1\}$ 为凸集。

2, $S_1 \cap S_2$ 为凸集

3, $S_1 + S_2 = \{x^{(1)} + x^{(2)} \mid x^{(1)} \in S_1, x^{(2)} \in S_2\}$ 为凸集

4, $S_1 - S_2 = \{x^{(1)} - x^{(2)} \mid x^{(1)} \in S_1, x^{(2)} \in S_2\}$ 为凸集

定义4 集合 $T \subset \mathbb{R}^n$ 的 **凸包** 是指所有包含 T 的凸集的交集, 记为 $\text{conv } T = \bigcap_{C \supseteq T} C$, C 为凸集。

1 凸集



定义5 有限点集 $\{x^0, x^1, \dots, x^m\} \subset R^n$ 的凸包称为**多胞形 (polytope)**。

若 $\{x^0, x^1, \dots, x^m\}$ 仿射无关时，对应的凸包称为 **m 维单纯形**。

向量 x^i 称为该单纯形的**顶点**。

多面体 (polyhedral set)是有限个闭半空间的交。

(可表示为 $\{x | Ax \leq b\}$).



定义 5.4 (极点)

凸集 C 中的点 x 称为**极点 (extreme point)**，如果它不能表示为 C 中两个不同点的严格凸组合。
即：


$$x = \lambda y + (1 - \lambda)z, \quad \lambda \in (0, 1), \quad y, z \in C$$

$$\implies x = y = z$$

极点是凸集的”角”——LP 的基可行解 (BFS) 就是可行域多面体的极点。

1 凸集

定义7 非空凸集中的点 x 称为**极点**,若 $x = \lambda x_1 + (1-\lambda)x_2$, $\lambda \in (0,1)$, $x_1, x_2 \in S$, 则 $x = x_1 = x_2$. 换言之, x 不能表示成 S 中两个不同点的凸组合.



由上面的例子可知:

任何有界闭凸集中任一点都可表成极点的凸组合.

例 4 (极点的几何直觉):

- 三角形区域的极点 = 三个顶点
- 正方形/长方体的极点 = 四个/八个顶点
- 圆盘 $\{x \mid \|x\|_2 \leq 1\}$ 的极点 = 整个圆周 (无穷多个极点!)
- LP 可行域 $\{x \mid Ax = b, x \geq 0\}$ 的极点 = 基可行解 (BFS)

极点与单纯形法的关系：LP 的最优解一定能在极点（BFS）处取得。单纯形法就是在极点之间移动，每次迭代从一个 BFS 跳到目标函数值更优的相邻 BFS。这是第 2 章单纯形法的理论基础。




图 5.3：极点示意图——多边形顶点为极点，内部点 x 可表为两个极点的凸组合

定理 5.1 (表示定理, 选读)

设多面体 $P = \{x \mid Ax \leq b\} \neq \emptyset$ 且 $\text{rank}(A) = n$ 。
 记 P 的极点集为 $\{x^k\}_{k \in K}$ (非空有限), 极方向集
 为 $\{d^j\}_{j \in J}$ (J 可为空)。则:

$$x \in P \iff x = \sum_{k \in K} \lambda_k x^k + \sum_{j \in J} \mu_j d^j$$

其中 $\lambda_k \geq 0$, $\sum \lambda_k = 1$, $\mu_j \geq 0$ 。此外, $J = \emptyset \iff P$ 有界 (称为多胞形)。

PPT 第 3.8 页: 表示定理。 PPT 第 3.9 页: BFS 存在推论。

1 凸集

3.8

定理 4 (表示定理) 若多面体 $P = \{x \in \mathbb{R}^n \mid Ax \leq b\}$, $\text{rank}(A) = n$, 则:


- (1) P 的极点集是非空的有限集合, 记为 $\{x^k : k \in K\}$
- (2) 记 P 的极方向集为 $\{d^j : j \in J\}$, 约定 P 不存在极方向时 $J = \emptyset$, 则有

$$P = \left\{ x \in \mathbb{R}^n \mid \begin{array}{l} x = \sum_{k \in K} \lambda_k x^k + \sum_{j \in J} \mu_j d^j \\ \sum_{k \in K} \lambda_k = 1, \lambda_k \geq 0, k \in K, \mu_j \geq 0, j \in J \end{array} \right\}$$

即: $x \in P$ 当且仅当 x 可以表为 $x_1, \dots, x_k$ 的凸组合和 $d_1, \dots, d_l$ 的非负线性组合。

- (3) 指标集 J 是空集当且仅当 P 是有界集合, 即多胞形。

推论1 若多面体 $S=\{x|Ax=b, x\geq 0\}$ 非空,则 S 必有极点.



考试定位：表示定理属选读内容，25 年未直接出题。核心记住推论——标准形 LP 可行域非空则 BFS 存在，单纯形法完备。

5.3 凸函数

定义 5.5 (凸函数)

设 $C \subseteq \mathbb{R}^n$ 为非空凸集, $f: C \rightarrow \mathbb{R}$ 。 f 称为凸函数, 若 $\forall x, y \in C, \lambda \in (0, 1)$:

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$$

若 $x \neq y$ 时严格不等式成立, 称为严格凸。若 $-f$ 是凸函数, 则 f 为凹函数; 若 $-f$ 是严格凸函数, 则 f 为严格凹函数。

PPT 第 3.10 页: 凸函数定义与几何图示。

1 凸集

□ 双曲锥

$$\{x | x^T P x \leq (c^T x)^2, c^T x \geq 0, P \in \mathcal{S}_+^n\}$$

□ 是凸集。

□ **透视变换的保凸性**：设集合 $\{(x, t) | x \in \mathbb{R}^n, t > 0\}$ 是凸集，其透视变换所得的集合为 $\{x/t | x \in \mathbb{R}^n, t > 0\}$ 。这个集合也是凸集。

□ **分式线性变换的保凸性**：若集合 $X = \{x | x \in \mathbb{R}^n\}$ 是凸集，则其分式线性变换所得的集合 $f(X) = \{(Ax + b)/(c^T x + d) | x \in \mathbb{R}^n, A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m, c \in \mathbb{R}^n, d \in \mathbb{R}, c^T x + d > 0\}$ 是凸集

几何解释（弦在曲线上方）：任取定义域内两点 x, y ，连接 $(x, f(x))$ 与 $(y, f(y))$ 的直线段 整个在函数图像上方。凹函数则反过来——弦在图像下方。仿射函数 $(a^T x + b)$ 两边都等号，既凸又凹。




图 5.2: 凸函数的几何解释

(弦在曲线上方)

例 5 (常见凸函数速查):

函数	定义域	凸性
$a^T x + b$ (仿射)	$\mathbb{R}^n$	既凸又凹
x^2	$\mathbb{R}$	严格凸
e^{ax}	$\mathbb{R}$	凸
$ x $	$\mathbb{R}$	凸 ($x = 0$ 不可微, 但仍凸!)
$x \ln x$	$(0, \infty)$	凸 (负熵)
$\ x\ $ (任意范数)	$\mathbb{R}^n$	凸 (三角不等式 + 齐次性)
$x_1^2 + x_2^2$	$\mathbb{R}^2$	严格凸
$x_1^2 - x_2^2$	$\mathbb{R}^2$	非凸非凹 (鞍面)
x^3	$\mathbb{R}$	非凸非凹 ($x > 0$ 凸, $x < 0$ 凹)

5.4 凸函数的判别方法

判断一个函数是否凸，有三层递进方法。三者的因果关系是逐步增加可微性假设，以此换取更强的计算可操作性：

方法 I：定义法（无需可微假设，适合理论证明与简单函数）



加上 f 一阶可微

方法 II：一阶条件/梯度不等式（适合理论推导，但仍需“ $\forall x, y$ ”）



加上 f 二阶可微

方法 III：二阶条件/Hessian 半正定（最适合具体计算——顺序主子式法系统可操作）

为什么二阶判别最实用？定义法须证不等式对任意两点成立；一阶条件虽简化了形式，仍需在“所有 $x, y \in S$ ”上验证。二阶条件将凸性判定转化为矩阵半正定性的代数判定——计算 Hessian 矩阵，检查顺序主子式。对给定的具体函数，只需微积分 + 初等代数，无需处理全称量词。这是考试中最常用的判别手段。

方法 5.1 (判别法一：定义法)

直接验证 $f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$ 。
无需可微性，仅适用于简单函数或理论证明。

例 6 (定义法验证 x^2 凸): $f(x) = x^2$ 。

$$\begin{aligned} & f(\lambda x + (1 - \lambda)y) - [\lambda f(x) + (1 - \lambda)f(y)] \\ &= (\lambda x + (1 - \lambda)y)^2 - \lambda x^2 - (1 - \lambda)y^2 \\ &= \lambda^2 x^2 + 2\lambda(1 - \lambda)xy + (1 - \lambda)^2 y^2 \\ &\quad - \lambda x^2 - (1 - \lambda)y^2 \\ &= -\lambda(1 - \lambda)(x^2 - 2xy + y^2) \\ &= -\lambda(1 - \lambda)(x - y)^2 \leq 0 \quad \checkmark \end{aligned}$$

例 7 (定义法验证范数凸): $f(x) = \|x\|$ (不可微，只能用定义法)。

$$\begin{aligned} \|\lambda x + (1 - \lambda)y\| &\leq \|\lambda x\| + \|(1 - \lambda)y\| \\ &= \lambda\|x\| + (1 - \lambda)\|y\| \quad \checkmark \end{aligned}$$

关键是三角不等式和范数的齐次性。

方法 5.2 (判别法二：一阶条件/梯度不等式)

设 f 在开凸集 S 上可微。则：

$$f \text{ 凸} \iff f(y) \geq f(x) + \nabla f(x)^T(y - x), \\ \forall x, y \in S$$

几何含义：函数图像在任意点处的切线（一阶 Taylor 展开）始终在函数图像下方。

（严格凸对应的不等号为严格 $>$ ， $\forall x \neq y$ 。）

PPT 第 3.12 页（定理 7）：可微凸函数 $\Leftrightarrow$ 一阶梯度不等式。

2 凸函数

3.12

凸函数的判别

定理7. 设 S 是 $\mathbb{R}^n$ 中的非空开凸集, $f(x): S \rightarrow \mathbb{R}$ 是可微的函数 则 $f(x)$ 是凸函数当且仅当对任意的 $x^* \in S$, 我们有

$$f(x) \geq f(x^*) + \nabla f(x^*)^T (x - x^*), \text{ 任意 } x \in S.$$

类似的, $f(x)$ 严格凸当且仅当对每一 $x^* \in S$,

$$f(x) > f(x^*) + \nabla f(x^*)^T (x - x^*), \text{ 任意 } x \in S.$$

证明:(1)必要性: 设 f 是凸函数, 于是对 $\forall \alpha, 0 \leq \alpha \leq 1$, 有

$$f(\alpha y + (1 - \alpha)x) \leq \alpha f(y) + (1 - \alpha)f(x)$$

因此, 对 $0 < \alpha \leq 1$,

$$\frac{f(x + \alpha(y - x)) - f(x)}{\alpha} \leq f(y) - f(x)$$

例 8 (一阶条件验证 e^x 凸): $\nabla f(x) = e^x$ 。需证 $e^y \geq e^x + e^x(y - x)$, 即 $e^{y-x} \geq 1 + (y - x)$ 。令 $t = y - x$, 需证 $e^t \geq 1 + t$ ($\forall t \in \mathbb{R}$)。这是指数函数的基本不等式, 由 e^t 的凸性可知成立。✓

方法 5.3 (判别法三: 二阶条件/Hessian 半正定)

★ 考试最常用

设 f 在开凸集 S 上二次可微。则:

$$f \text{ 凸} \iff \nabla^2 f(x) \succeq 0, \quad \forall x \in S$$

($\nabla^2 f(x) \succ 0$ 对所有 x 成立 $\implies f$ 严格凸, 但反过来不成立!)

对于二次函数 $f(x) = \frac{1}{2}x^T Qx + c^T x$: $\nabla^2 f(x) \equiv Q$ (常数矩阵), $f \text{ 凸} \iff Q \succeq 0$ 。

PPT 第 3.13 页 (定理 9): C^2 函数凸 $\Leftrightarrow$ Hessian 半正定; 严格凸 $\Leftarrow$ Hessian 正定。

定理 9 设 S 是 $\mathbf{R}^n$ 上的非空开凸集, $f(\mathbf{x})$ 为 S 到 $\mathbf{R}$ 上的二次可微函数. 则(1) $f(\mathbf{x})$ 是凸函数当且仅当 S 上每一点的 Hessian 矩阵是半正定的.

(2) $f(\mathbf{x})$ 是严格凸函数当且仅当 S 上每一点的 Hessian 矩阵是正定的.

顺序主子式法——Hessian 正/半正定的代数判据

对 $n \times n$ 实对称矩阵 H : (考试常见 $n = 2$)

- $H \succ 0$ (正定) $\iff$ 所有顺序主子式 > 0
- $H \succeq 0$ (半正定) 的判断需额外小心: 顺序主子式 ≥ 0 是必要条件但不充分。但对常见的 2×2 情形: $\Delta_1 \geq 0, \Delta_2 \geq 0$ 可结合矩阵结构判断。
- 2×2 矩阵快速判据: $H = \begin{pmatrix} a & b \\ b & c \end{pmatrix}$ 。 $H \succ 0 \iff a > 0, ac - b^2 > 0$ 。 $H \succeq 0 \iff a \geq 0, c \geq 0, ac - b^2 \geq 0$ 。

例 9 (Hessian 法练习——四种典型情形):

(a) 正定 (严格凸): $f(x_1, x_2) = 2x_1^2 + 3x_2^2$ 。

$$\nabla f = \begin{pmatrix} 4x_1 \\ 6x_2 \end{pmatrix}, \quad \nabla^2 f = \begin{pmatrix} 4 & 0 \\ 0 & 6 \end{pmatrix}$$

$\Delta_1 = 4 > 0, \Delta_2 = 24 > 0$ 。 $\nabla^2 f \succ 0 \Rightarrow f$ 严格凸。

(b) 正定 (严格凸, 带交叉项): $f(x_1, x_2) = x_1^2 + 2x_1x_2 + 3x_2^2$ 。

$$\nabla^2 f = \begin{pmatrix} 2 & 2 \\ 2 & 6 \end{pmatrix}$$

$\Delta_1 = 2 > 0$, $\Delta_2 = 2 \cdot 6 - 2 \cdot 2 = 8 > 0$ 。 $\nabla^2 f \succ 0 \Rightarrow$ 严格凸。

(c) 半正定 (凸但不严格凸): $f(x_1, x_2) = x_1^2 + 4x_1x_2 + 4x_2^2 = (x_1 + 2x_2)^2$ 。

$$\nabla^2 f = \begin{pmatrix} 2 & 4 \\ 4 & 8 \end{pmatrix}$$

$\Delta_1 = 2 > 0$, $\Delta_2 = 2 \cdot 8 - 4 \cdot 4 = 0$ 。 $\nabla^2 f \succeq 0$ 但非正定 $\Rightarrow f$ 凸但不严格凸。函数沿方向 $d = (-2, 1)^T$ 恒为零——在该方向上“平坦”。

(d) 不定 (非凸非凹): $f(x_1, x_2) = x_1^2 - 2x_1x_2 + \frac{1}{2}x_2^2$ 。

$$\nabla^2 f = \begin{pmatrix} 2 & -2 \\ -2 & 1 \end{pmatrix}$$

$\Delta_1 = 2 > 0$, $\Delta_2 = 2 \cdot 1 - (-2)^2 = -2 < 0$ 。 $\nabla^2 f$ 不定 $\Rightarrow f$ 非凸非凹 (鞍面)。

严格凸 $\neq$ Hessian 处处正定（重要陷阱！）

$\nabla^2 f \succ 0$ （处处正定）是严格凸的充分但不必要条件。反例： $f(x) = x^4$ （ $\mathbb{R}$ 上）， $f''(x) = 12x^2 \geq 0$ ， $f''(0) = 0$ （非正定），但 f 仍为严格凸函数。考试中若 Hessian 处处正定则直接下结论“严格凸”；若 Hessian 半正定但非正定，仍需结合其他方法确认是否严格凸。

5.5 凸规划

定义 5.6（凸规划）

最优化问题 $\min\{f(x) \mid x \in S\}$ 称为凸规划，如果：

- 可行域 S 是凸集
- 目标函数 f 是凸函数（对 min 问题；对 max 则要求 f 凹）

两个条件缺一不可。

定理 5.2（凸规划的核心性质）

对于凸规划 $\min\{f(x) \mid x \in S\}$:

1. 任意局部极小点都是全局极小点
2. 若 f 严格凸，则全局极小点唯一
3. 上述结论不需要任何约束规格——仅需 f 凸且 S 凸
4. 若约束规格成立，KKT 条件（将在第 6 章详细介绍）升级为全局最优性的充要条件
5. 全局极小点的集合是凸集

PPT 第 3.14 页（定理 6）：凸函数在凸集上的局部极小即全局极小，极小点集为凸集。

定理6 设 $S \subset \mathbb{R}^n$ 为一非空凸集, f 是定义在 S 上的凸函数, 则 f 在 S 上的局部极小点是整体极小点, 且极小点的集合为凸集。

证明: 设 $\bar{x}$ 是 f 在 S 上的局部极小点, 则存在 $\bar{x}$ 的 ε 邻域 $N_\varepsilon(\bar{x}) = \{x \mid \|x - \bar{x}\| < \varepsilon, \varepsilon > 0\}$, 使得对每个 $x \in S \cap N_\varepsilon(\bar{x})$, 成立 $f(x) \geq f(\bar{x})$

这为什么重要? 第 6 章的 KKT 条件只是一阶必要条件——满足 KKT 的点不一定是全局最优。但一旦确认问题是凸规划, KKT 点自动升级为全局最优解。这是连接第 5 章(凸性)和第 6 章(KKT)的关键桥梁。

判定流程: 目标函数凸? $\checkmark$ 可行域凸? $\checkmark \Rightarrow$ 凸规划 $\Rightarrow$ KKT 点 = 全局最优解。

5.6 凸函数的保凸运算

记住以下运算规则，可在不计算 Hessian 的情况下快速判断组合函数的凸性：

运算	条件与结论
非负加权和	f, g 凸, $\alpha, \beta \geq 0 \Rightarrow \alpha f + \beta g$ 凸
与仿射复合	f 凸 $\Rightarrow f(Ax + b)$ 凸
逐点最大值	$f_1, \dots, f_m$ 凸 $\Rightarrow \max_i f_i(x)$ 凸
逐点上确界	$\forall y \in A, f(\cdot, y)$ 凸 $\Rightarrow \sup_{y \in A} f(x, y)$ 凸
标量复合 (1)	g 凸, h 凸且单调不减 $\Rightarrow h(g(x))$ 凸
标量复合 (2)	g 凹, h 凸且单调不增 $\Rightarrow h(g(x))$ 凸

实战技巧：看到 $\max$ 结构立刻想到保凸运算。例如 $f(x) = \max\{x_1^2 + x_2^2, 2x_1 + 3x_2\}$ —— $x_1^2 + x_2^2$ 凸 ($\nabla^2 f \succ 0$)， $2x_1 + 3x_2$ 凸（仿射），逐点最大值保凸 $\Rightarrow f$ 凸。无需算 Hessian！

5.7 自编教学例题

题 1：凸集判定

判定以下集合是否为凸集，并简述理由：

- (1) $S_1 = \{(x_1, x_2) \mid x_1^2 + x_2^2 \leq 4, x_1 \geq 0\}$ (右半圆盘)
(2) $S_2 = \{(x_1, x_2) \mid |x_1| + |x_2| \leq 1\}$ (ℓ_1 范数球/菱形)
(3) $S_3 = \{(x_1, x_2) \mid x_1^2 - x_2 \leq 0\}$ (抛物线 $x_2 = x_1^2$ 的上方区域)

解:

- (1) 右半圆盘 = 圆盘 $\cap$ 右半平面。两个凸集的交是凸集 (凸集的性质)。✓ 凸。
(2) ℓ_1 范数球 = $\{x \mid \|x\|_1 \leq 1\}$ 。范数是凸函数, 凸函数的下水平集是凸集。几何上是以 $(\pm 1, 0), (0, \pm 1)$ 为顶点的菱形。✓ 凸。
(3) $S_3 = \{x \mid x_2 \geq x_1^2\}$ 。 $g(x) = x_1^2 - x_2$ 是凸函数 ($\nabla^2 g = \text{diag}(2, 0) \succeq 0$)。凸函数的下水平集是凸集。✓ 凸。几何上: 抛物线将平面分成”内部”(凹)和”外部”(凸), S_3 是外部区域。

题 2: 凸函数判定 (Hessian 法 + 顺序主子式)

判定以下二元函数的凸性:

- (1) $f(x_1, x_2) = 3x_1^2 + 2x_2^2 + 2x_1x_2$
(2) $f(x_1, x_2) = x_1^2 + x_2^4$
(3) $f(x_1, x_2) = -x_1^2 - 2x_2^2$ (注意负号!)

解：

$$(1) \nabla^2 f = \begin{pmatrix} 6 & 2 \\ 2 & 4 \end{pmatrix}. \Delta_1 = 6 > 0, \Delta_2 = 6 \cdot 4 - 2 \cdot 2 = 20 > 0. \nabla^2 f \succ 0 \Rightarrow \text{严格凸}.$$

$$(2) \nabla^2 f = \begin{pmatrix} 2 & 0 \\ 0 & 12x_2^2 \end{pmatrix}. \Delta_1 = 2 > 0, \Delta_2 = 24x_2^2 \geq 0$$

(对任意 x)。 $\nabla^2 f \succeq 0$ 恒成立 $\Rightarrow f$ 凸。注意 $x_2 = 0$ 处 Hessian 仅为半正定（非正定），但 f 实际上仍是严格凸——这再次说明 Hessian 正定只是严格凸的充分条件。

$$(3) \nabla^2 f = \begin{pmatrix} -2 & 0 \\ 0 & -4 \end{pmatrix}. \Delta_1 = -2 < 0, \Delta_2 = 8 > 0.$$

$\nabla^2 f \prec 0$ （负定） $\Rightarrow -f$ 严格凸 $\Rightarrow f$ 严格凹。

题 3：凸规划实例——局部 = 全局的威力

考虑问题：

$$\begin{aligned} \min f(x_1, x_2) &= x_1^2 + x_2^2 \quad \text{s.t.} \quad x_1 + x_2 \geq 1, \\ & \quad x_1 \geq 0, \quad x_2 \geq 0 \end{aligned}$$

(1) 验证这是凸规划。 (2) 求出全局最优解。

解：

(1) 可行域 $S = \{x \mid x_1 + x_2 \geq 1, x_1 \geq 0, x_2 \geq 0\}$ 是三个半空间的交 $\Rightarrow$ 多面体, 凸。目标函数 $\nabla^2 f = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} \succ 0 \Rightarrow$ 严格凸。 $\therefore$ 这是凸规划 (且 f 严格凸, 解唯一)。

(2) 几何解释: 原点 $(0,0)$ 不可行 ($0+0 \not\geq 1$)。全局最优解是可行域中离原点最近的点——即原点在半空间 $x_1 + x_2 \geq 1$ (正象限内) 的投影。由对称性 $x_1 = x_2$, 结合 $x_1 + x_2 = 1$ 得 $x_1^* = x_2^* = \frac{1}{2}$ 。 $f(x^*) = \frac{1}{2}$ 。KKT 验证 (凸规划下 KKT 充要): 构造 Lagrange 函数 $L = x_1^2 + x_2^2 + \lambda(1 - x_1 - x_2) - \mu_1 x_1 - \mu_2 x_2$ 。

$$\begin{aligned}\frac{\partial L}{\partial x_1} &= 2x_1 - \lambda - \mu_1 = 0 \\ \frac{\partial L}{\partial x_2} &= 2x_2 - \lambda - \mu_2 = 0\end{aligned}$$

互补松弛: $\lambda(1 - x_1 - x_2) = 0, \mu_1 x_1 = 0, \mu_2 x_2 = 0$ 。最优处 $x_1 > 0, x_2 > 0 \Rightarrow \mu_1 = \mu_2 = 0$ 。约束 $x_1 + x_2 \geq 1$ 在最优处积极 $\Rightarrow x_1 + x_2 = 1$ 。代入得 $2x_1 = \lambda = 2x_2 \Rightarrow x_1 = x_2 = \frac{1}{2}, \lambda = 1$ 。因为是凸规划, 此 KKT 点即全局最优。

题 4：从第 6 章真题提取凸性片段

25 年真题第六题：

$$\min x_1^2 + x_2^2, \quad \text{s.t. } (x_1 - 1)^3 - x_2^2 = 0$$

先看目标函数： $f(x) = x_1^2 + x_2^2$, $\nabla^2 f = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} \succ 0$

$\Rightarrow f$ 是严格凸函数。

再看约束： $g(x) = (x_1 - 1)^3 - x_2^2 = 0$ 。考虑曲线上的两点： $x^A = (2, 1)$ ($g = 1^3 - 1 = 0$) 和 $x^B = (2, -1)$ ($g = 1^3 - 1 = 0$)。中点 $x^M = (2, 0)$, $g(x^M) = 1^3 - 0 = 1 \neq 0$, 不在约束曲线上。约束集合非凸。

结论：目标凸 + 约束非凸 $\Rightarrow$ 不是凸规划。KKT 条件仅为必要条件——这正是该题有 FJ 点 $(1, 0)$ 但无 KKT 点的根本原因。凸规划判定必须两个条件同时满足，缺一不可！

判定凸规划的完整流程（考试操作步骤）

Step 1: 检查目标函数——求 Hessian、算顺序主子式，判断是否半正定/正定。

Step 2: 检查可行域——是否可写为 $\{x \mid g_i(x) \leq 0, h_j(x) = 0\}$ 形式，每个 g_i 是否凸（不等号 $\leq$ ）、每个 h_j 是否仿射（等号）。

Step 3: 两个条件都满足 $\Rightarrow$ 凸规划 $\Rightarrow$ 局部 = 全局，KKT 充要。

任一不满足 $\Rightarrow$ 非凸规划 $\Rightarrow$ KKT 仅为必要条件。

本章速查

- **凸集**：线段全在集合内。多面体（ $Ax \leq b$ ）、半空间、超平面、范数球都凸
- **凸集反例检验**：有洞（圆环）、有凹（月牙）、离散（ $\mathbb{Z}^n$ ）、不连通状
- **凸函数判别三层次**：定义法 $\rightarrow$ 一阶梯度不等式 $\rightarrow$ 二阶 Hessian 半正定

- **二阶判别最实用：**算 Hessian $\rightarrow$ 顺序主子式 $\rightarrow$ 正定/半正定/不定/负定
- **2×2 Hessian 快判：** $a > 0$, $ac - b^2 > 0$ 为正定； $ac - b^2 < 0$ 为不定
- **凸规划：**凸可行域 + 凸目标（对 min） $\Rightarrow$ 局部 = 全局，KKT 充要
- **凸规划判定：**目标凸性和可行域凸性缺一不可，必须分别验证
- **严格凸 $\Rightarrow$ 最优解唯一**（但 Hessian 正定仅仅是充分条件）
- **保凸运算：**非负加权和、与仿射复合、逐点最大值均保持凸性
- **常见凸函数：**仿射、 x^2 、 e^x 、 $|x|$ 、范数、 $x \ln x$ （负熵）
- **常见非凸/非凹：** $x_1^2 - x_2^2$ （鞍面）、 x^3 （ $\mathbb{R}$ 上）、 $\sin x$

第 6 章 最优性条件 (FJ 与 KKT)

6.1 无约束极值条件——起点

无约束优化 $\min f(x)$ 的最优性条件是我们最熟悉的出发点。PPT 第 7.3 页回顾了这三个经典结论，是一切有约束理论的基石。

7.1

7.1 无约束问题的极值条件

1, 无约束极值问题

考虑非线性规划问题

$$\min f(x), \quad x \in R^n$$

其中 $f(x)$ 是定义在 R^n 上的实值函数

——称为无约束极值问题 (UNLP)

无约束极值条件（定理 7.1.2–7.1.4）

设 f 适当光滑。

- **一阶必要条件：**若 x^* 是局部极小点且 f 在 x^* 可微，则 $\nabla f(x^*) = 0$ 。
- **二阶必要条件：**若 f 在 x^* 二次可微，则 $\nabla f(x^*) = 0$ 且 $\nabla^2 f(x^*)$ 半正定。
- **二阶充分条件：**若 $\nabla f(x^*) = 0$ 且 $\nabla^2 f(x^*)$ 正定，则 x^* 是严格局部极小点。

加上约束后，最优解可能落在约束边界上，此时 $\nabla f(x^*) \neq 0$ 是常态——梯度不需要消失，只要沿可行方向无法进一步下降即可。我们需要新工具来描述这种“受约束的静止”。

6.2 等式约束与 Lagrange 乘子法

先从最简单的情形入手：仅有等式约束。这是理解一切乘子法的入口。

定理 6.1 (Lagrange 乘子法, 等式约束)

考虑 $\min f(x)$, s.t. $h_i(x) = 0$ ($i = 1, \dots, m$)。定义 Lagrange 函数 $L(x, \mu) = f(x) + \sum_{i=1}^m \mu_i h_i(x)$ 。若 x^* 是局部极小点且 $\nabla h_i(x^*)$ 线性无关 (即 LICQ 成立), 则存在唯一的乘子 $\mu_1^*, \dots, \mu_m^*$, 使得:

$$\nabla_x L(x^*, \mu^*) = \nabla f(x^*) + \sum_{i=1}^m \mu_i^* \nabla h_i(x^*) = 0$$

几何含义: $-\nabla f(x^*)$ 落在约束法向量张成的子空间中。换句话说, 目标函数梯度在约束切空间上的投影为零——沿任何可行方向移动, 目标函数的一阶变化率都是零。




图 6.1: Lagrange 乘子法的几何解释——在约束切线上目标函数的梯度与约束梯度平行

【自编例题 1】具体数字演示 Lagrange 乘子法

例 1: $\min x_1^2 + x_2^2$, s.t. $x_1 + x_2 = 1$ 。

目标: 到原点的最小距离平方, 约束: 直线 $x_1 + x_2 = 1$ 。几何直觉: 原点至直线的垂足 $(\frac{1}{2}, \frac{1}{2})$ 应是最优解。

解 (Lagrange 乘子法): 构造 $L(x, \mu) = x_1^2 + x_2^2 + \mu(x_1 + x_2 - 1)$ 。

$$\frac{\partial L}{\partial x_1} = 2x_1 + \mu = 0 \Rightarrow x_1 = -\frac{\mu}{2}$$

$$\frac{\partial L}{\partial x_2} = 2x_2 + \mu = 0 \Rightarrow x_2 = -\frac{\mu}{2}$$

$$\frac{\partial L}{\partial \mu} = x_1 + x_2 - 1 = 0 \Rightarrow -\mu = 1 \Rightarrow \mu = -1$$

得 $x^* = (\frac{1}{2}, \frac{1}{2})^T$, $f^* = \frac{1}{2}$ 。验证与几何直觉一致。

解 (FJ 条件验证, 理解 λ_0 的角色): 这里只有一个等式约束, FJ 条件为: 存在不全为零的 $\lambda_0 \geq 0$ 和 μ ,

使得

$$\lambda_0 \begin{pmatrix} 2x_1 \\ 2x_2 \end{pmatrix} + \mu \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \quad x_1 + x_2 = 1$$

情形 $\lambda_0 = 0$: $\mu(1, 1)^T = (0, 0)^T \Rightarrow \mu = 0$, 全部乘子为零, 不满足”不全为零”的要求。此情形无解。

情形 $\lambda_0 \neq 0$: 归一化 $\lambda_0 = 1$, 得 $2x_1 + \mu = 0$, $2x_2 + \mu = 0$, $x_1 + x_2 = 1$ 。与 Lagrange 法完全一致, 得 $x^* = (\frac{1}{2}, \frac{1}{2})^T$, $\mu = -1$ 。

关键观察: 在此例中 $\lambda_0 = 0$ 的情形被”不全为零”条件排除, 因为我们只有一个等式约束且其梯度 $\nabla h = (1, 1)^T \neq 0$ (非退化)。当约束梯度非退化时, FJ 与 KKT 等价。

6.3 一般约束问题与 FJ 条件

现在加入不等式约束，考虑一般形式的约束优化问题：

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & g_i(x) \leq 0 \quad (i = 1, \dots, m) \\ & h_j(x) = 0 \quad (j = 1, \dots, p) \end{aligned}$$

PPT 第 7.17 页给出了 FJ 一阶最优性条件的形式——这是最一般、不依赖任何约束规格的必要条件。

3 一阶最优性条件

7.9

考虑约束优化 (COP)

$$\begin{aligned} \min \quad & f(x) \quad x \in E^n \\ \text{s.t.} \quad & g_i(x) \geq 0, \quad i = 1, 2, \dots, m \\ & h_j(x) = 0, \quad j = 1, 2, \dots, l \end{aligned} \quad (7.2.1)$$

记

$$g(x) = \begin{pmatrix} g_1(x) \\ g_2(x) \\ \dots \\ g_m(x) \end{pmatrix}, h(x) = \begin{pmatrix} h_1(x) \\ h_2(x) \\ \dots \\ h_l(x) \end{pmatrix}$$

(COP) 矩阵形式

$$\begin{aligned} \min \quad & f(x) \quad x \in E^n \\ \text{s.t.} \quad & g(x) \geq 0, \\ & h(x) = 0, \end{aligned} \quad (7.2.2)$$

定理 6.2 (Fritz John 条件, 1948)

设 x^* 是上述问题的局部极小点, f, g_i, h_j 在 x^* 附近连续可微。则存在不全为零的乘子 $\lambda_0, \lambda_1, \dots, \lambda_m, \mu_1, \dots, \mu_p$, 满足:

$$\lambda_0 \nabla f(x^*) + \sum_{i=1}^m \lambda_i \nabla g_i(x^*) + \sum_{j=1}^p \mu_j \nabla h_j(x^*) = 0$$

$$\lambda_i \geq 0 \quad (i = 0, 1, \dots, m)$$

$$\lambda_i g_i(x^*) = 0 \quad (i = 1, \dots, m)$$

(μ_j 无符号约束, 因为等式约束没有”方向”限制。)

为什么 λ_0 可以为零? ——FJ 条件的”软肋”

FJ 条件允许 $\lambda_0 = 0$ 是它的设计缺陷, 也是它的通用性代价。当 $\lambda_0 = 0$ 时:

$$\sum_{i=1}^m \lambda_i \nabla g_i(x^*) + \sum_{j=1}^p \mu_j \nabla h_j(x^*) = 0$$

目标函数的梯度 **完全消失**。FJ 条件退化为一组仅涉及约束梯度的线性依赖关系——它不携带任何关于 $f(x)$ 的信息。

几何情景：当某个约束的梯度在 x^* 处为零向量 ($\nabla g_i(x^*) = 0$) 时，该约束在 x^* 附近的行为是“平坦”的一阶近似失效。此时令 $\lambda_0 = 0$ 、该 $\lambda_i \neq 0$ 、其余乘子为零，FJ 方程自动成立——无论 x^* 对目标函数来说是好是坏。

一句话： FJ 条件“太松了”——在没有额外假设的情况下，它可能把一些跟目标函数毫无关系的点也标记出来。这正是引入约束规格的动机。

PPT 第 7.26 页讨论 FJ 条件中 w_0 (λ_0) 退化与约束规格的关系，是理解 CQ 动机的关键页面。

前面FJ条件中 w_0 不一定为正, 如果为0, 则不含目标函数信息, 因此对判别最优解没有作用, 为此, 我们通过增加约束规格来保证 w_0 为正, 得到著名的KKT最优性必要条件。

定理7.2.5(一阶必要条件 (Karush-Kuhn-Tucker定理): 代数特征)

设 $x^* \in S$ 是问题(7.2.1)的局部极小点, 函数 $f, g_i, (i \in I)$ 在点 x^* 处可微, $g_i, (i \notin I)$ 在点 x^* 处连续, h_j 在点 x^* 处连续可微. 若

$$\{\nabla g_i(x^*), \nabla h_j(x^*) \mid i \in I, j=1, 2, \dots, l\}$$

线性无关, 则 $\exists u_i \geq 0 (i \in I), v_j \in R (j=1, 2, \dots, l)$, 使得

$$\nabla f(x^*) = \sum_{i \in I} u_i \nabla g_i(x^*) + \sum_{j \in E} v_j \nabla h_j(x^*)$$

证明略

6.4 KKT 条件——FJ 的”补丁版”

KKT 条件在 FJ 的基础上加上约束规格, 强制 $\lambda_0 \neq 0$, 然后归一化 $\lambda_0 = 1$ 。这样目标函数的梯度永远不会被”消掉”。

PPT 第 7.19 和 7.20 页给出了 KKT 条件的矩阵形式和详细表述, 第 7.27 页展示了用 Lagrange 函数的紧凑写法。

定义集合

$$H = \{d \mid \nabla h_j(\bar{x})^T d = 0, \quad j = 1, 2, \dots, l\}$$

可证明, 当 $\nabla h_1(\bar{x}), \nabla h_2(\bar{x}), \dots, \nabla h_l(\bar{x})$ 线性无关时,
H等于等式约束

$$\begin{cases} h_1(x) = 0 \\ h_2(x) = 0 \\ \dots \\ h_l(x) = 0 \end{cases}$$

所定义的超曲面在 $\bar{x}$ 处的切平面 $T(\bar{x})$ 。

Th7.2.2 设 $\bar{x}$ 是曲面 $S = \{x \mid h(x) = 0\}$ 上一个正则点(即 $\nabla h_1(\bar{x}), \nabla h_2(\bar{x}), \dots, \nabla h_l(\bar{x})$ 线性无关), 则在点 $\bar{x}$ 切平面 $T(\bar{x})$ 等于子空间 $H = \{d \mid \nabla h(\bar{x})^T d = 0\}$.

证明略

定理 6.3 (KKT 条件, Karush–Kuhn–Tucker)

设 x^* 是局部极小点, 且 x^* 处某约束规格成立。
则存在乘子 $\lambda_i \geq 0$ (对 g_i) 和 μ_j (对 h_j), 满足:

$$1. \quad \nabla f(x^*) + \sum_{i=1}^m \lambda_i \nabla g_i(x^*) + \sum_{j=1}^p \mu_j \nabla h_j(x^*) = 0$$

$$2. \quad g_i(x^*) \leq 0, \quad h_j(x^*) = 0 \quad (\text{原始可行性})$$

$$3. \quad \lambda_i \geq 0 \quad (\text{对偶可行性})$$

$$4. \quad \lambda_i g_i(x^*) = 0 \quad (\text{互补松弛条件})$$

定义 Lagrange 函数 $L(x, \lambda, \mu) = f(x) + \sum \lambda_i g_i(x) + \sum \mu_j h_j(x)$, 则 (1) 即 $\nabla_x L = 0$,
(4) 即 $\lambda_i g_i = 0$ 。

进一步假设, g_i ($i \in I$) 在 x^* , 连续可微, 则

$$\nabla f(x^*) - \sum_{i=1}^m u_i \nabla g_i(x^*) - \sum_j \nabla h_j(x^*) = 0, \\ u_i g_i(x^*) = 0, u_i \geq 0 (i=1, \dots, m.)$$

若采用矩阵和向量记号, 则KKT条件可有如下的简洁表示。

定义Lagrange函数为

$$L(x, \lambda, \mu) = f(x) - g^T \lambda - h^T \mu \quad (7.2.3)$$

其中 g 和 h 分别是由 g_i 和 h_j 组成的向量函数。

约束规格到底解决什么问题？

约束规格 (Constraint Qualification, CQ) 保证了一件事：在 x^* 处，约束梯度所描述的局部几何与实际的可行域局部几何一致。

如果没有 CQ，可能出现这种情况：从一阶 Taylor 展开看，某个方向 d 满足 $\nabla g_i(x^*)^T d \leq 0$ (看似可行)，但实际上不存在沿该方向的可行弧。此时基于线性化的 KKT 条件可能出错——要么漏掉真正的极小点，要么把不可行的方向当作可行的。

LICQ 的直观意思：积极约束的梯度向量集合线性无关。

用平面几何比喻：每个积极约束在 x^* 处定义了一条曲线（或曲面），它的梯度 $\nabla g_i(x^*)$ 是法向量，垂直于这条曲线。LICQ 要求这些法向量互不“共线/共面”——没有哪个法向量可以写成其他法向量的线性组合。

- 如果 LICQ 成立，那么每个约束在 x^* 附近都是“独立的”（去掉任何一个都会改变可行域的形状）。
- 如果 LICQ 失败（如 $\nabla g_i(x^*) = 0$ ），意味着该约束在 x^* 附近至少二阶平坦——一阶信息不足以描述它。

常见约束规格一览

LICQ 积极约束的梯度线性无关。最常用，条件最强但验证简单。

MFCQ 积极约束梯度正线性相关。比 LICQ 稍弱。

Slater 对凸问题：存在严格可行点使 $g_i(x) < 0$ 。验证方便。

线性约束 若所有约束均为线性，则 CQ 自动成立，无需验证。

6.5 自编例题：完整 KKT 求解过程

【自编例题 2】混合约束的 KKT 完整演练

$\min x_1^2 + x_2^2, \text{s.t. } x_1^2 + x_2^2 \leq 1$ (单位圆盘内), $x_1 + x_2 = 0.5$ (直线上)。

几何直觉：直线穿过单位圆内部。最近原点的垂足 $x_1 = x_2 = 0.25$ 在圆内 ($0.125 < 1$)，不等式约束应不活跃。




图 6.2: KKT 条件示例——不等式约束非活跃

第 1 步: 写 Lagrange 函数。记 $g(x) = x_1^2 + x_2^2 - 1 \leq 0$,
 $h(x) = x_1 + x_2 - 0.5 = 0$ 。

$$L(x, \lambda, \mu) = x_1^2 + x_2^2 + \lambda(x_1^2 + x_2^2 - 1) + \mu(x_1 + x_2 - 0.5)$$

其中 $\lambda \geq 0$ (不等式乘子非负), μ 无约束 (等式乘子)。

第 2 步: 写 KKT 方程组。

$$\frac{\partial L}{\partial x_1} = 2x_1 + 2\lambda x_1 + \mu = 0 \quad (1)$$

$$\frac{\partial L}{\partial x_2} = 2x_2 + 2\lambda x_2 + \mu = 0 \quad (2)$$

$$\lambda \geq 0, \quad \lambda(x_1^2 + x_2^2 - 1) = 0 \quad (3)$$

$$x_1^2 + x_2^2 \leq 1, \quad x_1 + x_2 = 0.5 \quad (4)$$

第 3 步：分情况讨论（互补松弛 λ 的两种情况）。

情形 1： $\lambda = 0$ （不等式不活跃，最优解在圆内部）。由 KKT 方程： $2x_1 + \mu = 0$, $2x_2 + \mu = 0$ ，故 $x_1 = x_2 = -\mu/2$ 。代入 $x_1 + x_2 = 0.5$ ： $-\mu = 0.5$ ，得 $\mu = -0.5$ ， $x_1 = x_2 = 0.25$ 。验证： $0.25^2 + 0.25^2 = 0.125 \leq 1$ ✓， $\lambda = 0 \geq 0$ ✓。候选点： $x^* = (0.25, 0.25)^T$ ， $f^* = 0.125$ ， $\lambda^* = 0$ ， $\mu^* = -0.5$ 。

情形 2： $\lambda > 0$ （不等式活跃，最优解在圆周上）。由互补松弛 $x_1^2 + x_2^2 = 1$ 。由 KKT 方程 (1)(2) 相减得 $2(1 + \lambda)(x_1 - x_2) = 0$ 。因 $\lambda > 0$ 故 $1 + \lambda > 0$ ，得 $x_1 = x_2$ 。代入 $x_1 + x_2 = 0.5$ ： $x_1 = x_2 = 0.25$ 。但 $0.25^2 + 0.25^2 = 0.125 \neq 1$ ，矛盾！情形 2 无解。

第 4 步：结论。唯一 KKT 点： $x^* = (0.25, 0.25)^T$ ， $\lambda^* = 0$ ， $\mu^* = -0.5$ ， $f^* = 0.125$ 。不等式约束在该点不活跃（ $\lambda = 0$ ），与几何直觉一致。

这个例题教了什么？

1. KKT 求解的标准流程：写 Lagrange 函数 → 写 KKT 方程组 → 分情形讨论 → 逐一验证。
2. 互补松弛 $\lambda g(x) = 0$ 本质上是“开关”—— $\lambda = 0$ 时约束关闭（不活跃）， $\lambda > 0$ 时约束打开（活跃在边界）。
3. 若无不等式约束，直接 Lagrange 得 $(0.25, 0.25)$ ；加上后仍在圆内，约束冗余——KKT 正确识别（ $\lambda = 0$ ）。

6.6 FJ vs KKT 完整对比

表 6.1: FJ 与 KKT 的 系 统 对 比

比较维度	FJ 条件	KKT 条件
λ_0 (目标梯度 $\lambda_0 \geq 0$, 可以为零系数)		归一化 $\lambda_0 = 1$, 永不为零
是否需要 CQ	不需要, 无条件成立	必须满足 CQ
适用范围	所有局部极小点	仅满足 CQ 的局部极小点
$\lambda_0 = 0$ 时	目标梯度消失, 仅剩约束不存在此退化情形 束梯度线性相关	
乘子符号	$\lambda_i \geq 0$, μ_j 无约束	同 FJ
考试技巧	分 $\lambda_0 = 0$ 和 $\lambda_0 \neq 0$ 两情形讨论	令 $\lambda_0 = 1$, 分互补松弛情形讨论

PPT 第 7.23 页给出了 KKT 条件的具体算例 (例 7.2.1), 展示验证某点是否为 KKT 点的标准过程。

例7.2.1:

$$\begin{aligned}
 \min \quad & x_1^2 + x_2^2 \\
 \text{s.t.} \quad & x_1^2 + x_2^2 \leq 5, \\
 & -x_1 \leq 0, \\
 & -x_2 \leq 0, \\
 & x_1 + 2x_2 = 4
 \end{aligned}$$

验证在 $x = (4/5, 8/5)$ 处

Fritz John条件成立.

此处只有一个等式约束.

注意到在 x^* 处 $I = \emptyset$, 因此
与不等式相应的乘子为零.

$$\nabla f(x^*) = (8/5, 16/5)^T,$$

$$\nabla h_1(x^*) = (1, 2)^T$$

于是 $w\nabla f(x^*) + v\nabla h_1(x^*) = 0$ 即

$$w \begin{pmatrix} 8/5 \\ 16/5 \end{pmatrix} + v \begin{pmatrix} 1 \\ 2 \end{pmatrix} = 0$$

有合适解. 如取 $w = 5, v = -8$

6.7 真题解析：第六题 (1)(2)——FJ 与 KKT 的经典考试题

【2025 真题 · 第六题（节选）】

$$\min x_1^2 + x_2^2, \quad \text{s.t. } (x_1 - 1)^3 - x_2^2 = 0$$

(1) 找出所有满足 FJ 条件的可行点；(2) 证明不存在可行点满足 KKT 条件。

命题意图：约束梯度在最优解处退化 ($\nabla g = 0$)，体会 FJ 与 KKT 的本质差异。

6.7.1 问题分析

目标： $f(x) = x_1^2 + x_2^2$, $\nabla f(x) = (2x_1, 2x_2)^T$ 。

约束（等式）： $g(x) = (x_1 - 1)^3 - x_2^2 = 0$, $\nabla g(x) = (3(x_1 - 1)^2, -2x_2)^T$ 。

注意 ∇g 的退化点：当 $x_1 = 1, x_2 = 0$ 时， $\nabla g(1, 0) = (0, 0)^T = 0$ ——LICQ 不成立。

同时 $(1, 0)$ 满足约束 $(0)^3 - 0^2 = 0$ ，它是可行点且恰为目标极小点（ $f = 1$ 是可行集上的下确界）。

6.7.2 (1) FJ 条件求解

FJ 方程（仅一个等式约束，乘子 $\lambda_0 \geq 0$, μ 无约束）：

$$\lambda_0 \begin{pmatrix} 2x_1 \\ 2x_2 \end{pmatrix} + \mu \begin{pmatrix} 3(x_1 - 1)^2 \\ -2x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

且 $g(x) = (x_1 - 1)^3 - x_2^2 = 0$, $(\lambda_0, \mu) \neq (0, 0)$ 。

情形 1: $\lambda_0 = 0$ (退化情形)。方程化为 $\mu \cdot 3(x_1 - 1)^2 = 0$,

$\mu \cdot (-2x_2) = 0$ 。因 $(\lambda_0, \mu) \neq (0, 0)$, $\mu \neq 0$, 故

$x_1 = 1$, $x_2 = 0$ 。代入约束 $(1 - 1)^3 - 0^2 = 0$ ✓。得

FJ 点: $(1, 0)^T$ 。乘子 $(\lambda_0, \mu) = (0, \mu)$, μ 任意非零。

情形 2: $\lambda_0 \neq 0$ (非退化情形)。归一化 $\lambda_0 = 1$ ：

$$\begin{pmatrix} 2x_1 \\ 2x_2 \end{pmatrix} + \mu \begin{pmatrix} 3(x_1 - 1)^2 \\ -2x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

即：

$$2x_1 + 3\mu(x_1 - 1)^2 = 0 \quad (5)$$

$$2x_2 - 2\mu x_2 = 0 \Rightarrow 2x_2(1 - \mu) = 0 \quad (6)$$

由 (6): $\mu = 1$ 或 $x_2 = 0$ 。

子情形 2a ($\mu = 1$): 代入 (5): $2x_1 + 3(x_1 - 1)^2 = 0 \Rightarrow 3x_1^2 - 4x_1 + 3 = 0$ 。 $\Delta = 16 - 36 = -20 < 0$, 无实根。

子情形 2b ($x_2 = 0$): 由约束得 $x_1 = 1$ 。代入 (5): $2 + 0 = 2 \neq 0$, 矛盾。

情形 2 无解。

FJ 结论: 唯一 FJ 可行点 $(1, 0)^T$, 来自退化情形 $\lambda_0 = 0$ 。

6.7.3 (2) 证明 KKT 不存在

KKT 条件要求 $\lambda_0 \neq 0$ (归一化为 1), 这正是情形 2。已证情形 2 无解——不存在满足 KKT 条件的点。□

6.7.4 深层解读：这道题到底在考什么？

考试核心信息：

1. **FJ 找到了全局极小点 $(1, 0)$ ，但通过退化情形 $\lambda_0 = 0$ 。目标函数信息完全未用——只是凑巧 $\nabla g(1, 0) = 0$ 满足方程。** FJ 在任何约束梯度为零的可行点都可能触发，无论该点对目标函数好坏。
2. **KKT “漏掉”了真正的极小点。**不是 KKT 的错——在 $(1, 0)$ 处 $\nabla g = 0$, LICQ 不成立, KKT 的前提被破坏。KKT 是在“约束足够好”的前提下给出必要条件。
3. **几何：约束 $(x_1 - 1)^3 = x_2^2$ （即 $x_2 = \pm(x_1 - 1)^{3/2}$, $x_1 \geq 1$ ）在 $(1, 0)$ 处有尖点。**一阶信息无法刻画曲线局部走向——FJ 在此退化是非光滑几何的必然结果。
4. **考试答题模板：**
 - FJ 题：分 $\lambda_0 = 0$ 与 $\lambda_0 \neq 0$ 讨论， $\lambda_0 = 0$ 时用“不全为零”确定候选点

本章速查

FJ 条件 $\lambda_0 \nabla f + \sum \lambda_i \nabla g_i + \sum \mu_j \nabla h_j = 0$, $\lambda_0, \lambda_i \geq 0$, $\lambda_i g_i = 0$, 乘子不全为零

KKT 条 同上但 $\lambda_0 = 1$, 需要约束规格成立件

核心区别 FJ 允许 $\lambda_0 = 0$ (目标信息可能丢失), KKT 不允许

约束规格 LICQ (积极约束梯度线性无关) 最常用; 线性约束自动满足; Slater 适用于凸问题

FJ 解题 分 $\lambda_0 = 0$ 和 $\lambda_0 \neq 0$ 两情形讨论

KKT 解 设 $\lambda_0 = 1$, 写 Lagrange, 分互补松弛情形讨论题

退化判断 检查积极约束梯度是否为零向量 $\rightarrow$ 退化点处 LICQ 失败

第 7 章 非线性对偶

7.1 从线性对偶到非线性对偶

第 3 章讲线性规划对偶, 结论非常漂亮: 强对偶定理成立, 对偶间隙为零。到了非线性规划, 事情变得复杂——强对偶不总是成立, 对偶间隙可能大于零。

非线性对偶的核心工具是 **Lagrange 对偶函数**。思路：把约束”价格化”（乘子），问在乘子固定的情况下，无约束问题的最坏（最小）情况是什么。这个下确界（inf）给出了原问题最优值的一个下界。

7.2 Lagrange 对偶函数

考虑一般非线性规划（原问题）：

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & g_i(x) \leq 0 \quad (i = 1, \dots, m) \\ & h_j(x) = 0 \quad (j = 1, \dots, p) \\ & x \in X \end{aligned}$$

定义 7.1 (Lagrange 对偶函数)

对不等式约束引入乘子 $\lambda_i \geq 0$ ，对等式约束引入乘子 μ_j （无符号限制），定义 Lagrange 函数（在第 6 章已引入，此处结合对偶框架复用）：

$$L(x, \lambda, \mu) = f(x) + \sum_{i=1}^m \lambda_i g_i(x) + \sum_{j=1}^p \mu_j h_j(x)$$

则 **Lagrange 对偶函数**为：

$$\theta(\lambda, \mu) = \inf_{x \in X} L(x, \lambda, \mu)$$

即在乘子固定的条件下，对 x 取下确界。

PPT 第 7.51 页给出了 Lagrange 对偶的一个具体计算示例，我们在下面用自编例子展示完整的手算过程。

例7.3.2: 考虑非线性约束优化问题

$$\{\min f = x_1^2 + x_2^2, \text{ s. t. } x_1 + x_2 \geq 4, x \in \mathbf{R}_+^2\},$$

若取集合约束 $D = \mathbf{R}_+^n$, 则它的Lagrange函数为

$$\begin{aligned} \theta(\lambda, \mu) &= \inf\{x_1^2 + x_2^2 - \lambda(x_1 + x_2 - 4) \mid x \in \mathbf{R}_+^2\} \\ &= 4\lambda + \inf\{x_1^2 - \lambda x_1 \mid x_1 \geq 0\} + \inf\{x_2^2 - \lambda x_2 \mid x_2 \geq 0\} \end{aligned}$$

$$= \begin{cases} -\frac{1}{2}\lambda^2 + 4\lambda, & \lambda \geq 0 \\ 4\lambda, & \text{否则} \end{cases} \quad \text{于是该问题的对偶问题形如:}$$

$$\begin{aligned} \max \quad & -\frac{1}{2}\lambda^2 + 4\lambda \\ \text{s.t.} \quad & \lambda \geq 0 \end{aligned}$$

为什么取 $\inf$? 原问题是“在约束条件下最小化 $f(x)$ ”。引入乘子后，我们解除了约束，但用乘子施加惩罚： $g_i(x) \leq 0$ 若被违反 ($g_i > 0$)，则 $\lambda_i g_i$ 为正惩罚项；若满足 ($g_i \leq 0$)，则 $\lambda_i g_i \leq 0$ 反而是奖励。取 $\inf_x$ 意味着：在乘子固定时，寻找使“目标 + 惩罚”最小的 x 。这本质上是把原问题“放松”为一个无约束问题——由于去掉约束后容许的 x 更多，最小值只可能更小（或相等），从而提供了原最优值的下界。乘子不同，下界也不同；最优的下界就是对偶问题要寻找的。

7.3 自编教学例 1：手算对偶函数（凸问题，强对偶成立）

原问题：

$$\min x^2, \quad \text{s.t. } x \geq 1$$

这是一个凸规划（目标凸，约束 $1 - x \leq 0$ 中 $g(x) = 1 - x$ 是凸的（线性））。

Step 1：写 Lagrange 函数。将约束改写为标准形

式 $g(x) \leq 0$:

$$g(x) = 1 - x \leq 0$$

引入乘子 $\lambda \geq 0$:

$$L(x, \lambda) = x^2 + \lambda(1 - x) = x^2 - \lambda x + \lambda$$

Step 2: 对 x 取下确界, 得对偶函数 $\theta(\lambda)$ 。固定 $\lambda \geq 0$, $L(x, \lambda)$ 是 x 的二次函数 (开口向上), 求驻点:

$$\frac{\partial L}{\partial x} = 2x - \lambda = 0 \quad \Rightarrow \quad x = \frac{\lambda}{2}$$

代入得:

$$\theta(\lambda) = \left(\frac{\lambda}{2}\right)^2 - \lambda\left(\frac{\lambda}{2}\right) + \lambda = \frac{\lambda^2}{4} - \frac{\lambda^2}{2} + \lambda = \lambda - \frac{\lambda^2}{4}$$

(因为二次系数 > 0 , 驻点即全局最小, $\inf$ 就是 $\min$ 。)

Step 3: 写出对偶规划。对偶问题是最大化 $\theta(\lambda)$:

$$\max_{\lambda \geq 0} \theta(\lambda) = \max_{\lambda \geq 0} \left(\lambda - \frac{\lambda^2}{4}\right)$$

求导: $\theta'(\lambda) = 1 - \lambda/2 = 0 \Rightarrow \lambda^* = 2$ (满足 $\lambda \geq 0$)。

$$\theta^* = \theta(2) = 2 - \frac{4}{4} = 1$$

Step 4: 验证。原问题显然有 $x^* = 1$, $f^* = 1$ 。对偶最优值 $\theta^* = 1$ 。

$$f^* = \theta^* = 1 \Rightarrow \text{强对偶成立 (对偶间隙为零)}$$

原因：问题是凸规划且 Slater 条件成立（存在 $x = 2$ 使 $g(2) = 1 - 2 = -1 < 0$ ）。

PPT 第 7.36 页讲的就是弱对偶定理：原最优值永远不小于对偶值。我们的例子中 $1 \geq 1$ ，等式刚好成立（因为凸性保证了强对偶）。

7.3.2 对偶定理

7.36

对于上面的两例我们有原问题与对偶问题的最优值相等. 对一般形式的非线性规划问题, 是否也对? 即

$$\min_{x \in S} f(x) \stackrel{??}{=} \max_{(\lambda, \mu)} \theta(\lambda, \mu)$$

1. 弱对偶定理

定理 7.3.1 (弱对偶定理) 设 $x \in S$ 和 $(\lambda, \mu) \in \Delta$ 分别为原问题(PNLP) 和对偶问题(DNLP) 的可行解, 则

$$f(x) \geq \theta(\lambda, \mu)$$

7.4 弱对偶定理（永恒成立）

定理 7.1（弱对偶定理）

设 x 是原问题的任意可行解， (λ, μ) 是任意对偶乘子（ $\lambda \geq 0$ ）。则恒有：

$$f(x) \geq \theta(\lambda, \mu)$$

因此：

$$\inf\{f(x) \mid \text{可行}\} \geq \sup_{\lambda \geq 0, \mu} \theta(\lambda, \mu)$$

即：原最优值 $\geq$ 对偶最优值。差值称为对偶间隙。

弱对偶不需要任何条件——不需要凸性，不需要约束规格，对任意 f, g_i, h_j 都成立。证明仅用到 $\lambda_i \geq 0$ 和 $g_i(x) \leq 0$ 这两个不等式方向一致：

对可行 x ： $g_i(x) \leq 0$ 且 $\lambda_i \geq 0$ ，故 $\lambda_i g_i(x) \leq 0$ ；
 $h_j(x) = 0$ 故 $\mu_j h_j(x) = 0$ 。于是：

$$L(x, \lambda, \mu) = f(x) + \underbrace{\sum \lambda_i g_i(x)}_{\leq 0} + \underbrace{\sum \mu_j h_j(x)}_{=0} \leq f(x)$$

再对左边取 $\inf_x$ （下确界只可能更小）： $\theta(\lambda, \mu) \leq$

$L(x, \lambda, \mu) \leq f(x)$ 。得证。

PPT 第 7.24 页给出了弱对偶定理的完整证明框架，上面给出的就是其核心推理。

7.24

设集合 $\bar{S}$ 在点 $\bar{x}$ 的切锥为 $\bar{T}$ 。再定义一个集合

$$\bar{G} = \left\{ d \left| \begin{array}{l} \nabla g_i(\bar{x})^T d = 0, i \in I \text{ 且 } \bar{w}_i > 0 \\ \nabla g_i(\bar{x})^T d \geq 0, i \in I \text{ 且 } \bar{w}_i = 0 \\ \nabla h_j(\bar{x})^T d = 0, j = 1, 2, \dots, l \end{array} \right. \right\}$$

容易证明 $\bar{G} \supset \bar{T}$

证明略

切锥 $\bar{T}$ 必包含于 $\bar{G}$ ，但是反之不真。

下面，在 $\bar{G} \subset \bar{T}$ 也成立的假设下，给出关于问题(7.2.1)的局部最优解的二阶必要条件。

7.5 强对偶定理（需要条件）

定理 7.2（强对偶定理）

若原问题为凸规划（ f 凸，每个 g_i 凸，每个 h_j 仿射）且 Slater 条件成立（存在严格可行点使所有 $g_i(x) < 0$ ），则：

$$\min f(x) = \max_{\lambda \geq 0, \mu} \theta(\lambda, \mu)$$

且对偶问题的最优乘子就是原问题 KKT 条件（见第 6 章）中的乘子。

为什么强对偶需要条件？弱对偶的证明只用了“ $\lambda_i g_i \leq 0$ ”这个不等式，它对任意函数都成立。但要让等号成立，需要原问题和对偶问题之间没有“间隙”——这本质上是一个分离超平面的存在性问题：把原问题的最优值和对偶变量的可行集分离开。凸性保证了分离超平面的存在（Hahn-Banach 定理的推论），Slater 条件保证了分离是严格的（避免退化）。

自编例 1 满足条件： $f(x) = x^2$ 凸， $g(x) = 1 - x$ 线性（凸），Slater 成立，故强对偶成立（我们已验证 $f^* = \theta^* = 1$ ）。

PPT 第 7.55 页给出了强对偶定理的表述。PPT 第 7.39 页也涉及相关内容——强对偶保证了对偶方法可用于求解原问题的最优值。

7.39

3. 强对偶定理

定理**7.3.3**(强对偶定理) 对于凸规划问题, 假设 D 为非空的凸开集, f 为凸函数, $g_i (i=1, \dots, m)$ 为凹函数, $h_j (j=1, \dots, l)$ 为线性函数.

若函数 g, h 满足Slater约束规格, 并且 $0 \in \text{int } H(D)$,

$(H(D) = \{h(x) \mid x \in D\})$, 则

$$f_{\min} = \inf\{f(x) \mid x \in S\} = \sup\{\theta(\lambda, \mu) \mid (\lambda, \mu) \in \Delta\} = \theta_{\max}$$

此外, 若 $f_{\min} > -\infty$, 则存在某个 $(\bar{\lambda}, \bar{\mu}) \in \Delta$, 使得 $\theta(\bar{\lambda}, \bar{\mu}) = \theta_{\max}$.

特别的. 若存在 $\bar{x} \in S$, 使得 $f(\bar{x}) = f_{\min}$, 则互补松弛条件

$\bar{\lambda}^T g(\bar{x}) = 0$ 成立.

约束规格的角色: Slater 条件排除了退化情形。例如 $\min x \text{ s.t. } x^2 \leq 0$ (仅有 $x = 0$ 可行) ——虽然凸但无严格内点, 强对偶可能失败。

PPT 第 7.32 页展示了 Lagrange 对偶的一般理论框架和对偶形式。

7.3 对偶理论

7.3.1 对偶形式

考虑如下形式的约束优化问题

$$\begin{aligned}
 & \min f(x) \\
 (PNLP) \quad & s, t \quad g_i(x) \geq 0, \quad i = 1, \dots, m \\
 & h_j(x) = 0, \quad j = 1, \dots, l \\
 & x \in D \subseteq R^n
 \end{aligned} \tag{7.3.1}$$

其中 D 为问题的集合约束.

称(7.3.1)为非线性规划的原始形式(原问题).

7.6 自编教学例 2：非凸问题与对偶间隙

原问题：

$$\min x^2, \quad \text{s.t. } x^3 = 1$$

约束 $x^3 = 1$ 等价于 $x = 1$ (实数范围内), 故可行域仅一个点, $x^* = 1, f^* = 1$ 。

但注意：等式约束 $h(x) = 1 - x^3 = 0$ 中 $h(x)$ 不是仿射函数——问题不满足凸规划条件。

构造 Lagrange 对偶。等式约束引入乘子 μ (无符号

限制)：

$$L(x, \mu) = x^2 + \mu(1 - x^3) = -\mu x^3 + x^2 + \mu$$

对偶函数 $\theta(\mu) = \inf_{x \in \mathbb{R}} L(x, \mu)$ 。分情形讨论：

- $\mu = 0$: $L(x, 0) = x^2$, $\inf_x x^2 = 0$, 故 $\theta(0) = 0$ 。
- $\mu > 0$: 当 $x \rightarrow +\infty$ 时, $-\mu x^3$ 主导且趋于 $-\infty$, 故 $\theta(\mu) = -\infty$ 。
- $\mu < 0$: 当 $x \rightarrow -\infty$ 时, $x^3 \rightarrow -\infty$, $-\mu x^3 = |\mu|x^3 \rightarrow -\infty$, 故 $\theta(\mu) = -\infty$ 。

因此：

$$\theta(\mu) = \begin{cases} 0, & \mu = 0 \\ -\infty, & \mu \neq 0 \end{cases}$$

对偶规划： $\max_{\mu} \theta(\mu) = 0$, 最优值 $\theta^* = 0$ 。

结论：原最优值 $f^* = 1$, 对偶最优值 $\theta^* = 0$, 对偶间隙 $= 1$ 。

为什么会这样？核心原因是 x^3 这个三次项：当我们在 Lagrange 函数中解除约束后， $-\mu x^3$ 项使得无论 μ 取何非零值，三次主导项都会将 $L(x, \mu)$ 拉向 $-\infty$ 。只有 $\mu = 0$ 时对偶函数有限，但此时等价于完全忽略约束——对偶函数退化，无法提供紧的下界。

这正是非凸性导致对偶间隙的根本机制：非凸约束使得 Lagrange 放松后的下确界比原问题的最优值“低太多”。

7.7 变量消元法的陷阱

在处理等式约束时，有人会想：直接从约束解出一个变量代入目标函数，不就变成无约束问题了吗？

这是最常见的一种错误。原因：等式约束可能隐含不等式限制。

典型陷阱——考虑约束 $x_2^2 = (x_1 - 1)^3$ 。如果“解出” x_2^2 代入目标函数，表面上消除了 x_2 ，但实际上丢失了关键信息：

$$x_2^2 = (x_1 - 1)^3 \Rightarrow (x_1 - 1)^3 \geq 0 \Rightarrow x_1 \geq 1$$

因为左边 x_2^2 是非负的，右边也必须是。这个 $x_1 \geq 1$ 是隐含不等式约束——若不写出来，一元化后的目标可能在 $x_1 < 1$ 处取得更小值，但那是不可行的。

正确做法：变量消元后，必须显式加上所有隐含的不等式条件。

7.8 真题第六题 (3)(4)——变量消元与对偶规划

【真题 6】

$$\min x_1^2 + x_2^2, \quad \text{s.t. } (x_1 - 1)^3 - x_2^2 = 0$$

- (3) 用变量消元法求解，并指出常见的错误做法；
(4) 写出 Lagrange 对偶规划，求对偶最优值，说明对偶间隙。

(3) 变量消元法的正确与错误

错误做法（考试常见扣分点）：从约束直接解出 $x_2^2 = (x_1 - 1)^3$ ，代入目标得：

$$\min x_1^2 + (x_1 - 1)^3$$

然后对 x_1 求导找极小——错！遗漏了隐含条件。

正确做法：注意到 $x_2^2 \geq 0$ 恒成立，因此：

$$(x_1 - 1)^3 = x_2^2 \geq 0 \quad \Rightarrow \quad x_1 - 1 \geq 0 \quad \Rightarrow \quad x_1 \geq 1$$

变量消元后的正确问题是：

$$\min x_1^2 + (x_1 - 1)^3, \quad \text{s.t. } x_1 \geq 1$$

令 $g(x_1) = x_1^2 + (x_1 - 1)^3$ ，则：

$$g'(x_1) = 2x_1 + 3(x_1 - 1)^2 > 0 \quad (\text{当 } x_1 \geq 1)$$

故 g 在 $[1, +\infty)$ 上严格递增，最小值在 $x_1 = 1$ 处取得：

$$f^* = g(1) = 1^2 + 0^3 = 1, \quad x^* = (1, 0)^T$$

若遗漏 $x_1 \geq 1$ 会怎样？ $x_1^2 + (x_1 - 1)^3$ 当 $x_1 \rightarrow -\infty$ 时，三次项主导且系数为正， $x_1^3 \rightarrow -\infty$ ，但注意 $(x_1 - 1)^3$ 当 x_1 为大的负数时 x_1^2 是正的， $(x_1 - 1)^3$ 也是很大的负数……实际上当 $x_1 \rightarrow -\infty$ ： x_1^2 正二次增长， $(x_1 - 1)^3 \approx x_1^3$ 是三次负增长，三次主导，所以表达式 $\rightarrow -\infty$ 。无下界——这就是遗漏隐含约束的灾难性后果。

(4) 对偶规划

约束为等式 $h(x) = (x_1 - 1)^3 - x_2^2 = 0$ ，引入乘子 μ （无符号限制）：

$$L(x, \mu) = x_1^2 + x_2^2 + \mu[(x_1 - 1)^3 - x_2^2]$$

整理：

$$L(x, \mu) = x_1^2 + \mu(x_1 - 1)^3 + (1 - \mu)x_2^2$$

对偶函数 $\theta(\mu) = \inf_x L(x, \mu)$ ：

- 关于 x_1 ： $x_1^2 + \mu(x_1 - 1)^3$ 。当 $\mu \neq 0$ ，若 $x_1 \rightarrow -\infty$ ($\mu > 0$) 或 $x_1 \rightarrow +\infty$ ($\mu < 0$)，三次

项主导；更精细的分析表明除 $\mu = 0$ 外，关于 x_1 的 inf 都是 $-\infty$ 。当 $\mu = 0$ ： x_1^2 的 inf 是 0。

- 关于 x_2 ： $(1-\mu)x_2^2$ 。若 $1-\mu < 0$ (即 $\mu > 1$)，当 $x_2 \rightarrow \infty$ 时 $\rightarrow -\infty$ 。若 $1-\mu \geq 0$ (即 $\mu \leq 1$)，最小值为 0 (在 $x_2 = 0$ 处)。

综合考虑——当 $\mu = 0$ 时两项的 inf 都是 0，故 $\theta(0) = 0$ 。对任意 $\mu \neq 0$ ，至少有一项可以拉向 $-\infty$ ($\mu < 0$ 时 x_1 项， $\mu \in (0, 1]$ 时 x_1 项， $\mu > 1$ 时两项均可)，故 $\theta(\mu) = -\infty$ 。

$$\theta(\mu) = \begin{cases} 0, & \mu = 0 \\ -\infty, & \mu \neq 0 \end{cases}$$

对偶规划： $\max_{\mu} \theta(\mu) = 0$ 。

结论：

原最优值 $f^* = 1$ ， 对偶最优值 $\theta^* = 0$ ， 对偶间隙 = 1

为什么强对偶不成立？约束 $(x_1 - 1)^3 - x_2^2 = 0$ 中， $(x_1 - 1)^3$ 不是 x_1 的凸函数（它是奇函数形状，有拐点），因此整个问题不是凸规划。弱对偶仍然成立（ $1 > 0$ ，确实 $f^* \geq \theta^*$ ），但强对偶不成立。这个考题的设计意图正是要说明：一旦离开凸规划的领地，对偶间隙就可能出现。

PPT 第 7.22-7.23 页覆盖了二阶条件，PPT 第 7.34 页覆盖了一般约束下的最优性条件基础——理解 KKT 条件后才能深入对偶理论。

4.二阶条件

7.22

例 考虑如下约束优化问题,

$$\min f(x) = x_1^2 + x_2^2$$

$$\text{s.t. } g(x) = x_1^2 + x_2 - 1 \geq 0$$

对于可行点 $x^* = (0, 1)^T$, $I = \{1\}$, $\nabla f(x^*) = (0, 2)^T$,

$\nabla g(x^*) = (0, 1)^T$. 易见 x^* 是 KKT 条件. 此时线性独立约束规格 (LICQ) 成立, 即

$$\{\nabla g_i(x^*), \nabla h_j(x^*), i \in I, j = 1, \dots, l\}$$

线性无关. 但我们无法利用一阶最优性条件判断 x^* 是否为问题的局部极小点。

现在我们考虑问题(7.2.1).

设在可行点 $\bar{x}$, 对应不等式约束中的起作用约束和等式约束的Lagrange乘子分别为: $\bar{w}_i \geq 0, i \in I$; $\bar{v}_j, j=1, 2, \dots, l$. 定义一个集合。

$$\bar{S} = \left\{ x \left| \begin{array}{l} g_i(x) = 0, i \in I \text{ 且 } \bar{w}_i > 0 \\ g_i(x) \geq 0, i \in I \text{ 且 } \bar{w}_i = 0 \\ h_j(x) = 0, j = 1, 2, \dots, l \end{array} \right. \right\}$$

本章速查

- Lagrange 对偶函数: $\theta(\lambda, \mu) = \inf_{x \in X} \{ f(x) + \sum \lambda_i g_i(x) + \sum \mu_j h_j(x) \}$
- 弱对偶定理: $f(x) \geq \theta(\lambda, \mu)$ 恒成立 (无须任何条件), 证明核心是 $\lambda_i g_i(x) \leq 0$
- 强对偶定理: 需要凸规划 (f 凸, g_i 凸, h_j 仿射) + 约束规格 (如 Slater), 保证 $f^* = \theta^*$

- 对偶间隙：原最优值 - 对偶最优值，非凸问题可能 > 0
- 变量消元陷阱：必须保留隐含不等式约束（如 $x^2 \geq 0$ 等非负约束自动传递）
- 考试核心手法：对偶函数分 $\mu = 0$ 和 $\mu \neq 0$ 讨论 $\inf$ ，三次项主导导致 $-\infty$ 是典型考点

第 8 章 无约束优化方法

8.1 问题的版图：下降算法的通用框架

非线性规划的求解分两大战场：无约束问题和有约束问题。无约束优化 $\min f(x)$ 是一切的基础——罚函数法（将在第 9 章详述）、乘子法等约束方法的本质，就是把带约束问题转化为一系列无约束子问题。

无约束优化的共同骨架是迭代下降：从初始点出发，每步沿下降方向走一段步长，函数值严格递减，直到梯度趋于零。

定义 8.1（下降算法通用格式）

给定初始点 $x^{(0)}$ 。对 $k = 0, 1, 2, \dots$ ：

$$x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$$

其中：

- $d^{(k)}$ 是搜索方向，满足 $\nabla f(x^{(k)})^T d^{(k)} < 0$ （与负梯度成锐角，保证局部下降）
- $\lambda_k > 0$ 是步长，使 $f(x^{(k+1)}) < f(x^{(k)})$

终止准则： $\|\nabla f(x^{(k)})\| \leq \varepsilon$ 时停止。

为什么梯度为零是停机信号？无约束问题的一阶必要条件就是 $\nabla f(x^*) = 0$ 。当我们走到梯度足够小的点，说明已经接近某个驻点。对于凸函数（凸函数的判别方法见第 5 章），这就是全局最优。

具体例子： 设 $f(x) = x_1^2 + 2x_2^2$ ，取 $x^{(0)} = (3, 2)^T$ 。 $\nabla f = (2x_1, 4x_2)$ 。若选 $d^{(0)} = -\nabla f^{(0)} = (-6, -8)^T$ ， $\nabla f^T d = (-6)^2 + (-8)^2 = -100 < 0$ （下降）。若选 $d = (1, 0)^T$ ， $\nabla f^T d = 6 > 0$ （上升，不能用）。

PPT 第 10.1 页展示了下降算法的宏观流程——“指定初始点 $\rightarrow$ 确定搜索方向 $\rightarrow$ 一维搜索定步长 $\rightarrow$ 更新 $\rightarrow$ 检查终止”。本章所有方法的区别仅在于怎么选方向和怎么定步长。

10.3 共轭梯度法

□ 1 共轭方向与扩张子空间定理

定义10.3.1 设 A 是 $n \times n$ 对称矩阵,若 R^n 中的两个方向 d^1 和 d^2 满足 $(d^1)^T A d^2 = 0$ (10.3.1)
则称这两个方向关于 A 共轭,或称它们关于 A 正交.

若 $d^{(1)}, d^{(2)}, \dots, d^{(k)}$ 是 R^n 中 k 个方向,它们两两关于 A 共轭,即

$$d^{(i)T} A d^{(j)} = 0, i \neq j, \quad i, j = 1, 2, \dots, k. \quad (10.3.2)$$

则称这组方向是**A共轭**,或称它们为**A的k个共轭方向**

8.2 最速下降法——局部最快，全局最慢

最速下降法取负梯度方向为搜索方向。梯度指向函数增长最快的方向，其反方向就是局部下降最快的方向。

定义 8.2 (最速下降法 / 梯度法)

方向: $d^{(k)} = -\nabla f(x^{(k)})$

步长: $\lambda_k = \operatorname{argmin}_{\lambda \geq 0} f(x^{(k)} + \lambda d^{(k)})$ (精确线搜索)

具体例子： $f(x_1, x_2) = x_1^2 + 9x_2^2$, $x^{(0)} = (9, 1)^T$ 。

- $\nabla f = (2x_1, 18x_2)$, $\nabla f^{(0)} = (18, 18)^T$
- $d^{(0)} = -(18, 18)^T = -18(1, 1)^T$
- 代入线搜索: $\phi(\lambda) = (9 - 18\lambda)^2 + 9(1 - 18\lambda)^2 = 90 - 648\lambda + 3240\lambda^2$
- $\phi'(\lambda) = -648 + 6480\lambda = 0 \Rightarrow \lambda_0 = 0.1$
- $x^{(1)} = (9 - 1.8, 1 - 1.8)^T = (7.2, -0.8)^T$
- $f(x^{(1)}) = 57.6$ (从 90 只降到 57.6, 仅降 36%)

锯齿现象的根源： 精确线搜索下, $d^{(k)} \perp d^{(k+1)}$ (连续两方向正交)。因为 $\phi'(\lambda_k) = \nabla f^{(k+1)T} d^{(k)} = 0$, 即 $\nabla f^{(k+1)} \perp d^{(k)}$, 而 $d^{(k+1)} = -\nabla f^{(k+1)}$, 所以 $d^{(k+1)} \perp d^{(k)}$ 。在狭长的“山谷”地形 (Hessian 矩阵条件数大; Hessian 的概念与判定见第 5 章) 中, 它 在山谷两侧反复横跳, 而不是沿谷底前进——这就是“局部最快, 全局最慢”的根源。

8.3 牛顿法——一步到位的理想

牛顿法利用目标函数的二阶泰勒展开，在局部用二次函数逼近 f ，然后直接跳到该二次逼近的极小点。

定义 8.3（牛顿法）

方向： $d^{(k)} = -[\nabla^2 f(x^{(k)})]^{-1} \nabla f(x^{(k)})$

步长： $\lambda_k = 1$ （纯牛顿法，不搜索）

具体例子（接上例）：同取 $f = x_1^2 + 9x_2^2$, $x^{(0)} = (9, 1)^T$ 。

- $\nabla^2 f = \begin{pmatrix} 2 & 0 \\ 0 & 18 \end{pmatrix}$, $[\nabla^2 f]^{-1} = \begin{pmatrix} 1/2 & 0 \\ 0 & 1/18 \end{pmatrix}$
- $\nabla f^{(0)} = (18, 18)^T$
- $d^{(0)} = -H^{-1}\nabla f = -(9, 1)^T$
- $x^{(1)} = (9, 1) - 1 \cdot (9, 1) = (0, 0)^T$
- $\nabla f(0, 0) = (0, 0)^T$ ，一步精确收敛！ $f(0, 0) = 0$
（全局最优）

牛顿法的收敛速度是二次收敛：误差平方级递减（ $\|x^{(k+1)} - x^*\| \leq C\|x^{(k)} - x^*\|^2$ ），远快于最速下降法

的线性收敛。但代价高昂——需要计算 Hessian 逆矩阵。

8.4 自编对比例题：最速下降 vs 牛顿法

下面用一个完整的对比例题，直观展示两种方法的巨大差距。

【自编教学例】

$$\min f(x_1, x_2) = x_1^2 + 9x_2^2, \quad x^{(0)} = (9, 1)^T$$

目标：分别用最速下降法和牛顿法各执行一轮迭代。

牛顿法（第 1 轮）

$$\nabla f = (2x_1, 18x_2)^T, \quad \nabla^2 f = \text{diag}(2, 18), \quad H^{-1} = \text{diag}(\frac{1}{2}, \frac{1}{18}).$$

在 $x^{(0)}$ 处: $\nabla f^{(0)} = (18, 18)^T$ 。牛顿方向:

$$\begin{aligned}d_{\text{Newton}}^{(0)} &= -H^{-1}\nabla f^{(0)} \\&= -\begin{pmatrix} 1/2 & 0 \\ 0 & 1/18 \end{pmatrix} \begin{pmatrix} 18 \\ 18 \end{pmatrix} = -\begin{pmatrix} 9 \\ 1 \end{pmatrix}\end{aligned}$$

$x^{(1)} = (9, 1) - (9, 1) = (0, 0)^T$ 。 $\nabla f(0, 0) = (0, 0)^T$,
 $f = 0$ 。一步到达全局最优。

最速下降法（第 1 轮）

方向: $d_{\text{SD}}^{(0)} = -\nabla f^{(0)} = -(18, 18)^T = -18(1, 1)^T$ 。

代入 f 做线搜索:

$$\phi(\lambda) = (9 - 18\lambda)^2 + 9(1 - 18\lambda)^2 = 90 - 648\lambda + 3240\lambda^2$$

$$\phi'(\lambda) = -648 + 6480\lambda = 0 \Rightarrow \lambda_0 = 0.1。$$

$$x_{\text{SD}}^{(1)} = (9 - 1.8, 1 - 1.8)^T = (7.2, -0.8)^T$$

$f(x_{\text{SD}}^{(1)}) = 7.2^2 + 9 \times 0.64 = 57.6$ 。第二方向 $d^{(1)} = -\nabla f^{(1)} = -(14.4, -14.4)^T$, 验证锯齿: $d^{(0)} \cdot d^{(1)} = (-18)(-14.4) + (-18)(14.4) = 0$ (正交!)。

对比总结

	最速下降法	牛顿法
第 1 轮后 x	$(7.2, -0.8)$	$(0, 0)$
第 1 轮后 $f(x)$	57.6	0
与最优值差距	$57.6 > 0$	0 (已收敛)
每步成本	梯度 $O(n)$	Hessian + 求逆 $O(n^3)$
方向间关系	正交 (锯齿)	直指极小点

启示：如果能把“牛顿的准”和“梯度的省”结合起来，该多好？这就是下一节拟牛顿法的出发点。

8.5 线搜索——步长怎么定

无论在哪个方向下行，步长必须保证“走得足够远但不过头”。

精确线搜索

给定方向 d ，求 $\min_{\lambda \geq 0} \phi(\lambda) = f(x + \lambda d)$ 。将 $x + \lambda d$ 代入 f 得 $\phi(\lambda)$ （一元函数），解 $\phi'(\lambda) = 0$ 即得最优步长。

PPT 第 9.8 页对比了精确线搜索与非精确线搜索的概念。精确线搜索理论上最优，但每次要解一个一元

方程——在前几步不需要这么精确。

9.8

9.4. 非精确线搜索算法

精确线搜索算法

$$\phi(\alpha) = f(x^k + \alpha d^k)$$

$$\alpha_k = \arg \min_{\alpha > 0} \phi(\alpha),$$

非精确线搜索算法

不要求 α_k 是 $\phi(\alpha)$ 的最小值点，而是仅仅要求 $\phi(\alpha_k)$ 满足某些不等式性质。

Armijo 准则（非精确线搜索）

实际计算中，每次迭代精确求解 $\min_{\lambda} \phi(\lambda)$ 代价太高。Armijo 准则用“回溯法”找一个“足够好”的步长：从 $\lambda = 1$ 开始，不断缩小 λ （乘以 $\beta \in (0, 1)$ ，常用 $\beta = 0.5$ ），直到满足充分下降条件：

$$f(x + \lambda d) \leq f(x) + \alpha \lambda \nabla f(x)^T d$$

其中 $\alpha \in (0, 1)$ (常用 $\alpha = 10^{-4}$)。右边是沿方向 d 的线性下降预期——如果实际下降达不到这个预期，说明步长太大，需要缩步。

PPT 第 9.9 页展示了 Armijo 准则的几何含义和回溯流程，这是拟牛顿法和共轭梯度法常用的步长策略。

线搜索准则

9.9

- 在非精确线搜索算法中，选取 α_k 需要满足一定的要求，这些要求被称为线搜索准则。

9.4.1. Armijo 准则

定义 4.1 (Armijo 准则) 设 d^k 是点 x^k 处的下降方向，若

$$f(x^k + \alpha d^k) \leq f(x^k) + c_1 \alpha \nabla f(x^k)^T d^k,$$

则称步长 α 满足 **Armijo 准则**，其中 $c_1 \in (0, 1)$ 是一个常数。




图 4.1 Armijo 准则

精确 vs 非精确线搜索的选择： 考试中手算题用精确线搜索（因为函数简单，可手解 $\phi'(\lambda) = 0$ ）。实际软件中 Armijo 准则更常见——省时，且对 DFP/BFGS 的收敛性理论保证已完备。

8.6 共轭梯度法——不存矩阵，用巧劲

核心动机

最速下降法的锯齿因连续方向正交而低效，牛顿法虽好但存 Hessian 太贵 ($O(n^2)$ 存储, $O(n^3)$ 求逆)。共轭梯度法在两者之间取平衡：不存矩阵， n 步收敛——对正定二次函数，至多 n 轮精确收敛到极小点。

定义 8.4 (FR 共轭梯度法)

初始： $d^{(0)} = -\nabla f(x^{(0)})$ 。

对 $k \geq 1$ ：

$$\beta_k = \frac{\|\nabla f^{(k)}\|^2}{\|\nabla f^{(k-1)}\|^2}, \quad d^{(k)} = -\nabla f^{(k)} + \beta_k d^{(k-1)}$$

方向 $d^{(k)}$ 与 $d^{(k-1)}$ 关于 Hessian Q 共轭：
 $(d^{(k)})^T Q d^{(k-1)} = 0$ 。共轭不等于正交——共轭考虑了目标函数的曲率（通过 Q 加权），使每一步方向在 Q -内积意义下互不干扰。

简单算例

仍用 $f(x) = \frac{1}{2}(x_1^2 + 2x_2^2)$, $x^{(0)} = (2, 1)^T$, $Q = \text{diag}(1, 2)$ 。

第 1 步（同最速下降）： $\nabla f^{(0)} = (2, 2)^T$, $d^{(0)} = -(2, 2)^T$ 。线搜索： $\phi(\lambda) = 3 - 8\lambda + 6\lambda^2$, $\lambda_0 = 2/3$ 。
 $x^{(1)} = (2/3, -1/3)^T$ 。

第 2 步（共轭修正）： $\nabla f^{(1)} = (2/3, -2/3)^T$,
 $\beta_1 = \frac{\|(2/3, -2/3)\|^2}{\|(2, 2)\|^2} = \frac{8/9}{8} = \frac{1}{9}$ 。

$$\begin{aligned} d^{(1)} &= - \begin{pmatrix} 2/3 \\ -2/3 \end{pmatrix} + \frac{1}{9} \begin{pmatrix} -2 \\ -2 \end{pmatrix} \\ &= \begin{pmatrix} -2/3 - 2/9 \\ 2/3 - 2/9 \end{pmatrix} = \begin{pmatrix} -8/9 \\ 4/9 \end{pmatrix} = \frac{4}{9} \begin{pmatrix} -2 \\ 1 \end{pmatrix} \end{aligned}$$

线搜索沿 $d^{(1)}$ 精确到 $x^{(2)} = (0, 0)$ 。**两轮收敛** ($n = 2$)!

验证共轭性：

$$(d^{(1)})^T Q d^{(0)} = \left(-\frac{8}{9}, \frac{4}{9}\right) \text{diag}(1, 2) (-2, -2)^T = \left(-\frac{8}{9}\right)(-2) +$$

共轭梯度法的优势： 存储量 $O(n)$ （只需存上一轮梯度），每次迭代只需算梯度（无需 Hessian），对大规模问题（ n 成千上万）是唯一可行的选择。PPT 第 10.7 页给出了共轭梯度法的归纳证明框架。

10.3 共轭梯度法

证明: 由于 $f(x)$ 严格凸, 要证明 $x^{(k+1)}$ 是函数 $f(x)$ 在线性流形 $x^{(1)} + \Gamma_k$ 上的唯一极小点, 只要证在 $x^{(k+1)}$ 点, $\nabla f(x^{(k+1)})$ 与子空间 Γ_k 正交.

用归纳法证之, 为方便, 用 g_j 表示函数 $f(x)$ 在 $x^{(j)}$ 处的梯度, 即

$$g_j = \nabla f(x^{(j)}) \quad (10.3.6)$$

证明 $g_{k+1} \perp \Gamma_k$, 对 k 归纳

当 $k=1$, 由一维搜索的定义知 $g_2 \perp \Gamma_1$.

假设 $k=m < n$ 时 $g_{m+1} \perp \Gamma_m$, 下证 $g_{m+2} \perp \Gamma_{m+1}$.

8.7 拟牛顿法——用梯度变化”猜”曲率

8.7.1 牛顿法的三大软肋

牛顿法方向 $d = -[\nabla^2 f]^{-1} \nabla f$ 好在哪里? 好在方向精确——它直接指向二次模型的极小点。但它有三个实际障碍:

1. **Hessian 矩阵计算贵:** $\nabla^2 f$ 有 $n(n+1)/2$ 个独立二阶偏导数

2. 求逆更贵：矩阵求逆是 $O(n^3)$ 量级

3. 不一定正定：牛顿方向可能不是下降方向（若 Hessian 有负特征值）

核心洞察：我们其实不需要直接知道 Hessian 的全部信息——只需要从迭代过程中观察到的梯度变化来推断曲率。就像盲人用拐杖探路：每走一步感知一次坡度变化，走得多了自然摸清地形轮廓。

8.7.2 拟牛顿条件的由来

观察一个关键事实。对二次函数 $f(x) = \frac{1}{2}x^T Qx + c^T x$ ，有 $\nabla f(x) = Qx + c$ 。因此相邻两点 $x^{(k)}$ 与 $x^{(k-1)}$ 的梯度差满足：

$$\nabla f^{(k)} - \nabla f^{(k-1)} = Q(x^{(k)} - x^{(k-1)})$$

记 $s_{k-1} = x^{(k)} - x^{(k-1)}$ （位移差）， $y_{k-1} = \nabla f^{(k)} - \nabla f^{(k-1)}$ （梯度差），则：

$$y_{k-1} = Qs_{k-1} \implies s_{k-1} = Q^{-1}y_{k-1}$$

注意： Q^{-1} 就是 Hessian 的逆！对于一般的非二次函数，我们要求近似 Hessian 逆矩阵 H_k 也满足同样的关系：

定义 8.5（拟牛顿条件 / 割线方程）

$$H_k y_{k-1} = s_{k-1}$$

解读：在方向 y_{k-1} 上， H_k 把“梯度变化”映射为“位移变化”——这和真正的 Hessian 逆的行为一致。 H_k 不能仅由此式唯一确定（ n 个方程 vs n^2 个未知数），不同补充条件导出不同的拟牛顿公式。

8.7.3 DFP 校正公式——两项的含义

DFP（Davidon-Fletcher-Powell）方法维护 $H_k \approx [\nabla^2 f]^{-1}$ （Hessian 逆的近似）。每步从 H_{k-1} 出发，加上两个秩 1 修正：

定义 8.6 (DFP 校正公式)

$$H_k = H_{k-1} + \underbrace{\frac{s_{k-1}s_{k-1}^T}{s_{k-1}^T y_{k-1}}}_{\text{正定修正}} - \underbrace{\frac{H_{k-1}y_{k-1}y_{k-1}^T H_{k-1}}{y_{k-1}^T H_{k-1} y_{k-1}}}_{\text{擦除修正}}$$

两项的因果逻辑:

- **第一项 (正定修正):** 用位移差 s_{k-1} 构造秩 1 矩阵。这一项保证了 $H_k y_{k-1} = s_{k-1}$ 在 $H_{k-1} = 0$ 的极端情况下也成立——它“塞入”了方向 s_{k-1} 上的新曲率信息。分子 ss^T 是外积, 分母 $s^T y$ 做归一化。
- **第二项 (擦除修正):** 减去 H_{k-1} 在 y_{k-1} 方向上的“投影”。 H_{k-1} 中存储的旧曲率可能不准确——这一项把 H_{k-1} 沿 y_{k-1} 方向上的分量“擦掉”, 给第一项新信息腾位置。代入检验可知: 若无第二项, $H_k y_{k-1} \neq s_{k-1}$ 。
- **遗传正定性:** 若 $H_{k-1} \succ 0$ 且 $s_{k-1}^T y_{k-1} > 0$, 则 $H_k \succ 0$ 也正定——每一步都保持 Hessian 逆近似的正定性。

PPT 第 10.52 页给出了 DFP 算法（原称变尺度法）的整体流程，包括初始化 $H_0 = I$ 、确定方向 $d = -H\nabla f$ 、线搜索、计算 s 和 y 、DFP 校正的完整循环。

10.4 拟牛顿法

10.52

□ 4.3 对称秩2校正

•4.3.1, DFP算法(变尺度法)

定义校正矩阵

$$\Delta H_k = \frac{p^{(k)} p^{(k)T}}{p^{(k)T} q^{(k)}} - \frac{H_k q^{(k)} q^{(k)T} H_k}{q^{(k)T} H_k q^{(k)}} \quad (10.4.17)$$

则

$$H_{k+1} = H_k + \frac{p^{(k)} p^{(k)T}}{p^{(k)T} q^{(k)}} - \frac{H_k q^{(k)} q^{(k)T} H_k}{q^{(k)T} H_k q^{(k)}} \quad (10.4.18)$$

DFP(Davidon-Fletcher-Powell)公式

10.4 拟牛顿法

□ DFP算法

Step1, 给定初始点 $x^{(k)} \in E^n$, 允许误差 $\varepsilon > 0$,

Step2, 置 $H_1 = I_n$, 计算出在 $x^{(1)}$ 处的梯度

$$g_1 = \nabla f(x^{(1)})$$

置 $k = 1$

Step3, 令 $d^{(k)} = -H_k g_k$

Step4, 从 $x^{(k)}$ 出发, 沿 $d^{(k)}$ 进行一维搜索, 求 λ_k , 使

$$f(x^{(k)} + \lambda_k d^{(k)}) = \min_{\lambda \geq 0} f(x^{(k)} + \lambda d^{(k)})$$

令 $x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$,

8.7.4 DFP 2×2 矩阵算例——手把手演示

下面用最简单的情形展示 DFP 校正公式如何把 $H_0 = I$ (对角) 变成包含曲率信息的 H_1 (非对角)。

【2×2 DFP 演示】

$$f(x_1, x_2) = \frac{1}{2}(x_1^2 + 2x_2^2), \quad x^{(0)} = (2, 1)^T, \quad H_0 = I$$

(f 是正定二次函数, $Q = \text{diag}(1, 2)$, 真逆 $Q^{-1} = \text{diag}(1, 1/2)$ 。)

第 1 步 (同最速下降, $H_0 = I$)

$$\nabla f = (x_1, 2x_2)^T, \quad \nabla f^{(0)} = (2, 2)^T. \quad d^{(0)} = -H_0 \nabla f^{(0)} = -(2, 2)^T.$$

线搜索: $\phi(\lambda) = \frac{1}{2}[(2-2\lambda)^2 + 2(1-2\lambda)^2] = 3 - 8\lambda + 6\lambda^2$.
 $\phi'(\lambda) = -8 + 12\lambda = 0 \Rightarrow \lambda_0 = 2/3$ 。

$$x^{(1)} = \left(2 - \frac{4}{3}, 1 - \frac{4}{3}\right)^T = \left(\frac{2}{3}, -\frac{1}{3}\right)^T$$

计算 s_0 和 y_0

$$\nabla f^{(1)} = (2/3, -2/3)^T.$$

$$s_0 = x^{(1)} - x^{(0)} = \left(-\frac{4}{3}, -\frac{4}{3}\right)^T = -\frac{4}{3} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$y_0 = \nabla f^{(1)} - \nabla f^{(0)} = \left(-\frac{4}{3}, -\frac{8}{3}\right)^T = -\frac{4}{3} \begin{pmatrix} 1 \\ 2 \end{pmatrix}$$

验证: $Qs_0 = \text{diag}(1, 2) \cdot (-\frac{4}{3})(1, 1)^T = (-\frac{4}{3})(1, 2)^T = y_0$ 。

✓

DFP 校正 (从 $H_0 = I$ 到 H_1)

计算三项中间量:

$$s_0^T y_0 = \frac{16}{9}(1 \cdot 1 + 1 \cdot 2) = \frac{48}{9} = \frac{16}{3}$$

$$s_0 s_0^T = \frac{16}{9} \begin{pmatrix} 1 \\ 1 \end{pmatrix} \begin{pmatrix} 1 & 1 \end{pmatrix} = \frac{16}{9} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$$

$$y_0^T H_0 y_0 = \frac{16}{9}(1^2 + 2^2) = \frac{80}{9}$$

$$H_0 y_0 y_0^T H_0 = \frac{16}{9} \begin{pmatrix} 1 \\ 2 \end{pmatrix} \begin{pmatrix} 1 & 2 \end{pmatrix} = \frac{16}{9} \begin{pmatrix} 1 & 2 \\ 2 & 4 \end{pmatrix}$$

第一项 (正定修正):

$$\frac{s_0 s_0^T}{s_0^T y_0} = \frac{\frac{16}{9} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}}{\frac{16}{3}} = \frac{1}{3} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$$

第二项 (擦除修正):

$$\frac{H_0 y_0 y_0^T H_0}{y_0^T H_0 y_0} = \frac{\frac{16}{9} \begin{pmatrix} 1 & 2 \\ 2 & 4 \end{pmatrix}}{\frac{80}{9}} = \frac{1}{5} \begin{pmatrix} 1 & 2 \\ 2 & 4 \end{pmatrix}$$

合并得到 H_1 :

$$\begin{aligned} H_1 &= I + \frac{1}{3} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} - \frac{1}{5} \begin{pmatrix} 1 & 2 \\ 2 & 4 \end{pmatrix} \\ &= \begin{pmatrix} 1 + \frac{1}{3} - \frac{1}{5} & \frac{1}{3} - \frac{2}{5} \\ \frac{1}{3} - \frac{2}{5} & 1 + \frac{1}{3} - \frac{4}{5} \end{pmatrix} \\ &= \begin{pmatrix} \frac{17}{15} & -\frac{1}{15} \\ -\frac{1}{15} & \frac{8}{15} \end{pmatrix} \approx \begin{pmatrix} 1.133 & -0.067 \\ -0.067 & 0.533 \end{pmatrix} \end{aligned}$$

解读 H_1 : 对比真逆 $Q^{-1} = \text{diag}(1, 0.5)$, H_1 的对角元已开始逼近真实值 ($1.133 \rightarrow 1$, $0.533 \rightarrow 0.5$), 且出现了非对角元 (-0.067) ——这意味着 DFP“意识到”两个坐标轴之间存在曲率耦合 (尽管本题 Q 实际是对角的, 初始 $H_0 = I$ 的不准确导致了非对角补偿)。一次校正虽未精确复原 Q^{-1} , 但已经显著优于 $H_0 = I$ 。

第 2 步 (使用 H_1 , 验证二次终止性)

$d^{(1)} = -H_1 \nabla f^{(1)}$ 。先算矩阵乘向量：

$$\begin{aligned} H_1 \nabla f^{(1)} &= \begin{pmatrix} \frac{17}{15} & -\frac{1}{15} \\ -\frac{1}{15} & \frac{8}{15} \end{pmatrix} \begin{pmatrix} 2/3 \\ -2/3 \end{pmatrix} \\ &= \begin{pmatrix} 34/45 + 2/45 \\ -2/45 - 16/45 \end{pmatrix} = \begin{pmatrix} 36/45 \\ -18/45 \end{pmatrix} \end{aligned}$$

故 $d^{(1)} = -H_1 \nabla f^{(1)} = (-4/5, 2/5)^T$ 。

线搜索： $\phi(\lambda) = \frac{1}{2}[(\frac{2}{3} - \frac{4}{5}\lambda)^2 + 2(-\frac{1}{3} + \frac{2}{5}\lambda)^2] = \frac{1}{3} - \frac{4}{5}\lambda + \frac{12}{25}\lambda^2$ 。 $\phi'(\lambda) = -\frac{4}{5} + \frac{24}{25}\lambda = 0 \Rightarrow \lambda_1 = \frac{5}{6}$ 。

$$\begin{aligned} x^{(2)} &= \left(\frac{2}{3} - \frac{4}{5} \cdot \frac{5}{6}, -\frac{1}{3} + \frac{2}{5} \cdot \frac{5}{6} \right)^T \\ &= \left(\frac{2}{3} - \frac{2}{3}, -\frac{1}{3} + \frac{1}{3} \right)^T = (0, 0)^T \end{aligned}$$

$\nabla f(0, 0) = (0, 0)^T$ 。两轮收敛 ($n = 2$)！

DFP 的二次终止性：对正定二次函数，DFP 法至多 n 步收敛到精确极小点。且若每步精确线搜索，则产生的方向 $d^{(0)}, \dots, d^{(n-1)}$ 关于 Q 相互共轭。

PPT 第 10.56–10.57 页通过数值示例展示了拟牛顿法

的第 1 次和第 2 次迭代全过程, PPT 第 10.63 页专门论证了 DFP 的二次终止性。

10.56

10.4 拟牛顿法

第1次迭代

在点 $x^{(1)}$ 处的梯度 $g_1 = \begin{pmatrix} 4 \\ 2 \end{pmatrix}$

令搜索方向

$$d^{(1)} = -H_1 g_1 = \begin{pmatrix} -4 \\ -2 \end{pmatrix}$$

从 $x^{(1)}$ 出发,沿方向 $d^{(1)}$ 进行一维搜索,求步长 λ_1 :

$$\min_{\lambda \geq 0} f(x^{(1)} + \lambda d^{(1)})$$

得到

$$\lambda_1 = \frac{5}{18}$$

10.4 拟牛顿法

令

$$x^{(2)} = x^{(1)} + \lambda_1 d^{(1)} = \begin{bmatrix} 2 \\ 1 \end{bmatrix} + \frac{5}{18} \begin{bmatrix} -4 \\ -2 \end{bmatrix} = \begin{bmatrix} 8/9 \\ 4/9 \end{bmatrix}$$

$$g_2 = \begin{bmatrix} 4(\frac{8}{9}-1) \\ 2\frac{4}{9} \end{bmatrix} = \begin{bmatrix} -4/9 \\ 8/9 \end{bmatrix}$$

10.4 拟牛顿法

□ 2 DFP算法的正定性及二次终止性

定理10.4.1 若 $g_i \neq 0, i = 1, 2, \dots, n$, 则DFP方法构造的矩阵 $H_i (i = 1, 2, \dots, n)$ 为对称正定矩阵.

证明: 用归纳法

DFP方法中, H_1 是给定的对称正定矩阵.

设 H_j 是对称正定矩阵, 下证 H_{j+1} 也是对称正定矩阵.

根据定义, 对称性是显然的, 下证正定性

8.7.5 BFGS——DFP 的互补兄弟

BFGS 不是维护 H_k (逆的近似), 而是维护 $B_k \approx \nabla^2 f$ (Hessian 本身的近似)。将 DFP 公式中所有 s 与 y 互换, H 换成 B , 就得到 BFGS:

定义 8.7 (BFGS 校正公式)

$$B_k = B_{k-1} + \frac{y_{k-1}y_{k-1}^T}{y_{k-1}^T s_{k-1}} - \frac{B_{k-1}s_{k-1}s_{k-1}^T B_{k-1}}{s_{k-1}^T B_{k-1}s_{k-1}}$$

拟牛顿条件对应为 $B_k s_{k-1} = y_{k-1}$ (B_k 把位移映射为梯度变化)。

DFP 与 BFGS 的对偶关系:

- DFP 校 H (逆) $\longleftrightarrow$ BFGS 校 B (Hessian 本身)
- DFP: $H_k y = s \longleftrightarrow$ BFGS: $B_k s = y$
- 记忆口诀: DFP 公式中分子是 ss^T 和 $Hyy^T H$, BFGS 公式中分子是 yy^T 和 $Bss^T B$

考试以 DFP 为主。BFGS 在实际计算中通常更鲁棒（对非精确线搜索不敏感），但公式结构完全对称，理解了一个就理解了另一个。

8.8 真题示例：第四题——DFP 拟牛顿法完整求解

【2025 真题 · 第四题】

$$\min f(X) = x_1^2 + 2x_2^2 + x_1$$

$$X^{(0)} = (2, 1)^T, \quad H_0 = I$$

用 DFP 方法求解（需做两轮迭代至收敛）。

第 1 轮迭代

梯度： $\nabla f = (2x_1 + 1, 4x_2)^T$ 。在 $X^{(0)}$ 处： $\nabla f^{(0)} = (5, 4)^T$ 。

方向： $d^{(0)} = -H_0 \nabla f^{(0)} = -(5, 4)^T$ （第一步等价于最速下降）。

一维搜索： $X^{(0)} + \lambda d^{(0)} = (2 - 5\lambda, 1 - 4\lambda)^T$ 。

$$\begin{aligned}\phi(\lambda) &= (2 - 5\lambda)^2 + 2(1 - 4\lambda)^2 + (2 - 5\lambda) \\&= (4 - 20\lambda + 25\lambda^2) + 2(1 - 8\lambda + 16\lambda^2) + 2 - 5\lambda \\&= (25 + 32)\lambda^2 + (-20 - 16 - 5)\lambda + (4 + 2 + 2) \\&= 57\lambda^2 - 41\lambda + 8\end{aligned}$$

$$\phi'(\lambda) = 114\lambda - 41 = 0 \Rightarrow \lambda_0 = 41/114。$$

$$X^{(1)} = \frac{1}{114}(228 - 205, 114 - 164)^T = \frac{1}{114}(23, -50)^T$$

$$\nabla f^{(1)} = \left(\frac{46}{114} + 1, \frac{-200}{114} \right)^T = \frac{1}{114}(160, -200)^T$$

DFP 校正 ($H_0 \rightarrow H_1$)

$$s_0 = X^{(1)} - X^{(0)} = \frac{1}{114}(-205, -164)^T = -\frac{41}{114}(5, 4)^T$$

$$y_0 = \nabla f^{(1)} - \nabla f^{(0)} = \frac{1}{114}(-410, -656)^T = -\frac{41}{114}(10, 16)^T$$

三个中间量（提取公共因子 41/114）：

$$s_0^T y_0 = \frac{41^2}{114^2} (5 \cdot 10 + 4 \cdot 16) = \frac{41^2}{114}$$

$$s_0 s_0^T = \frac{41^2}{114^2} \begin{pmatrix} 25 & 20 \\ 20 & 16 \end{pmatrix}$$

$$y_0^T H_0 y_0 = \frac{41^2}{114^2} (10^2 + 16^2) = \frac{41^2}{114^2} \cdot 356$$

DFP 两项（代入化简）：

$$\begin{aligned} \frac{s_0 s_0^T}{s_0^T y_0} &= \frac{41^2/114^2}{41^2/114} \begin{pmatrix} 25 & 20 \\ 20 & 16 \end{pmatrix} \\ &= \frac{1}{114} \begin{pmatrix} 25 & 20 \\ 20 & 16 \end{pmatrix} \approx \begin{pmatrix} 25/114 & 20/114 \\ 20/114 & 16/114 \end{pmatrix} \end{aligned}$$

$$\begin{aligned} \frac{H_0 y_0 y_0^T H_0}{y_0^T H_0 y_0} &= \frac{41^2/114^2}{41^2/114^2 \cdot 356} \begin{pmatrix} 100 & 160 \\ 160 & 256 \end{pmatrix} \\ &= \frac{1}{356} \begin{pmatrix} 100 & 160 \\ 160 & 256 \end{pmatrix} \approx \begin{pmatrix} 100/356 & 160/356 \\ 160/356 & 256/356 \end{pmatrix} \end{aligned}$$

$$H_1 = I + \frac{1}{114} \begin{pmatrix} 25 & 20 \\ 20 & 16 \end{pmatrix} - \frac{1}{356} \begin{pmatrix} 100 & 160 \\ 160 & 256 \end{pmatrix}$$

(完整数值结果见课件。核心： H_1 从对角 I 变成了非对角矩阵，包含了从 s_0, y_0 中提取的曲率信息。)

第 2 轮迭代与收敛

$d^{(1)} = -H_1 \nabla f^{(1)}$ 。一维搜索得 $\lambda_1 = 89/228$ 。

$$X^{(2)} = \left(-\frac{1}{2}, 0\right)^T$$

$\nabla f(X^{(2)}) = (0, 0)^T \Rightarrow$ 驻点。 $\nabla^2 f = \text{diag}(2, 4) \succ 0 \Rightarrow X^{(2)}$ 是全局极小点。

$$f^* = f\left(-\frac{1}{2}, 0\right) = \frac{1}{4} + 0 - \frac{1}{2} = -\frac{1}{4}$$

二次终止性验证： $n = 2$ ，恰好两轮收敛——DFP 的理论保证在此得到完美展示。

本章速查

- 下降算法框架: $x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}, \nabla f^T d < 0$
- 最速下降: $d = -\nabla f$, 局部最快但全局锯齿, $d^{(k)} \perp d^{(k+1)}$
- 牛顿法: $d = -[\nabla^2 f]^{-1} \nabla f$, 二次收敛但 $O(n^3)$ 贵
- 精确线搜索: 解 $\phi'(\lambda) = 0$; **Armijo**: 回溯缩步, 保证充分下降
- **FR 共轭梯度**: $\beta_k = \|\nabla f^{(k)}\|^2 / \|\nabla f^{(k-1)}\|^2$, $d^{(k)} = -\nabla f^{(k)} + \beta_k d^{(k-1)}$, $O(n)$ 存储, n 步收敛
- 拟牛顿条件 (割线方程): $H_k y_{k-1} = s_{k-1}$
- **DFP 公式** (校 H , 逆): 两项秩 1 修正——正定修正 $(s s^T / s^T y)$ + 擦除修正 $(H y y^T H / y^T H y)$
- **BFGS 公式** (校 B , Hessian 本身): DFP 的 $s \leftrightarrow y$ 对偶, 考试以 DFP 为主

- **二次终止性：**对正定二次函数，DFP/BFGS/共轭梯度法至多 n 步收敛
- **遗传正定性：**在 $s^T y > 0$ 条件下，DFP/BFGS 保持近似矩阵的正定性

第 9 章 约束优化方法

9.1 约束优化方法的两大流派

第 8 章的方法适用于无约束问题。一旦加上等式或不等式约束，下降方向的选择就必须兼顾“能不能走”（可行性）。由此分出两条路：

- **可行方向法：**始终保持在可行域内，每次迭代找下降可行方向——既要让目标下降，又不能跑出可行域。代表：Zoutendijk 法、Rosen 梯度投影法。
- **罚函数法：**将约束问题转化为一系列无约束问题。对违反约束的行为加以惩罚，惩罚力度逐轮加大，迫使无约束问题的解趋向原约束问题

的解。代表：外点法（SUMT）、内点法（障碍法）、乘子法。

PPT 第 12.1–12.2 页给出了可行方向法的引入动机和基本框架。

12 可行方向法

12.1

求解无约束问题下降算法的过程是

在当前点 $x^{(k)}$ 处，寻找目标函数 f 的下降方向 $d^{(k)}$ ，然后从 $x^{(k)}$ 出发，沿 $d^{(k)}$ 进行一维搜索，产生步长 λ_k ，进而得到

$$x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$$

解约束问题的可行方向法与求解无约束问题的下降算法类似：可行方向法从问题的可行点出发，在该点的可行方向中，寻找使目标函数下降的方向，然后沿该方向进行线性搜索，得到一个新的可行点。

1. Zoutendijk可行方向法

1.1 线性约束情形

考虑NLP问题

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & Ax \geq b \\ & Ex = e \end{aligned} \quad (12.1.1)$$

其中 $f(x)$ 可微, A 为 $m \times n$ 矩阵, E 为 $l \times n$ 矩阵,
 $x \in R^n$, b 和 c 分别为 m 和 l 维列向量.

9.2 可行方向法通用框架

假设当前在可行点 $x^{(k)}$ 。我们需要：

1. 找下降方向 d : $\nabla f(x^{(k)})^T d < 0$
2. 同时 d 是可行方向: 对充分小的 $\lambda > 0$, $x^{(k)} + \lambda d$ 仍在可行域内

积极约束 (active constraints) —— 当前取等号的不等式约束 —— 决定了可行方向的范围：

- 对于积极不等式约束 $g_i(x) \leq 0$ （此时 $g_i(x) = 0$ ），可行方向要求 $\nabla g_i(x)^T d \leq 0$ （不能指向域外）
- 对于等式约束 $h_j(x) = 0$ ，可行方向要求 $\nabla h_j(x)^T d = 0$ （必须沿切向）
- 非积极约束（ $g_i(x) < 0$ ）在局部可以忽略——只要步长足够小就不会碰到边界

通用算法框架：

1. 给定初始可行点 $x^{(0)}$ ，令 $k = 0$
2. 确定 $x^{(k)}$ 处的积极约束集 I_k
3. 求解子问题得到下降可行方向 $d^{(k)}$
4. 沿 $d^{(k)}$ 做一维搜索（详见第 8 章），找到能保持可行性的最大步长
5. 更新 $x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$
6. 若满足 KKT 条件则停止（KKT 条件的定义见第 6 章），否则 $k \leftarrow k + 1$ 回第 2 步

不同的可行方向法，区别在于第 3 步如何确定搜索方向。

9.3 Rosen 梯度投影法

核心思想

Rosen 法的核心思想：将负梯度方向投影到约束的切空间上，得到既下降又（局部）可行的方向。

为什么要投影？ 负梯度 $-\nabla f$ 是下降最快的方向（详见第 8 章最速下降法），但它可能指向可行域外部——直接沿负梯度走会违反约束。我们把 $-\nabla f$ 投影到约束的切空间（所有可行方向所在的空间），得到的投影方向既保留了下降性，又保证了局部可行性。

投影矩阵

设积极约束的系数矩阵为 M （每行是一个积极约束的梯度 $\nabla g_i(x)^T$ ，仅对线性约束）。则投影矩阵为：

$$P = I - M^T(MM^T)^{-1}M$$

P 是把任意向量正交投影到约束切空间（ M 的零空间）上的投影算子。

搜索方向： $d = -P\nabla f$ （负梯度在切线空间上的正交投影）。

投影矩阵的具体算例

问题：设有一条约束 $x_1 + x_2 = 0$ （一维直线），求投影矩阵，并验证投影效果。

解：积极约束系数矩阵 $M = [1 \ 1]$ 。

1. 计算 $MM^T = [1 \ 1] \begin{bmatrix} 1 \\ 1 \end{bmatrix} = [2]$ ，即 $2 \times 1 = 2$

2. $(MM^T)^{-1} = [\frac{1}{2}]$

$$3. M^T(MM^T)^{-1}M = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \cdot \frac{1}{2} \cdot [1 \quad 1] = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 0.5 & 0.5 \\ 0.5 & 0.5 \end{bmatrix}$$

$$4. P = I - M^T(MM^T)^{-1}M:$$

$$P = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} - \begin{bmatrix} 0.5 & 0.5 \\ 0.5 & 0.5 \end{bmatrix} = \begin{bmatrix} 0.5 & -0.5 \\ -0.5 & 0.5 \end{bmatrix}$$

验证：约束 $x_1 + x_2 = 0$ 的切空间是 $\{d : d_1 + d_2 = 0\}$ ，即沿 $(1, -1)$ 方向。

$$\bullet P \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \begin{bmatrix} 0.5 & -0.5 \\ -0.5 & 0.5 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \begin{bmatrix} 1 \\ -1 \end{bmatrix} \text{——切向量保持不变}$$

$$\bullet P \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 0.5 & -0.5 \\ -0.5 & 0.5 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \text{——法向量被消灭}$$

这正是投影算子的性质：切空间内的向量原样保留，法向量（梯度方向）被归零。

投影矩阵的几何直觉： $P\nabla f = 0$ 意味着梯度完全落在约束法向量的张成空间中——此时 $-\nabla f$ 没有“切向分量”可走，说明当前点已是（局部）约束最优，这就是 KKT 条件的几何解释。 $P\nabla f \neq 0$ 意味着梯度在切方向上有分量，沿 $-P\nabla f$ 移动可以下降且不立即违反约束。




图 9.1: Rosen 梯度投影法的几何解释——将负梯度投影到约束切空间

PPT 第 12.36、12.38 页给出了 Rosen 法的概念和投影方向推导，下面两页对照阅读。

2. Rosen梯度投影法

定义1 对于矩阵 $P \in R^{n \times n}$, 若 $P^2 = P$, 则称 P 为投影算子矩阵. 若 $P^2 = P$, 且 $P^T = P$, 则称 P 为正交投影算子矩阵. 对于投影算子 P , 集合

$$\mathfrak{R}(P) = \{Px \mid x \in R^n\}, N(P) = \{(I - P)x \mid x \in R^n\}$$

分别称为它的值空间和零空间.

例1 设矩阵

$$P = \begin{pmatrix} 1 & 1 \\ 0 & 0 \end{pmatrix}, \Rightarrow P^2 = P, R(P) = \{x = (x_1, x_2) \mid x_2 = 0\};$$

$$N(P) = \{x = (x_1, x_2) \mid x_1 + x_2 = 0\}$$

2. Rosen梯度投影法

基本思想: 用积极约束系数矩阵的行向量生成一个法向量空间, 将目标函数的负梯度方向正交投影到该法向量空间的正交补中, 获得一个使目标函数下降的可行方向; 然后, 从当前的迭代点出发, 沿着使目标函数下降的可行方向搜索, 寻找一个新的改进点, 直到得到约束优化问题 (LCO) 的一个 KKT 点.

定理12.2.1 设 x 为问题 (12.1.1) 的可行点, 在 x 处 $A_1 x = b_1, A_2 x > b_2$.

其中 $A = \begin{pmatrix} A_1 \\ A_2 \end{pmatrix}$, $b = \begin{pmatrix} b_1 \\ b_2 \end{pmatrix}$, 记矩阵 $M = \begin{pmatrix} A_1 \\ E \end{pmatrix}$ 是行满秩的,

$P_{N(M)} = I - M^T (MM^T)^{-1} M$ 且正交投影向量 $d = -P_{N(M)} \nabla f(\bar{x}) \neq 0$,

则 d 是问题 (12.1.1) 的一个下降的可行方向.

积极约束集的维护（关键难点）

Rosen 法最精巧之处在于何时加入约束、何时移除约束。这不是一个“有了投影矩阵就万事大吉”的方法——积极约束集会随着迭代变化。

加入：一维搜索时，若步长 λ 被某个之前非积极的不等式约束 g_i 所限制（即 $x + \lambda d$ 使 g_i 从 < 0 变为 $= 0$ ），将该约束加入积极集 M ，重新计算 P 。

移除：若 $d = -P\nabla f = 0$ （投影梯度为零，当前积极集内无法再下降），检查 KKT 乘子 $\lambda = -(MM^T)^{-1}M\nabla f$ 。若存在 $\lambda_i < 0$ ，说明第 i 个约束其实是“假的”积极约束——去掉它反而可以继续下降。将 $\lambda_i < 0$ 对应的约束从积极集中移除，回到前一步重新计算 P 。

因果逻辑： $\lambda_i < 0$ 的几何含义是该约束的法向量与目标下降方向“同向”——约束在“推”着我们往错误的方向走。去掉它，目标函数才能继续下降。若所有 $\lambda_i \geq 0$ ，则满足 KKT 必要条件，当前点即局部最优。PPT 第 12.40 页给出了 Rosen 法完整的算法流程和积极约束集增删的判断逻辑。

2. Rosen梯度投影法

步1 (初始化) 初始点 x^0 , 置 $k=0$

步2 (计算投影向量) 确定积极约束指标集 $A(x^k) = I(x^k) \cup E(x^k)$ 和积极约束系数矩阵 $M = (a_i \mid i \in A(x^k))^T$. 计算负梯度方向

$d^k = -P_{N(M)} \nabla f(x^k)$. 若 $d^k = 0$, 转步3, 否则转步4

步3 (收敛性检验) 计算 $w = (MM^T)^{-1} M \nabla f(x^k) = (u^T, v^T)^T$, 令

$u^T = (u_i \mid i \in I(x^k))$, $v^T = (v_j \mid j \in E(x^k))$,

若 $u \geq 0$, 则 x^k 为KKT点, Stop; 否则选择 $i_0 = \arg \min_i u_i$, 从矩阵M中

去掉 i_0 对应的行, 得子矩阵 $\tilde{M}$, 重新计算 $d^k = -P_{N(\tilde{M})} \nabla f(x^k)$, 转步4.

步4 (迭代改进) 求解对应的一维优化问题 (13.1.25), 当最优解有界时得线搜索的最优步长 α_k , 并且置, $x^{k+1} = x^k + \alpha_k d^k$ 转步2, 否则, 算法停止。

9.4 Zoutendijk 可行方向法

Zoutendijk 法用线性规划子问题来找方向: 在满足所有下降条件和可行方向条件的前提下, 选择使目标函数沿该方向下降最快的方向。本质是把“找方向”变成一个 LP 求解。

对线性约束情况，子问题是：

$$\begin{aligned} \min \quad & \nabla f(x^{(k)})^T d \\ \text{s.t.} \quad & \nabla g_i(x^{(k)})^T d \leq 0 \quad (i \in I_k) \\ & -1 \leq d_j \leq 1 \quad (\text{归一化防止无界}) \end{aligned}$$

Zoutendijk 法适用范围广，但每步都要解一个 LP，计算成本比 Rosen 法高。考试重点在 Rosen 法。

9.5 真题示例：第五题——Rosen 梯度投影法

【2025 真题 · 第五题】（完整保留）

$$\begin{aligned} \min \quad & x_1^2 + 2x_2^2 - x_1x_2 + x_3^2 + x_3 \\ \text{s.t.} \quad & x_1 + x_2 = 6 \\ & -x_1 + x_2 + x_3 \leq 2 \\ & x_1, x_2, x_3 \geq 0 \end{aligned}$$

化简与初始点

目标函数对 x_3 的偏导数： $\frac{\partial f}{\partial x_3} = 2x_3 + 1$ 。在可行域内 $x_3 \geq 0$ ，故 $\frac{\partial f}{\partial x_3} > 0$ (x_3 增大则 f 增大)，最优解必在 $x_3^* = 0$ 处。问题化为二维。

取初始可行点 $X^{(0)} = (2, 2, 2)^T$ 。验证： $x_1 + x_2 = 4 \neq 6$ ——不对！实际取 $X^{(0)} = (2, 4, 0)^T$ 更合适。

取 $X^{(0)} = (2, 2, 2)^T$ 验证约束： $x_1 + x_2 = 4 \neq 6$ ，该点不可行。重新选：设 $x_3 = 0$ ， $x_1 + x_2 = 6$ ，取对称点 $x_1 = x_2 = 3$ 。检查 $-3 + 3 + 0 = 0 \leq 2$ ，可行。故取 $X^{(0)} = (3, 3, 0)^T$ 。

在 $X^{(0)}$ 处， $x_1 + x_2 = 6$ （等式，始终积极）， $x_3 = 0$ （积极）。故积极约束有两个：

$$h_1 : x_1 + x_2 - 6 = 0, \quad g_1 : -x_3 \leq 0 \text{ (即 } x_3 \geq 0 \text{)}$$

积极约束系数矩阵（取梯度）：

$$\nabla h_1 = (1, 1, 0)^T, \quad \nabla(-x_3) = (0, 0, -1)^T$$

$$M = \begin{pmatrix} 1 & 1 & 0 \\ 0 & 0 & -1 \end{pmatrix}$$

计算梯度

$$\nabla f = \begin{pmatrix} 2x_1 - x_2 \\ 4x_2 - x_1 \\ 2x_3 + 1 \end{pmatrix}, \quad \nabla f^{(0)} = \begin{pmatrix} 3 \\ 9 \\ 1 \end{pmatrix}$$

计算投影矩阵

$$MM^T = \begin{pmatrix} 1 & 1 & 0 \\ 0 & 0 & -1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 1 & 0 \\ 0 & -1 \end{pmatrix} = \begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix}$$

$$(MM^T)^{-1} = \begin{pmatrix} 1/2 & 0 \\ 0 & 1 \end{pmatrix}$$

$$M^T(MM^T)^{-1} = \begin{pmatrix} 1 & 0 \\ 1 & 0 \\ 0 & -1 \end{pmatrix} \begin{pmatrix} 1/2 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 1/2 & 0 \\ 1/2 & 0 \\ 0 & -1 \end{pmatrix}$$

$$M^T(MM^T)^{-1}M = \begin{pmatrix} 1/2 & 0 \\ 1/2 & 0 \\ 0 & -1 \end{pmatrix} \begin{pmatrix} 1 & 1 & 0 \\ 0 & 0 & -1 \end{pmatrix} = \begin{pmatrix} 1/2 & 1/2 & 0 \\ 1/2 & 1/2 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

$$P = I - M^T(MM^T)^{-1}M = \begin{pmatrix} 1/2 & -1/2 & 0 \\ -1/2 & 1/2 & 0 \\ 0 & 0 & 0 \end{pmatrix}$$

搜索方向:

$$d^{(0)} = -P\nabla f^{(0)} = -\begin{pmatrix} 1/2 & -1/2 & 0 \\ -1/2 & 1/2 & 0 \\ 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} 3 \\ 9 \\ 1 \end{pmatrix} = -\begin{pmatrix} -3 \\ 3 \\ 0 \end{pmatrix}$$

验证: 沿 $d^{(0)}$ 移动, x_1 增 3, x_2 减 3, 满足 $x_1 + x_2 = 6$ (切方向), x_3 不变 (保持 $x_3 = 0$)。

一维搜索

$$X^{(0)} + \lambda d^{(0)} = (3 + 3\lambda, 3 - 3\lambda, 0)^T。$$

代入 f :

$$\phi(\lambda) = (3 + 3\lambda)^2 + 2(3 - 3\lambda)^2 - (3 + 3\lambda)(3 - 3\lambda) + 0 + 0$$

展开：

$$(3 + 3\lambda)^2 = 9 + 18\lambda + 9\lambda^2$$

$$2(3 - 3\lambda)^2 = 2(9 - 18\lambda + 9\lambda^2) = 18 - 36\lambda + 18\lambda^2$$

$$\begin{aligned} -(3 + 3\lambda)(3 - 3\lambda) &= -(9 - 9\lambda^2) \\ &= -9 + 9\lambda^2 \end{aligned}$$

$$\begin{aligned} \phi(\lambda) &= (9 + 18\lambda + 9\lambda^2) + (18 - 36\lambda + 18\lambda^2) \\ &\quad + (-9 + 9\lambda^2) \\ &= 18 - 18\lambda + 36\lambda^2 \end{aligned}$$

$$\phi'(\lambda) = -18 + 72\lambda = 0 \Rightarrow \lambda_0 = 1/4 = 0.25。$$

$X^{(1)} = (3 + 0.75, 3 - 0.75, 0)^T = (3.75, 2.25, 0)^T$ 。此时 $x_3 = 0$ 仍积极。

第二次迭代与 KKT 判定

在 $X^{(1)} = (3.75, 2.25, 0)^T$ ：

$$\nabla f^{(1)} = \begin{pmatrix} 2(3.75) - 2.25 \\ 4(2.25) - 3.75 \\ 2(0) + 1 \end{pmatrix} = \begin{pmatrix} 5.25 \\ 5.25 \\ 1 \end{pmatrix}$$

积极约束不变 ($x_1 + x_2 = 6$ 和 $x_3 = 0$), M 不变, P 不变。

$$d^{(1)} = -P\nabla f^{(1)} = -\begin{pmatrix} 1/2 & -1/2 & 0 \\ -1/2 & 1/2 & 0 \\ 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} 5.25 \\ 5.25 \\ 1 \end{pmatrix} = -\begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} = (0, 0, 0)^T$$

$d^{(1)} = 0$, 说明在当前积极约束集内梯度已在法向量张成空间中。检查 KKT 乘子:

$$\begin{aligned} \lambda &= -(MM^T)^{-1}M\nabla f^{(1)} \\ &= -\begin{pmatrix} 1/2 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 1 & 0 \\ 0 & 0 & -1 \end{pmatrix} \begin{pmatrix} 5.25 \\ 5.25 \\ 1 \end{pmatrix} \end{aligned}$$

$$M\nabla f^{(1)} = \begin{pmatrix} 10.5 \\ -1 \end{pmatrix}, \quad \lambda = -\begin{pmatrix} 5.25 \\ -1 \end{pmatrix} = \begin{pmatrix} -5.25 \\ 1 \end{pmatrix}$$

$\lambda_1 = -5.25 < 0$ (对应等式约束 $x_1 + x_2 = 6$) ——说明该约束的 KKT 乘子为负? 等等, 等式约束的乘子可以取任意实数值, 不等式约束的乘子必须 ≥ 0 。

对等式约束 $h = 0$, KKT 条件中乘子 μ 无符号限制。 $\mu = -5.25$ 是可以的。对不等式约束 $x_3 \geq 0$ ($-x_3 \leq 0$), 乘子 $\lambda_2 = 1 > 0$, 满足非负条件。

$d^{(1)} = 0$ 且不等式乘子 ≥ 0 , $X^{(1)}$ 是 KKT 点。

检查凸性: $\nabla^2 f = \begin{pmatrix} 2 & -1 & 0 \\ -1 & 4 & 0 \\ 0 & 0 & 2 \end{pmatrix}$, 顺序主子式 $2 > 0$,

$8 - 1 = 7 > 0$, $2 \times 7 = 14 > 0$, 正定。 f 凸, 约束线性 $\rightarrow$ 凸规划 $\rightarrow$ KKT 点即全局最优。

最优解 $X^* = (3.75, 2.25, 0)^T$, $f^* = 3.75^2 + 2(2.25)^2 - 3.75 \times 2.25 = 14.0625 + 10.125 - 8.4375 = 15.75$ 。

继续迭代验证 KKT 条件, 参考投影方向推导和算法步骤。

2. Rosen梯度投影法

基本思想:用积极约束系数矩阵的行向量生成一个法向量子空间,将目标函数的负梯度方向正交投影到该法向量子空间的正交补中,获得一个使目标函数下降的可行方向;然后,从当前的迭代点出发,沿着使目标函数下降的可行方向搜索,寻找一个新的改进点,直到得到约束优化问题(LCO)的一个KKT点.

定理12.2.1 设 $\bar{x}$ 为问题(12.1.1)的可行点,在 $\bar{x}$ 处 $A_1\bar{x} = b_1, A_2\bar{x} > b_2$.

其中 $A = \begin{pmatrix} A_1 \\ A_2 \end{pmatrix}$, $b = \begin{pmatrix} b_1 \\ b_2 \end{pmatrix}$, 记矩阵 $M = \begin{pmatrix} A_1 \\ E \end{pmatrix}$ 是行满秩的,

$P_{N(M)} = I - M^T(MM^T)^{-1}M$ 且正交投影向量 $d = -P_{N(M)}\nabla f(\bar{x}) \neq 0$, 则 d 是问题(12.1.1)的一个下降的可行方向.

2. Rosen梯度投影法

步1 (初始化)初始点 x^0 ,置 $k=0$

步2(计算投影向量)确定积极约束指标集 $A(x^k) = I(x^k) \cup E(x^k)$ 和积极约束系数矩阵 $M = (a_i \mid i \in A(x^k))^T$.计算负梯度方向

$d^k = -P_{N(M)}\nabla f(x^k)$.若 $d^k = 0$,转步3, 否则转步4

步3(收敛性检验)计算 $w = (MM^T)^{-1}M\nabla f(x^k) = (u^T, v^T)^T$, 令

$u^T = (u_i \mid i \in I(x^k)), v^T = (v_j \mid j \in E(x^k))$,

若 $u \geq 0$, 则 x^k 为KKT点, Stop; 否则选择 $i_0 = \arg \min_i u_i$, 从矩阵 M 中

去掉 i_0 对应的行, 得子矩阵 $\tilde{M}$, 重新计算 $d^k = -P_{N(\tilde{M})}\nabla f(x^k)$, 转步4.

步4(迭代改进) 求解对应的一维优化问题(13.1.25), 当最优解有界时得线搜索的最优步长 α_k , 并且置, $x^{k+1} = x^k + \alpha_k d^k$ 转步2, 否则, 算法停止.

9.6 罚函数法

罚函数法的基本思想：把约束优化转化为无约束优化。对违反约束的行为加惩罚项，惩罚力度逐步加大，使无约束解序列趋于原约束问题的解。

PPT 第 13.1–13.2 页给出了罚函数法的引入动机和 SUMT 框架，这是三种罚函数法的共同基础。

13 惩罚函数法

13.1

考虑约束问题

$$\begin{aligned} & \min f(x) \\ \text{s.t. } & g_i(x) \geq 0, i = 1, \dots, m \\ & h_j(x) = 0, j = 1, 2, \dots, l \end{aligned} \quad (13.1.1)$$

其中 $f(x)$, $g_i(x)$ 和 $h_j(x)$ 连续.

向量形式

$$\begin{aligned} & \min f(x) \\ \text{s.t. } & g(x) \geq 0, \\ & h(x) = 0 \end{aligned}$$

其中

$$\begin{aligned} g(x) &= (g_1(x), \dots, g_m(x))^T \\ h(x) &= (h_1(x), \dots, h_l(x))^T \end{aligned}$$

令问题的可行域为：

$$D = \left\{ x \left| \begin{array}{l} g_i(x) \geq 0, i = 1, \dots, m. \\ h_j(x) = 0, j = 1, \dots, l \end{array} \right. \right\}.$$

如何求解约束问题？

可行方向法：沿下降可行方向搜索

其他方法？

序列无约束优化算法：通过求解一系列无约束问题的解来近似约束问题的解。

罚函数法是序列无约束问题算法的典型代表。

9.6.1 外点法 (SUMT)

外点罚函数

对约束问题 $\min\{f(x) \mid g_i(x) \leq 0, h_j(x) = 0\}$, 构造罚函数:

$$P(x, \sigma) = f(x) + \sigma \sum_i [\max\{0, g_i(x)\}]^2 \\ + \sigma \sum_j h_j(x)^2$$

$\sigma > 0$ 是罚因子。当 x 违反约束时, 惩罚项 > 0 。
 σ 逐步增大, 罚款越来越重, 最优解被迫回到可行域附近。

序列: 选 $\sigma_1 < \sigma_2 < \cdots \rightarrow \infty$, 对每个 σ_k 求解 $\min_x P(x, \sigma_k)$, 得 $x^{(k)}$ 。 $x^{(k)} \rightarrow x^*$ 。

为什么叫”外点法”、为什么允许不可行中间点? 外点法对违反约束的惩罚是”从零开始逐渐加码”的。中间迭代点往往不在可行域内 (在”外部”), 因为罚因子不够大时, 惩罚项的威慑力不足以把解完全拉进可行域。这种”先不管约束、逐步逼近”的策略是外点法的核心特征——它从可行域外向可行域收敛。优

点是初始点不需要可行；缺点是中间结果不可用（不可行），且 $\sigma \rightarrow \infty$ 时 Hessian 条件数爆炸。

外点法教学算例

自编例题： $\min f(x) = x_1^2 + x_2^2$, s.t. $x_1 + x_2 = 1$ 。（精确解： $x_1^* = x_2^* = 0.5$, $f^* = 0.5$, $\lambda^* = -1$ ）

外点法求解：

$$P(x, \sigma) = x_1^2 + x_2^2 + \sigma(x_1 + x_2 - 1)^2$$

令 $\nabla P = 0$ ：

$$\frac{\partial P}{\partial x_1} = 2x_1 + 2\sigma(x_1 + x_2 - 1) = 0$$

$$\frac{\partial P}{\partial x_2} = 2x_2 + 2\sigma(x_1 + x_2 - 1) = 0$$

两式相减得 $2x_1 = 2x_2$ ，故 $x_1 = x_2$ 。代入第一式：

$$x_1 + \sigma(2x_1 - 1) = 0 \Rightarrow x_1(1 + 2\sigma) = \sigma \Rightarrow x_1 = \frac{\sigma}{1 + 2\sigma}$$

迭代两步：

- $\sigma_1 = 1$ ： $x^{(1)} = (\frac{1}{3}, \frac{1}{3})^T$, $x_1 + x_2 = \frac{2}{3}$ （不满足约束，在可行域外）， $f = \frac{2}{9} \approx 0.222$

- $\sigma_2 = 10$: $x^{(2)} = (\frac{10}{21}, \frac{10}{21})^T \approx (0.476, 0.476)^T$,
 $x_1 + x_2 \approx 0.952$ (更接近可行), $f \approx 0.454$
- 极限 $\sigma \rightarrow \infty$: $x \rightarrow (0.5, 0.5)^T$, 回到可行域,
 $f^* = 0.5$

可见外点法从”外部” ($x_1 + x_2 < 1$) 逐步逼近约束, 每步的点都不完全可行。

9.6.2 内点法（障碍法）

与外点法相反, 内点法始终保持在可行域内部, 通过加一个”障碍项”来阻止迭代点靠近边界。

内点障碍函数（对仅含不等式约束的问题 $g_i(x) \leq 0$ ）

倒数障碍：

$$B(x, r) = f(x) + r \sum_i \frac{-1}{g_i(x)}$$

对数障碍：

$$B(x, r) = f(x) - r \sum_i \ln(-g_i(x))$$

$r > 0$ 是障碍因子。 $r \rightarrow 0^+$ 时障碍项的影响逐渐消失。

严格可行初始点： x 必须满足 $g_i(x) < 0$ （严格内部），否则 $\frac{-1}{g_i(x)}$ 或 $\ln(-g_i(x))$ 无定义。

为什么内点法要求严格可行内部点？障碍项在 $g_i(x) \rightarrow 0^-$ （逼近边界）时 $\rightarrow +\infty$ ，形成一堵“无形的墙”，阻止迭代点越界。如果从可行域外部出发，障碍项符号反转（变成“吸引力”而非“排斥力”），完全失去障碍作用。因此内点法必须从严格可行内部点出发，且一维搜索必须限制步长保证不越界。

PPT 第 13.14 页展示了内点法的障碍函数构造和几何示意图。

13.14

将上两式的两端分别相加并整理得

$$(\mu_{k+1} - \mu_k)P(x^{(k)}) \geq (\mu_{k+1} - \mu_k)P(x^{(k+1)}) \quad (13.1.16)$$

由 $\mu_{k+1} > \mu_k$, 故

$$P(x^{(k)}) \geq P(x^{(k+1)}) \quad (13.1.17)$$

最后证3.:

因 $x^{(k)}$ 为 $F(x, \mu_k)$ 的极小点, 则

$$f(x^{(k)}) + \mu_k P(x^{(k)}) \leq f(x^{(k+1)}) + \mu_k P(x^{(k+1)}) \quad (13.1.18)$$

内点法教学算例

同一问题改写为不等式形式: $\min f(x) = x_1^2 + x_2^2$, s.t. $1 - x_1 - x_2 \leq 0$ (即 $x_1 + x_2 \geq 1$)。

内点法求解 (用对数障碍):

$$B(x, r) = x_1^2 + x_2^2 - r \ln(x_1 + x_2 - 1)$$

令 $\nabla B = 0$:

$$\begin{aligned}\frac{\partial B}{\partial x_1} &= 2x_1 - \frac{r}{x_1 + x_2 - 1} = 0 \\ \frac{\partial B}{\partial x_2} &= 2x_2 - \frac{r}{x_1 + x_2 - 1} = 0\end{aligned}$$

两式相减得 $x_1 = x_2$ 。代入: $2x_1 = \frac{r}{2x_1 - 1}$, 即 $4x_1^2 - 2x_1 - r = 0$ 。

$$x_1 = \frac{2 + \sqrt{4 + 16r}}{8} = \frac{1 + \sqrt{1 + 4r}}{4}$$

迭代两步:

- $r_1 = 1$: $x^{(1)} = (\frac{1+\sqrt{5}}{4}, \frac{1+\sqrt{5}}{4})^T \approx (0.809, 0.809)^T$,
 $x_1 + x_2 \approx 1.618 > 1$ (严格可行内部), $f \approx 1.309$
- $r_2 = 0.1$:

$$x^{(2)} = \left(\frac{1 + \sqrt{1.4}}{4}, \frac{1 + \sqrt{1.4}}{4} \right)^T \approx (0.546, 0.546)^T$$

此时 $x_1 + x_2 \approx 1.092$ (逼近边界), $f \approx 0.596$

- 极限 $r \rightarrow 0^+$: $x \rightarrow (0.5, 0.5)^T$, $f^* = 0.5$

内点法始终从”内部” ($x_1 + x_2 > 1$) 逼近边界, 与外点法方向相反。

9.6.3 乘子法（增广 Lagrange 法）

外点法的致命弱点： $\sigma \rightarrow \infty$ 时 Hessian 的条件数也 $\rightarrow \infty$ ，导致无约束子问题越来越病态，数值求解困难。乘子法通过引入 Lagrange 乘子估计（Lagrange 乘子概念见第 6 章 KKT 条件），避免了 $\sigma \rightarrow \infty$ 的需求。

增广 Lagrange 函数 (对等式约束 $h_j(x) = 0$)

$$L_A(x, \lambda, \sigma) = f(x) + \sum_j \lambda_j h_j(x) + \frac{\sigma}{2} \sum_j h_j(x)^2$$

乘子更新公式: $\lambda_j^{(k+1)} = \lambda_j^{(k)} + \sigma h_j(x^{(k)})$ 。

算法:

1. 选初始乘子 $\lambda^{(0)}$ 和罚因子 $\sigma > 0$ (固定不变!)
2. 对 $k = 0, 1, 2, \dots$ 求解 $\min_x L_A(x, \lambda^{(k)}, \sigma)$ 得 $x^{(k)}$
3. 若 $\|h(x^{(k)})\|$ 足够小则停止; 否则更新 $\lambda^{(k+1)} = \lambda^{(k)} + \sigma h(x^{(k)})$, $k \leftarrow k + 1$

为什么 σ 不需要趋于无穷? 关键在于乘子更新公式 $\lambda^{(k+1)} = \lambda^{(k)} + \sigma h(x^{(k)})$ 。当 $x^{(k)}$ 不满足约束时, $h(x^{(k)}) \neq 0$, 乘子被修正以”补偿”违反量。随着 $\lambda^{(k)}$ 逼近真实乘子 λ^* , 原问题的 KKT 条件被逐步满足, 不需要靠 $\sigma \rightarrow \infty$ 来强力施压。增广项 $\frac{\sigma}{2} h^2$ 的作用

是”拉弯”Hessian 使 L_A 在 x^* 附近凸且良态, 但收敛主要靠乘子迭代驱动。

PPT 第 13.24–13.25 页展示了乘子法的基本思想和增广 Lagrange 函数的构造。

13.24

内点罚函数法的基本思想:构造辅助(光滑)函数 F_μ
该函数在严格可行域 S_0 以外的取值为无穷大, 且当
点 x 从 S_0 趋于 S 的边界时, 函数值趋于无穷大. 这样, 无
约束问题
$$\min F_\mu = F(x, \mu)$$

的解一定在 S_0 内。我们希望当 $\mu \rightarrow 0$ 时, 上述无约束
问题的解 $x(\mu)$ 趋于问题(13.2.1)的解. 辅助函数 $F(x, \mu)$
在 S 的边界筑起了一道很高的墙, 把无约束问题
 $\min F(x, \mu)$ 的解挡住了可行域 S 的内部

. 因此, 内点法也称为障碍函数法.

保持迭代点含于可行域内部的方法是定义**障碍函数**

$$F(x, \mu) = f(x) + \mu B(x) \quad (13.2.3)$$

其中 $B(x)$ 是连续函数,当点 x 趋向可行域边界时, $B(x) \rightarrow \infty$. μ 是很小的正数.

这样,当 x 趋向边界时,函数 $F(x, \mu)$ 趋于无穷大;否则,由于 μ 很小,则函数 $F(x, \mu)$ 的取值近似 $f(x)$.

因此可通过求解下列问题得到原问题的近似解:

$$\begin{array}{ll} \min & F(x, \mu) \\ \text{s.t.} & x \in \text{int } S \end{array} \quad (13.2.4)$$

乘子法教学算例

同一问题: $\min f(x) = x_1^2 + x_2^2$, s.t. $x_1 + x_2 = 1$ 。取 $\sigma = 1$ (固定), $\lambda^{(0)} = 0$ 。

增广 Lagrange 函数:

$$L_A(x, \lambda, \sigma) = x_1^2 + x_2^2 + \lambda(x_1 + x_2 - 1) + \frac{1}{2}(x_1 + x_2 - 1)^2$$

令 $\nabla L_A = 0$:

$$2x_1 + \lambda + (x_1 + x_2 - 1) = 0$$

$$2x_2 + \lambda + (x_1 + x_2 - 1) = 0$$

故 $x_1 = x_2$ 。 $2x_1 + \lambda + (2x_1 - 1) = 0$, $x_1(2 + 2) = 1 - \lambda$,
 $x_1 = \frac{1-\lambda}{4}$ 。

迭代过程:

- $k = 0$: $\lambda^{(0)} = 0$, $x^{(0)} = (\frac{1}{4}, \frac{1}{4})^T$, $h = x_1 + x_2 - 1 = -0.5$
- $\lambda^{(1)} = 0 + 1 \times (-0.5) = -0.5$
- $k = 1$: $x^{(1)} = (\frac{1.5}{4}, \frac{1.5}{4})^T = (0.375, 0.375)^T$,
 $h = 0.75 - 1 = -0.25$
- $\lambda^{(2)} = -0.5 + (-0.25) = -0.75$
- $k = 2$: $x^{(2)} = (\frac{1.75}{4}, \frac{1.75}{4})^T = (0.4375, 0.4375)^T$,
 $h = -0.125$
- $\lambda^{(3)} = -0.75 + (-0.125) = -0.875$
- $k = 3$: $x^{(3)} = (\frac{1.875}{4}, \frac{1.875}{4})^T = (0.46875, 0.46875)^T$

序列 $x^{(k)} \rightarrow (0.5, 0.5)^T$, $\lambda^{(k)} \rightarrow -1$ (真实乘子), 而 $\sigma = 1$ 从未改变。对比外点法: 外点法需要 $\sigma \rightarrow \infty$ 才能逼近精确解, 乘子法用固定 σ 配合乘子更新即可。

乘子更新公式的直觉: $\lambda^{(k+1)} = \lambda^{(k)} + \sigma h(x^{(k)})$ 。如果 $h > 0$ (x 超出约束), 加大 λ 使下一轮增广 Lagrange 函数更”惩罚”正的 h , 把 x 拉回来。如果 $h < 0$, 减小 λ 把 x 推回去。这就是”乘子自适应调整”的因果机制。

PPT 第 13.30 页展示了乘子法的收敛性质: 乘子序列收敛到真实乘子, 这是乘子法优于纯外点法的理论保障。

2.3. 收敛性


Th13.2.1 设在问题(13.2.1)中,可行域内部 $\text{int } S$ 非空,且存在最优解,又设对每一个 μ_k ,由(13.2.3)定义的 $F(x, \mu_k)$ 在 $\text{int } S$ 内存在极小点,并且内点法产生的序列 $\{x^{(k)}\}$ 存在子列收敛到 $\bar{x}$,则 $\bar{x}$ 是问题(13.2.1)的最优解.

证明:先证 $\{F(x^{(k)}, \mu_k)\}$ 是单调减有下界的序列.


设 $x^{(k)}, x^{(k+1)} \in \text{int } S$ 分别为 $F(x, \mu_k)$ 和 $F(x, \mu_{k+1})$ 极小点,由于 $\mu_{k+1} < \mu_k$,则

9.7 三种罚函数法的对比

	外点法	内点法	乘子法
迭代点位置	可行域外	严格域内	均可
关键参数	$\sigma \rightarrow \infty$	$r \rightarrow 0^+$	σ 固定
参数趋势	递增	递减	不变
收敛驱动	惩罚加重	障碍减弱	乘子迭代
中间结果	不可用	始终可行	可用
等式约束	支持	不支持	支持
数值稳定性	差	中等	好
初始点要求	任意	需严格内部	任意



外点法



内点法

图 9.2: 三种罚函数法的迭代路径对比——外点法从可行域外逼近，内点法从域内逼近边界，乘子法通过乘子自适应调整沿路径收敛

本章速查

- 可行方向法框架: $x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$, $\nabla f^T d < 0$ 且 d 可行
- 积极约束: 取等号的不等式约束, 决定可行方向范围
- Rosen 投影法: $P = I - M^T(MM^T)^{-1}M$, $d = -P\nabla f$

- **积极集维护**: 步长被新约束限 $\rightarrow$ 加入; $d = 0$ 且 $\lambda_i < 0 \rightarrow$ 移除该约束
- **Zoutendijk 法**: LP 子问题找方向, 适用线性约束
- **外点法**: $P(x, \sigma) = f + \sigma \sum [\max(0, g_i)]^2 + \sigma \sum h_j^2$, $\sigma \rightarrow \infty$
- **内点法**: $B(x, r) = f - r \sum \ln(-g_i)$ 或 $f + r \sum (-1/g_i)$, $r \rightarrow 0^+$
- **乘子法**: $L_A = f + \sum \lambda_j h_j + \frac{\sigma}{2} \sum h_j^2$, $\lambda^{(k+1)} = \lambda^{(k)} + \sigma h(x^{(k)})$
- **乘子法优势**: σ 不需趋于无穷, 数值稳定, 兼具 Lagrange 乘子的理论优雅
- **外点 vs 内点 vs 乘子**: 外点”从外往里逼”、内点”从里往外逼”、乘子”自适应校准”