



北京邮电大学

BEIJING UNIVERSITY OF POSTS AND TELECOMMUNICATIONS

最优化理论与算法

帅天平

数学科学学院

tpshuai@bupt.edu.cn



第七章 最优性条件

- 无约束问题的极值条件
- 约束极值问题的最优性条件
- 对偶及鞍点

7.1 无约束问题的极值条件

1, 无约束极值问题

考虑非线性规划问题

$$\min f(x), \quad x \in R^n$$

其中 $f(x)$ 是定义在 R^n 上的实值函数

——称为无约束极值问题 (UNLP)

2, 必要条件

Th7.1.1(非极小点的充分条件) 设 $f(x)$ 在点 x^* 处可微, 若存在方向 $d(\geq 0) \in R^n$, 使得 $\nabla f(x^*)^T d < 0$, 则存在 $\varepsilon > 0$, 使得对任意 $\lambda \in (0, \varepsilon)$, 有 $f(x^* + \lambda d) < f(x^*)$. 此时, 我们称 d 为 $f(x)$ 在 x^* 的一个下降方向.

证明. 由 $f(x)$ 在 x^* 可微, 则

$$f(x^* + \lambda d) = f(x^*) + \lambda \nabla f(x^*)^T d + \lambda \|d\| \alpha(x^*; \lambda d),$$

其中 $\alpha(x^*; \lambda d) \rightarrow 0$ (当 $\lambda \rightarrow 0$).

移项且两边同除以 $\lambda(\lambda \neq 0)$,得

$$(f(\mathbf{x}^* + \lambda \mathbf{d}) - f(\mathbf{x}^*)) / \lambda = \nabla f(\mathbf{x}^*)^T \mathbf{d} + \|\mathbf{d}\| \alpha(\mathbf{x}^*; \lambda \mathbf{d})$$

由于 $\nabla f(\mathbf{x}^*)^T \mathbf{d} < 0$ 且 $\alpha(\mathbf{x}^*; \lambda \mathbf{d}) \rightarrow 0$ 当 $\lambda \rightarrow 0$.

从而存在 $\delta > 0$ 使得对 任意 $\lambda \in (0, \delta)$,

$$\nabla f(\mathbf{x}^*)^T \mathbf{d} + \|\mathbf{d}\| \alpha(\mathbf{x}^*; \lambda \mathbf{d}) < 0. \quad \text{定理立明.}$$

定理7.1.2-3(极小点的必要条件) 设 $\mathbf{x}^*$ 处是问题 (UNLP)的局部极小点.

(1) 当 $f(\mathbf{x})$ 在 $\mathbf{x}^*$ 可微时, 则梯度 $\nabla f(\mathbf{x}^*) = 0$.

(2) 当 $f(\mathbf{x})$ 在 $\mathbf{x}^*$ 二次可微时. 则 $\nabla f(\mathbf{x}^*) = 0$ 且 **Hessian** 矩阵 $\mathbf{H}(\mathbf{x}^*)$ 是半正定的

证明(1). 若 $\nabla f(\mathbf{x}^*) \neq 0$, 作 $\mathbf{d} = -\nabla f(\mathbf{x}^*)$. 则有 $\nabla f(\mathbf{x}^*)^T \mathbf{d} < 0$
由Th7.1.1, 存在 $\delta > 0$ 使得 $f(\mathbf{x}^* + \lambda \mathbf{d}) < f(\mathbf{x}^*)$, $\forall \lambda \in (0, \delta)$, 此与
 $\mathbf{x}^*$ 为局部极小相矛盾, 故 $\nabla f(\mathbf{x}^*) = 0$.

(2). 给定任意向量 $\mathbf{d}$. 由 $f(\mathbf{x})$ 在 $\mathbf{x}^*$ 的二次可微性, 有

$$f(\mathbf{x}^* + \lambda \mathbf{d}) = f(\mathbf{x}^*) + \lambda \nabla f(\mathbf{x}^*)^T \mathbf{d} + \lambda^2 \mathbf{d}^T H(\mathbf{x}^*) \mathbf{d} / 2 + \lambda^2 \|\mathbf{d}\| \alpha(\mathbf{x}^*; \lambda \mathbf{d}) \quad (\text{I}),$$

其中 $\alpha(\mathbf{x}^*; \lambda \mathbf{d}) \rightarrow 0$ ($\lambda \rightarrow 0$). 由 (1) 的证明有 $\nabla f(\mathbf{x}^*) = \mathbf{0}$.

移项整理并两端除以 λ^2 , 得

$$\frac{f(\mathbf{x}^* + \lambda \mathbf{d}) - f(\mathbf{x}^*)}{\lambda^2} = \mathbf{d}^T H(\mathbf{x}^*) \mathbf{d} / 2 + \|\mathbf{d}\| \alpha(\mathbf{x}^*; \lambda \mathbf{d}) \quad (\text{II}).$$

因 $\mathbf{x}^*$ 局部极小, 对充分小 λ 有 $f(\mathbf{x}^* + \lambda \mathbf{d}) \geq f(\mathbf{x}^*)$

3, 二阶充分条件

由(II), 显见

$$d^T H(x^*) d / 2 + \alpha(x^*; \lambda d) \|d\|^2 \geq 0$$

对充分小的 λ 成立, 对 $\lambda \rightarrow 0$ 取极限, 则有 $d^T H(x^*) d \geq 0$,
从而, $H(x^*)$ 半正定

3, 二阶充分条件

定义1 若 $f(x)$ 在点 x^* 处可微, 且 $\nabla f(x^*) = 0$, 则称 x^* 为 $f(x)$ 的一个驻点或平稳点. 既不是极大点也不是极小点的驻点称为鞍点.

Th7.1.4 (二阶充分条件). 假设 $f(x)$ 在 x^* 点二次可微, 若 $\nabla f(x^*) = 0$ 且 **Hessian** 矩阵 $H(x^*)$ 是正定的, 则 x^* 是 (UNLP) 的一个 (严格) 局部极小点

证明. 因 f 在 $\mathbf{x}^*$ 二次可微, 故对任意 $\mathbf{x}$, 有

$$f(\mathbf{x}) = f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*)^T (\mathbf{x} - \mathbf{x}^*) + \frac{1}{2} (\mathbf{x} - \mathbf{x}^*)^T \mathbf{H}(\mathbf{x}^*) (\mathbf{x} - \mathbf{x}^*)$$

+ $\|\mathbf{x} - \mathbf{x}^*\|^2 \alpha(\mathbf{x}^*; \mathbf{x} - \mathbf{x}^*)$, 这里 $\alpha(\mathbf{x}^*; \mathbf{x} - \mathbf{x}^*) \rightarrow 0$, 当 $\mathbf{x} \rightarrow \mathbf{x}^*$.

假设命题不真, $\mathbf{x}^*$ 不是局部极小, 则存在序列 $\{\mathbf{x}_k\}$ 收敛到 $\mathbf{x}^*$ 并使得 $f(\mathbf{x}_k) < f(\mathbf{x}^*)$ 对每一 k 成立。定义序列

$$(\mathbf{x}_k - \mathbf{x}^*) / \|\mathbf{x}_k - \mathbf{x}^*\| = \mathbf{d}_k.$$

则上述方程蕴含 $\mathbf{d}_k^T \mathbf{H}(\mathbf{x}^*) \mathbf{d}_k / 2 + \alpha(\mathbf{x}^*; \mathbf{x}_k - \mathbf{x}^*) \leq 0$ ($\forall k$)

但对每一 k , $\|\mathbf{d}_k\| = 1$, 从而 $\{\mathbf{d}_{k_j}\} \rightarrow \mathbf{d}$, 当 $k_j \rightarrow \infty$, 这里 $\|\mathbf{d}\| = 1$.

由 $\nabla f(\mathbf{x}^*) = \mathbf{0}$, 我们有 $\mathbf{d}^T \mathbf{H}(\mathbf{x}^*) \mathbf{d} \leq 0$, 此与其正定性矛盾.

4, 充要条件

定理7.1.5 (充要条件). 假设 $f(\mathbf{x}): R^n \rightarrow R$ 是可微的凸函数, 则 $\mathbf{x}^*$ 是(UNLP)的全局最小点当且仅当 $\nabla f(\mathbf{x}^*)=\mathbf{0}$.

证明. (必要性) 若 $\mathbf{x}^*$ 全局最优, 由Th7.1.2, $\nabla f(\mathbf{x}^*)=\mathbf{0}$.

(充分性) 设 $\nabla f(\mathbf{x}^*)=\mathbf{0}$, 则 $\nabla f(\mathbf{x}^*)^T(\mathbf{x}-\mathbf{x}^*)=0$, $\mathbf{x}^* \in R^n$

由 $f(x)$ 可微凸, 有

$$f(\mathbf{x}) \geq f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*)^T(\mathbf{x}-\mathbf{x}^*) = f(\mathbf{x}^*)$$

定理得证.

例7.1.1 利用极值条件解下列问题：

$$\min f(x) = (x_1^2 - 1)^2 + x_1^2 + x_2^2 - 2x_1$$

解：先求驻点， 由于

$$\frac{\partial f}{\partial x_1} = 4x_1^3 - 2x_1 - 2, \frac{\partial f}{\partial x_2} = 2x_2$$

$$\text{令 } \nabla f(x) = 0, \text{ 即 } 4x_1^3 - 2x_1 - 2 = 0, 2x_2 = 0$$

解得驻点 $x^* = (1, 0)'$

$$\text{又Hessian阵 } \nabla^2 f(x) = \begin{bmatrix} 12x_1^2 - 2 & 0 \\ 0 & 2 \end{bmatrix} \Rightarrow \nabla^2 f(x^*) = \begin{bmatrix} 10 & 0 \\ 0 & 2 \end{bmatrix}$$

正定，故 $x^* = (1, 0)'$ 是局部极小点。

例7.1.2 利用极值条件解下列问题：

$$\min f(x) = \frac{1}{3}x_1^3 + \frac{1}{3}x_2^3 - x_2^2 - x_1$$

解：先求驻点， 由于

$$\frac{\partial f}{\partial x_1} = x_1^2 - 1, \frac{\partial f}{\partial x_2} = x_2^2 - 2x_2$$

令 $\nabla f(x)=0$,即 $x_1^2 - 1=0, x_2^2 - 2x_2 = 0$

$$\text{解得驻点 } x^{(1)} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, x^{(2)} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, x^{(3)} = \begin{bmatrix} -1 \\ 0 \end{bmatrix}, x^{(4)} = \begin{bmatrix} -1 \\ 2 \end{bmatrix}$$

$$\text{又Hessian阵}\nabla^2 f(\mathbf{x}) = \begin{bmatrix} 2x_1 & 0 \\ 0 & 2x_2 - 2 \end{bmatrix} \Rightarrow$$

$$\nabla^2 f(\mathbf{x}^{(1)}) = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix}, \nabla^2 f(\mathbf{x}^{(2)}) = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

$$\nabla^2 f(\mathbf{x}^{(3)}) = \begin{bmatrix} -2 & 0 \\ 0 & -2 \end{bmatrix}, \nabla^2 f(\mathbf{x}^{(4)}) = \begin{bmatrix} -2 & 0 \\ 0 & 2 \end{bmatrix}$$

由于 $\nabla^2 f(\mathbf{x}^{(1)})$, $\nabla^2 f(\mathbf{x}^{(3)})$, $\nabla^2 f(\mathbf{x}^{(4)})$ 不定或负定, 仅 $\nabla^2 f(\mathbf{x}^{(2)})$ 正定,

故 $\mathbf{x}^{(2)} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$ 是局部极小点。

7.2 约束极值问题的最优性条件

1, 约束极值问题

有约束的极值问题一般表示为

$$\begin{aligned} \min \quad & f(x) \quad x \in \mathbb{R}^n \\ s.t. \quad & g_i(x) \geq 0, \quad i = 1, 2, \dots, m \\ & h_j(x) = 0, \quad j = 1, 2, \dots, l \end{aligned}$$

其中 $g_i(x) \geq 0$ 称为不等式约束, $h_j(x) = 0$ 称为等式约束,

$$\text{集合 } S = \left\{ x \left| \begin{array}{l} g_i(x) \geq 0, i = 1, 2, \dots, m \\ h_j(x) = 0, \quad j = 1, 2, \dots, l \end{array} \right. \right\}$$

称为可行集合或可行域

2, 可行方向和下降方向

定义 7.2.1. 设 $f(\mathbf{x})$ 定义在 R^n 上的实值函数. $\mathbf{x}^* \in R^n$, $\mathbf{d} \neq \mathbf{0}$, 若存在 $\delta > 0$ 使得 $f(\mathbf{x}^* + \lambda \mathbf{d}) < f(\mathbf{x}^*)$ ($\forall \lambda \in (0, \delta)$), 则 $\mathbf{d}$ 称为 $f(\mathbf{x})$ 在 $\mathbf{x}^*$ 的下降方向(*decedent direction*)

设 $f(\mathbf{x})$ 在 $\mathbf{x}^*$ 可微. 若存在向量 $\mathbf{d}$ 满足 $\nabla f(\mathbf{x}^*)^T \mathbf{d} < 0$, 则由定理 7.1.1, $\mathbf{d}$ 是 $f(\mathbf{x})$ 在 $\mathbf{x}^*$ 的下降方向。记所有这样的向量集合为

$$F_0 = \{\mathbf{d} \mid \nabla f(\mathbf{x}^*)^T \mathbf{d} < 0\}$$

定义 7.2.2 设 $\mathbf{x} \in \text{cl}S$, $\mathbf{d} \in R^n$. 若 $\exists \delta > 0$, 使得 $\forall \lambda \in [0, \delta]$, $\mathbf{x} + \lambda \mathbf{d} \in S$, 则称 $\mathbf{d}$ 为集合 S 在点 $\mathbf{x}$ 的一个可行方向。集合 S 在 $\mathbf{x}$ 点的所有可行方向集合称为 S 在 $\mathbf{x}$ 点的可行方向锥, 记为 D (或 $FD(\mathbf{x}, S)$)

$$D = \{\mathbf{d} \mid \mathbf{d} \neq \mathbf{0}, \mathbf{x} \in \text{cl}S, \exists \delta > 0, \text{使得对 } \forall \lambda \in (0, \delta), \text{有 } \mathbf{x} + \lambda \mathbf{d} \in S\}$$

由可行方向定义知, 从点 $\mathbf{x}^*$, 沿可行方向 $\mathbf{d} \in \mathbf{D}(\mathbf{x}^*)$ 作一个很小的移动还是可行点. 进一步, 由 **定理 7.1.1**, 若 $\nabla f(\mathbf{x}^*)^T \mathbf{d} < 0$, 则 $\mathbf{d}$ 是 f 在 $\mathbf{x}^*$ 的下降方向。下面定理将说明 若 $\mathbf{x}^*$ 是局部最优且 $\nabla f(\mathbf{x}^*)^T \mathbf{d} < 0$, 则 $\mathbf{d} \notin \mathbf{D}(\mathbf{x}^*)$. 即不是可行方向。

定理 7.2.1. (必要条件) 考虑极小化问题:

$$\min f(\mathbf{x}), \quad \text{subject to } \mathbf{x} \in S,$$

其中 S 是 R^n 中非空集合, 设 $f(\mathbf{x})$ 在 $\mathbf{x}^*$ 可微。若 $\mathbf{x}^*$ 是局部极小点, 则 $F_0(\mathbf{x}^*) \cap \mathbf{D} = \emptyset$, 其中 $F_0(\mathbf{x}^*) = \{\mathbf{d} \mid \nabla f(\mathbf{x}^*)^T \mathbf{d} < 0\}$, $\mathbf{D}$ 是 S 在 $\mathbf{x}^*$ 的可行方向锥。

证明：反证法，设存在向量 $d \in F_0(x^*) \cap D$. 由定理7.1.1知

(1)：存在 $\delta_1 > 0$, $f(x^* + \lambda d) < f(x^*)$, $\forall \lambda \in (0, \delta_1)$,

又由D的定义,

(2)：存在 $\delta_2 > 0$, $x^* + \lambda d \in S$, $\forall \lambda \in (0, \delta_2)$

此与局部极小矛盾。

3 一阶最优性条件

考虑约束优化(COP)

$$\begin{aligned} \min \quad & f(x) \quad x \in E^n \\ s, t \quad & g_i(x) \geq 0, \quad i = 1, 2, \dots, m \\ & h_j(x) = 0, \quad j = 1, 2, \dots, l \end{aligned} \quad (7.2.1)$$

记

$$g(x) = \begin{pmatrix} g_1(x) \\ g_2(x) \\ \dots \\ g_m(x) \end{pmatrix}, h(x) = \begin{pmatrix} h_1(x) \\ h_2(x) \\ \dots \\ h_l(x) \end{pmatrix}$$

(COP) 矩阵形式

$$\begin{aligned} \min \quad & f(x) \quad x \in E^n \\ s, t \quad & g(x) \geq 0, \\ & h(x) = 0, \end{aligned} \quad (7.2.2)$$

定义7.2.3 设 $\bar{x}$ 为可行点, 记 $I = \{i \mid g_i(\bar{x}) = 0\}$ (即在 $\bar{x}$ 点起作用的约束下标集), 若向量组 $\{\nabla g_i(\bar{x}), \nabla h_j(\bar{x}) \mid i = 1, 2, \dots, m, j = 1, 2, \dots, l\}$ 线性无关, 则称 $\bar{x}$ 为约束 $g(x)$ 和 $h(x)$ 的**正则点**。

定义7.2.4 点集 $\{x = x(t) \mid t_0 \leq t \leq t_1\}$ 称为曲面 $S = \{x \mid h(x) = 0\}$ 上的一条曲线, 如果对所有 $t \in [t_0, t_1]$ 均有 $h(x(t)) = 0$.

显然, 曲线上点是参数 t 的函数, 若导数 $x'(t) = \frac{dx(t)}{dt}$ 存在则称曲线是可微的。曲线 $x(t)$ 的一阶导数 $x'(t)$ 是曲线在点 $x(t)$ 处的切向量。曲面 S 上在点 x 处所有可微曲线的切向量组成的集合, 称为曲面 S 在点 x 的切平面, 记做 $T(x)$ 。

定义集合

$$H = \{d \mid \nabla h_j(\bar{x})^T d = 0, \quad j = 1, 2, \dots, l\}$$

可证明，当 $\nabla h_1(\bar{x}), \nabla h_2(\bar{x}), \dots, \nabla h_l(\bar{x})$ 线性无关时， H 等于等式约束

$$\begin{cases} h_1(x) = 0 \\ h_2(x) = 0 \\ \dots \\ h_l(x) = 0 \end{cases}$$

所定义的超曲面在 $\bar{x}$ 处的切平面 $T(\bar{x})$ 。

*Th*7.2.2 设 $\bar{x}$ 是曲面 $S = \{x \mid h(x) = 0\}$ 上一个正则点(即 $\nabla h_1(\bar{x}), \nabla h_2(\bar{x}), \dots, \nabla h_l(\bar{x})$ 线性无关), 则在点 $\bar{x}$ 切平面 $T(\bar{x})$ 等于子空间 $H = \{d \mid \nabla h(\bar{x})^T d = 0\}$.

证明略

Th7.2.3 设在约束极值问题(7.2.1)中, $\bar{x}$ 为可行点, $I = \{i \mid g_i(\bar{x}) = 0\}$, f 和 $g_i (i \in I)$ 在点 $\bar{x}$ 可微, $g_i (i \notin I)$ 在点 $\bar{x}$ 连续, $h_j (j = 1, 2, \dots, l)$ 在点 $\bar{x}$ 连续可微, 且 $\nabla h_1(\bar{x}), \nabla h_2(\bar{x}), \dots, \nabla h_l(\bar{x})$ 线性无关. 若 $\bar{x}$ 是局部最优解, 则在点 $\bar{x}$ 处, 有 $F_0 \cap G_0 \cap H_0 = \Phi$ 其中

$$F_0 = \{d \mid d^T \nabla f(\bar{x}) < 0\}$$

$$G_0 = \{d \mid d^T \nabla g_i(\bar{x}) > 0 \ (i \in I)\}$$

$$H_0 = \{d \mid d^T \nabla h_j(\bar{x}) = 0 \ (j = 1, 2, \dots, l)\}$$

证明略

下面给出一阶必要条件的代数表示. 我们有如下定理.

Th7. 2. 4(Fritz John条件)设在约束极值问题(7.2.1)中, $\bar{x}$ 为可行点, $I = \{i \mid g_i(\bar{x}) = 0\}$, f 和 $g_i (i \in I)$ 在点 $\bar{x}$ 可微, $g_i (i \notin I)$ 在点 $\bar{x}$ 连续, $h_j (j = 1, 2, \dots, l)$ 在点 $\bar{x}$ 连续可微. 若 $\bar{x}$ 是局部最优解, 则 $\exists$ 不全为零的数 $u_0, u_i \geq 0 (i \in I), v_j \in R (j = 1, 2, \dots, l)$, 使得

$$u_0 \nabla f(\bar{x}) - \sum_{i \in I} u_i \nabla g_i(\bar{x}) - \sum_{j=1}^l v_j \nabla h_j(\bar{x}) = 0$$

证明略

例7.2.1:

$$\begin{array}{ll}\min & x_1^2 + x_2^2 \\s.t & x_1^2 + x_2^2 \leq 5, \\& -x_1 \leq 0, \\& -x_2 \leq 0, \\& x_1 + 2x_2 = 4\end{array}$$

验证在 $x = (4/5, 8/5)$ 处
Fritz John条件成立.

此处只有一个等式约束.

注意到在 x^* 处 $I = \emptyset$, 因此
与不等式相应的乘子为零.

$$\nabla f(x^*) = (8/5, 16/5)^T,$$

$$\nabla h_1(x^*) = (1, 2)^T$$

于是 $w\nabla f(x^*) + v\nabla h_1(x^*) = 0$ 即

$$w \begin{pmatrix} 8/5 \\ 16/5 \end{pmatrix} + v \begin{pmatrix} 1 \\ 2 \end{pmatrix} = 0$$


有合适解. 如取 $w = 5, v = -8$

例7.2.2

$$\min -x_1$$

$$x_2 - (1 - x_1)^3 = 0,$$

$$-x_2 - (1 - x_1)^3 = 0,$$



此问题只有一个可行解 $x^* = (1, 0)^T$.
在此点有

$$\nabla f(x^*) = (-1, 0)^T, \nabla h_1(x^*) = (0, 1)^T,$$

$$\nabla h_2(x^*) = (0, -1)^T,$$

$$FJ \text{ 条件 } w_0 \begin{pmatrix} -1 \\ 0 \end{pmatrix} + v_1 \begin{pmatrix} 0 \\ 1 \end{pmatrix} + v_2 \begin{pmatrix} 0 \\ -1 \end{pmatrix} = 0$$

仅当 $w_0 = 0, v_1 = -v_2 = a$ (a 为任意数) 成立
故在 x^* 满足FJ条件.

$$\min -x_1$$

$$x_2 - (1 - x_1)^3 = 0,$$

$$-x_2 - (1 - x_1)^3 = 0,$$

前面FJ条件中 w_0 不一定为正, 如果为0, 则不含目标函数信息, 因此对判别最优解没有作用, 为此, 我们通过增加约束规格来保证 w_0 为正, 得到著名的KKT最优性必要条件。

定理7.2 .5(一阶必要条件 (Karush-Kuhn-Tucker 定理): 代数特征)

设 $\mathbf{x}^* \in S$ 是问题(7.2.1)的局部极小点, 函数 $f, g_i, (i \in I)$ 在点 $\mathbf{x}^*$ 处可微, $g_i, (i \notin I)$ 在点 $\mathbf{x}^*$ 处连续, h_j 在点 $\mathbf{x}^*$ 处连续可微. 若

$$\{\nabla g_i(\mathbf{x}^*), \nabla h_j(\mathbf{x}^*) \mid i \in I, j=1, 2, \dots, l\}$$

线性无关, 则 $\exists u_i \geq 0 (i \in I), v_j \in R (j=1, 2, \dots, l)$, 使得

$$\nabla f(\mathbf{x}^*) = \sum_{i \in I} u_i \nabla g_i(\mathbf{x}^*) + \sum_{j \in E} v_j \nabla h_j(\mathbf{x}^*)$$

证明略

进一步假设, $g_i (i \notin I)$ 在 $\mathbf{x}^*$, 连续可微, 则

$$\nabla f(\mathbf{x}^*) - \sum_{i=1}^m u_i \nabla g_i(\mathbf{x}^*) - \sum v_j \nabla h_j(\mathbf{x}^*) = \mathbf{0},$$

$$u_i g_i(\mathbf{x}^*) = 0, u_i \geq 0 (i=1, \dots, m.)$$

若采用矩阵和向量记号, 则KKT条件可有如下的简洁表示。

定义Lagrange函数为

$$L(\mathbf{x}, \lambda, \mu) = f(\mathbf{x}) - \mathbf{g}^T \lambda - \mathbf{h}^T \mu \quad (7.2.3)$$

其中 $\mathbf{g}$ 和 $\mathbf{h}$ 分别是由 g_i 和 h_j 组成的向量函数.

记向量值函数 $\mathbf{g}$ 和 $\mathbf{h}$ 在 $\mathbf{x}$ 点的梯度为

$$\nabla \mathbf{g}(\mathbf{x}) = \mathbf{J}_g(\mathbf{x})^T = (\nabla g_i, i \in I),$$

$$\nabla \mathbf{h}(\mathbf{x}) = \mathbf{J}_h(\mathbf{x})^T = (\nabla h_j, j = 1, 2, \dots, l),$$

其中 $\mathbf{J}_g(\mathbf{x}), \mathbf{J}_h(\mathbf{x})$ 分别是 $\mathbf{g}, \mathbf{h}$ 在 $\mathbf{x}$ 点的Jacobi矩阵.

则KKT条件可表为

$$\nabla f(\mathbf{x}^*) = \nabla \mathbf{g}(\mathbf{x}^*)\lambda + \nabla \mathbf{h}(\mathbf{x}^*)\mu$$

$$\mathbf{g}(\mathbf{x}^*)^T \lambda = 0, \quad \lambda \geq 0 \quad (7.2.4)$$

$$\mathbf{g}(\mathbf{x}^*) \geq 0, \quad \mathbf{h}(\mathbf{x}^*) = 0$$

定义7.2.5: 若 $\mathbf{x}^* \in \mathbf{R}^n, \lambda \in \mathbf{R}^{|I|}, \mu \in \mathbf{R}^l$ 满足KKT条件(7.2.4), 则 $\mathbf{x}^*$ 称为约束优化问题(COP)的一个KKT点, λ 和 μ 称为 $\mathbf{x}^*$ 处的Lagrange乘子. 特别的, $\mathbf{g}(\mathbf{x}^*)^T \lambda = 0$ 称为互补松弛条件.

定理7.2.6 (充分条件 : 凸规划情形)

设 f 为凸函数, g_i 为凹函数, h_j 为线性函数。对于 $x^* \in S$ 若 f, g_i, h_j 在点 x^* 处可微, 并且KKT条件(7.2.4)成立, 则 x^* 为优化问题(COP)的全局极小点。

证明略




定义7.2.6 设 S 是 R^n 中的一个非空集合, 点 $\bar{x} \in clS$ 集合
 $T = \{d \mid \exists x^{(k)} \in S, x^{(k)} \rightarrow \bar{x} \text{ 及 } \lambda_k > 0, \text{ 使得 } d = \lim_{k \rightarrow \infty} \lambda_k (x^{(k)} - \bar{x})\}$
则称 T 为集合 S 在点 $\bar{x}$ 的切锥。

根据上述定义, 如果序列 $\{x^{(k)}\} \subset S, x^{(k)} \rightarrow \bar{x}$

$x^{(k)} \neq \bar{x}$, 使得 $\lim_{k \rightarrow \infty} \frac{x^{(k)} - \bar{x}}{\|x^{(k)} - \bar{x}\|} = d$, 则 $d \in T$ 。

如果 $\bar{x} \in \text{int } S$, 则 S 在 $\bar{x}$ 的切锥 $T = R^n$ 。

例



定理 7.2.7 (充分条件) 设 $x^* \in S$, 函数 f, g_i, h_j 在点 x^* 处可微, 且

$$d^T \nabla f(x^*) > 0, \forall d \in T \setminus \{0\}$$

则 x^* 为 (COP) 的严格局部极小点, 其中 T 为 S 在 x^* 处的切锥.

证明略

4.二阶条件

例 考虑如下约束优化问题,

$$\min f(\mathbf{x}) = x_1^2 + x_2^2$$

$$s.t. \ g(\mathbf{x}) = x_1^2 + x_2 - 1 \geq 0$$

对于可行点 $\mathbf{x}^* = (0, 1)^T$, $I = \{1\}$, $\nabla f(\mathbf{x}^*) = (0, 2)^T$,

$\nabla g(\mathbf{x}^*) = (0, 1)^T$. 易见 $\mathbf{x}^*$ 是KKT条件. 此时线性独立约束规格 (LICQ) 成立, 即

$$\{\nabla g_i(\mathbf{x}^*), \nabla h_j(\mathbf{x}^*), i \in I, j = 1, \dots, l\}$$

线性无关. 但我们无法利用一阶最优性条件判断 $\mathbf{x}^*$ 是否为问题的局部极小点。

现在我们考虑问题(7.2.1).

设在可行点 $\bar{x}$, 对应不等式约束中的起作用约束和等式约束的Lagrange乘子分别为: $\bar{w}_i \geq 0, i \in I$; $\bar{v}_j, j = 1, 2, \dots, l$. 定义一个集合。

$$\bar{S} = \left\{ x \left| \begin{array}{l} g_i(x) = 0, i \in I \text{ 且 } \bar{w}_i > 0 \\ g_i(x) \geq 0, i \in I \text{ 且 } \bar{w}_i = 0 \\ h_j(x) = 0, j = 1, 2, \dots, l \end{array} \right. \right\}$$

设集合 $\bar{S}$ 在点 $\bar{x}$ 的切锥为 $\bar{T}$ 。再定义一个集合

$$\bar{G} = \left\{ d \left| \begin{array}{l} \nabla g_i(\bar{x})^T d = 0, i \in I \text{ 且 } \bar{w}_i > 0 \\ \nabla g_i(\bar{x})^T d \geq 0, i \in I \text{ 且 } \bar{w}_i = 0 \\ \nabla h_j(\bar{x})^T d = 0, j = 1, 2, \dots, l \end{array} \right. \right\}$$

容易证明 $\bar{G} \supset \bar{T}$

证明略

切锥 $\bar{T}$ 必包含于 $\bar{G}$ ，但是反之不真。

下面，在 $\bar{G} \subset \bar{T}$ 也成立的假设下，给出关于问题(7.2.1)的局部最优解的二阶必要条件。

定理 7.2.8(二阶必要条件) 设 $\bar{x}$ 是问题(7.2.1)的局部最优解, $f_i, g_i (i = 1, \dots, m)$ 和 $h_j (j = 1, \dots, l)$ 二次连续可微, 并存在满足(7.2.43)的乘子 $\bar{w} = (\bar{w}_1, \dots, \bar{w}_m)$ 和 $\bar{v} = (\bar{v}_1, \dots, \bar{v}_l)$, 再假设在点 $\bar{x}$ 约束规格 $\bar{G} = \bar{T}$ 成立, 则对每一个向量 $d \in \bar{G}$, 都有

$$d^T \nabla_x^2 L(\bar{x}, \bar{w}, \bar{v}) d \geq 0$$

其中 $\nabla_x^2 L(\bar{x}, \bar{w}, \bar{v}) = \nabla^2 f(\bar{x}) - \sum_{i=1}^m \bar{w}_i \nabla^2 g_i(\bar{x}) - \sum_{j=1}^l \bar{v}_j \nabla^2 h_j(\bar{x})$

是Lagrange函数 $L(x, w, v)$ 在点 $\bar{x}$ 关于 x 的Hessian 矩阵.

证明略

为给出局部最优解的二阶充分条件，我们定义集合

$$G = \left\{ d \left| \begin{array}{l} d \neq 0 \\ \nabla g_i(\bar{x})^T d = 0, i \in I \text{ 且 } \bar{w}_i > 0 \\ \nabla g_i(\bar{x})^T d \geq 0, i \in I \text{ 且 } \bar{w}_i = 0 \\ \nabla h_j(\bar{x})^T d = 0, j = 1, 2, \dots, l \end{array} \right. \right\}$$

Theorem 7.2.9(二阶充分条件) 设在问题7.2.1 中，
 $f_i, g_i (i = 1, \dots, m)$ 和 $h_j (j = 1, \dots, l)$ 二次连续可微，并存在满足
(7.2.43) 的乘子 $\bar{w} = (\bar{w}_1, \dots, \bar{w}_m)^T$ 和 $\bar{v} = (\bar{v}_1, \dots, \bar{v}_l)^T$, $\bar{x}$ 为可行点，
且对每一个向量 $d \in G$, 都有 $d^T \nabla_x^2 L(\bar{x}, \bar{w}, \bar{v}) d > 0$
则 $\bar{x}$ 是严格的局部最优解。

证明略

例7.2.3 考虑下列非线性规划问题

$$\min x_1$$

$$s.t. 3(x_1 - 3)^2 + x_2 \geq 0$$

$$(x_1 - 3)^2 + x_2^2 - 10 = 0$$

检验以下各点是否为局部最优解

$$x^{(1)} = \begin{bmatrix} 2 \\ -3 \end{bmatrix}, x^{(2)} = \begin{bmatrix} 4 \\ -3 \end{bmatrix}, x^{(3)} = \begin{bmatrix} 3 + \sqrt{10} \\ 0 \end{bmatrix}, x^{(4)} = \begin{bmatrix} 3 - \sqrt{10} \\ 0 \end{bmatrix}$$

记目标函数和约束函数分别为 $f(x), g(x), h(x)$, 他们在点 x 处的梯度分别是

$$\nabla f(x) = \begin{Bmatrix} 1 \\ 0 \end{Bmatrix}, \nabla g(x) = \begin{Bmatrix} 6(x_1 - 3) \\ 1 \end{Bmatrix}, \nabla h(x) = \begin{Bmatrix} 2(x_1 - 3) \\ 2x_2 \end{Bmatrix}$$

Lagrange函数是

$$L(x, w, v) = x_1 - w[3(x_1 - 3)^2 + x_2] - v[(x_1 - 3)^2 + x_2^2 - 10]$$

Lagrange函数关于 x 的Hessian矩阵是

$$\nabla_x^2 L = \begin{bmatrix} -6w - 2v & 0 \\ 0 & -2v \end{bmatrix}$$

检查 $x^{(1)}$: 是可行点, 且两约束都是起作用约束。

$$\nabla f(x^{(1)}) = \begin{Bmatrix} 1 \\ 0 \end{Bmatrix}, \nabla g(x^{(1)}) = \begin{Bmatrix} -6 \\ 1 \end{Bmatrix}, \nabla h(x^{(1)}) = \begin{Bmatrix} -2 \\ -6 \end{Bmatrix}$$

按照KKT条件, 设

$$\begin{Bmatrix} 1 \\ 0 \end{Bmatrix} - w \begin{Bmatrix} -6 \\ 1 \end{Bmatrix} - v \begin{Bmatrix} -2 \\ -6 \end{Bmatrix} = 0 \Rightarrow w = -\frac{3}{19}, v = -\frac{1}{38}$$

不存在使 $w \geq 0$ 的解, 故它不是KKT点.

检查 $x^{(2)}$:是可行点, 且两约束都是起作用约束。

$$\nabla f(x^{(2)}) = \begin{Bmatrix} 1 \\ 0 \end{Bmatrix}, \nabla g(x^{(2)}) = \begin{Bmatrix} 6 \\ 1 \end{Bmatrix}, \nabla h(x^{(1)}) = \begin{Bmatrix} 2 \\ -6 \end{Bmatrix}$$

按照KKT条件, 设

$$\begin{Bmatrix} 1 \\ 0 \end{Bmatrix} - w \begin{Bmatrix} 6 \\ 1 \end{Bmatrix} - v \begin{Bmatrix} 2 \\ -6 \end{Bmatrix} = 0 \Rightarrow w = \frac{3}{19}, v = \frac{1}{38}$$

故它是KKT点, 此点Lagrange函数的Hessian矩阵为:

$$\nabla_x^2 L(x^{(2)}, w, v) = \begin{bmatrix} -1 & 0 \\ 0 & -\frac{1}{19} \end{bmatrix}$$

求集合 $\bar{G}$ 中的元素。由于 $w > 0$,根据 $\bar{G}$ 的定义, 令

$$\nabla g(x^{(2)})^T d=0, \nabla h(x^{(2)})^T d=0$$

$$\text{上述方程组即} \begin{cases} 6d_1+d_2=0 \\ 2d_1-6d_2=0 \end{cases} \Rightarrow d = (0,0)'$$

故 $G=\Phi$ 。此情况表明在充分条件中对曲率的要求自然满足, 因此该点是局部最优解。

后两点请自行验证之

例7.2.4 考虑下列非线性规划问题

$$\min x_1^2 + (x_2 - 2)^2$$

$$s.t. \beta x_1^2 - x_2 = 0$$

其中 β 为某个实数。讨论点 $x = (0, 0)$ 是否为局部最优解。

记目标函数和约束函数分别为 $f(x)$, $h(x)$, 他们在点 x 处的梯度分别是

$$\nabla f(x) = \begin{bmatrix} 0 \\ -4 \end{bmatrix}, \nabla h(x) = \begin{bmatrix} 0 \\ -1 \end{bmatrix}$$

$$\text{设} \begin{bmatrix} 0 \\ -4 \end{bmatrix} - v \begin{bmatrix} 0 \\ -1 \end{bmatrix} = 0 \Rightarrow v=4$$

*Lagrange*函数为

例 $L(x, v) = x_1^2 + (x_2 - 2)^2 - v(\beta x_1^2 - x_2)$
它关于 x 的Hessian矩阵是

$$\nabla_x^2 L = \begin{bmatrix} 2 - 2\beta v & 0 \\ 0 & 2 \end{bmatrix}$$

在点 $x^{(0)}$ 处, 有 $\nabla_x^2 L(x^{(0)}, v) = \begin{bmatrix} 2 - 2\beta v & 0 \\ 0 & 2 \end{bmatrix}$

求集合 G 的元素 d , 令 $(0, -1) \begin{bmatrix} d_1 \\ d_2 \end{bmatrix} = 0 \Rightarrow d_2 = 0$

解得 $d = (d_1, 0)^T$, d_1 可取任意实数。此时有

$$d^T \nabla_x^2 L(x^{(0)}, v) d = 2(1 - 4\beta) d_1^2$$

当 $\beta < 1/4$ 时。对每一个向量 $d \in G$, 有

$$d^T \nabla_x^2 L(x^{(0)}, v) d > 0$$

故 $x^{(0)} = (0, 0)$ 是局部最优解。

当 $\beta > 1/4$ 时。对每一个向量 $d \in G$,有

$$d' \nabla_x^2 L(x^{(0)}, v) d < 0$$

此时不满足局部最优解的二阶必要条件，故

$x^{(0)} = (0,0)$ 不是局部最优解。

当 $\beta = 1/4$ 时利用二阶条件给不出结论，可用其他方法判断。

此时原问题即

$$\begin{aligned} \min \quad & x_1^2 + (x_2 - 2)^2 \\ \text{s.t.} \quad & x_1^2 / 4 - x_2 = 0 \end{aligned}$$

利用约束条件，从目标函数中消去一个变量，把问题化为

无约束问题 $\min 4x_2 + (x_2 - 2)^2$ ，显见 $x^{(0)} = (0,0)$ 为局部最优解

7.3 对偶理论

7.3.1 对偶形式

考虑如下形式的约束优化问题

$$\begin{aligned} & \min f(x) \\ (PNLP) \quad & s, t \quad g_i(x) \geq 0, \quad i = 1, \dots, m \\ & h_j(x) = 0, \quad j = 1, \dots, l \\ & x \in D \subseteq R^n \end{aligned} \tag{7.3.1}$$

其中 D 为问题的集合约束.

称(7.3.1)为非线性规划的原始形式(原问题).

其对偶形式(对偶问题)定义如下

$$\begin{aligned} & \max \theta(\lambda, \mu) \\ (\textcolor{red}{DNLP}) \quad & \text{s.t. } \lambda \geq 0 \end{aligned} \quad (7.3.2)$$

其中目标函数

$$\theta(\lambda, \mu) = \inf \{ \textcolor{blue}{f}(\textcolor{blue}{x}) - \textcolor{blue}{g}(\textcolor{blue}{x})^T \lambda - \textcolor{blue}{h}(\textcolor{blue}{x})^T \mu \mid \textcolor{blue}{x} \in \textcolor{blue}{D} \} \quad (7.3.3)$$

称为问题(PNLP)的Lagrange对偶函数.

问题(PNLP)和(DNLP)的可行域分别记为S和 Δ ,相应的Lagrange函数为

$$\textcolor{blue}{L}(\textcolor{blue}{x}, \lambda, \mu) \equiv \textcolor{blue}{f}(\textcolor{blue}{x}) - \textcolor{blue}{g}(\textcolor{blue}{x})^T \lambda - \textcolor{blue}{h}(\textcolor{blue}{x})^T \mu, \textcolor{blue}{x} \in \textcolor{blue}{D}, \lambda \in \textcolor{blue}{R}_+^m, \mu \in \textcolor{blue}{R}^l.$$

例7.3.1 考虑LP问题,

于是(LP)问题(*)的对偶形如

$$\begin{array}{ll} \min & \mathbf{c}^T \mathbf{x} \\ \text{s.t.} & \mathbf{A}_1 \mathbf{x} \geq \mathbf{b}_1 \\ & \mathbf{A}_2 \mathbf{x} = \mathbf{b}_2 \\ & \mathbf{x} \in \mathbf{R}_+^n \end{array} \quad (*)$$

$$\begin{array}{ll} \max & \lambda^T \mathbf{b}_1 + \mu^T \mathbf{b}_2 \\ \text{s.t.} & \mathbf{A}_1^T \lambda + \mathbf{A}_2^T \mu \leq \mathbf{c} \\ & \lambda \geq 0 \end{array}$$

若取集合约束 $\mathbf{D} = \mathbf{R}_+^n$ 则该LP问题的Lagrange对偶函数为

$$\begin{aligned} \theta(\lambda, \mu) &= \inf \{ \mathbf{c}^T \mathbf{x} - \lambda^T (\mathbf{A}_1 \mathbf{x} - \mathbf{b}_1) - \mu^T (\mathbf{A}_2 \mathbf{x} - \mathbf{b}_2) \mid \mathbf{x} \in \mathbf{R}_+^n \} \\ &= \inf \{ (\mathbf{c}^T - \lambda^T \mathbf{A}_1 - \mu^T \mathbf{A}_2) \mathbf{x} + \lambda^T \mathbf{b}_1 + \mu^T \mathbf{b}_2 \mid \mathbf{x} \in \mathbf{R}_+^n \} \\ &= \begin{cases} \lambda^T \mathbf{b}_1 + \mu^T \mathbf{b}_2, & \text{若 } \mathbf{c}^T - \lambda^T \mathbf{A}_1 - \mu^T \mathbf{A}_2 \geq 0 \\ -\infty, & \text{否则} \end{cases} \end{aligned}$$

例7.3.2: 考虑非线性约束优化问题

$$\{\min \mathbf{f} = \mathbf{x}_1^2 + \mathbf{x}_2^2, \quad \text{s. t.} \quad \mathbf{x}_1 + \mathbf{x}_2 \geq 4, \mathbf{x} \in \mathbf{R}_+^2\},$$

若取集合约束 $\mathbf{D} = \mathbf{R}_+^n$, 则它的Lagrange函数为

$$\begin{aligned} \theta(\lambda, \mu) &= \inf\{\mathbf{x}_1^2 + \mathbf{x}_2^2 - \lambda(\mathbf{x}_1 + \mathbf{x}_2 - 4) \mid \mathbf{x} \in \mathbf{R}_+^2\} \\ &= 4\lambda + \inf\{\mathbf{x}_1^2 - \lambda\mathbf{x}_1 \mid \mathbf{x}_1 \geq 0\} + \inf\{\mathbf{x}_2^2 - \lambda\mathbf{x}_2 \mid \mathbf{x}_2 \geq 0\} \end{aligned}$$

$$= \begin{cases} -\frac{1}{2}\lambda^2 + 4\lambda, & \lambda \geq 0 \\ 4\lambda, & \text{否则} \end{cases} \quad \text{于是该问题的对偶问题形如:}$$

$$\begin{aligned} \max \quad & -\frac{1}{2}\lambda^2 + 4\lambda \\ \text{s.t.} \quad & \lambda \geq 0 \end{aligned}$$

7.3.2 对偶定理

对于上面的两例我们有原问题与对偶问题的最优值相等. 对一般形式的非线性规划问题, 是否也对? 即

$$\min_{\mathbf{x} \in S} f(\mathbf{x}) \stackrel{??}{=} \max_{(\lambda, \mu)} \theta(\lambda, \mu)$$

1. 弱对偶定理

定理7.3.1 (弱对偶定理) 设 $\mathbf{x} \in S$ 和 $(\lambda, \mu) \in \Delta$ 分别为原问题(PNLP)和对偶问题(**DNLP**)的可行解, 则

$$f(\mathbf{x}) \geq \theta(\lambda, \mu)$$

推论7.3.1 对于原问题(PNLP)和对偶问题(DNLP), 则下述结论成立:

(1) 若 $\mathcal{S} \neq \Phi, \Delta \neq \Phi$, 则

$$f_{\min} = \inf\{f(\mathbf{x}) \mid \mathbf{x} \in \mathcal{S}\} \geq \theta_{\max} = \sup\{\theta(\lambda, \mu) \mid (\lambda, \mu) \in \Delta\}$$

(2) 若存在 $\bar{\mathbf{x}} \in \mathcal{S}$ 和 $(\bar{\lambda}, \bar{\mu}) \in \Delta$, 使得 $f(\bar{\mathbf{x}}) \leq \theta(\bar{\lambda}, \bar{\mu})$, 则 $\bar{\mathbf{x}}$ 和 $(\bar{\lambda}, \bar{\mu})$ 分别是原问题(PNLP)和对偶问题(DNLP)的最优解.

(3) 若 $f_{\min} = \infty$, 则 $\forall (\lambda, \mu) \in \Delta, \theta(\lambda, \mu) = -\infty$. 若 $\theta_{\max} = +\infty$, 则原问题(PNLP)没有可行解.

(PNLP)问题的对偶间隙定义为 $\delta = f_{\min} - \theta_{\max}$

2. 凸规划与Slater约束规格

定义7.3.1 对于凸规划来说,若相对内点的集合,

$$riS = \{x \mid h(x) = 0, g(x) > 0, x \in D\} \neq \Phi$$

则称约束函数满足Slater条件.

定理7.3.2 (凸规划的一阶必要条件) 假设在包含凸规划的可行域 S 的凸开集上函数 $f, g_i (i \in I)$ 可微. 若函数 g, h 满足Slater约束规格, 且 x^* 为凸规划的最优解, 则存在lagrange乘子向量 $\lambda^* \geq 0, \mu^*$, 使得 (x^*, λ^*, μ^*) 满足KKT条件.

3. 强对偶定理

定理7.3.3(强对偶定理) 对于凸规划问题, 假设 D 为非空的凸开集, f 为凸函数, $g_i(i = 1, \dots, m)$ 为凹函数, $h_j(j = 1, \dots, l)$ 为线性函数. 若函数 g, h 满足Slater约束规格, 并且 $0 \in \text{int } H(D)$, $(H(D) = \{h(x) \mid x \in D\})$, 则

$$f_{\min} = \inf\{f(x) \mid x \in S\} = \sup\{\theta(\lambda, \mu) \mid (\lambda, \mu) \in \Delta\} = \theta_{\max}$$

此外, 若 $f_{\min} > -\infty$, 则存在某个 $(\bar{\lambda}, \bar{\mu}) \in \Delta$, 使得 $\theta(\bar{\lambda}, \bar{\mu}) = \theta_{\max}$.

特别的. 若存在 $\bar{x} \in S$, 使得 $f(\bar{x}) = f_{\min}$, 则互补松施条件 $\bar{\lambda}^T g(\bar{x}) = 0$ 成立.

□ 例7.3.3 考虑如下约束优化问题

$$\min \left\{ f(\mathbf{x}) = \frac{1}{\mathbf{x}} \mid g(\mathbf{x}) = \mathbf{x} - 1 \geq 0, \mathbf{x} \in \mathbf{D} \right\}$$

其中 $\mathbf{D} = (0, +\infty)$.

显然该问题无最优解,但目标函数的下确界 $f_{\min}=0$.
该问题的Lagrange对偶函数

$$\theta(\lambda) = \inf \left\{ \frac{1}{\mathbf{x}} - \lambda(\mathbf{x} - 1) \mid \mathbf{x} \in \mathbf{D} \right\} = \begin{cases} -\infty, \lambda > 0 \\ 0, \lambda = 0 \\ 2\sqrt{-\lambda} + \lambda, \lambda < 0 \end{cases}$$

于是,对偶问题 $\max \{ \theta(\lambda) \mid \lambda \geq 0 \}$ 的最优解为 $\bar{\lambda}=0$,
最优值 $\theta_{\max} = 0 = f_{\min}$.

7.3.3 鞍点定理

定义7.3.2 设 $L(\mathbf{x}, \lambda, \mu) = f(\mathbf{x}) - \lambda^T g(\mathbf{x}) - \mu^T h(\mathbf{x})$ 是问题 (PNLP) 的 Lagrange 函数, 若存在 $(\bar{\mathbf{x}}, \bar{\lambda}, \bar{\mu}) \in D \times \mathbf{R}_+^m \times \mathbf{R}^l$, 使得对任意的 $(\mathbf{x}, \lambda, \mu) \in D \times \mathbf{R}_+^m \times \mathbf{R}^l$, 有

$$L(\bar{\mathbf{x}}, \lambda, \mu) \leq L(\bar{\mathbf{x}}, \bar{\lambda}, \bar{\mu}) \leq L(\mathbf{x}, \bar{\lambda}, \bar{\mu})$$

则称 $(\bar{\mathbf{x}}, \bar{\lambda}, \bar{\mu})$ 为函数 $L(\mathbf{x}, \lambda, \mu)$ 的一个鞍点.

1 鞍点与最优解

定理7.3.4(最优解型鞍点定理)

(1) 设 $(\bar{\mathbf{x}}, \bar{\lambda}, \bar{\mu})$ 为问题(PNLP)的Lagrange函数 $L(\mathbf{x}, \lambda, \mu)$ 的鞍点, 则 $(\bar{\mathbf{x}})$ 和 $(\bar{\lambda}, \bar{\mu})$ 分别是问题(PNLP)和(DNLP)的最优解;

(2) 设 $D \subset R^n$ 为凸的开集, $f : D \rightarrow R$ 为凸函数, $g_i (i = 1, \dots, m) : D \rightarrow R$ 为凹函数, $h(\mathbf{x}) = A\mathbf{x} - \mathbf{b}$ (其中 A 为行满秩矩阵). 若 $\mathbf{x}$ 为问题(PNLP)的最优解, 函数 g, h 满足Slater约束规格, 并且 $0 \in \text{int } H(D)$, 则存在 $\bar{\lambda} \geq 0$ 和 $\bar{\mu}$, 使得 $(\bar{\mathbf{x}}, \bar{\lambda}, \bar{\mu})$ 是问题(PNLP)的Lagrange函数的鞍点.

2. 鞍点与KKT点

定理7.3.5 (KKT型鞍点定理) 设问题(PNLP)中的函数 f, g 和 h 在包含可行域 S 的开集 D 内连续可微, 则

(1) 设 $(\bar{x}, \bar{\lambda}, \bar{\mu}) \in D \times \mathbf{R}_+^m \times \mathbf{R}^l$ 为问题(PNLP)的Lagrange函数 $L(x, \lambda, \mu)$ 的鞍点, 则 $(\bar{x}, \bar{\lambda}, \bar{\mu})$ 是问题(PNLP)的一个KKT点对.

(2) 设 $D \subset \mathbf{R}^n$ 为包含可行域 S 的凸开集, 问题(PNLP)是凸规划, 且 $(\bar{x}, \bar{\lambda}, \bar{\mu})$ 是问题(PNLP)的一个KKT点对, 则 $(\bar{x}, \bar{\lambda}, \bar{\mu})$ 是问题(PNLP)的Lagrange函数的鞍点.