



北京邮电大学

BEIJING UNIVERSITY OF POSTS AND TELECOMMUNICATIONS

最优化理论与算法

帅天平

数学科学学院

tpshuai@bupt.edu.cn



第八章 算法

- 算法概念
- 算法收敛问题

8 算法-概念

□ 8.1.1 算法映射

考虑极小化问题 $f(x) \text{ s.t. } x \in S$

这里 f 是目标函数， S 是可行域。对于求解这一问题的解答程序或算法可以看作是一个迭代过程，这过程按照规定的一组指令和终止准则一起产生一个点序列。

迭代下降算法

迭代, 即从一点 $x^{(k)}$ 出发, 按照某种规则A求出后继点 $x^{(k+1)}$, 用 $k+1$ 代替 k , 重复以上过程, 便产生点列 $\{x^{(k)}\}$

下降, 即对某个函数, 在每次迭代中后继点处的函数值要有所减小。

给出一个向量 x_k ,应用算法指令,我们就得到一个新的点 x_{k+1} .

这个过程可用一个算法映射 A 来描述。

此映射一般是一个点到集的映射,它把定义域 X 中的每一点指定到 X 的一个子集。于是,给出一个初始点 x_1 ,算法映射生成一系列的点 $x_1, x_2, \dots$,其中对每一 k , $x_{k+1} \in A(x_k)$.

通过这一映射构造的迭代算法把 x_k 变成 x_{k+1} .

定义8.1.1 算法 A 是定义在空间 X 上的点到集映射,即对每一个点 $x \in X$, 给定一个子集 $A(x) \subset X$.

例1 考虑如下NLP


$$\begin{array}{ll}\min & x^2 \\ \text{s.t.} & x \geq 1\end{array}$$

最优解显为 $x^* = 1$. 设点到点的算法映射为 $A(x) = (x+1)/2$ 则容易验证, 应用映射 A , 对任何初始点所得到的序列都收敛于最优解 $x^* = 1$. 例如, 当 $x_1 = 4$, 算法生成序列 $\{4, 2.5, 1.75, 1.375, 1.1875, \dots\}$

若定义算法映射为点到集合的映射, 如定义算法 A 为

$$A(x) = \begin{cases} [1, (x+1)/2], & \text{若 } x \geq 1 \\ [(x+1)/2, 1] & \text{若 } x < 1 \end{cases}$$

如图所示,应用算法A时,经A作用得到一个闭区间,从此区间中任取一点作为后继点,重复这个过程,得由算法产生得点列,在一定条件下,它收敛于问题的解. 例如 $\{3, 2, 3/2, 5/4, \dots\}$ $\{3, 3/2, 9/8, 33/32, \dots\}$ etc.



8.1.2 解集合

考虑

$$\min_{x \in S} f(x)$$

为了求解上述问题，要求使用的算法具有这样的性质：

由算法产生的点列收敛于整体最优解

然而，在许多情形下，要满足这一点很难做到。事实上由于非凸性，问题的规模和其它一些困难，达到整体最优几乎不可能，因此当达到属于预定集的某一点达到，则可以停止迭代，这个预定集就称之为解集合

常用的解集合有如下几种类型：

- 1, $\Omega = \{x^* : x^* \text{是问题的一个局部最优解}\}$
- 2, $\Omega = \{x^* : x^* \in S, f(x^*) \leq b\}$, b 是一个可接受的目标值
- 3, $\Omega = \{x^* : x^* \in S, f(x^*) < LB + \varepsilon\}$, 其中 $\varepsilon > 0$ 是允许限,
 LB 是最优目标值的下界, 一个典型的下界是 *lagrange*
对偶问题的目标值
- 4, $\Omega = \{x^* : x^* \in S, f(x^*) - f(\hat{x}) < \varepsilon\}$, 其中 $f(\hat{x})$ 是整体最小值,
 $\varepsilon > 0$ 是指定的值
- 5, $\Omega = \{x^* : x^* \in \text{是} KKT \text{点}\}$
- 6, $\Omega = \{x^* : x^* \in S \text{是} FJ \text{点}\}$

8.1.3 下降函数

定义8.1.2 设 $\Omega \subset X$ 为解集合, A 为 X 上的一个算法, $\alpha(x)$ 是定义在 X 上的连续实函数, 若满足

1, 当 $x \notin \Omega$ 且 $y \in A(x)$ 时, $\alpha(y) < \alpha(x)$

2, 当 $x \in \Omega$ 且 $y \in A(x)$ 时, $\alpha(y) \leq \alpha(x)$

则称 α 是关于解集合 Ω 和算法 A 的下降函数。

一般地, 当求解 NLP :

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & x \in S \end{aligned}$$

时, 通常取 $\|\nabla f(x)\|$ 或 $f(x)$ 作为下降函数

8.1.4 闭映射

定义8.1.3 设 X 和 Y 分别是空间 R^p 和 R^q 中的非空闭集。

$A: X \rightarrow Y$ 为点到集映射, 若

$$x^{(k)} \in X, x^{(k)} \rightarrow x$$

$$y^{(k)} \in A(x^{(k)}), y^{(k)} \rightarrow y$$

蕴含 $y \in A(x)$, 则称映射 A 在 $x \in X$ 处是闭的。

如果映射 A 在集合 $Z \subset X$ 上每一点是闭的, 则称映射 A 在集合 Z 上是闭的。

重新考虑例1

$$\begin{array}{ll}\min & x^2 \\ \text{s.t.} & x \geq 1\end{array}$$

设 Ω 是整体最优解的集合，即 $\Omega=\{1\}$ 。考虑算法映射，定义为


$$A(x) = \begin{cases} \left[\frac{3}{2} + \frac{x}{4}, 1 + \frac{x}{2} \right], & \text{若 } x \geq 2 \\ \frac{1}{2}(x+1), & \text{若 } x < 2 \end{cases}$$

映射在下图中说明

显然对任何初始点 $x_1 \geq 2$, 由映射 A 产生的任何序列都收敛于点 $x^*=2 \notin \Omega$ 对初始点 $x_1 < 2$, 由映射 A 产生的任何序列都收敛于点 $x^*=1 \in \Omega$

此例表明算法在区间 $(-\infty, 2)$ 上收敛于集 Ω 中点, 而在 $[2, \infty)$ 上却不收敛于 Ω 中点, 从而算法不是闭的

$$\begin{aligned} & \left(\text{取 } x_k = 2 - \frac{1}{k}, x_k \rightarrow x = 2, \right. \\ & y_k = \frac{1}{2} \left(3 - \frac{1}{k} \right), y_k \rightarrow y = \frac{3}{2}, \\ & \left. y = \frac{3}{2} \notin A(2) \right) \end{aligned}$$



评注：上面例子表明初始点 x_1 选取的重要性：若 $x_1 < 2$ 则达到收敛于 Ω 中的点，否则就不能实现。另外注意到，在上面的例子中都满足如下条件：

- 1, 给出一可行点 $x_k \geq 1$,任何后继点 x_k 也是可行的,即 $x_{k+1} \geq 1$
- 2, 给出一个不在解集 Ω 内的可行点 x_k ,任何后继点 x_{k+1} 满足

$$f(x_{k+1}) < f(x_k), \text{ 其中 } f(x) = x^2.$$

即目标函数严格下降。

- 3, 给出一在 Ω 内的可行点 $x_k (=1)$,任何后继点 x_{k+1} 也在 Ω 内,即

$$x_{k+1} = 1$$

但对任何 $x_1 \geq 2$ 都不收敛于 $x^*=1$,即算法不是闭的


8.1.5 合成映射

定义8.1.4 设 X , Y , Z 分别是空间 R^n , R^p 和 R^q 中的非空闭集。

$B: X \rightarrow Y$, 和 $C: Y \rightarrow Z$ 为点到集映射, 合成映射

$A = CB$ 定义为
$$A(x) = \bigcup_{y \in B(x)} C(y)$$

它是点到集映射 $A: X \rightarrow Z$



定理8.1.1 设 $B: X \rightarrow Y$ 和 $C: Y \rightarrow Z$ 是点到集映射, B 在点 x 处是闭的, C 在 $B(x)$ 上是闭的. 再设若 $x^{(k)} \rightarrow x$ 且 $y^{(k)} \in B(x^{(k)})$ 则存在收敛子列, 则合成映射 $A = CB$ 在 x 处是闭的.

简证: 设 $x_k \rightarrow x, z_k \in A(x_k), z_k \rightarrow z$. 往证 $z \in A(x)$. 由 A 的定义, 对每个 $k, \exists y_k \in B(x_k)$ 使得 $z_k \in C(y_k)$. 由假设, 存在一极限为 y 的收敛子列 $\{y^{(k_j)}\}$, 因为 B 在 x 是闭的, 则 $y \in B(x)$. 又 C 在 $B(x)$ 上是闭的, 则它在 y 也是闭的, 故 $z \in C(y) \in CB(x) = A(x)$, 从而 A 在 x 是闭的

推论1 设 X, Y, Z 分别是空间 R^n, R^p 和 R^q 中的非空闭集。
 $B: X \rightarrow Y$ 和 $C: Y \rightarrow Z$ 为点到集映射, B 在 $x \in X$ 处是闭的, C 在 $B(x)$ 上是闭的且 Y 是紧的, 则合成映射
 $A = CB$ 在 x 处是闭的。

推论2 设 X, Y, Z 分别是空间 R^n, R^p 和 R^q 中的非空闭集。
 $B: X \rightarrow Y$ 是点到点的映射. $C: Y \rightarrow Z$ 为点到集映射. B 在
 $x \in X$ 处连续, C 在 $B(x)$ 上是闭的, 则合成映射 $A = CB$ 在
 x 处是闭的。

8 算法-收敛定理

▣ 8.2.1 收敛定理

定理8.2.1 设 A 为 X 上的一个算法, Ω 为解集合,给定初始点 $x^{(1)}$,进行如下迭代:

如果 $x^{(k)} \in \Omega$,则停止迭代,否则,令 $x^{(k+1)} \in A(x^{(k)})$

用 $k+1$ 代替 k ,重复以上过程.这样产生序列 $\{x^{(k)}\}$

又设:1,序列 $\{x^{(k)}\}$ 含于 X 的紧子集中

2,存在一个连续函数 α ,它是关于 Ω 和 A 的下降函数;

3,映射 A 在 Ω 的补集上是闭的.

则序列 $\{x^{(k)}\}$ 的任一收敛子列的极限属于 Ω .

证明:先证对应序列 $\{x^{(k)}\}$ 的下降函数值数列 $\{\alpha(x^{(k)})\}$ 有极限. 设算法产生序列 $\{x^{(k)}\}$, 由于所有 $x^{(k)}$ 含于 X 的紧子集, 因此存在收敛子序列 $\{x^{(k)}\}_K$, 设其极限 $x \in X$. 由于 α 连续, 对 $k \in K$, 有 $\alpha(x^{(k)}) \rightarrow \alpha(x)$. 于是, 对 $\forall \varepsilon > 0, \exists N$, 当 $k \geq N (k \in K)$ 时有

$$\alpha(x^{(k)}) - \alpha(x) < \varepsilon \quad (2.1)$$

特别的, 必有 $\alpha(x^{(N)}) - \alpha(x) < \varepsilon$ (2.2)

对于所有的 $k > N$ (包括不属于 K 的 k), 由于 α 是下降函数, 故

$$\alpha(x^{(k)}) - \alpha(x^{(N)}) < 0 \quad (2.3)$$

由(2.2)和(2.3)可得

$$\alpha(x^{(k)}) - \alpha(x) = \alpha(x^{(k)}) - \alpha(x^{(N)}) + \alpha(x^{(N)}) - \alpha(x) \\ < 0 + \varepsilon = \varepsilon \quad (2.4)$$

此式对所有 $k > N$ 都成立.

另一方面, 由 α 是下降函数知

$$\alpha(x^{(k)}) - \alpha(x) \geq 0 \quad (2.5)$$

由(2.4)和(2.5)得

$$\lim_{k \rightarrow \infty} \alpha(x^{(k)}) = \alpha(x) \quad (2.6)$$

下证 $x \in \Omega$ (反证法)

假设 $x \notin \Omega$. 考虑序列 $\{x^{(k+1)}\}_K, k \in K$. 由于此序列含于紧集, 故存在收敛子序列 $\{x^{(k+1)}\}_{\bar{K}}, \bar{K} \subset K$, 设其极限为 $\bar{x} \in X$.

用上面的方法可证

$$\lim_{k \rightarrow \infty} \alpha(x^{(k+1)}) = \alpha(\bar{x}) \quad (2.7)$$

$$\text{由极限唯一性, } \alpha(\bar{x}) = \alpha(x) \quad (2.8)$$

再次,由上分析可知, $\bar{K} \subset K$, 对于 $k \in \bar{K}$, 有

$$x^{(k)} \rightarrow x$$

$$x^{(k+1)} \rightarrow \bar{x}, x^{(k+1)} \in A(x^{(k)})$$

由于算法 A 在 Ω 的补集上是闭的, $x \notin \Omega$, 因此 A 在 x 处是闭的, 于是有 $\bar{x} \in A(x)$

由 α 是关于 Ω 和 A 的下降函数, $x \notin \Omega$, 知必有

$$\alpha(\bar{x}) < \alpha(x) \quad (2.9)$$

此与(2.8)矛盾. 故 $x \in \Omega$.

8.2.2实用收敛准则

•正如在收敛定理中所指出，若我们达到解集 Ω 中的一个点时，就终止算法。然而，在大多数情形下，收敛于 Ω 中的点仅仅出现在极限意义上，因此我们必须依靠终止迭代过程的某些实际规则，下面给出一些常用的终止规则。这里 $\varepsilon > 0$ 和正整数 N 是预先给定的。

1) $\|\mathbf{x}_{k+N} - \mathbf{x}_k\| < \varepsilon$

如果应用映射 A 的 N 次后移动的距离小于 ε 时，算法终止

2), $\|x_{k+1} - x_k\| < \varepsilon$ or

$$\frac{\|x_{k+1} - x_k\|}{\|x_k\|} < \varepsilon$$

3),当函数值(或下降函数值)的下降量充分小时停止计算,即

$$f(x_{k+1}) - f(x_k) < \varepsilon$$

或

$$\left| \frac{f(x_{k+1}) - f(x_k)}{f(x_k)} \right| < \varepsilon$$

4) 在无约束最优化中, 当梯度充分接近于0时停止计算, 即

$$\|\nabla f(x_k)\| < \varepsilon$$

8.2.3 收敛速率

定义8.2.1 设序列 $\{\gamma^k\}$ 收敛于 γ^* ，定义满足

$$0 \leq \overline{\lim}_{k \rightarrow \infty} \frac{\|\gamma^{k+1} - \gamma^*\|}{\|\gamma^k - \gamma^*\|^p} = \beta < \infty$$

的非负数 p 的上确界为序列 $\{\gamma^k\}$ 的收敛级

若序列的收敛级为 p ，则称序列是 p 级收敛的。

若在定义式中， $p = 1$ ， $\beta < 1$ ，则称序列是以收敛比 β 线性收敛的。

若在定义式中 $p > 1$ ，或者 $p = 1$ 且 $\beta = 0$ ，则称序列是超线性收敛的。