



北京邮电大学

BEIJING UNIVERSITY OF POSTS AND TELECOMMUNICATIONS

最优化理论与算法

帅天平

数学科学学院

tpshuai@bupt.edu.cn



第九章 一维搜索

- 一维搜索的基本概念
- 试探法
- 函数逼近法
- 非精确线搜索

9.1 一维搜索概念

最优化方法的基本结构:

给定初始点 $\mathbf{x}_0$

(a) 确定搜索方向 $\mathbf{d}_k$, 即按照一定规则, 构造 f 在 $\mathbf{x}_k$ 点处的下降方向 $\mathbf{d}_k$ 作为搜索方向;

(b) 确定步长因子 α_k , 使目标函数值有某种意义下的下降;

(c) 令 $\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$

若 $\mathbf{x}_{k+1}$ 满足某种终止条件 则停止迭代, 得到近似最优解 $\mathbf{x}_{k+1}$, 否则, 重复上述步骤。

注意到上述迭代算法中, 当方向确定后, 涉及到求一个步长 α_k , 使得目标函数值减小(极小化问题), 这就是在一直线上求目标函数的极小点, 即极小化 $f(\mathbf{x}_k + \alpha \mathbf{d}_k)$ 。这称为对变量 α 的一维搜索问题, 或称为线搜索。

设目标函数为 $f(x)$,过点 $x^{(k)}$ 沿方向 $d^{(k)}$ 的直线可用点集来表示:

$$L = \{x \mid x = x^{(k)} + \lambda d^{(k)}, -\infty < \lambda < +\infty\} \quad (9.1.1)$$

求 $f(x)$ 在直线 L 上的极小点就转化为求

$$\varphi(\lambda) = f(x^{(k)} + \lambda d^{(k)}) \quad (9.1.2)$$

的极小点.

设 $\varphi(\lambda)$ 的极小点为 λ_k ,称 λ_k 为沿方向 $d^{(k)}$ 的步长因子
于是 $f(x)$ 在直线 L 上的极小点为

$$x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)} \quad (9.1.3)$$

一维
搜索

{

试探法

函数逼近法/插值法

□ 一维搜索算法的闭性

假设一维搜索是以 x 为起点,沿方向 d 进行的,并定义为算法映射 M

定义9.1.1 算法映射 $M : \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}^n$ 定义为

$$M(x, d) = \{y \mid y = x + \bar{\lambda}d, \bar{\lambda} \text{ 满足}$$

$$f(x + \bar{\lambda}d) = \min_{\lambda \geq 0} f(x + \lambda d)\} \quad (9.1.4)$$

定理9.1.1 设 f 是定义在 R^n 的连续函数, $d \neq 0$,则(9.1.4)定义的算法映射 M 在 (x,d) 处是闭的

证: 设序列 $\{x^{(k)}\}$ 和 $\{d^{(k)}\}$ 满足

$$(x^{(k)}, d^{(k)}) \rightarrow (x, d); \quad y^{(k)} \rightarrow y, y^{(k)} \in M(x^{(k)}, d^{(k)})$$

下证 $y \in M(x, d)$, 注意到, 对每个 $k, \lambda_k \geq 0$, 使

$$y^{(k)} = x^{(k)} + \lambda_k d^{(k)} \quad (9.1.5)$$

由 $d \neq 0$, 当 k 充分大时, 必有 $d^{(k)} \neq 0$, 于是由(9.1.5)

$$\lambda_k = \frac{\|y^{(k)} - x^{(k)}\|}{\|d^{(k)}\|} \quad (9.1.6)$$

$$\text{令 } k \rightarrow \infty, \text{ 则 } \lambda_k \rightarrow \bar{\lambda} = \frac{\|y - x\|}{\|d\|} \quad (9.1.7)$$

(9.1.5)中令 $k \rightarrow \infty$ 并注意到(9.1.7), 有

$$y = x + \bar{\lambda}d \quad (9.1.8)$$

根据M的定义, 对每个 k 及 $\lambda \geq 0$, 有

$$f(y^{(k)}) \leq f(x^{(k)} + \lambda d^{(k)}) \quad (9.1.9)$$

由于 f 连续, 令 $k \rightarrow \infty$, 则由(9.1.9)得

$$f(y) \leq f(x + \lambda d)$$

$$\text{故 } f(x + \bar{\lambda}d) = \min_{\lambda \geq 0} f(x + \lambda d)$$

即知 $y \in M(x, d)$


9.2.1, 黄金分割法(0.618法)

定义9.2.1 设 f 是定义在闭区间 $[a, b]$ 上的一元实函数, $\bar{x}$ 是 f 在 $[a, b]$ 上的极小点, 且对 $\forall x^{(1)}, x^{(2)} \in [a, b]$, $x^{(1)} < x^{(2)}$, 有

$$\text{当 } x^{(2)} \leq \bar{x} \text{ 时 } f(x^{(1)}) > f(x^{(2)})$$

$$\text{当 } \bar{x} \leq x^{(1)} \text{ 时 } f(x^{(1)}) < f(x^{(2)})$$

则称 f 是在闭区间 $[a, b]$ 上的(下)单峰函数.





定理9.2.1 设 f 是区间 $[a,b]$ 上的单峰函数, $x^{(1)}, x^{(2)} \in [a,b]$.

且 $x^{(1)} < x^{(2)}$, 则

(1) 若 $f(x^{(1)}) > f(x^{(2)})$, 则 $\forall x \in [a, x^{(1)}], f(x) > f(x^{(2)})$

(2) 若 $f(x^{(1)}) \leq f(x^{(2)})$, 则 $\forall x \in [x^{(2)}, b], f(x) \geq f(x^{(1)})$,



证明:仅证(1),反证,如若不然,存在点 $x^* \in [a, x^{(1)}]$,使

$$f(x^*) \leq f(x^{(2)})$$

显然 $x^{(1)}$ 不是极小点.此时要么极小点 $\bar{x} \in [a, x^{(1)}]$

要么 $\bar{x} \in [x^{(1)}, b]$.

若 $\bar{x} \in [a, x^{(1)}]$,则 $f(x^{(1)}) < f(x^{(2)})$,矛盾.

若 $\bar{x} \in [x^{(1)}, b]$,则 $f(x^*) > f(x^{(1)}) > f(x^{(2)})$,矛盾.

根据以上定理,只需选择两个点就可缩短包含极小点的

区间: (1)若 $f(x^{(1)}) > f(x^{(2)})$,则极小点 $\bar{x} \in [x^{(1)}, b]$;

(2)若 $f(x^{(1)}) \leq f(x^{(2)})$,则极小点 $\bar{x} \in [a, x^{(2)}]$.

黄金分割法(0.618法)

基本思想:通过取试探点使包含极小点的区间(不确定区间)不断缩小,当区间长度小到一定程度时,区间上各点的函数值均接近极小值,此时该区间内任一点都可以作为极小点的近似值。

设 $\varphi(\alpha)$ 是搜索区间 $[a_1, b_1]$ 上的单峰函数. 设在第 k 次迭代时搜索区间为 $[a_k, b_k]$. 取两个试探点 $\lambda_k, \mu_k \in [a_k, b_k], \lambda_k < \mu_k$. 计算 $\varphi(\lambda_k)$ 和 $\varphi(\mu_k)$, 根据 Th1:

(1), 若 $\varphi(\lambda_k) \leq \varphi(\mu_k)$, 令 $a_{k+1} = a_k, b_{k+1} = \mu_k$, (2.1)

(2), 若 $\varphi(\lambda_k) > \varphi(\mu_k)$, 令 $a_{k+1} = \lambda_k, b_{k+1} = b_k$, (2.2)

我们要求两个试探点 λ_k 和 μ_k 满足下列条件：

(1), λ_k 和 μ_k 到搜索区间 $[a_k, b_k]$ 的端点等距,即

$$b_k - \lambda_k = \mu_k - a_k, \quad (2.3)$$

(2), 每次迭代, 搜索区间长度的缩短率相同, 即

$$b_{k+1} - a_{k+1} = r(b_k - a_k), \quad (2.4)$$

由(2.3)和(2.4)得到

$$\lambda_k = a_k + (1-r)(b_k - a_k), \quad (2.5)$$

$$\mu_k = a_k + r(b_k - a_k), \quad (2.6)$$

今考虑(2.1)的情形,此时新的搜索区间为

$$[a_{k+1}, b_{k+1}] = [a_k, \mu_k] \quad (2.7)$$

为进一步缩短区间. 需取试探点 λ_{k+1} 和 μ_{k+1} . 由(2. 6)

$$\begin{aligned} \mu_{k+1} &= a_{k+1} + r(b_{k+1} - a_{k+1}) \\ &= a_k + r(\mu_k - a_k) \\ &= a_k + r(a_k + r(b_k - a_k) - a_k), \\ &= a_k + r^2(b_k - a_k) \end{aligned} \quad (2.8)$$

若令 $r^2 = 1 - r$ (2.9)

则 $\mu_{k+1} = a_k + (1 - r)(b_k - a_k) = \lambda_k$ (2.10)

这样新的试探点 μ_{k+1} 就不用重新计算只要取 λ_k , 于是每次迭代中 (除第一次) 只需取一个试探点.

类似的, 如考虑 (2. 2) 的情形, 新的试探点 $\lambda_{k+1} = \mu_k$, 它也不需重新计算.

解方程 (2.9) 立得区间长度缩短率 $r = \frac{-1 \pm \sqrt{5}}{2}$

由于 $r > 0$, 故取 $r = \frac{-1 + \sqrt{5}}{2} \approx 0.618$ (2.11)

这样,计算公式(2.5)、(2.6)可写为

$$\lambda_k = a_k + 0.382(b_k - a_k), \quad (2.12)$$



$$\mu_k = a_k + 0.618(b_k - a_k), \quad (2.13)$$

由于每次函数计算后极小区间的缩短率为 r ,故若初始区间为 $[a_1, b_1]$,则最终区间长度为 $r^{n-1}(b_1 - a_1)$,因此可知0.618法是线性收敛的。

0.618法也叫黄金分割法,因为缩短率 r 叫黄金分割数,它满足比率

$$\frac{r}{1} = \frac{1-r}{r}, \quad \text{即} \quad \tau^2 + \tau - 1 = 0。$$

其几何意义:黄金分割率 r 对应的点在单位长区间 $[0,1]$ 中的位置相当于其对称点 $1-r$ 在区间 $[0,r]$ 中的位置



黄金分割法（0.618法）

步1:选取初始数据,确定初始搜索区间 $[a_1, b_1]$ 和精度要求 $\delta > 0$. 计算最初两试探点 λ_1, μ_1 :

$$\lambda_1 = a_1 + 0.382(b_1 - a_1),$$

$$\mu_1 = a_1 + 0.618(b_1 - a_1),$$

计算 $\varphi(\lambda_1)$ 和 $\varphi(\mu_1)$.

步2:比较函数值.若 $\varphi(\lambda_k) > \varphi(\mu_k)$,则转步3,

否则, $\varphi(\lambda_k) \leq \varphi(\mu_k)$ 转步4

步3:若 $\mathbf{b}_k - \lambda_k \leq \delta$,停止计算,输出 μ_k ;否则,令

$$\mathbf{a}_{k+1} := \lambda_k, \mathbf{b}_{k+1} := \mathbf{b}_k, \lambda_{k+1} := \mu_k,$$

$$\varphi(\lambda_{k+1}) = \varphi(\mu_k), \mu_{k+1} = \mathbf{a}_{k+1} + 0.618(\mathbf{b}_{k+1} - \mathbf{a}_{k+1}),$$

计算 $\varphi(\mu_{k+1})$ 转步5

步4:若 $\mu_k - \mathbf{a}_k \leq \delta$,停止计算,输出 λ_k ;否则,令

$$\mathbf{a}_{k+1} := \mathbf{a}_k, \mathbf{b}_{k+1} := \mu_k, \mu_{k+1} := \lambda_k,$$

$$\varphi(\mu_{k+1}) := \varphi(\lambda_k), \lambda_{k+1} = \mathbf{a}_{k+1} + 0.382(\mathbf{b}_{k+1} - \mathbf{a}_{k+1}),$$

计算 $\varphi(\lambda_{k+1})$,转步5

步5: $k := k + 1$,转步2。

9.2.2 Fibonacci法

Fibonacci法是与0.618法类似的一种分割方法。

它与0.618法的主要区别在于：搜索区间长度的缩短率不是采用黄金分割数，而是采用 Fibonacci 数：

$$F_{n+1} = F_n + F_{n-1}, \quad F_0 = F_1 = 1, \quad n = 1, 2, \dots$$

Fibonacci法中计算公式为：

$$\begin{aligned}\lambda_k &= a_k + \left(1 - \frac{F_{n-k}}{F_{n-k+1}}\right)(b_k - a_k) \\ &= a_k + \frac{F_{n-k-1}}{F_{n-k+1}}(b_k - a_k), k = 1, 2, \dots, n-1 \\ \mu_k &= a_k + \frac{F_{n-k}}{F_{n-k+1}}(b_k - a_k), k = 1, 2, \dots, n-1\end{aligned}$$

显然, 这里 F_{n-k}/F_{n-k+1} 相当于0.618法(1.5)-(1.6)中的 τ , 每次的缩短率满足

$$b_{k+1} - a_{k+1} = \frac{F_{n-k}}{F_{n-k+1}} (b_k - a_k)$$

这里 n 是计算函数值的次数,即要求经过 n 次计算函数值后,最后区间的长度不超过 δ ,即 $b_n - a_n \leq \delta$

由于

$$\begin{aligned} b_n - a_n &= \frac{F_1}{F_2} (b_{n-1} - a_{n-1}) \\ &= \frac{F_1}{F_2} \cdot \frac{F_2}{F_3} \cdot \dots \cdot \frac{F_{n-1}}{F_n} (b_1 - a_1) = \frac{1}{F_n} (b_1 - a_1) \end{aligned}$$

故
$$\frac{1}{F_n}(b_1 - a_1) \leq \delta \Rightarrow F_n \geq \frac{b_1 - a_1}{\delta} \quad (2.14)$$

给出最终区间长度得的上界 δ , 由(2.14)求出*Fibonacci*数 F_n ,再跟据 F_n 确定出 n ,从而搜索一直进行到第 n 个搜索点为止. 注意到

$$F_n = \frac{1}{\sqrt{5}} \left\{ \left(\frac{1+\sqrt{5}}{2} \right)^{k+1} - \left(\frac{1-\sqrt{5}}{2} \right)^{k+1} \right\}$$

$$\text{从而} \lim_{k \rightarrow \infty} \frac{F_{k-1}}{F_k} = \frac{\sqrt{5}-1}{2} = \tau$$

上式表明当 n 趋于无穷时,Fibonacci法与0.618法的区间缩短率相同,因而也是以收敛比 r 线性收敛。可以证明Fibonacci法是分割方法求一维极小化问题的最优策略, 而0.618法是近似最优的。

Fibonacci法

步1, 给定初始区间 $[a_1, b_1]$ 和最终区间长度 L . 求计算

函数值的次数 n , 使得 $F_n \geq \frac{b_1 - a_1}{L}$

置辨别常数 $\delta > 0$. 计算试探点 λ_1 和 μ_1 :

$$\lambda_1 = a_1 + \frac{F_{n-2}}{F_n} (b_1 - a_1), \mu_1 = a_1 + \frac{F_{n-1}}{F_n} (b_1 - a_1)$$

计算函数值 $\varphi(\lambda_1)$, $\varphi(\mu_1)$. 置 $k=1$

步2,若 $\varphi(\lambda_k) > \varphi(\mu_k)$, 转3; 若 $\varphi(\lambda_k) \leq \varphi(\mu_k)$, 转4。

步3,令 $a_{k+1} = \lambda_k, b_{k+1} = b_k, \lambda_{k+1} = \mu_k$. 计算试探点 μ_{k+1}

$$\mu_{k+1} = a_{k+1} + \frac{F_{n-k-1}}{F_{n-k}} (b_{k+1} - a_{k+1}).$$

若 $k = n - 2$, 转6, 否则, 计算 $\varphi(\mu_{k+1})$, 转5。

步4,令 $a_{k+1} = \lambda_k, b_{k+1} = \mu_k, \mu_{k+1} = \lambda_k$. 计算试探点 λ_{k+1}

$$\lambda_{k+1} = a_{k+1} + \frac{F_{n-k-2}}{F_{n-k}} (b_{k+1} - a_{k+1}).$$

若 $k = n - 2$, 转6, 否则, 计算 $\varphi(\lambda_{k+1})$, 转5。

步5, 置 $k:=k+1$, 转2.

步6, 令 $\lambda_n = \lambda_{n-1}, \mu_n = \lambda_{n-1} + \delta$. 计算 $\varphi(\lambda_n), \varphi(\mu_n)$ 。

若 $\varphi(\lambda_k) > \varphi(\mu_k)$, 则令 $a_n = \lambda_n, b_n = b_{n-1}$;

若 $\varphi(\lambda_k) \leq \varphi(\mu_k)$, 则令 $a_n = a_{n-1}, b_n = \lambda_n$ 。

停止计算, 极小点含于 $[a_n, b_n]$.

9.2.3 进退法

进退法是确定搜索区间的一种简单方法。其基本思想是：从一点出发，按一定的步长，试图确定出函数值呈现“高-低-高”的三点。一个方向不成功，就退回来，再沿着相反的方向寻找。

具体言之，给定初始点 a_0 ，初始步长 $h_0 > 0$ ，若

$$\varphi(a_0 + h_0) < \varphi(a_0)$$

则下一步从新点 $a_0 + h_0$ 出发，加大步长，再向前搜索。若

$$\varphi(a_0 + h_0) > \varphi(a_0)$$

则下一步还从点 a_0 出发，再沿反方向同样搜索，直到目标函数上升就停止。这样就得到一个搜索区间。

算法(进退法)

步1: 选取初始数据, 初始点 a_0 , 初始步长 $h_0 > 0$, 加倍系数 $t > 1$, 计算 $\varphi(a_0)$, $k=0$ 。

步2: 比较目标函数值。令 $a_{k+1} = a_k + h_k$, 计算 $\varphi(a_{k+1})$, 若 $\varphi(a_{k+1}) < \varphi(a_k)$, 转步3, 否则转步4。

步3: 加大探索步长。令 $h_{k+1} = th_k$, $\alpha = a_k$, $a_k = a_{k+1}$, $\varphi(a_k) = \varphi(a_{k+1})$, $k=k+1$, 转步2。

步4: 反向探索。若 $k=0$, 转换探索反向, 令 $h_k = -h_k$, $a_k = a_{k+1}$, 转步2, 否则, 停止迭代, 令

$$a = \min\{\alpha, a_{k+1}\}, b = \max\{\alpha, a_{k+1}\}$$

输出 $[a, b]$ 。

9.3 一维搜索-函数逼近法（插值法）

9.3.1. 牛顿法（一点二次插值法）

考虑问题 $\min f(x), x \in \mathbb{R}$ (3.1)

令

$$\varphi(x) = f(x^{(k)}) + f'(x^{(k)})(x - x^{(k)}) + \frac{1}{2} f''(x^{(k)})(x - x^{(k)})^2$$

又令

$$\varphi'(x) = f'(x^{(k)}) + f''(x^{(k)})(x - x^{(k)})$$

得到 $\varphi(x)$ 的驻点，记做 $x^{(k+1)}$ ，则

$$x^{(k+1)} = x^{(k)} - \frac{f'(x^{(k)})}{f''(x^{(k)})} \quad (3.2)$$

在点 $x^{(k)}$ 附近, $f(x) \approx \varphi(x)$, 因此可用 $\varphi(x)$ 的极小点作为目标函数 $f(x)$ 的极小点的估计。如果 $x^{(k)}$ 是 $f(x)$ 的极小点, 则利用(3.2)可以得到极小点的一个进一步的估计. 于是得到一个序列 $\{x^{(k)}\}$.

算法(牛顿法)

Step1, 给定初始点 $x^{(0)}$, 允许误差 $\varepsilon > 0$, 置 $k = 0$;

Step2, 若 $|f'(x^{(k)})| < \varepsilon$, 停止, 得 $x^{(k)}$ 。

Step3, 计算点 $x^{(k+1)}$:

$$x^{(k+1)} = x^{(k)} - \frac{f'(x^{(k)})}{f''(x^{(k)})} \quad \text{置 } k = k + 1. \text{ 转2}$$

定理3.1 设 $f(x)$ 存在连续三阶导数, $\bar{x}$ 满足

$$f'(\bar{x}) = 0, f''(\bar{x}) \neq 0$$

初始点 $x^{(1)}$ 充分接近 $\bar{x}$, 则牛顿法产生的序列 $\{x^{(k)}\}$ 至少以2阶收敛速率收敛于 $\bar{x}$.

证明: 牛顿法可定义为算法映射

$$A(x) = x - \frac{f'(x)}{f''(x)} \quad (3.3)$$

设解集合 $\Omega = \{\bar{x}\}$, 定义函数 $\alpha(x) = |x - \bar{x}|$

下证 α 是关于解集合 Ω 和算法 A 的下降函数

设 $x^{(k)} \neq \bar{x}$, $x^{(k+1)} \in A(x^{(k)})$. 由 $f'(\bar{x}) = 0$, 有

$$\begin{aligned}\alpha(x^{(k+1)}) &= \left| x^{(k+1)} - \bar{x} \right| = \left| x^{(k)} - \frac{f'(x^{(k)})}{f''(x^{(k)})} - \bar{x} \right| \\ &= \frac{1}{|f''(x^{(k)})|} \left| x^{(k)} f''(x^{(k)}) - f'(x^{(k)}) - \bar{x} f''(x^{(k)}) \right| \\ &= \frac{1}{|f''(x^{(k)})|} \left| f'(\bar{x}) - [f'(x^{(k)}) + (\bar{x} - x^{(k)}) f''(x^{(k)})] \right| \\ &= \frac{1}{|f''(x^{(k)})|} \leq \frac{1}{2} (\bar{x} - x^{(k)})^2 |f'''(\xi)| \quad (3.4)\end{aligned}$$

其中 ξ 在 $\bar{x}$ 与 $x^{(k)}$ 之间。

由于 $f''(x)$ 和 $f'''(x)$ 连续, $f''(\bar{x}) \neq 0$, 故当 $x^{(k)}$ 接近 $\bar{x}$ 时, 必存在 $k_1, k_2 > 0$ 使得在包含 $x^{(k)}$ 和 $\bar{x}$ 的闭区间上的每一点 x 处有

$$|f''(x)| \geq k_1, |f'''(x)| \leq k_2 \quad (3.5)$$

代入(3.4), 则 $|x^{(k+1)} - \bar{x}| \leq \frac{k_2}{2k_1} (\bar{x} - x^{(k)})^2$ (3.6)

取初始点 $x^{(1)}$ 充分接近 $\bar{x}$, 使得

$$\frac{k_2}{2k_1} |\bar{x} - x^{(1)}| < 1$$


由此推得 $\{x^{(k)}\} \subset X = \{x \mid |x - \bar{x}| \leq |x^{(1)} - \bar{x}|\}$

且 $|x^{(k+1)} - \bar{x}| < |x^{(k)} - \bar{x}|$ (3.7)

由此知, α 是关于解集合 Ω 和算法 A 的下降函数。且 X 为紧集, $A(x)$ 在 X 上连续. 根据 $Th8.2.1$, $\{x^{(k)}\}$ 收敛于 $\bar{x}$. 由(3.6)知收敛阶为2.

9.3.2. 割线法（二点二次插值法）

基本思想：用割线逼近目标函数的导函数的曲线 $y=f'(x)$ 把割线的零点作为目标函数的驻点的估计。



设在点 $x^{(k)}$ 和 $x^{(k-1)}$ 处的导数分别为 $f'(x^{(k)})$ 和 $f'(x^{(k-1)})$ 。令

$$\varphi(x) = f'(x^{(k)}) + \frac{f'(x^{(k)}) - f'(x^{(k-1)})}{x^{(k)} - x^{(k-1)}}(x - x^{(k)}) = 0$$
$$\Rightarrow x^{(k+1)} = x^{(k)} - \frac{x^{(k)} - x^{(k-1)}}{f'(x^{(k)}) - f'(x^{(k-1)})} f'(x^{(k)}) \quad (3.8)$$

用公式(3.8)进行迭代，得到序列 $\{x^{(k)}\}$ 。

□ 在一定的条件下，这个序列收敛于解：

定理3.2 设 $f(x)$ 存在连续三阶导数, $\bar{x}$ 满足

$$f'(\bar{x}) = 0, f''(\bar{x}) \neq 0$$

若 $x^{(1)}$ 和 $x^{(2)}$ 充分接近 $\bar{x}$, 则割线法产生的序列 $\{x^{(k)}\}$ 收敛于 $\bar{x}$.
收敛阶为1.618.

证明： 设 $\Delta = \{x \mid |x - \bar{x}| \leq \delta\}$ 是包含 $\bar{x}$ 的某个充分小的闭区间，
使得对每一个 $x \in \Delta$, 有 $f''(x) \neq 0$, 取 $x^{(1)}, x^{(2)} \in \Delta$.

以 $x^{(k)}, x^{(k-1)} \in \Delta$ 为节点构造插值多项式

$$\varphi(x) = f'(x^{(k)}) + \frac{f'(x^{(k)}) - f'(x^{(k-1)})}{x^{(k)} - x^{(k-1)}}(x - x^{(k)}) \quad (3.9)$$

⇒ 插值余项

$$f'(x) - \varphi(x) = \frac{f'''(\xi_1)}{2} (x - x^{(k)})(x - x^{(k-1)}) \quad (3.10)$$

其中 $\xi_1 \in \Delta$ 。

由于 $f'(\bar{x})=0$ ，因此由(3.10)得到

$$\varphi(\bar{x}) = -\frac{f'''(\xi_1)}{2} e_k e_{k-1} \quad (3.11)$$

$$e_k = x^{(k)} - \bar{x}, e_{k-1} = x^{(k-1)} - \bar{x}$$

另一方面，由(3.8)知 $\varphi(x^{(k+1)}) = 0$ ，由(3.9)知

$$\varphi'(x) = \frac{f'(x^{(k)}) - f'(x^{(k-1)})}{x^{(k)} - x^{(k-1)}}$$

$$\begin{aligned} \Rightarrow \varphi(\bar{x}) &= \varphi(\bar{x}) - \varphi(x^{(k+1)}) = \varphi'(\xi_2)(\bar{x} - x^{(k+1)}) \\ &= \frac{f'(x^{(k)}) - f'(x^{(k-1)})}{x^{(k)} - x^{(k-1)}} (\bar{x} - x^{(k+1)}) = f''(\xi_3)(\bar{x} - x^{(k+1)}) \\ &= -f''(\xi_3)e_{k+1}, \end{aligned} \quad (3.12)$$

其中 $e_{k+1} = x^{(k+1)} - \bar{x}$, ξ_3 在 $x^{(k)}$ 和 $x^{(k-1)}$ 之间, $f''(\xi_3) \neq 0$.

由**(3.11)**和**(3.12)**得到

$$e_{k+1} = \frac{f'''(\xi_1)}{2f''(\xi_3)} e_k e_{k-1} \quad (3.13)$$

上式两端取绝对值，则

$$|e_{k+1}| = \frac{|f'''(\xi_1)|}{2|f''(\xi_3)|} |e_k| |e_{k-1}| \quad (3.14)$$

令
$$M = \frac{\max_{x \in \Delta} |f'''(x)|}{2 \min_{x \in \Delta} |f''(x)|}$$

则
$$|e_{k+1}| \leq M |e_k| |e_{k-1}| \quad (3.15)$$

取充分小的 Δ .使得
$$M\delta < 1 \quad (3.16)$$

则
$$|e_{k+1}| \leq M\delta\delta < \delta$$

于是, $x^{(k)}, x^{(k-1)} \in \Delta \Rightarrow x^{(k+1)} \in \Delta$, 进而由 $x^{(1)}, x^{(2)} \in \Delta$
 $\Rightarrow x^{(k)} \in \Delta, \forall k$, 由(3.15) $\Rightarrow \{x^{(k)}\}$ 收敛于 $\bar{x}$.

下面考虑收敛速率，考虑 k 取充分大的情形。根据 **(3.14)**

$$|e_{k+1}| \approx \bar{M} |e_k| |e_{k-1}| \quad (3.17)$$

其中 $\bar{M} = \frac{|f'''(\bar{x})|}{2|f''(\bar{x})|}$

令 $|e_k| = a^{y_k} / \bar{M} \quad (3.18)$

代入 (3.17). 于是可考虑差分方程

$$y_{k+1} = y_k + y_{k-1}$$

它的特征方程是 $\tau^2 - \tau - 1 = 0$

其两个根是 $\tau_1 = \frac{1+\sqrt{5}}{2} \approx 1.618, \tau_2 = \frac{1-\sqrt{5}}{2} \approx -0.618$

$$\text{于是 } |e_k| = \frac{1}{\bar{M}} a^{c_1 \tau_1^k + c_2 \tau_2^k} \approx \frac{1}{\bar{M}} a^{c_1 \tau_1^k} (k \geq 1) \quad (3.19)$$

$$|e_{k+1}| \approx \frac{1}{\bar{M}} a^{c_1 \tau_1^{k+1}} (k \geq 1) \quad (3.20)$$

$$\Rightarrow \frac{|e_{k+1}|}{|e_k|^{\tau_1}} \approx \bar{M}^{\tau_1 - 1} (k \geq 1)$$

3.3 抛物线法（三点二次插值法）

□ 基本思想：在极小点附近用二次三项式 x 逼近目标函数 $f(x)$, 令 x 与 $f(x)$ 在三点 $x^{(1)} < x^{(2)} < x^{(3)}$ 处有相同的函数值, 并假设 $f(x^{(1)}) > f(x^{(2)})$, $f(x^{(2)}) < f(x^{(3)})$

□ 令
$$x = a + bx + cx^2 \quad (9.3.21)$$

□ 又令
$$x^{(1)} = a + bx^{(1)} + c(x^{(1)})^2 = f(x^{(1)}) \quad (9.3.22)$$

$$x^{(2)} = a + bx^{(2)} + c(x^{(2)})^2 = f(x^{(2)}) \quad (9.3.23)$$

$$x^{(3)} = a + bx^{(3)} + c(x^{(3)})^2 = f(x^{(3)}) \quad (9.3.24)$$

解方程组(9.3.22-24), 求二次逼近函数 x 的系数 a, b, c 为书写方便, 记

$$\begin{aligned}
 B_1 &= ((x^{(2)})^2 - (x^{(3)})^2) f(x^{(1)}), B_2 = ((x^{(3)})^2 - (x^{(1)})^2) f(x^{(2)}) \\
 B_3 &= ((x^{(1)})^2 - (x^{(2)})^2) f(x^{(3)}), C_1 = (x^{(2)} - x^{(3)}) f(x^{(1)}), \\
 C_2 &= (x^{(3)} - x^{(1)}) f(x^{(2)}), C_3 = (x^{(1)} - x^{(2)}) f(x^{(3)}); \\
 D &= (x^{(1)} - x^{(2)})(x^{(2)} - x^{(3)})(x^{(3)} - x^{(1)})
 \end{aligned}$$

$$\text{则} \Rightarrow b = \frac{B_1 + B_2 + B_3}{D}, \quad (3.25)$$

$$c = \frac{C_1 + C_2 + C_3}{D} \quad (3.26)$$

为求 $\varphi(x)$ 的极小点, 令 $\varphi'(x) = b + 2cx = 0$

$$\text{解得} \quad x = -\frac{b}{2c} \quad (3.27)$$

把 $\varphi(x)$ 的驻点记做 $\bar{x}^{(k)}$.则

$$\bar{x}^{(k)} = \frac{B_1 + B_2 + B_3}{2(C_1 + C_2 + C_3)} \quad (3.28)$$

这样把 $\bar{x}^{(k)}$ 作为 $f(x)$ 的极小点的一个估计.再从 $x^{(1)}, x^{(2)}, x^{(3)}, \bar{x}^{(k)}$ 中选择目标函数值最小的点及其左右两点,给予相应的上标,代入公式,求出极小点的新的估计值 $\bar{x}^{(k+1)}$.

以此类推,产生点列 $\{x^{(k)}\}$,

在一定条件下,这个点列收敛于问题的解,其收敛级为1.3.

3.4 两点三次插值法

基本思想:首先选取两个点 $x^{(1)}, x^{(2)}$ ($x^{(1)} < x^{(2)}$),使得 $f'(x^{(1)}) < 0, f'(x^{(2)}) > 0$.于是区间 $(x^{(1)}, x^{(2)})$ 内存在极小点.利用在这两点的函数值和导数构造一个三次多项式 $\varphi(x)$,使它与 $f(x)$ 在 $x^{(1)}$ 和 $x^{(2)}$ 有相同的函数值和相同的导数,用 $\varphi(x)$ 逼近 $f(x)$.进而用 $\varphi(x)$ 的极小点估计 $f(x)$ 的极小点.

令

$$\varphi(x) = a(x - x^{(1)})^3 + b(x - x^{(1)})^2 + c(x - x^{(1)}) + d \quad (3.29)$$

$$\varphi(x^{(1)}) = f(x^{(1)}), \quad (3.30); \quad \varphi'(x^{(1)}) = f'(x^{(1)}), \quad (3.31)$$

$$\varphi(x^{(2)}) = f(x^{(2)}), \quad (3.32); \quad \varphi'(x^{(2)}) = f'(x^{(2)}), \quad (3.33)$$

将(3.30)-(33)依次代入(3.29)得

$$\left\{ \begin{array}{l} d = f(x^{(1)}) \\ c = f'(x^{(1)}) \\ a(x^{(2)} - x^{(1)})^3 + b(x^{(2)} - x^{(1)})^2 + c(x^{(2)} - x^{(1)}) + d = f(x^{(2)}) \\ 3a(x^{(2)} - x^{(1)})^2 + 2b(x^{(2)} - x^{(1)}) + c = f'(x^{(2)}) \end{array} \right. \quad (3.34)$$

目的是求 $\varphi(x)$ 的极小点,期望用它来逼近极小点,或者基于此再确定新的迭代,为此,求出满足极值条件的点,即满足 $\varphi'(x)=0$, $\varphi''(x)>0$ 的点.

$$\varphi'(x) = 3a(x - x^{(1)})^2 + 2b(x - x^{(1)}) + c \quad (3.35)$$

$$\varphi''(x) = 6a(x - x^{(1)}) + 2b, \quad (3.36);$$

$$\text{令 } \varphi'(x) = 0 \Rightarrow$$

$$a(x - x^{(1)})^2 + 2b(x - x^{(1)}) + c = 0, \quad (3.37)$$

解此方程

$$(1)a = 0 \Rightarrow \bar{x} - x^{(1)} = -\frac{c}{2b}, \quad (3.38);$$

$$(2)a \neq 0 \Rightarrow \bar{x} - x^{(1)} = -\frac{-b \pm \sqrt{b^2 - 3ac}}{3a} \quad (3.33)$$

第一种情形,有 $\varphi''(x) = 2b > 0$ (由假设及 (3.24) 可得)

故 $\bar{x}$ 是 $\varphi(x)$ 的极小点.

第二种情形,将方程的根代入(3.36)

$$\varphi''(\bar{x}) = 6a(\bar{x} - x^{(1)}) + 2b = 6a \frac{-b \pm \sqrt{b^2 - 3ac}}{3a} + 2b$$

$$= \pm 2\sqrt{b^2 - 3ac}$$

要使 $\varphi''(x) > 0$

$$\Rightarrow \text{应取 } \bar{x} = \frac{-b + \sqrt{b^2 - 3ac}}{3a} = \frac{-c}{b + \sqrt{b^2 - 3ac}} \quad (3.40)$$

注意到当 $a=0$ 时, $b>0$,故当 $a=0$ 时由(3.40)得

$$\bar{x} - x^{(1)} = -\frac{c}{2b}$$

这个结果恰好是(3.38).这表明(3.40)是在 $a=0$ 和 $a\neq 0$ 两种情形下极小点的统一表达式.

这样可以解方程组来求出系数 a, b, c 再代入(3.40), 从而可得 $\varphi(x)$ 的极小点 x^* .

下面给出用 $f(x^{(1)})$, $f'(x^{(1)})$, $f(x^{(2)})$ 和 $f'(x^{(2)})$ 表示的 $\varphi(x)$ 的极小点 $\bar{x}$ 的表达式.

记
$$s = \frac{3[f(x^{(2)}) - f(x^{(1)})]}{x^{(2)} - x^{(1)}} \quad (3.41)$$

$$z = s - f'(x^{(1)}) - f'(x^{(2)}) \quad (3.42)$$

$$w^2 = z^2 - f'(x^{(1)})f'(x^{(2)}), \quad (3.43)$$

$$\Rightarrow \bar{x} = x^{(1)} + (x^{(2)} - x^{(1)})\left(1 - \frac{f'(x^{(2)}) + w + z}{f'(x^{(2)}) - f'(x^{(1)}) + 2w}\right) \quad (3.44)$$

式(3.44)中必有 $f'(x^{(2)}) - f'(x^{(1)}) + 2w \neq 0$

(事实上, $f'(x^{(1)}) < 0$, $f'(x^{(2)}) > 0$, w 由(3.43)确定, 取算术根, 故 $w > 0$,)
于是利用公式 (3.41)-(43)求出 w, z ,再由 (3.44) 求得极小点 $\bar{x}$.

若 $|f'(x)|$ 充分小, $\bar{x}$ 就可作为 $f(x)$ 的可接受的极小点, 否则,

可从 $x^{(1)}, x^{(2)}$ 和 $\bar{x}$ 中确定两个插值点, 再利用上述公式进行计算.

算法(两点三次插值法)

步1: 给定初点 $x^{(1)}, x^{(2)}$, 计算 $f(x^{(1)}), f'(x^{(1)}), f(x^{(2)}), f'(x^{(2)})$,
要求满足 $x^{(2)} > x^{(1)}, f'(x^{(1)}) < 0, f'(x^{(2)}) > 0$, 给定允许误差 δ .

步2: 按公式(3.41)–(3.44)式计算 $s, z, w, \bar{x}$

步3: 若 $|x^{(2)} - x^{(1)}| \leq \delta$, 停止, 得点 $\bar{x}$. 否则转4

步4: 计算 $f(\bar{x}), f'(\bar{x})$. 若 $f'(\bar{x}) = 0$ 停止, 得点 $\bar{x}$.

若 $f'(\bar{x}) < 0$, 令 $x^{(1)} = \bar{x}, f(\bar{x}) = f(x^{(1)}), f'(\bar{x}) = f'(x^{(1)})$. 转2

若 $f'(\bar{x}) > 0$, 令 $x^{(2)} = \bar{x}, f(\bar{x}) = f(x^{(2)}), f'(\bar{x}) = f'(x^{(2)})$. 转2.

9.4. 非精确线搜索算法

精确线搜索算法

$$\phi(\alpha) = f(x^k + \alpha d^k).$$

$$\alpha_k = \arg \min_{\alpha > 0} \phi(\alpha),$$

非精确线搜索算法

不要求 α_k 是 $\phi(\alpha)$ 的最小值点，而是仅仅要求 $\phi(\alpha_k)$ 满足某些不等式性质。

线搜索准则

- 在非精确线搜索算法中，选取 α_k 需要满足一定的要求，这些要求被称为线搜索准则.

9.4.1. Armijo 准则

定义 4.1 (Armijo 准则) 设 d^k 是点 x^k 处的下降方向，若

$$f(x^k + \alpha d^k) \leq f(x^k) + c_1 \alpha \nabla f(x^k)^T d^k,$$

则称步长 α 满足 **Armijo 准则**，其中 $c_1 \in (0,1)$ 是一个常数.




图4.1 Armijo 准则

-
- 引入Armijo 准则的目的是保证每一步迭代充分下降
 - Armijo 准则有直观的几何含义, 它指的是点 $(\alpha, \varphi(\alpha))$ 必须在直线

$$l(\alpha) = \varphi(0) + c_1 \alpha \nabla f(x^k)^T d^k$$

的下方, 上图中区间 $[0, \alpha_1]$ 中的点均满足Armijo 准则

- 参数 c_1 通常选为一个很小的正数, 例如 $c_1 = 10^{-3}$, Armijo准则非常容易得到满足
- Armijo 准则需要配合其他准则以保证迭代的收敛性, 因为 $\alpha = 0$ 显然满足Armijo准则, 此时迭代序列中的点固定不变

寻找一个满足Armijo 准则的步长是比较容易的，一个最常用的算法是回退法．给定初值 $\hat{\alpha}$ ，回退法通过不断以指数方式缩小试探步长，找到第一个满足Armijo 准则(4.1)的点．

算法4.1 线搜索回退法

1. 选择初始步长 $\hat{\alpha}$ ，参数 $\gamma, c \in (0, 1)$ ．初始化 $\alpha \leftarrow \hat{\alpha}$ ．
 2. **while** $f(x^k + \alpha d^k) > f(x^k) + c\alpha \nabla f(x^k)^T d^k$ **do**
 3. 令 $\alpha \leftarrow \gamma \alpha$ ．
 4. **end while**
 5. 输出 $\alpha_k = \alpha$ ．
-

-
- 为了克服Armijo 准则的缺陷, 我们需要引入其他准则来保证每一步的 α^k 不会太小
 - Armijo准则只要求点 $(\alpha, \varphi(\alpha))$ 必须处在某直线下方, 我们也可使用相同的形式使得该点必须处在另一条直线的上方. 这就是Armijo-Goldstein 准则, 简称Goldstein 准则


9.4.2. Goldstein 准则

定义4.2 (Goldstein 准则) 设 d^k 是点 x^k 处的下降方向, 若

$$f(x^k + \alpha d^k) \leq f(x^k) + c\alpha \nabla f(x^k)^T d^k,$$

$$f(x^k + \alpha d^k) \geq f(x^k) + (1 - c)\alpha \nabla f(x^k)^T d^k,$$

则称步长 α 满足 **Goldstein 准则**, 其中 $c \in \left(0, \frac{1}{2}\right)$.




9.4.3. Wolfe 准则

定义 4.3 (Wolfe 准则) 设 d^k 是点 x^k 处的下降方向, 若

$$f(x^k + \alpha d^k) \leq f(x^k) + c_1 \alpha \nabla f(x^k)^T d^k,$$

$$\nabla f(x^k + \alpha d^k)^T d^k \geq c_2 \nabla f(x^k)^T d^k,$$

则称步长 α 满足 **Wolfe 准则**, 其中 $c_1, c_2 \in (0, 1)$ 为给定的常数且 $c_1 < c_2$.



9.4.4 非单调线搜索准则

定义 4.4 (Grippo) 设 d^k 是点 x^k 处的下降方向, $M > 0$ 为给定的正整数. 以下不等式可作为一种线搜索准则:

$$f(x^k + \alpha d^k) \leq \max_{0 \leq j \leq \min\{k, M\}} f(x^{k-j}) + c_1 \alpha \nabla f(x^k)^T d^k,$$

其中 $c_1 \in (0, 1)$ 为给定的常数.

定理4.1 (Zoutendijk) 考虑一般的迭代格式(9.1.3), 其中 d^k 是搜索方向, α_k 是步长, 且在迭代过程中Wolfe准则(4.4)满足. 假设目标函数 f 下有界、连续可微且梯度 L -利普希茨连续, 即

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|, \forall x, y \in \mathbf{R}^n,$$

那么

$$\sum_{k=0}^{\infty} \cos^2 \theta_k \|\nabla f(x^k)\|^2 < +\infty,$$

其中 $\cos \theta_k$ 为负梯度 $-\nabla f(x^k)$ 和下降方向 d^k 夹角的余弦, 即

$$\cos \theta_k = \frac{-\nabla f(x^k)^T d^k}{\|\nabla f(x^k)\| \|d^k\|}.$$

推论4.1 (线搜索算法的收敛性) 对于迭代法 (9.1.3), 设 θ_k 为每一步负梯度 $-\nabla f(x^k)$ 与下降方向 d^k 的夹角, 并假设对任意的 k , 存在常数 $\gamma > 0$, 使得

$$\theta_k < \frac{\pi}{2} - \gamma$$

则在定理4.1成立的条件下, 有

$$\lim_{k \rightarrow \infty} \nabla f(x^k) = 0.$$

一维搜索的MATLAB求解

□ 求解函数

在 MATLAB 优化工具箱中提供了求解一维搜索问题的优化函数 `fminbnd`，该函数用于求解下列问题

$$\begin{cases} \min & f(x) \\ \text{s.t.} & x_1 < x < x_2 \end{cases}$$

x, x_1, x_2 均为标量，函数 $f(x)$ 的返回值也为标量

函数 `fminbnd` 的调用格式为：

`x = fminbnd(fun,x1,x2)`

`x = fminbnd(fun,x1,x2,options)`

`x = fminbnd(problem)`

`[x,fval] = fminbnd(...)`

`[x,fval,exitflag] = fminbnd(...)`

`[x,fval,exitflag,output] = fminbnd(...)`

一维搜索的MATLAB求解

□ 函数概要

- **fminbnd**函数可以计算一元函数最小值优化问题，它用于求解一维设计变量在固定区间内的目标函数的最小值，亦即最优化问题的约束条件只有设计变量的上下界。其求解的算法是我们在前面小结中重点讲述的基于**黄金分割法和抛物线插值法**。
- 在使用**fminbnd**进行优化的过程中，除非**x1**和**x2**十分接近，否则算法将不会在区间的端点评价目标函数，因而设计变量的限制条件需要指定为开区间(**x1**,**x2**)，如果目标函数的最小值恰好在**x1**处或者**x2**处取得，**fminbnd**将返回该区间的**一个内点**，且其与端点**x1**或者**x2**的距离不超过**2ToIX**，其中**ToIX**为最优解**x**处的误差限。

一维搜索的MATLAB求解

□ 输入参数和输出参数

在 `fminbnd` 中参数 `fun` 为需要最小化的目标函数，在 `fun` 函数中需要输入标量参数 `x`，返回 `x` 处的目标函数值。`fun` 可以是一个在 `M` 函数中定义的函数句柄，例如：

```
x = fminbnd(@myfun,x1,x2)
```

`M`-函数文件 `myfun.m` 必须有下面的形式：

```
function f = myfun(x)
f = ...           % 目标函数
```

`fun` 还可以是匿名函数句柄和字符串，例如：

```
x = fminbnd(@(x)sin(x^2),x1,x2);
x = fminbnd('sin(x^2)',x1,x2);
```

`fminbnd` 的输出参数和线性规划的 `linprog` 以及 0-1 规划的 `bintprog` 也类似，其中 `exitflag` 中各值代表的物理意义和输出参数 `output` 结构变量中所包含的信息分别如下页的表所示

一维搜索的MATLAB求解

参数 `exitflag` 的物理意义

值	物理意义
1	已经收敛到解 <code>x</code>
0	已经达到最大迭代次数限制 <code>options.MaxIter</code> 或者已经达到函数评价次数的最大允许值 <code>options.FunEvals</code>
-1	算法被输出函数终止
-3	设计变量的边界矛盾

参数 `output` 所包含的信息

属性名称	属性含义
<code>output.iterations</code>	优化过程的实际迭代次数
<code>output.algorithm</code>	优化过程中所采用的具体算法
<code>output.funcCount</code>	目标函数的评价次数
<code>output.message</code>	退出信息

一维搜索的MATLAB求解

□ 控制参数设置

函数 fminbnd 的优化控制参数设置

参数名称	参数设置
Display	设置显示信息的级别，当该参数值为 off 时，不显示任何输出信息；当参数值为 iter 时，将显示每一步迭代的输出信息，iter 参数值仅对大型规模算法和中型规模的单纯形算法有效；当参数值为 final 时，仅显示最终的输出信息
FunValCheck	检查目标函数值是否合法。当参数值为 on 时，若目标函数值为一复数、Inf 或者 NaN，则返回错误信息，当参数值为 off（默认值）时，不返回该错误信息
MaxFunEvals	目标函数评价的最大允许次数，默认值为 500
MaxIter	算法运行中的最大迭代次数，默认值为 500
OutputFcn	在优化计算的过程中按用户要求指定在一次迭代中需要调用的一个或者多个函数，函数形式可以是函数句柄，或者以元胞数组形式出现的函数句柄，默认值为 []
PlotFcns	在算法执行过程中按照不同的标准绘制优化进程，可以是预定义的方案或者用户自定义的方案。默认值为 []，如果设定为 '@optimplotx' 则绘制迭代过程中的当前点，设定为 '@optimplotfunccount' 则绘制函数的评价次数，如果设定为 '@optimplotfval' 则绘制目标函数值
TolX	解 x 处的误差限

一维搜索的MATLAB求解

□ 命令详解

- `x = fminbnd(fun,x1,x2)`

返回标量函数**fun**在满足 $x1 < x < x2$ 条件下取最小值时设计变量**x**的值。

- `x = fminbnd(fun,x1,x2,options)`

在求解问题的同时用**options**指定的优化参数进行目标函数的最小化

- `[x,fval] = fminbnd(...)`

返回最优解**x**处的目标函数值**fval**。

- `[x,fval,exitflag] = fminbnd(...)`

在优化计算结束之时返回**exitflag**值，描述函数计算的退出条件

- `[x,fval,exitflag,output] = fminbnd(...)`

在优化计算结束之时返回返回结构变量**output**

□ 命令分析

- **fminbnd**只能解决设计变量为实变量的最优化问题，所求解最优化问题的目标函数必须是连续的，且**fminbnd**给出的可能只是目标函数的局部最优解。
- 当最优化问题的解位于区间边界附近时，**fminbnd**算法可能收敛的很慢，此时使用**fmincon**函数求解问题时的计算速度更快，计算精度更高，**fmincon**的用法我们将在之后讲解。

一维搜索的MATLAB求解

□ 例1 求解一维搜索问题

$$\begin{cases} \min & f(x) = \sin x \\ \text{s.t.} & x \in (0, 2\pi) \end{cases}$$

```
[x,fval,exitflag,output] = fminbnd(@sin,0,2*pi)
```

```
%最优解
```

```
x =
```

```
4.7124
```

```
%最优解x处的目标函数值
```

```
fval =
```

```
-1.0000
```

```
exitflag =
```

```
1
```

```
output =
```

```
iterations: 8
```

```
funcCount: 9
```

```
algorithm: 'golden section search, parabolic interpolation'
```

```
message: [1x112 char]To find the minimum of the function
```

一维搜索的MATLAB求解

□ 例2 求解一维搜索问题

$$\begin{cases} \min & f(x) = (x-5)^2 + 7 \\ \text{s.t.} & x \in (0,10) \end{cases}$$

首先用M-函数定义目标函数

```
function f=myfun(x)
f=(x-5)^2+7;
```

然后调用fminbnd函数求解

```
[x,fval] = fminbnd(@myfun,0,10)
x =
    5
fval =
    7
```

如果用匿名函数的形式则可以写成如下形式

```
[x,fval] = fminbnd(@(x) (x-5)^2+7,0,10)
x =
    5
fval =
    7
```