



北京邮电大学

BEIJING UNIVERSITY OF POSTS AND TELECOMMUNICATIONS

最优化理论与算法

帅天平

数学科学学院

tpshuai@bupt.edu.cn



12 可行方向法

求解无约束问题下降算法的过程是

在当前点 $x^{(k)}$ 处，寻找目标函数 f 的下降方向 $d^{(k)}$ ，然后从 $x^{(k)}$ 出发，沿 $d^{(k)}$ 进行一维搜索，产生步长 λ_k ，进而得到

$$x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$$

解约束问题的可行方向法与求解无约束问题的下降算法类似：可行方向法从问题的可行点出发，在该点的可行方向中，寻找使目标函数下降的方向，然后沿该方向进行线性搜索，得到一个新的可行点。

1. Zoutendijk可行方向法

1.1 线性约束情形

考虑NLP问题

$$\begin{aligned} & \min f(x) \\ \text{s.t. } & Ax \geq b \\ & Ex = e \end{aligned} \quad (12.1.1)$$

其中 $f(x)$ 可微, A 为 $m \times n$ 矩阵, E 为 $l \times n$ 矩阵,
 $x \in R^n$, b 和 c 分别为 m 和 l 维列向量.

怎样选择下降可行方向？

Th12.1.1 设 $\hat{x}$ 是问题(12.1.1)的可行解，在点 $\hat{x}$ 处有 $A_1\hat{x} = b_1, A_2\hat{x} > b_2$ ，其中

$$A = \begin{bmatrix} A_1 \\ A_2 \end{bmatrix}, b = \begin{pmatrix} b_1 \\ b_2 \end{pmatrix}$$

则非零向量 d 为 $\hat{x}$ 处的可行方向的充要条件是

$$A_1 d \geq 0, E d = 0.$$

证明 (1)必要性:设非零向量 d 是 $\hat{x}$ 处的可行方向,于是存在 $\delta \geq 0$,使得对每个 $\lambda \in (0, \delta)$, 有 $\hat{x} + \lambda d$ 为可行点, 即

$$A(\hat{x} + \lambda d) \geq b \quad (12.1.2)$$

$$E(\hat{x} + \lambda d) = e \quad (12.1.3)$$

由于

$$A(\hat{x} + \lambda d) = \begin{bmatrix} A_1 \\ A_2 \end{bmatrix} (\hat{x} + \lambda d) = \begin{bmatrix} b_1 + \lambda A_1 d \\ A_2 \hat{x} + \lambda A_2 d \end{bmatrix}$$

因此

$$\begin{bmatrix} b_1 + \lambda A_1 d \\ A_2 \hat{x} + \lambda A_2 d \end{bmatrix} \geq \begin{bmatrix} b_1 \\ b_2 \end{bmatrix} \quad (12.1.4)$$

注意到 $\lambda > 0$, 故有 $A_1 d \geq 0$

又由(12.1.3)得 $Ed = 0$

(2) 充分性。 设

$$A_1 d \geq 0, Ed = 0 \quad (12.1.5)$$

由于 $A_2 \hat{x} > b_2$, 则存在正数 δ , 使得对 $\forall \lambda \in [0, \delta)$, 成立

$$A_2 (\hat{x} + \lambda d) \geq b_2 \quad (12.1.6)$$

根据假设(12.1.5)及 $A_1 \hat{x} = b_1$, 得

$$A_1 (\hat{x} + \lambda d) \geq b_1 \quad (12.1.7)$$

(12.1.6)和(12.1.7)即

$$A(\hat{x} + \lambda d) \geq b \quad (12.1.8)$$

又由 $Ed = 0$ 及 $E\hat{x} = e$ 可知

$$E(\hat{x} + \lambda d) = e \quad (12.1.9)$$

由上可知, $\hat{x} + \lambda d$ 是可行点。因此 d 是 $\hat{x}$ 处的可行方向.

于是,如果非零向量 d 同时满足

$$\nabla f(\hat{x})^T d < 0, A_1 d \geq 0, Ed = 0$$

则 d 是在 $\hat{x}$ 处的下降可行方向。

Zoutendijk法把确定搜索方向归结为求解LP:

$$\begin{aligned} \min \quad & \nabla f(x)^T d \\ \text{s.t.} \quad & A_1 d \geq 0, \\ & Ed = 0, \\ & |d_j| \leq 1, j = 1, \dots, n \end{aligned} \quad (12.1.10)$$

显然 $d=0$ 是可行解。由此可知,目标函数的最优值必小于等于0。若最优值小于0,则可得下降可行方向 d ,否则我们可证 x 是KKT点.

Th12.1.2 考虑问题(12.1.1), 设 x 是可行解, 在点 x 处有
 $A_1x = b_1, A_2x > b_2$, 其中

$$A = \begin{bmatrix} A_1 \\ A_2 \end{bmatrix}, b = \begin{pmatrix} b_1 \\ b_2 \end{pmatrix}$$

则 x 为KKT点的充要条件是问题(12.1.10)的目标函数最优值为0.

证明: 根据定义, x 为KKT点的充要条件是, $\exists w \geq 0$ 和 v , 使得

$$\nabla f(x) - A_1^T w - E^T v = 0 \quad (12.1.11)$$

令 $v=p-q, p,q\geq 0$. (12.1.11)写成

$$(-A_1^T, -E^T, E^T) \begin{bmatrix} w \\ p \\ q \end{bmatrix} = -\nabla f(x) \quad (12.1.12)$$

$$(w, p, q)^T \geq 0$$

根据Farkars定理, 上述方程有解的充要条件是

$$(-A_1, -E, E)^T d \leq 0, -\nabla f(x)^T d > 0$$

无解

$$(12.1.13)$$

即

$$\nabla f(x)^T d < 0, A_1 d \geq 0, Ed = 0 \text{ 无解}$$

所以 x 为KKT点的充要条件是问题(12.1.10)的目标函数最优值为0。

根据上述定理，求解问题(12.1.10)的结果或者是得到下降可行方向，或者得到KKT点。

怎样确定一维搜索的步长？

设 $x^{(k)}$ 是(12.1.1)的可行解，不妨看作第 k 次迭代的出发点。

$d^{(k)}$ 为 $x^{(k)}$ 处一个下降可行方向。后继点 $x^{(k+1)}$ 由下列迭代

公式给出：
$$x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)} \quad (12.1.14)$$

怎样确定 λ_k ? λ_k 的取值原则有两点:

第一, 保持迭代点 $x^{(k)} + \lambda_k d^{(k)}$ 的可行性;

第二, 使目标函数值尽可能减小。

根据上述原则, 可以通过求解下列一维搜索问题来确定步长:

$$\begin{aligned} & \min \quad f(x^{(k)} + \lambda d^k) \\ & \text{s.t.} \quad A(x^{(k)} + \lambda d^k) \geq b \\ & \quad E(x^{(k)} + \lambda d^k) = e \\ & \quad \lambda \geq 0 \end{aligned} \tag{12.1.15}$$

问题(12.1.15)可作进一步简化。

由于 $d^{(k)}$ 是可行方向,必有

$$Ed^{(k)} = 0$$

$$Ex^{(k)} = e$$

因此,(12.1.15)中第2个约束是多余的

在点 $x^{(k)}$ 处,根据约束是否起作用, 记 $A = (A_1, A_2)^T$,

$$b = (b_1, b_2)^T$$

$$A_1 x^{(k)} = b_1 \quad (12.1.16)$$

$$A_2 x^{(k)} > b_2 \quad (12.1.17)$$

于是,(12.1.15)中第1个约束可写成:

$$\begin{bmatrix} A_1 x^{(k)} + \lambda A_1 d^{(k)} \\ A_2 x^{(k)} + \lambda A_2 d^{(k)} \end{bmatrix} \geq \begin{bmatrix} b_1 \\ b_2 \end{bmatrix} \quad (12.1.19)$$

由于 $d^{(k)}$ 为可行方向, $A_1 d^{(k)} \geq 0$, $A_1 x^{(k)} = b_1, \lambda \geq 0$

$A_1 x^{(k)} + \lambda A_1 d^{(k)} \geq b_1$ 自然成立。

约束(12.1.19)化为

$$A_2 x^{(k)} + \lambda A_2 d^{(k)} \geq b_2 \quad (12.1.20)$$

这样,问题(12.1.15)化简为

$$\begin{aligned} & \min f(x^{(k)} + \lambda d^{(k)}) \\ \text{s.t.} \quad & A_2 x^{(k)} + \lambda A_2 d^{(k)} \geq b_2 \\ & \lambda \geq 0 \end{aligned} \quad (12.1.21)$$

根据(12.1.21)的约束条件, 易求出 λ 的上限,令

$$\hat{b} = b_2 - A_2 x^{(k)} \quad (12.1.22)$$

$$\hat{d} = A_2 d^{(k)} \quad (12.1.23)$$

由(12.1.17)知 $\hat{b} < 0$.(12.1.21)的约束可写成
$$\begin{cases} \lambda \hat{d} \geq \hat{b} \\ \lambda \geq 0 \end{cases}$$

由此得到 λ 的上限

$$\lambda_{\max} = \begin{cases} \min \left\{ \frac{\hat{b}_i}{\hat{d}_i} \mid \hat{d}_i < 0, \text{ 当 } \hat{d} \not\geq 0 \right\} \\ \infty, & \text{当 } \hat{d} \geq 0 \end{cases} \quad (12.1.24)$$

问题(12.1.15)于是化为:

$$\begin{aligned} & \min \quad f(x^{(k)} + \lambda d^k) \\ & \text{s.t.} \quad 0 \leq \lambda \leq \lambda_{\max} \end{aligned} \quad (12.1.25)$$

于是, 给定问题(12.1.1)和一个可行点, 可以通过求解问题(12.1.10)得到下降可行方向, 通过求解问题(12.1.25)确定沿此方向进行一维搜索的步长.

于是，给定问题(12.1.1)和一个可行点，可以通过求解问题(12.1.10)得到下降可行方向，通过求解问题(12.1.25)确定沿此方向进行一维搜索的步长.

可以通过解辅助LP得到一可行点：

$$\min \quad \sum_{i=1}^m \xi_i + \sum_{i=1}^t \eta_i$$

可以通过解辅助LP得到一可行点:

$$\begin{aligned} \min \quad & \sum_{i=1}^m \xi_i + \sum_{i=1}^t \eta_i \\ \text{s.t.} \quad & Ax + \xi \geq b \\ & Ex + \eta = e \\ & \xi \geq 0, \eta \geq 0 \end{aligned} \tag{12.1.26}$$

若(12.1.26)的最优解为

$$(x^*, \bar{\xi}, \bar{\eta}) = (x^*, 0, 0)$$

则 x^* 是(12.1.1)的一个可行解

计算步骤

1, 给定初始可行点 $x^{(1)}$, 置 $k = 1$.

2, 在点 $x^{(k)}$ 处对 A 和 b 进行分解: $\begin{bmatrix} A_1 \\ A_2 \end{bmatrix}$ 和 $\begin{bmatrix} b_1 \\ b_2 \end{bmatrix}$

使得 $A_1 x^{(k)} = b_1, A_2 x^{(k)} > b_2$.

3, 求解LP: $\min \nabla f(x^{(k)})^T d$

$$s.t \quad A_1 d \geq 0$$

$$Ed = 0$$

$$-1 \leq d_j \leq 1, j = 1, \dots, n$$

得到最优解 $d^{(k)}$.

4, 如果 $\nabla f(x^{(k)})^T d^{(k)} = 0$, 停止, $x^{(k)}$ 为KKT点。

否则, 转步5

5, 利用 (1.22) – (1.24) 计算 $\lambda_{\max}$, 然后在 $[0, \lambda_{\max}]$

上作一维搜索:

$$\begin{array}{ll} \min & f(x^{(k)} + \lambda d^k) \\ \text{s.t.} & 0 \leq \lambda \leq \lambda_{\max} \end{array}$$

得最优解 λ_k , 令 $x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$

6, 置 $k := k + 1$, 转2。

例1 用Zoutendijk法求解下列问题

$$\min \quad x_1^2 + x_2^2 - 2x_1 - 4x_2 + 6$$

$$s.t. \quad -2x_1 + x_2 + 1 \geq 0$$

$$-x_1 - x_2 + 2 \geq 0$$

$$x_1 \geq 0$$

$$x_2 \geq 0$$

$$\text{初点 } x^{(1)} = (0, 0)^T$$

$\nabla f(x^{(1)}) = (-2, -4)^T$, 在 $x^{(1)}$ 处, 起作用约束和不起作用约束的系数矩阵和右端向量分别为:

$$A_1 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, A_2 = \begin{bmatrix} -2 & 1 \\ -1 & -1 \end{bmatrix}, b_1 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, b_2 = \begin{bmatrix} -1 \\ -2 \end{bmatrix}$$

先求在 $x^{(1)}$ 处的下降可行方向, 解 LP :

$$\begin{array}{ll} \min \nabla f(x^{(k)})^T d & \min -2d_1 - 4d_2 \\ s.t. \quad A_1 d \geq 0 & s.t. \quad d_1 \geq 0 \\ \quad \quad Ed = 0 & \quad \quad d_2 \geq 0 \\ \quad \quad -1 \leq d_j \leq 1, j = 1, \dots, n & \quad \quad -1 \leq d_j \leq 1, j = 1, 2 \end{array} \quad \Rightarrow$$

用单纯形法求得最优解

$$d^{(1)} = (1, 1)^T$$

再求步长 λ_1

$$\hat{d} = A_2 d^{(1)} = \begin{bmatrix} -2 & 1 \\ -1 & -1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} -1 \\ -2 \end{bmatrix}$$

$$\hat{b} = b_2 - A_2 x^{(1)} = \begin{bmatrix} -1 \\ -2 \end{bmatrix} - \begin{bmatrix} -2 & 1 \\ -1 & -1 \end{bmatrix} \begin{bmatrix} 0 \\ 0 \end{bmatrix} = \begin{bmatrix} -1 \\ -2 \end{bmatrix}$$

$$\lambda_{\max} = \min\left\{\frac{-1}{-1}, \frac{-2}{-2}\right\} = 1$$

解一维搜索：

$$\min f(x^{(1)} + \lambda d^{(1)}) = 2\lambda^2 - 6\lambda + 6$$

$$s.t \quad 0 \leq \lambda \leq 1$$

得

$$\lambda_1 = 1$$

令

$$x^{(2)} = x^{(1)} + \lambda_1 d^{(1)} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

重复迭代最后可得最优解 $x^*=(1/2, 3/2)$

1.2 非线性约束

考虑不等式约束问题

$$\begin{aligned} & \min f(x) \\ & s.t \quad g_i(x) \geq 0, i = 1, \dots, m \end{aligned} \quad (12.1.27)$$

其中 $x \in E^n$, $f(x), g_i(x)$ 可微.

1) 选择下降可行方向.

Th12.1.3 设 x 是问题(12.1.27)的可行解, $I = \{i | g_i(x) = 0\}$ 是在 x 处起作用约束下标集, 又设函数 $f(x)$, $g_i(x)$ ($i \in I$) 在 x 处可微, 函数 $g_i(x)$ ($i \notin I$) 在 x 连续, 如果

$$\nabla f(x)^T d < 0,$$

$$\nabla g_i(x)^T d > 0, \quad i \in I$$

则 d 是下降可行方向.

证明: 设方向 d 满足

$$\nabla f(x)^T d < 0, \quad \nabla g_i(x)^T d > 0, \quad (i \in I)$$

当 $i \notin I$ 时, $g_i(x) > 0$, 由于 $g_i(x)$ ($i \notin I$)在 x 连续, 故对充分小的 $\lambda > 0$, 有

$$g_i(x + \lambda d) \geq 0 \quad i \notin I \quad (12.1.28)$$

当 $i \in I$ 时, 由于 $g_i(x)$ 在 x 可微, 故有

$$g_i(x + \lambda d) = g_i(x) + \lambda \nabla g_i(x)^T d + \lambda \|d\| \alpha(x, \lambda d)$$

其中当 $\lambda \rightarrow 0$, 有 $\alpha(x, \lambda d) \rightarrow 0$.

$$\Rightarrow \frac{g_i(x + \lambda d) - g_i(x)}{\lambda} = \nabla g_i(x)^T d + \|d\| \alpha(x, \lambda d) \quad (12.1.29)$$

又 $\nabla g_i(x)^T d > 0$, 故当 $\lambda > 0$ 充分小时, (12.1.29) 右端 > 0 .

从而左端 > 0 . 由于 $g_i(x) = 0 (i \in I)$ 所以

$$g_i(x + \lambda d) > 0,$$

由上分析, 知对充分小的 $\lambda > 0$, 有

$$g_i(x + \lambda d) \geq 0, i = 1, \dots, m \quad (12.1.30)$$

因此 d 为 x 处的可行方向。

又 $\nabla f(x)^T d < 0$, 故 d 为下降方向。

因此 d 为 x 处的下降可行方向。

因此求下降可行方向即求满足下述方程组的 d 。

$$\nabla f(x)^T d < 0,$$

$$\nabla g_i(x)^T d > 0, \quad (i \in I)$$

进而归结为求解LP:

$$\min \quad z$$

$$\text{s.t. } \nabla f(x)^T d - z \leq 0,$$

$$\nabla g_i(x)^T d + z \geq 0, \quad i \in I \quad (12.1.31)$$

$$|d_j| \leq 1, \quad j = 1, \dots, n$$

设(12.1.31)的最优解为 (x^*, d^*) .若 $z^* < 0$,则 d^* 是在 x 处的下降可行方向.若 $z^* = 0$,则我们可以证明相应的 x 必为Fritz John点

Th12.1.4 设 x 是问题(12.1.27)的可行解, $I = \{i \mid g_i(x) = 0\}$, 则 x 是Fritz John点 $\Leftrightarrow$ (12.1.31)的最优目标函数值为0.

证明:问题(12.1.31)的目标函数最优值为0的充要条件是不等式组

$$\begin{aligned} \nabla f(x)^T d &< 0, \\ \nabla g_i(x)^T d &> 0, \quad (i \in I) \end{aligned} \quad (12.1.32)$$

无解

即

$$\begin{aligned}\nabla f(x)^T d &< 0, \\ -\nabla g_i(x)^T d &< 0, \quad (i \in I) \quad (12.1.33)\end{aligned}$$

无解.

由Gordan定理,其无解的充要条件为

存在不全为0的数 $w_0 \geq 0, w_i \geq 0, i \in I$ 使得

$$w_0 \nabla f(x) - \sum_{i \in I} w_i \nabla g_i(x)^T = 0$$

即 x 是Fritz John点.

为求步长,求解一维搜索问题:

$$\begin{aligned} \min \quad & f(x^{(k)} + \lambda d^{(k)}) \\ \text{s.t.} \quad & 0 \leq \lambda \leq \lambda_{\max} \end{aligned} \quad (12.1.34)$$

$$\text{其中 } \lambda_{\max} = \text{SUP}\{\lambda \mid g_i(x^{(k)} + \lambda d^{(k)}) \geq 0, i = 1, \dots, m\} \quad (12.1.35)$$

计算步骤

1, 给定初始可行点 $x^{(1)}$, 置 $k = 1$.

2, 令 $I = \{i \mid g_i(x^{(k)}) = 0\}$, 解LP:

$$\begin{aligned}
& \min \quad z \\
& \text{s.t. } \nabla f(x)^T d - z \leq 0, \\
& \quad \nabla g_i(x)^T d + z \geq 0, \quad i \in I \\
& \quad |d_j| \leq 1, j = 1, \dots, n
\end{aligned}$$

得最优解 $(z_k, d^{(k)})$, 若 $z_k = 0$, 停止, $x^{(k)}$ 为Fritz John点; 否则, 转3
3, 求解一维搜索问题

$$\begin{aligned}
& \min f(x^{(k)} + \lambda d^{(k)}) \\
& \text{s.t. } 0 \leq \lambda \leq \lambda_{\max}
\end{aligned} \tag{12.1.34}$$

得最优解 λ_k , 其中 $\lambda_{\max}$ 由(12.1.35)给出

4, 令 $x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$, 置 $k := k + 1$, 转2.

1.3 Zoutendijk算法的收敛问题

Zoutendijk算法映射A是M和D的合成映射.

其中D是确定搜索方向的映射,它定义为:

每给定一个可行点 x ,通过解(12.1.10),确定下降可行方向 d ,从而得到 (x,d) ,即 $(x,d) \in D(x)$

因此,D是 E^n 到 $E^n \times E^n$ 的映射.M是一维搜索的映射,它是 $E^n \times E^n$ 到 E^n 的映射,即每一个点 x 和一下降可行方向 d ,通过求解问题

$$\text{Min } f(x + \lambda d)$$

$$\text{s.t. } x + \lambda d \in S$$

$$\lambda \geq 0 \quad (S \text{ 为可行域}),$$

确定最优解 y (在连接 x 和 $x + \lambda_{\max} d$ 的线段上), $y \in M(x,d)$.

注意:D和M不一定是闭映射


例1: 考虑下列问题

$$\begin{aligned} \min \quad & -2x_1 - x_2 \\ \text{s.t.} \quad & -x_1 - x_2 + 2 \geq 0 \\ & x_1 \geq 0 \\ & x_2 \geq 0 \end{aligned}$$

如图12.1.1所示. 考虑序列 $\{x^{(k)}\}$, 其中

$x^{(k)} = (0, 2 - \frac{1}{k})^T$, 在序列中的每一点处,

都只有 $x_1 \geq 0$ 为起作用约束.



因此求搜索方向的线性规划问题为

$$\min \quad -2d_1 - d_2$$

$$s.t \quad 0 \leq d_1 \leq 1$$

$$\text{解此问题得最优解} \quad -1 \leq d_2 \leq 1$$

$$d^{(k)} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

序列的极限点 $x = (0, 2)^T$, 在此点, 起作用的约束有:

$$-x_1 - x_2 + 2 \geq 0$$

$$x_1 \geq 0$$

为确定 $D(x)$,需解线性规划

$$\min \quad -2d_1 - d_2$$

$$s.t \quad -d_1 - d_2 \geq 0$$

$$0 \leq d_1 \leq 1$$

$$-1 \leq d_2 \leq 1$$

用单纯形法求得此问题的最优解

$$d = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

因此, $D(x) = \{(x, d)\}$.

当 $x^{(k)} \rightarrow x$ 时, $(x^{(k)}, d^{(k)}) \rightarrow (x, d)$, 其中 $d = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$.

显然 $(x, d) \notin D(x)$. 因此 D 在 x 处不是闭的.

由于不能保证 Zoutendijk 方法的方向映射和一维搜索映射是闭的, 因此迭代产生的序列可能不收敛于 K-T 点. 事实上, Wolfe 于 1972 年给出这样的例.

1.4 Topkis-Veinott修正

Topkis和Veinott对Zoutendijk算法进行了修正.把求方向的LP换为:

$$\begin{aligned} & \min \quad z \\ \text{s.t.} \quad & \nabla f(x)^T d - z \leq 0, \\ & \nabla g_i(x)^T d + z \geq -g_i(x), \quad i = 1, \dots, n \\ & |d_j| \leq 1, j = 1, \dots, n \end{aligned}$$

Topkis-Veinott 修正算法

1, 给定初始可行点 $x^{(1)}$, 置 $k = 1$.

2, 解LP:

$$\begin{aligned} & \min \quad z \\ \text{s.t.} \quad & \nabla f(x)^T d - z \leq 0, \\ & \nabla g_i(x)^T d + z \geq -g_i(x), \quad i = 1, \dots, n \\ & |d_j| \leq 1, \quad j = 1, \dots, n \end{aligned}$$

得最优解 $(z_k, d^{(k)})$.

3, 若 $z_k = 0$, 停止, $x^{(k)}$ 为 Fritz John 点; 否则, 转4.

1. Zoutendijk可行方向法

4, 求解一维搜索问题

$$\begin{aligned} \min \quad & f(x^{(k)} + \lambda d^{(k)}) \\ \text{s.t.} \quad & 0 \leq \lambda \leq \lambda_{\max} \end{aligned}$$

其中 $\lambda_{\max}$ 由(12.1.35)给出得最优解 λ_k

5, 令 $x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$, 置 $k := k + 1$, 转2.

Th12.1.5 考虑问题(12.1.27), 设函数 $f(x), g_i(x) (i = 1, \dots, m)$ 连续可微, 又设 $\{x^{(k)}\}$ 是 *Topkis – Veinott* 算法产生的序列, 则 $\{x^{(k)}\}$ 的任一聚点都是 *Fritz John* 点.

2. Rosen梯度投影法

定义1 对于矩阵 $P \in R^{n \times n}$, 若 $P^2 = P$, 则称 P 为投影算子矩阵. 若 $P^2 = P$, 且 $P^T = P$, 则称 P 为正交投影算子矩阵. 对于投影算子 P , 集合

$$\mathcal{R}(P) = \{Px \mid x \in R^n\}, N(P) = \{(I - P)x \mid x \in R^n\}$$

分别称为它的值空间和零空间.

例1 设矩阵

$$P = \begin{pmatrix} 1 & 1 \\ 0 & 0 \end{pmatrix}, \Rightarrow P^2 = P, \mathcal{R}(P) = \{x = (x_1, x_2) \mid x_2 = 0\};$$

$$N(P) = \{x = (x_1, x_2) \mid x_1 + x_2 = 0\}$$

2. Rosen梯度投影法

例2 设矩阵 $A \in R^{m \times n}$ 行满秩, 则

$$P_{R(A^T)} = A^T (AA^T)^{-1} A, P_{N(A)} = I - A^T (AA^T)^{-1} A$$

分别是 R^n 到子空间 $R(A^T)$ 和 $N(A)$ 上的正交投影矩阵.

命题1

- (1) 投影矩阵的特征根或者为0, 或者为1;
- (2) 矩阵 P 为(正交)投影矩阵当且仅当 $I-P$ 为(正交)投影矩阵;
- (3) 对于正交投影矩阵 P , 其值空间 $R(P)$ 和 $N(P)$ 是互补且正交的线性子空间.

2. Rosen梯度投影法

基本思想: 用积极约束系数矩阵的行向量生成一个法向量子空间, 将目标函数的负梯度方向正交投影到该法向子空间的正交补中, 获得一个使目标函数下降的可行方向; 然后, 从当前的迭代点出发, 沿着使目标函数下降的可行方向搜索, 寻找一个新的改进点, 直到得到约束优化问题 (LC0) 的一个KKT点.

定理12.2.1 设 $\mathbf{x}$ 为问题(12.1.1)的可行点, 在 $\mathbf{x}$ 处 $\mathbf{A}_1 \mathbf{x} = \mathbf{b}_1, \mathbf{A}_2 \mathbf{x} > \mathbf{b}_2$.

其中 $\mathbf{A} = \begin{pmatrix} \mathbf{A}_1 \\ \mathbf{A}_2 \end{pmatrix}$, $\mathbf{b} = \begin{pmatrix} \mathbf{b}_1 \\ \mathbf{b}_2 \end{pmatrix}$, 记矩阵 $\mathbf{M} = \begin{pmatrix} \mathbf{A}_1 \\ \mathbf{E} \end{pmatrix}$ 是行满秩的,

$\mathbf{P}_{N(\mathbf{M})} = \mathbf{I} - \mathbf{M}^T (\mathbf{M} \mathbf{M}^T)^{-1} \mathbf{M}$ 且正交投影向量 $\mathbf{d} = -\mathbf{P}_{N(\mathbf{M})} \nabla f(\bar{\mathbf{x}}) \neq 0$, 则 $\mathbf{d}$ 是问题(12.1.1)的一个下降的可行方向.

2. Rosen梯度投影法

定理12.2.2 设 $\mathbf{x}$ 为问题(12.1.1)的可行点,在 $\mathbf{x}$ 处 $\mathbf{A}_1\mathbf{x} = \mathbf{b}_1, \mathbf{A}_2\mathbf{x} > \mathbf{b}_2$.

其中 $\mathbf{A} = \begin{pmatrix} \mathbf{A}_1 \\ \mathbf{A}_2 \end{pmatrix}$, $\mathbf{b} = \begin{pmatrix} \mathbf{b}_1 \\ \mathbf{b}_2 \end{pmatrix}$, 记矩阵 $\mathbf{M} = \begin{pmatrix} \mathbf{A}_1 \\ \mathbf{E} \end{pmatrix}$ 是行满秩的,

$$\mathbf{P}_{N(\mathbf{M})} = \mathbf{I} - \mathbf{M}^T (\mathbf{M}\mathbf{M}^T)^{-1} \mathbf{M}, \mathbf{w} = (\mathbf{M}\mathbf{M}^T)^{-1} \mathbf{M} \nabla f(\mathbf{x}) = (\mathbf{u}^T, \mathbf{v}^T)^T,$$

$\mathbf{u}, \mathbf{v}$ 分别对应于 $\mathbf{A}_1$ 和 $\mathbf{E}$, 投影向量 $\mathbf{P}_{N(\mathbf{M})} \nabla f(\mathbf{x}) = 0$, 则有

(1) 当 $\mathbf{u} \geq 0$ 时, $\mathbf{x}$ 为问题的KKT点

(2) 当 $\mathbf{u} \geq 0$ 不成立时, 不妨设 $u_{i_0} < 0$, 若从矩阵 $\mathbf{M}$ 中去掉 u_{i_0} 对

应的行, 生成一个子矩阵 $\tilde{\mathbf{M}}$, 那么 $\tilde{\mathbf{d}} = -\mathbf{P}_{N(\tilde{\mathbf{M}})} \nabla f(\mathbf{x})$ 为问题的

一个下降的可行方向.

2. Rosen梯度投影法

步1 (初始化)初始点 $\mathbf{x}^0$,置 $k=0$

步2(计算投影向量)确定积极约束指标集 $A(\mathbf{x}^k) = I(\mathbf{x}^k) \cup E(\mathbf{x}^k)$ 和积极约束系数矩阵 $M = (\mathbf{a}_i \mid \mathbf{i} \in A(\mathbf{x}^k))^T$.计算负梯度方向

$\mathbf{d}^k = -\mathbf{P}_{N(M)} \nabla f(\mathbf{x}^k)$.若 $\mathbf{d}^k = 0$,转步3, 否则转步4

步3(收敛性检验)计算 $\mathbf{w} = (MM^T)^{-1} M \nabla f(\mathbf{x}^k) = (\mathbf{u}^T, \mathbf{v}^T)^T$, 令
 $\mathbf{u}^T = (\mathbf{u}_i \mid \mathbf{i} \in I(\mathbf{x}^k))$, $\mathbf{v}^T = (\mathbf{v}_j \mid \mathbf{j} \in E(\mathbf{x}^k))$,

若 $\mathbf{u} \geq 0$, 则 $\mathbf{x}^k$ 为KKT点, Stop; 否则选择 $\mathbf{i}_0 = \arg \min_i \mathbf{u}_i$, 从矩阵M中去掉 $\mathbf{i}_0$ 对应的行, 得子矩阵 $\tilde{M}$, 重新计算 $\mathbf{d}^k = -\mathbf{P}_{N(\tilde{M})} \nabla f(\mathbf{x}^k)$, 转步4.

步4(迭代改进) 求解对应的一维优化问题 (13.1.25), 当最优解有界时得线搜索的最优步长 α_k , 并且置, $\mathbf{x}^{k+1} = \mathbf{x}^k + \alpha_k \mathbf{d}^k$ 转步2, 否则, 算法停止。

例3：求解如下约束优化问题

$$\min f(x) = x_1^2 + x_2^2 + 6x_1 + 9$$

$$s.t \quad 2x_1 + x_2 \geq 4$$

$$x_1, x_2 \geq 0$$

初始可行点 $x_0 = (2, 0)^T$

解：目标函数梯度 $\nabla f(x) = \begin{pmatrix} 2x_1 + 6 \\ 2x_2 \end{pmatrix}$

第一次迭代： x_0 处的梯度为

$$\nabla f(x_0) = \begin{pmatrix} 10 \\ 0 \end{pmatrix}$$

在 x_0 处的有效约束指标集 $I=\{1,3\}$,即

$$2x_1 + x_2 \geq 4; \quad x_2 \geq 0$$

是 x_0 处的有效约束, 将约束系数矩阵 A 和右端向量 b 分解为

$$A_1 = \begin{pmatrix} 2 & 1 \\ 0 & 1 \end{pmatrix}, b_1 = \begin{pmatrix} 4 \\ 0 \end{pmatrix}, A_2 = (1 \quad 0), b_2 = (0)$$

因 $E=$, 故 $M=A_1$, 计算投影矩阵

$$P = I - A_1^T (A_1 A_1^T)^{-1} A_1$$

$$= \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} - \begin{pmatrix} 2 & 0 \\ 1 & 1 \end{pmatrix} \left[\begin{pmatrix} 2 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 2 & 0 \\ 1 & 1 \end{pmatrix} \right]^{-1} \begin{pmatrix} 2 & 1 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}$$

令

$$\mathbf{d}_0 = -\mathbf{P} \nabla f(\mathbf{x}_0) = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\lambda = (A_1 A_1^T)^{-1} A_1 \nabla f(\mathbf{x}_0)$$

$$= \left[\begin{pmatrix} 2 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 2 & 0 \\ 1 & 1 \end{pmatrix} \right]^{-1} \begin{pmatrix} 2 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 10 \\ 0 \end{pmatrix} = \begin{pmatrix} 5 \\ -5 \end{pmatrix} = \begin{pmatrix} \lambda_1 \\ \lambda_2 \end{pmatrix}$$

修正 A_1 : 去掉中对应 $x_2=-5$ 的行, 得到 $\tilde{A}_1=(2 \ 1)$

再求投影矩阵

$$\begin{aligned}\tilde{P} &= I - \tilde{A}_1^T (\tilde{A}_1 \tilde{A}_1^T)^{-1} \tilde{A}_1 \\ &= \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} - \begin{pmatrix} 2 \\ 1 \end{pmatrix} \left[(2 \ 1) \begin{pmatrix} 2 \\ 1 \end{pmatrix} \right]^{-1} (2 \ 1) = \frac{1}{5} \begin{pmatrix} 1 & -2 \\ -2 & 4 \end{pmatrix}\end{aligned}$$

令

$$\tilde{d}_0 = -\tilde{P} \nabla f(x_0) = -\frac{1}{5} \begin{pmatrix} 1 & -2 \\ -2 & 4 \end{pmatrix} \begin{pmatrix} 10 \\ 0 \end{pmatrix} = \begin{pmatrix} -2 \\ 4 \end{pmatrix}$$

求步长 α_0 : $\min f(x_0 + \alpha \tilde{d}_0)$

由于 $s.t \quad 0 \leq \alpha \leq \bar{\alpha}$

$$\hat{b} = b_2 - A_2 x_0 = 0 - (1 \ 0) \begin{pmatrix} 2 \\ 0 \end{pmatrix} = -2$$

$$\hat{d} = A_2 \tilde{d}_0 = (1 \ 0) \begin{pmatrix} -2 \\ 4 \end{pmatrix} = -2, \quad \bar{\alpha} = -2 / -2 = 1$$

$$\min 20\alpha^2 - 20\alpha + 25$$

$$s.t \quad 0 \leq \alpha \leq 1 \quad \Rightarrow \alpha_0 = 0.5$$

$$\therefore x_1 = x_0 + \alpha \tilde{d}_0 = \begin{bmatrix} 2 \\ 0 \end{bmatrix} + \frac{1}{2} \begin{pmatrix} -2 \\ 4 \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$$

第2次迭代

$$\nabla f(x_1) = \begin{pmatrix} 8 \\ 4 \end{pmatrix}$$

$$A_1 = \begin{pmatrix} 2 & 1 \end{pmatrix}, b_1 = (4), A_2 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, b_2 = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

因 $E = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}$ ，故 $M = A_1$ ，计算投影矩阵

$$P = I - A_1^T (A_1 A_1^T)^{-1} A_1 = \frac{1}{5} \begin{pmatrix} 1 & -2 \\ -2 & 4 \end{pmatrix}$$

$$d_2 = -P \nabla f(x_1) = -\frac{1}{5} \begin{pmatrix} 1 & -2 \\ -2 & 4 \end{pmatrix} \begin{pmatrix} 8 \\ 4 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\lambda = (A_1 A_1^T)^{-1} A_1 \nabla f(x_1) = 4 > 0$$

故 $x_1 = (1, 2)^T$ 是KKT点

3 Frank-Wolfe方法

3.1 算法简介

Frank和Wolfe 1956年提出求解线性约束问题的一种算法.
考虑非线性规划问题

$$\begin{aligned} \min & f(x) \\ \text{s.t. } & Ax = b \\ & x \geq 0 \end{aligned} \tag{12.3.1}$$

其中A是 $m \times n$ 矩阵,秩为 m , b 是 m 维列向量, $f(x)$ 是连续可微函数, $x \in E^n$.

记问题的可行域为

$$S = \{x \mid Ax = b, x \geq 0\} \tag{12.3.2}$$

Frank-Wolfe算法的基本思想是,在每一次迭代中,将目标函数 $f(x)$ 线性化,通过解线性规划求得下降可行方向,进而沿此方向在可行域内作一维搜索.

假设已知可行点 $x^{(k)}$,将 $f(x)$ 在 $x^{(k)}$ 展开,并用一阶Taylor

多项式 $f(x^{(k)}) + \nabla f(x^{(k)})^T (x - x^{(k)})$

$$= \nabla f(x^{(k)})^T x + [f(x^{(k)}) - \nabla f(x^{(k)})^T x^{(k)}]$$

逼近 $f(x)$. 解线性规划问题:

$$\min \quad \nabla f(x^{(k)})^T x + [f(x^{(k)}) - \nabla f(x^{(k)})^T x^{(k)}]$$

$$s.t \quad x \in S \quad (12.3.3)$$

去掉目标函数中的常数项,将此问题改写成

$$\begin{aligned} \min \quad & \nabla f(x^{(k)})^T x \\ \text{s.t} \quad & x \in S \end{aligned} \quad (12.3.4)$$

假设此问题存在有限最优解 $y^{(k)}$,则此最优解可在某极点达到

求解LP (12.3.4)的结果必为下列两种情形之一:

1.若 $\nabla f(x^{(k)})^T (y^{(k)} - x^{(k)}) = 0$,则停止迭代,

可以证明, $x^{(k)}$ 是原问题 (12.3.1)的 $K - T$ 点.

2. 若 $\nabla f(x^{(k)})^T (y^{(k)} - x^{(k)}) \neq 0$,则必有

$$\nabla f(x^{(k)})^T (y^{(k)} - x^{(k)}) < 0$$

因此 $y^{(k)} - x^{(k)}$ 为 $x^{(k)}$ 处的下降方向.

由于 S 是凸集, $y^{(k)}$ 是 S 的极点,连结 $y^{(k)}$ 与 $x^{(k)}$ 的线段必含于 S ,即对每一个 $\lambda \in [0,1]$,有

$$\lambda y^{(k)} + (1-\lambda)x^{(k)} = x^{(k)} + \lambda(y^{(k)} - x^{(k)}) \in S$$

因此, $y^{(k)} - x^{(k)}$ 是可行方向,故为下降可行方向.这时,从 $x^{(k)}$ 出发,沿此方向作一维搜索:

$$\begin{array}{ll} \min f(x^{(k)} + \lambda(y^{(k)} - x^{(k)})) \\ \text{s.t.} & 0 \leq \lambda \leq 1 \end{array} \quad (12.3.5)$$

求得 λ_k ,令 $x^{(k+1)} = x^{(k)} + \lambda_k(y^{(k)} - x^{(k)})$

由于 $y^{(k)} - x^{(k)} \neq 0$, 且为下降方向, 因此有

$$f(x^{(k+1)}) < f(x^{(k)}) \quad (12.3.6)$$

得到 $x^{(k+1)}$ 后, 再重复以上过程.

*Frank – Wolfe*方法

1. 给定初始可行点 $x^{(1)}$, 允许误差 $\varepsilon > 0$, 置 $k = 1$.

2. 求解线性规划问题

$$\begin{aligned} \min \quad & \nabla f(x^{(k)})^T x \\ \text{s.t.} \quad & x \in S \end{aligned}$$

得到最优解 $y^{(k)}$.

3.若 $|\nabla f(x^{(k)})^T (y^{(k)} - x^{(k)})| \leq \varepsilon$,则停止计算,得到点 $x^{(k)}$;

否则进行步4.

4.从 $x^{(k)}$ 出发,沿方向 $y^{(k)} - x^{(k)}$ 在连接 $y^{(k)}$ 与 $x^{(k)}$ 的线段上搜索:

$$\min f(x^{(k)} + \lambda(y^{(k)} - x^{(k)}))$$

$$s.t \quad 0 \leq \lambda \leq 1$$

得到 λ_k .

5.令 $x^{(k+1)} = x^{(k)} + \lambda(y^{(k)} - x^{(k)})$

置 $k := k + 1$,返回步2.

2 算法收敛性

定理12.3.1 设 $y^{(k)}$ 是线性规划(12.3.4)的最优解,且满足

$$\nabla f(x^{(k)})^T (y^{(k)} - x^{(k)}) = 0$$

则 $x^{(k)}$ 是问题(12.3.1)的 $K-T$ 点.

证明: 根据假设, $y^{(k)}$ 是线性规划(12.3.4)的最优解, 且

$$\nabla f(x^{(k)})^T x^{(k)} = \nabla f(x^{(k)})^T y^{(k)}$$

因此 $x^{(k)}$ 也是这个线性规划问题的最优解,

故 $x^{(k)}$ 是 K - T 点.于是,存在乘子 $w \geq 0$ ($w \in E^n$)和 $v \in E^m$,使

$$\nabla f(x^{(k)}) - w - A^T v = 0 \quad (12.3.7)$$

$$w^T x^{(k)} = 0$$

$$Ax^{(k)} = b$$

$$x^{(k)} \geq 0$$

以上诸式恰是(12.3.1)的 K - T 条件,因此 $x^{(k)}$ 是问题(12.3.1)的 K - T 点.

根据上述定理,若在某此迭代中恰有

$$\nabla f(x^{(k)})^T (y^{(k)} - x^{(k)}) = 0$$

则达到 K - T 点.;否则迭代不终止,产生序列 $\{x^{(k)}\}$

3 Frank-Wolfe方法

下面定理表明,这序列的每一聚点都是KKT点

Th12.3.2 设 f 连续可微,下列两条件之一成立:

1, $S = \{x \mid Ax = b, x \geq 0\}$ 有界

2, 当 $\|x\| \rightarrow \infty$ 时 $f(x) \rightarrow \infty$

初始点 $x^{(1)} \in S$, 则Frank-Wolfe算法收敛于问题(12.3.1)的 $K-T$ 点.

4 Wolfe既约梯度法

考虑如下线性约束优化问题：

$$\min f(x) \quad (4.1)$$

$$s.t. Ax = b, x \geq 0, x \in R^n \quad (4.2)$$

思想:借鉴线性规划单纯形算法思想,选择某些变量为基变量,其他的作为非基变量,并用非基变量表示基变量.从而能从目标函数 $f(x)$ 中消去基变量,得到只含非基变量的既约目标函数. 利用既约目标函数的梯度(称为既约梯度),构造使目标函数下降的可行方向,寻找新的改进点. -----称这种可行方向法称为**Wolfe既约梯度法**.

假设 $A = (B, N)$, 其中 B 为可逆子矩阵. 若令 x_B 和 x_N 分别表示基变量和非基变量, 则 $x = (x_B, x_N)^T$, 且 $x_B = B^{-1}b - B^{-1}Nx_N$, 代入 $f(x)$ 得问题(4.1-2)的等价形式:

$$\min F(x_N) = f(x)|_{x_B = x_B(x_N)} \quad (4.3)$$

$$\text{s.t. } x_B \geq 0, \quad x_N \geq 0 \quad (4.4)$$

则约化后的目标函数 $F(x_N)$ 关于 x_j 的导数

$$r_j = \frac{\partial F}{\partial x_j} = \frac{\partial f}{\partial x_j} + \sum_{i \in B} \frac{\partial F}{\partial x_i} \cdot \frac{\partial x_i}{\partial x_j}$$

因此,目标函数 $f(x)$ 在 x_N 处的既约梯度

$$r(x_N) = \nabla_{x_N} f - (B^{-1}N)^T \nabla_{x_B} f \quad (4.5)$$

约束系数矩阵 A 的零空间中的向量可表为

$$d = \begin{pmatrix} d_B \\ d_N \end{pmatrix} = \begin{pmatrix} -B^{-1}N \\ I \end{pmatrix} d_N \quad (4.6)$$

为保证 d_N 相对于约束 $x_N \geq 0$ 的可行性,我们要求

$$(d_N)_j = \begin{cases} 0, & r_j(x_N) \geq 0 \\ -r_j(x_N), & r_j(x_N) < 0 \end{cases} \quad (4.7)$$

4 Wolfe既约梯度法

定理4.1 设 $\bar{x} = (\bar{x}_B, \bar{x}_N)^T$ 为问题(4.1–4.2)的可行点.且 $\bar{x}_B > 0$,若 $f(x)$ 在 $\bar{x}$ 点是可微的,并且由式(4.6)和(4.7)确定一个向量 d ,则当 $d \neq 0$ 时它是一个下降的可行方向.此外 $d = 0$ 当且仅当 $\bar{x}$ 为KKT点.

给定一个下降方向 d ,若置最大的移动步长

$$\lambda_{\max} = \begin{cases} \min \left\{ \frac{-\bar{x}_i}{d_i} \mid d_i < 0 \right\}, & \text{当 } d \not\geq 0 \\ \infty, & \text{当 } d \geq 0 \end{cases} \quad (4.8)$$

则最优步长对应着如下的一维优化问题

$$\begin{aligned} & \min \quad f(\bar{x} + \lambda d) \\ \text{s.t.} \quad & 0 \leq \lambda \leq \lambda_{\max} \end{aligned} \quad (4.9)$$