



北京邮电大学

BEIJING UNIVERSITY OF POSTS AND TELECOMMUNICATIONS

最优化理论与算法

帅天平

数学科学学院

tpshuai@bupt.edu.cn



13 惩罚函数法

考虑约束问题

$$\begin{aligned} & \min f(x) \\ & s.t. \quad g_i(x) \geq 0, i = 1, \dots, m \\ & \quad \quad h_j(x) = 0, j = 1, 2, \dots, l \end{aligned} \quad (13.1.1)$$

其中 $f(x)$, $g_i(x)$ 和 $h_j(x)$ 连续.

向量形式

$$\begin{aligned} & \min f(x) \\ & s.t. \quad g(x) \geq 0, \\ & \quad \quad h(x) = 0 \end{aligned}$$

其中

$$\begin{aligned} g(x) &= (g_1(x), \dots, g_m(x))^T \\ h(x) &= (h_1(x), \dots, h_l(x))^T \end{aligned}$$

13 惩罚函数法

令问题的可行域为：

$$D = \left\{ x \left| \begin{array}{l} g_i(x) \geq 0, i = 1, \dots, m. \\ h_j(x) = 0, j = 1, \dots, l \end{array} \right. \right\}.$$

如何求解约束问题？

可行方向法：沿下降可行方向搜索

其他方法？

序列无约束优化算法：通过求解一系列无约束问题的解来近似约束问题的解。

罚函数法是序列无约束问题算法的典型代表。

13.1 外点惩罚函数法

罚函数法的**基本思想**是构造辅助函数 F ,把原来的约束问题转化为求极小化辅助函数的无约束问题

例如可以定义函数 $F:R^n \rightarrow R$ 为

$$F(x) = \begin{cases} f(x), & x \in D \\ +\infty, & x \notin D \end{cases}$$

易见约束问题(13.1.1)的解等价于

的解
$$\min F(x), \quad x \in R^n$$

但由于 F 在可行域 D 的边界不连续.因此难以直接由求解 F 的极小值来求问题(13.1.1)的极小点.

于是构造辅助函数极为重要!!!

外点法的基本思想是构造辅助函数

$$F_{\mu} : R^n \rightarrow R \quad (\mu > 0)$$

函数 F_{μ} 在可行域 D 的内部取值与问题(13.1.1)的目标函数 f 的取值相等,而在可行域的外部取值远远大于目标函数 f 的值.

换言之,对可行域外部点的目标函数值加以惩罚,使得无约束问题 $\min F_{\mu}(x)$ 的解是约束问题(13.1.1)的近似解. 且当 $\mu \rightarrow \infty$ 时,问题 $\min F_{\mu}(x)$ 的解 $x(\mu)$ 趋于约束问题的解.

对于约束问题

$$\begin{array}{ll} \min f(x) \\ s.t. \quad h_j(x) = 0, j = 1, 2, \dots, l \end{array} \quad (13.1.2)$$

可定义辅助函数:

$$F_1(x, \mu) = f(x) + \mu \sum_{j=1}^l h_j^2(x) \quad (13.1.3)$$

参数 μ 是很大的正数.

于是(13.1.2)转化为:

$$\min F_1(x, \mu) \quad (13.1.4)$$

对于不等式约束问题

$$\begin{array}{ll} \min & f(x) \\ \text{s.t.} & g_i(x) \geq 0, i = 1, 2, \dots, m \end{array} \quad (13.1.5)$$

可定义辅助函数:

$$F_2(x, \mu) = f(x) + \mu \sum_{i=1}^m (\max\{0, -g_i(x)\})^2 \quad (13.1.6)$$

参数 μ 是很大的正数.

于是(13.1.2)转化为:

$$\min F_2(x, \mu) \quad (13.1.7)$$

对于一般形式的问题(13.1.1).可定义辅助函数

$$F(x, \mu) = f(x) + \mu P(x) \quad (13.1.8)$$

其中 $P(x)$ 具有如下形式:

$$P(x) = \sum_{i=1}^m \phi(g_i(x)) + \sum_{j=1}^l \psi(h_j(x)) \quad (13.1.9)$$

连续函数 ϕ 和 ψ 满足

$$\phi(y) \begin{cases} = 0, y \geq 0 \\ > 0, y < 0 \end{cases}, \quad \psi(y) \begin{cases} = 0, y = 0 \\ > 0, y \neq 0 \end{cases}.$$

连续函数 ϕ 和 ψ 的典型取法有

$$\phi = (\max \{0, -g_i(x)\})^\alpha$$

$$\psi = |h_j(x)|^\beta \quad (\alpha \geq 1, \beta \geq 1)$$

于是把约束问题(13.1.1)转化为无约束问题

$$\min F(x, \mu) = f(x) + \mu P(x) \quad (13.1.10)$$

其中 μ 是很大的正数, $P(x)$ 是连续函数

例1 $\min f(x) = x^2$
 $s.t. \quad g(x) = -x - 1 \geq 0$ (13.1.11)

该问题的可行域 $D=(-\infty, -1]$, 最优解 $x^* = -1$

$$\begin{aligned} \text{令 } F(x, \mu) &= f(x) + \frac{1}{2} \mu \sum_{i=1}^m (\max\{0, -g_i(x)\})^2 \\ &= x^2 + \frac{1}{2} \mu (\max\{0, x + 1\})^2 \end{aligned} \quad (13.1.12)$$

$$\Rightarrow \min F(x, \mu) \text{ 的解为 } x(\mu) = -\frac{\mu}{2 + \mu}$$

$$\Rightarrow x(\mu) = -\frac{\mu}{2 + \mu} \rightarrow -1 = x^*, \mu \rightarrow +\infty$$

罚因子的选取非常重要!!!

一般的策略是:取一趋向无穷大的严格递增正数列 $\{\mu_k\}$,
从某个 μ_1 开始,对每个 k ,求解

$$\min \quad f(x) + \mu_k P(x) \quad (13.1.13)$$

从而得到一个极小点的序列 $\{x_{\mu_k}\}$ 在适当条件下,此序列
收敛于约束问题的最优解.

——序列无约束极小化方法(SUMT)

外点法

1, 给定初点 $x^{(0)}$, 初始罚因子 μ_1 , 放大系数 $c > 1$, 允许误差 $\varepsilon > 0$, 置 $k = 1$.

2, 以 $x^{(k-1)}$ 为初点, 解无约束问题

$$\min f(x) + \mu_k P(x)$$

得极小点为 $x^{(k)}$

3, 若 $\mu_k P(x^{(k)}) < \varepsilon$, 停止, 得点 $x^{(k)}$; 否则, 令 $\mu_{k+1} = c\mu_k$.

置 $k := k + 1$, 转2

1.3 收敛性

引理13.1.1 设 $0 < \mu_k < \mu_{k+1}$, $x^{(k)}$ 和 $x^{(k+1)}$ 分别为取罚因子 μ_k 和 μ_{k+1} 时无约束问题的极小点, 则下列各式成立

$$1, F(x^{(k)}, \mu_k) \leq F(x^{(k+1)}, \mu_{k+1})$$

$$2, P(x^{(k)}) \geq P(x^{(k+1)})$$

$$3, f(x^{(k)}) \leq f(x^{(k+1)})$$

证明: 先证1

根据 $x^{(k)}$ 是 $F(x, \mu_k)$ 的极小点, $\mu_k < \mu_{k+1}$. 由 $F(x, \mu)$ 的定义

$$\begin{aligned}
F(x^{(k)}, \mu_k) &= f(x^{(k)}) + \mu_k P(x^{(k)}) \\
&\leq f(x^{(k+1)}) + \mu_k P(x^{(k+1)}) \\
&\leq f(x^{(k+1)}) + \mu_{k+1} P(x^{(k)}) \\
&= F(x^{(k+1)}, \mu_{k+1})
\end{aligned}$$

证2

因为 $x^{(k)}$ 和 $x^{(k+1)}$ 分别为 $F(x, \mu_k)$ 和 $F(x, \mu_{k+1})$ 极小点, 则

$$f(x^{(k)}) + \mu_k P(x^{(k)}) \leq f(x^{(k+1)}) + \mu_k P(x^{(k+1)}) \quad (13.1.14)$$

$$f(x^{(k+1)}) + \mu_{k+1} P(x^{(k+1)}) \leq f(x^{(k)}) + \mu_{k+1} P(x^{(k)}) \quad (13.1.15)$$

将上两式的两端分别相加并整理得

$$(\mu_{k+1} - \mu_k)P(x^{(k)}) \geq (\mu_{k+1} - \mu_k)P(x^{(k+1)}) \quad (13.1.16)$$

由 $\mu_{k+1} > \mu_k$, 故

$$P(x^{(k)}) \geq P(x^{(k+1)}) \quad (13.1.17)$$

最后证3.:

因 $x^{(k)}$ 为 $F(x, \mu_k)$ 的极小点, 则

$$f(x^{(k)}) + \mu_k P(x^{(k)}) \leq f(x^{(k+1)}) + \mu_k P(x^{(k+1)}) \quad (13.1.18)$$

由(13.1.17)和(1.18)可得:

$$f(x^{(k)}) \leq f(x^{(k+1)})$$

由上引理知,若迭代不终止,则 $\{f(x^{(k)})\}, \{F(x^{(k)}, \mu_k)\}$ 为非减序列, $\{P(x^{(k)})\}$ 为非增序列.

引理13.1.2 设 $\bar{x}$ 是问题(13.1.1)的最优解,且对任意的 $\mu_k > 0$, 由(13.1.3)定义的 $F(x, \mu_k)$ 存在极小点 $x^{(k)}$, 则对每一个 k 成立

$$f(\bar{x}) \geq F(x^{(k)}, \mu_k) \geq f(x^{(k)}) \quad (13.1.19)$$

证明：由于 $\mu_k P(x^{(k)}) \geq 0$, 则

$$F(x^{(k)}, \mu_k) = f(x^{(k)}) + \mu_k P(x^{(k)}) \geq f(x^{(k)}) \quad (13.1.20)$$

由于 $\bar{x}$ 是问题(13.1.1)的最优解, 从而是可行点,

由 $P(x)$ 的定义, 有 $P(\bar{x}) = 0$

又 $x^{(k)}$ 为 $F(x, \mu_k)$ 的极小点, 则

$$\begin{aligned} f(\bar{x}) &= f(\bar{x}) + \mu_k P(\bar{x}) \\ &\geq f(x^{(k)}) + \mu_k P(x^{(k+1)}) \quad (13.1.21) \\ &= F(x^{(k)}, \mu_k) \end{aligned}$$

由(13.1.20)-(13.1.21)知(13.1.19)成立.

Th13.1.3 设问题(13.1.1)的可行域 S 非空,且 $\exists \varepsilon > 0$,使得集合

$$S_\varepsilon = \left\{ x \left| \begin{array}{l} g_i(x) \geq -\varepsilon, i = 1, \dots, m \\ |h_j(x)| \leq \varepsilon, j = 1, 2, \dots, l \end{array} \right. \right\} \quad (13.1.22)$$

是紧的,又设 $\{\mu_k\}$ 是趋向 ∞ 的严格递增正数列,且对每个 k ,问题(13.1.13)存在最优解 $x^{(k)}$,则 $\{(x^{(k)})\}$ 存在一个收敛子序列 $\{x^{(k_j)}\}$,并且任何这样的收敛子序列的极限都是问题(13.1.1)的最优解.

证明:根据假设, S 是紧集, $f(x)$ 是连续函数,因此问题(13.1.1)存在最优解 $\bar{x}$.

由引理13.1.1和1.2可知,

$\{F(x^{(k)}, \mu_k)\}$ 和 $\{f(x^{(k)})\}$ 均为单调增有上界序列

故可设: $\lim_{k \rightarrow \infty} F(x^{(k)}, \mu_k) = \hat{F}$ (13.1.23)

$$\lim_{k \rightarrow \infty} f(x^{(k)}) = \hat{f} \quad (13.1.24)$$

于是

$$\lim_{k \rightarrow \infty} \mu_k P(x^{(k)}) = \hat{F} - \hat{f} \quad (13.1.25)$$

由于当 $k \rightarrow \infty$ 时, $\mu_k \rightarrow \infty$, 故

$$\lim_{k \rightarrow \infty} P(x^{(k)}) = 0 \quad (13.1.26)$$

根据 $P(x)$ 的定义, 当 $x \in S, P(x)=0$, 当 $x \notin S$, 时, $P(x)>0$.

注意到(13.1.26),可以断言,对每个 $\delta > 0$.存在正整数 $K(\delta)$,使得当 $k > K(\delta)$ 时有 $x^{(k)} \in S_\delta$.

于是, 存在充分大的正整数 $\hat{K}(\varepsilon)$,使得所有满足 $k > \hat{K}(\varepsilon)$ 的点 $x^{(k)} \in S_\varepsilon$,又知 S_ε 是紧集,故存在收敛子列 $\{x^{(k_j)}\}$.

设

$$\lim_{k_j \rightarrow \infty} x^{(k_j)} = \hat{x} \quad (13.1.27)$$

由(13.1.16)可知 $P(\hat{x}) = 0$

因此, $\hat{x} \in S$.

由于 $\bar{x}$ 是问题(13.1.1)的最优解,则

$$f(\bar{x}) \leq f(\hat{x}) \quad (13.1.28)$$

根据引理13.1.2,对每一 k_j ,有

$$f(x^{(k_j)}) \leq f(\bar{x})$$

令 $k_j \rightarrow \infty$,故

$$f(\hat{x}) \leq f(\bar{x}) \quad (13.1.29)$$

由(13.1.28)和(1.29)可知

$$f(\hat{x}) = f(\bar{x}) \quad (13.1.30)$$

因此, $\hat{x}$ 是问题(13.1.1)的最优解

此外, 由 $f(x^{(k)}) \leq F(x^{(k)}, \mu_k)$ 得

$$\hat{f} \leq \hat{F} \quad (13.1.31)$$

另一方面, 由于 $f(x)$ 连续, 则

$$\lim_{k_j \rightarrow \infty} f(x^{(k_j)}) = f(\hat{x})$$

又考虑到(13.1.24)和(13.1.30), 则

$$\text{由 } F(x^{(k)}, \mu_k) \leq f(\bar{x}), \text{ 故} \quad \hat{f} = f(\hat{x}) = f(\bar{x})$$

$$\hat{F} \leq f(\bar{x}) = \hat{f} \quad (13.1.32)$$

于是

$$\hat{F} = \hat{f} \quad (13.1.33)$$

由(13.1.25)得

$$\lim_{k \rightarrow \infty} \mu_k P(x^{(k)}) = 0 \quad (13.1.34)$$

此即 $\mu_k P(x^{(k)}) < \varepsilon$ 作为终止准则的原因.

13.2 内点罚函数法

13.2.1 基本思想

内点法产生的点列从可行域的内部逼近问题的解

因此,此方法适用于下列不等式约束的问题:

$$\begin{aligned} & \min f(x) \\ & s.t. \quad g_i(x) \geq 0, i = 1, 2, \dots, m \end{aligned} \quad (13.2.1)$$

其中 $f(x), g_i(x) (i = 1, \dots, m)$ 是连续函数.

记可行域为

$$S = \{x \mid g_i(x) \geq 0, i = 1, 2, \dots, m\} \quad (13.2.2)$$

$$S_0 = \{x \mid g_i(x) > 0, i = 1, 2, \dots, m\} - \text{严格可行域}$$

内点罚函数法的基本思想:构造辅助(光滑)函数 F_μ
该函数在严格可行域 S_0 以外的取值为无穷大,且当
点 x 从 S_0 趋于 S 的边界时,函数值趋于无穷大.这样,无
约束问题

$$\min F_\mu = F(x, \mu)$$

的解一定在 S_0 内。我们希望当 $\mu \rightarrow 0$ 时,上述无约束
问题的解 $x(\mu)$ 趋于问题(13.2.1)的解.辅助函数 $F(x, \mu)$
在 S 的边界筑起了一道很高的墙,把无约束问题
 $\min F(x, \mu)$ 的解挡住了可行域 S 的内部

.因此,内点法也称为障碍函数法.

保持迭代点含于可行域内部的方法是定义**障碍函数**

$$F(x, \mu) = f(x) + \mu B(x) \quad (13.2.3)$$

其中 $B(x)$ 是连续函数,当点 x 趋向可行域边界时, $B(x) \rightarrow \infty$. μ 是很小的正数.

这样,当 x 趋向边界时,函数 $F(x, \mu)$ 趋于无穷大;否则,由于 μ 很小,则函数 $F(x, \mu)$ 的取值近似 $f(x)$.

因此可通过求解下列问题得到原问题的近似解:

$$\begin{aligned} & \min F(x, \mu) \\ & s.t. \quad x \in \text{int } S \end{aligned} \quad (13.2.4)$$

两种最重要的形式:

$$B(x) = \sum_{i=1}^m \frac{1}{g_i(x)} \quad (13.2.5)$$

$$B(x) = -\sum_{i=1}^m \log g_i(x) \quad (13.2.6)$$

2.2 计算步骤

1, 给定初始内点 $x^{(0)} \in \text{int} S$, 允许误差 $\varepsilon > 0$, 初始参数 μ_1 , 缩小系数 $\beta \in (0, 1)$, 置 $k = 1$.

2, 以 $x^{(k-1)}$ 为初点, 解无约束问题

$$\min f(x) + \mu_k B(x)$$

得极小点为 $x^{(k)}$

3, 若 $\mu_k B(x^{(k)}) < \varepsilon$, 停止, 得点 $x^{(k)}$; 否则, 令 $\mu_{k+1} = \beta \mu_k$.

置 $k := k + 1$, 转 2

例13.2.1 用内点法求解下列问题

$$\begin{aligned} \min \quad & \frac{1}{12}(x_1 + 1)^3 + x_2 \\ \text{s.t.} \quad & x_1 - 1 \geq 0 \\ & x_2 \geq 0 \end{aligned}$$

定义障碍函数

$$F(x, \mu_k) = \frac{1}{12}(x_1 + 1)^3 + x_2 + \mu_k \left(\frac{1}{x_1 - 1} + \frac{1}{x_2} \right)$$

用解析法求解问题

$$\begin{aligned} \min \quad & F(x, \mu_k) \\ \text{s.t.} \quad & x \in S \end{aligned}$$

令

$$\frac{\partial F}{\partial x_1} = \frac{1}{4}(x_1 + 1)^2 - \frac{\mu_k}{(x_1 - 1)^2} = 0$$

$$\frac{\partial F}{\partial x_2} = 1 - \frac{\mu_k}{x_2^2} = 0$$

解得

$$\bar{x}_{\mu_k} = (x_1, x_2) = (\sqrt{1 + 2\sqrt{\mu_k}}, \sqrt{\mu_k})$$

当 $\mu_k \rightarrow 0$ 时, $\bar{x}_{\mu_k} \rightarrow \bar{x} = (1, 0)$,

$\bar{x}$ 是问题的最优解。

2.3. 收敛性

Th13.2.1 设在问题(13.2.1)中,可行域内部 $\text{int } S$ 非空,且存在最优解,又设对每一个 μ_k ,由(13.2.3)定义的 $F(x, \mu_k)$ 在 $\text{int } S$ 内存在极小点,并且内点法产生的序列 $\{x^{(k)}\}$ 存在子列收敛到 $\bar{x}$,则 $\bar{x}$ 是问题(13.2.1)的最优解

证明:先证 $\{F(x^{(k)}, \mu_k)\}$ 是单调减有下界的序列

设 $x^{(k)}, x^{(k+1)} \in \text{int } S$ 分别为 $F(x, \mu_k)$ 和 $F(x, \mu_{k+1})$ 极小点,

由于 $\mu_{k+1} < \mu_k$,则

$$\begin{aligned} F(x^{(k+1)}, \mu_{k+1}) &= f(x^{(k+1)}) + \mu_{k+1}B(x^{(k+1)}) \\ &\leq f(x^{(k)}) + \mu_{k+1}B(x^{(k)}) \\ &\leq f(x^{(k)}) + \mu_k B(x^{(k)}) \\ &= F(x^{(k)}, \mu_k) \end{aligned} \tag{13.2.8}$$

设 x^* 是问题(13.2.1)的最优解.

由于 $x^{(k)}$ 是可行点,则 $f(x^{(k)}) \geq f(x^*)$

又知

$$F(x^{(k)}, \mu_k) \geq f(x^{(k)})$$

故有

$$F(x^{(k)}, \mu_k) \geq f(x^*) \quad (13.2.9)$$

从而

$\{F(x^{(k)}, \mu_k)\}$ 为单调减有下界序列从而存在极限:

$$\hat{G} \geq f(x^*)$$

下证 $\hat{G} = f(x^*)$.

如若不然, $\hat{G} > f(x^*)$. 由于 $f(x)$ 是连续函数, 故存在正数 δ , 使得当 $\|x - x^*\| < \delta$ 且 $x \in \text{int } S$ 时有

即

$$f(x) - f(x^*) \leq \frac{1}{2}(\hat{G} - f(x^*))$$

$$f(x) \leq \frac{1}{2}(\hat{G} + f(x^*)) \quad (13.2.10)$$

任取一点 $\hat{x} \in \text{int } S$, 使 $\|\hat{x} - x^*\| < \delta$. 由于 $\mu_k \rightarrow 0$, 因此存在 K , 当 $k > K$ 时,

$$\mu_k B(\hat{x}) < \frac{1}{4}(\hat{G} - f(x^*))$$

于是, 当 $k > K$ 时, 根据 $F(x^{(k)}, \mu_k)$ 的定义及式(13.2.10), 故有

$$\begin{aligned} F(x^{(k)}, \mu_k) &= f(x^{(k)}) + \mu_k B(x^{(k)}) \\ &\leq f(\hat{x}) + \mu_k B(\hat{x}) \\ &\leq \frac{1}{2}(\hat{G} + f(x^*)) + \frac{1}{4}(\hat{G} - f(x^*)) \\ &= \hat{G} - \frac{1}{4}(\hat{G} - f(x^*)) \end{aligned}$$

上式与 $F(x^{(k)}, \mu_k) \rightarrow \hat{G}$ 相矛盾.故必有

$$\hat{G} = f(x^*)$$

下证 $\bar{x}$ 是最优解.

设 $\{x^{(k_j)}\}$ 是 $\{x^{(k)}\}$ 的收敛子列, 且

$$\lim_{k_j \rightarrow \infty} x^{(k_j)} = \bar{x}$$

由于 $x^{(k_j)}$ 是可行域 S 的内点, 即满足

$$g_i(x^{(k_j)}) > 0, i = 1, \dots, m$$

$g_i(x)$ 连续, 故

$$\lim_{k_j \rightarrow \infty} g_i(x^{(k_j)}) = g_i(\bar{x}), i = 1, \dots, m \quad (13.2.11)$$

由此可知, $\bar{x}$ 是可行点. 又 x^* 是(13.2.1)的最优解, 故

$$f(x^*) \leq f(\bar{x}) \quad (13.2.12)$$

上式必为等式.如若不然, $f(x^*) < f(\bar{x})$

则 $\lim_{k_j \rightarrow \infty} \{f(x^{(k_j)}) - f(x^*)\} = f(\bar{x}) - f(x^*) > 0$

于是当 $k_j \rightarrow \infty$ 时,

$$\begin{aligned} F(x^{(k_j)}, \mu_k) - f(x^*) &= f(x^{(k_j)}) - f(x^*) + \mu_{k_j} B(x^{(k_j)}) \\ &\geq f(x^{(k_j)}) - f(x^*) \end{aligned}$$

不趋于0,

此与

$$\lim_{k \rightarrow \infty} F(x^{(k)}, \mu_k) = \bar{G} = f(x^*), \quad \text{矛盾。}$$

故

$$f(x^*) = f(\bar{x})$$

从而 $\bar{x}$ 是(13.2.1)的最优解.

3 乘子法

利用外罚函数或内罚函数（如障碍函数法）求解约束优化时，为获得较好的近似解，通常要求罚因子 μ 逐渐的趋于 ∞ （或障碍因子 μ 逐渐的趋于0），这会造成数值计算方面的困难。是否存在其他形式的罚函数，使得罚因子 μ 大于某个正数 μ^* （或者障碍参数 μ 小于某个正数 μ^* ）后，极小化该罚函数即可得到原来问题的最优解呢？形如

$$\phi_1(x, \mu) = f(x) + \mu \sum_{j \in E} |h_j(x)| + \mu \sum_{i \in I} \max \{-g_i(x), 0\}$$

的函数就可以满足这种要求——精确罚函数
困难： μ^* 事先未知，且精确罚函数一般非光滑，会造成数学处理方面的其它问题。

3 乘子法

对于纯等式约束的优化问题 $\min f(x), \text{ s.t. } h(x) = 0$

考虑如下形式的增广 *Lagrange* 函数:

$$\begin{aligned} L_A(x, \lambda, \mu) &= L(x, \lambda) + \frac{1}{2} \mu \|h\|_2^2 \\ &= f(x) - \lambda^T h(x) + \frac{1}{2} \mu \sum_{j \in E} h_j(x)^2 \end{aligned}$$

该函数关于 x 的梯度向量

$$\nabla_x L_A(x, \lambda, \mu) = \nabla f(x) - \sum_{j \in E} [\lambda - \mu h_j(x)] \nabla h_j(x)$$

假设在第 k 次迭代时, 固定罚因子 $\mu = \mu_k > 0$, 乘子 $\lambda = \lambda^k$

3 乘子法

然后，对增广 *Lagrange* 函数 $L_A(x, \lambda^k, \mu_k)$ 关于 x 进行极小化，得到相应的近似局部极小点 x^k 。若 x^k 接近原来问题的 *KKT* 点，不妨设相应的 *Lagrange* 乘子向量是 λ^* ，则

$$\lambda_j^* \approx \lambda_j^k - \mu_k h_j(x^k), j \in \mathcal{E},$$

即
$$h_j(x^k) \approx - (\lambda_j^* - \lambda_j^k) / \mu_k, j \in \mathcal{E}$$

这表明，对于同样的罚因子 μ_k ，当 λ^k 接近于 *KKT* 点的乘子向量 λ^* 时， x^k 的不可行性将大大地降低，从而使求解过程相对地变得容易。二次罚函数法中约束函数值与 μ_k 是成反比例的，只有不断增加罚因子 μ_k ，才能提高 x^k 的可行性。

算法 乘子法（增广 *Lagrange* 法）

步1: (初始化) 给定初始点 x_s^0 , 容许误差序列 $\{\varepsilon_k \mid k = 0, 1, 2, \dots\}$ 和 $\varepsilon > 0$, 确定初始罚因子 $\mu_0 > 0$ 和参数 λ^0 , 置 $k=0$ 。

步2: (无约束极小化) 以 x_s^k 为第 k 次迭代的初始点, 极小化 $L_A(x, \lambda^k, \mu_k)$ 得满足 $\|\nabla_x L_A(x, \lambda, \mu)\| \leq \varepsilon_k$ 的近优解 x^k 。

步3: (最优性检验) 若 $|L_A(x, \lambda^k, \mu_k) - f(x^k)| < \varepsilon$ 成立, 则纯等式约束优化问题的近似最优解取为 x^k , 算法停止; 否则, 置下次迭代的初始点 $x_s^{k+1} = x_s^k$, 乘子向量的估计值 $\lambda^{k+1} = \lambda^k - \mu_k h(x^k)$, 取 $\mu_{k+1} \in (\mu_k, \infty)$, 并置迭代指标 $k+1 \Rightarrow k$, 转步骤2。

例1 对于约束优化问题

$$\min \left\{ x_1 + x_2 \mid x_1^2 + x_2^2 = 2 \right\},$$

其最优解 $x^* = (-1, -1)^T$, 相应的 $Lagrange$ 乘子向量 $\lambda^* = -0.5$

该问题的二次罚函数和增广 $Lagrange$ 函数分别定义为

$$Q(x, \mu) = x_1 + x_2 + \frac{1}{2} \mu (x_1^2 + x_2^2 - 2)^2,$$

$$L_A(x, \lambda, \mu) = x_1 + x_2 - \lambda (x_1^2 + x_2^2 - 2) + \frac{1}{2} \mu (x_1^2 + x_2^2 - 2)^2.$$

3 乘子法

假设在取罚因子 $\mu_k=1$ 时, 通过求解 $\min_x Q(x, \mu_k)$, 得到了最优解 x^* 的一个近似值 $x^k = (-1.1, -1.1)^T$.

由于 $h(x^k) = (-1.1)^2 + (-1.1)^2 - 2 = 0.42$, 定理表明 $Lagrange$ 乘子 $\lambda^* \approx -\mu_k h(x^k)$, 所以, 取 $Lagrange$ 乘子的近似值 $\lambda^k = -0.4$. 这样, 通过极小化增广 $Lagrange$ 函数 $\min_x L_A(x, \lambda^k, \mu_k)$, 可得到更接近于最优解的近似值 $\bar{x}^k = (-1.01, -1.01)^T$.

尽管前后两个近似解 x^k 和 $\bar{x}^k$ 对应着同样的罚因子 $\mu_k=1$, 但是, 后者具有更高的可行性。

3 乘子法

定理1 设 x^* 是纯等式约束优化问题的一个局部极小点，在 x^* 点线性独立约束规格成立(即 $\{\nabla h_j(x^*)|j \in \varepsilon\}$ 是线性无关的)，记相应的 $Lagrange$ 乘子向量为 λ^* 。若 x^* 满足约束优化问题的二阶最优性约束充分条件，则存在 $\bar{\mu} > 0$ ，使得对 $\forall \mu, \mu \geq \bar{\mu}$ ， x^* 是增广 $Lagrange$ 函数 $L_A(x, \lambda^*, \mu)$ 的严格局部极小点。

3 乘子法

定理2 设 (x^*, λ^*) 满足定理2, $\bar{\mu}$ 是定理1所确定的量, 则 $\exists \delta > 0, \varepsilon > 0, M > 0$, 使得

(1) 对 $\forall$ 满足 $\|\lambda^k - \lambda^*\| \leq \mu_k \delta, \mu_k \geq \bar{\mu}$

的 *Lagrange* 乘子估计量 λ^k 和罚因子 μ_k , 子问题

$$\min_x L_A(x, \lambda^k, \mu) \quad s.t. \quad \|x - x^*\| \leq \varepsilon$$

存在唯一的最优解 x^k . 且下面估计式成立

$$\|x^k - x^*\| \leq M \mu_k \|\lambda^k - \lambda^*\| \leq M \delta$$

3 乘子法

(2) 对满足(1)的乘子估计量 λ^k 和罚因子 μ_k , 有

$$\|\lambda^{k+1} - \lambda^*\| \leq M/\mu_k \|\lambda^k - \lambda^*\| \leq M\delta$$

其中 $\lambda^{k+1} = \lambda^k - \mu_k h(x^k)$,

(3) 对满足(1)的乘子估计量 λ^k 和罚因子 μ_k , 矩阵

$\nabla_{xx}^2 L_A(x^k, \lambda^k, \mu_k)$ 正定, 且 $\{\nabla h_j(x^k) \mid j \in E\}$ 线性无关, 此时

梯度矩阵 $\nabla h(x^k)$ 列满秩

3 乘子法-不等式情形

$$(1) g(x) \geq 0 \Leftrightarrow g(x) - s = 0, s \geq 0$$

(2)构造子问题

$$\begin{aligned} \min_{x,s} \bar{L}_A(x, s, \lambda^k, \mu_k) &= f(x) - (g(x) - s)^T \lambda^k \\ &\quad + \frac{1}{2} \mu_k \sum_{i \in I} (g_i(x) - s_i)^2 \\ s.t. \quad &s \geq 0 \end{aligned}$$

注意到s的分量独立,故可先对每个 s_i 进行极小化,再对 $\mathbf{x}$ 进行极小化.

3 乘法-不等式

易知: 最优向量 $s \geq 0$ 必须满足 $s = \max \{g(x) - \mu_k \lambda^k, 0\}$

于是, 子问题等价于

$$\min_x L_A(x, \lambda^k, \mu_k) \stackrel{\text{def}}{=} f(x) + \sum_{i \in I} \psi(g_i(x), \lambda_i^k, \mu_k)$$

其中

$$\psi(g_i(x), \lambda_i^k, \mu_k) = \begin{cases} \sum_{i \in X} -\lambda_i^k g_i(x) + \frac{1}{2} \mu_k g_i(x)^2, & \text{若 } g_i(x) - \frac{\lambda_i^k}{\mu_k} \leq 0, \\ \sum_{i \in X} -\frac{(\lambda_i^k)^2}{2\mu_k}, & \text{其他} \end{cases}$$

3 乘子法-不等式

特别的,子问题的近优点 x^k 处有

$$\nabla_x L_A(x^k, \lambda^k, \mu_k) = \nabla f(x) - \sum_{i \in X, g_i(x^k) \leq \lambda_i^k / \mu_i} [\lambda_i^k - \mu_k g_i(x^k)] \nabla g_i(x^k) \approx 0$$

λ^k 的修正公式可设为:

$$\lambda^{k+1} = \max \{ \lambda^k - \mu_k g(x^k), 0 \}$$

4 凸优化问题的增广拉格朗日函数法

考虑凸优化问题

$$\begin{aligned} \min_{x \in \mathbf{R}^n} \quad & f(x), \\ \text{s.t.} \quad & c_i(x) \leq 0, i = 1, 2, \dots, m, \end{aligned}$$

其中 $f: \mathbf{R}^n \rightarrow \mathbf{R}$, $c_i: \mathbf{R}^n \rightarrow \mathbf{R}$, $i = 1, 2, \dots, m$ 为闭凸函数. 其增广拉格朗日函数为

$$L_\sigma(x, \lambda) = f(x) + \frac{\sigma}{2} \sum_{i=1}^m \left(\max \left\{ \frac{\lambda_i}{\sigma} + c_i(x), 0 \right\}^2 - \frac{\lambda_i^2}{\sigma^2} \right),$$

其中 λ 和 σ 分别为乘子以及罚因子.

-
- 给定一系列单调递增的乘子 $\sigma_k \uparrow \sigma_\infty$ ，以及初始乘子 λ_0 ，该问题的增广拉格朗日函数法为

$$\begin{cases} x^{k+1} \approx \operatorname{argmin}_{x \in \mathbb{R}^n} L_{\sigma_k}(x, \lambda^k), \\ \lambda^{k+1} = \lambda^k + \sigma_k \nabla_{\lambda} L_{\sigma_k}(x^{k+1}, \lambda^k) = \max\{0, \lambda^k + \sigma_k c(x^{k+1})\}. \end{cases}$$

为了方便叙述，以下定义 $\phi_k(x) = L_{\sigma_k}(x, \lambda_k)$ 。由于 $\phi_k(x)$ 的最小值点的显式表达式通常是未知的，我们往往调用迭代算法求其一个近似解。为了保证收敛性，我们要求该近似解至少满足如下非精确条件之一

$$\begin{aligned}\phi_k(x^{k+1}) - \inf \phi_k &\leq \frac{\varepsilon_k^2}{2\sigma_k}, \quad \varepsilon_k \geq 0, \sum_{k=1}^{\infty} \varepsilon_k < +\infty, \\ \phi_k(x^{k+1}) - \inf \phi_k &\leq \frac{\delta_k^2}{2\sigma_k} \|\lambda^{k+1} - \lambda^k\|_2^2, \quad \delta_k \geq 0, \sum_{k=1}^{\infty} \delta_k < +\infty, \\ \text{dist}(0, \partial\phi_k(x^{k+1})) &\leq \frac{\delta'_k}{\sigma_k} \|\lambda^{k+1} - \lambda^k\|_2, \quad 0 \leq \delta'_k \rightarrow 0,\end{aligned}$$

其中 $\varepsilon_k, \delta_k, \delta'_k$ 是人为设定的参数, $\text{dist}(0, \partial\phi_k(x^{k+1}))$ 表示0 到集合 $\partial\phi_k(x^{k+1})$ 的欧几里得距离. 根据 λ_{k+1} 的更新格式, 有

$$\begin{aligned}\|\lambda^{k+1} - \lambda^k\|_2 &= \|\max\{0, \lambda^k + \sigma_k c(x^{k+1})\} - \lambda^k\|_2 \\ &= \|\max\{-\lambda^k, \sigma_k c(x^{k+1})\}\|_2.\end{aligned}$$

由于 $\inf \phi_k$ 是未知的，直接验证上述不精确条件中的前两式是数值上不可行的. 但是，如果 ϕ_k 是 α -强凸函数（在某些应用中可以计算出 α 或得到其估计值），那么

$$\phi_k(x) - \inf \phi_k \leq \frac{1}{2\alpha} \text{dist}^2(0, \partial \phi_k(x)).$$

根据上式，可以进一步构造如下数值可验证的不精确条件：

$$\text{dist}(0, \partial \phi_k(x^{k+1})) \leq \sqrt{\frac{\alpha}{\sigma_k}} \varepsilon_k, \quad \varepsilon_k \geq 0, \sum_{k=1}^{\infty} \varepsilon_k < +\infty,$$

$$\text{dist}(0, \partial \phi_k(x^{k+1})) \leq \sqrt{\frac{\alpha}{\sigma_k}} \delta_k \|\lambda^{k+1} - \lambda^k\|_2, \quad \delta_k \geq 0, \sum_{k=1}^{\infty} \delta_k < +\infty,$$

$$\text{dist}(0, \partial \phi_k(x^{k+1})) \leq \frac{\delta'_k}{\sigma_k} \|\lambda^{k+1} - \lambda^k\|_2, \quad 0 \leq \delta'_k \rightarrow 0.$$

算法

1. 选取初始点 x^0 , 乘子 λ^0, μ^0 , 罚因子 $\sigma_0 > 0$, 约束违反度常数 $\varepsilon > 0$, 精度常数 $\eta > 0$, 以及常数 $0 < \alpha \leq \beta \leq 1$ 和 $\rho > 1$. 令 $\eta_0 = \frac{1}{\sigma_0}$, $\varepsilon_0 = \frac{1}{\sigma_0^\alpha}$ 以及 $k = 0$.
2. **for** $k = 0, 1, 2, \dots$ **do**
3. 以 x^k 为初始点, 求解

$$\min_x L_{\sigma_k}(x, \lambda^k, \mu^k),$$

得到满足精度条件

$$\|L_{\sigma_k}(x^{k+1}, \lambda^k, \mu^k)\|_2 \leq \eta_k$$

的解 x^{k+1} .

4. **if** $v_k(x^{k+1}) \leq \varepsilon_k$ **then**
5. **if** $v_k(x^{k+1}) \leq \varepsilon$ 且 $\|\nabla_x L_{\sigma_k}(x^{k+1}, \lambda^k, \mu^k)\|_2 \leq \eta$ **then**
6. 得到逼近解 $x^{k+1}, \lambda^k, \mu^k$, 终止迭代.
7. **end if**

8. 更新乘子:

$$\lambda_i^{k+1} = \lambda_i^k + \sigma_k c_i(x^{k+1}), \quad i \in \mathcal{E},$$
$$\mu_i^{k+1} = \max\{\mu_i^k + \sigma_k c_i(x^{k+1}), 0\}, \quad i \in \mathcal{I}.$$

9. 罚因子不变: $\sigma_{k+1} = \sigma_k$.

10. 减小子问题求解误差和约束违反度: $\eta_{k+1} = \frac{\eta_k}{\sigma_{k+1}}, \varepsilon_{k+1} = \frac{\varepsilon_k}{\sigma_{k+1}^\beta}$.

11. **else**

12. 乘子不变: $\lambda^{k+1} = \lambda^k$.

13. 更新罚因子: $\sigma_{k+1} = \rho \sigma_k$.

14. 调整子问题求解误差和约束违反度: $\eta_{k+1} = \frac{1}{\sigma_{k+1}}, \varepsilon_{k+1} = \frac{1}{\sigma_{k+1}^\alpha}$.

15. **end if**

16. **end for**